


摘要：

Kimi K3开源半个月后，阿里Qwen于8月13日开放首个Max规模权重Qwen3.8-2.4T。模型共92层、2.4T参数、激活95B，采用512个专家及3:1混合注意力架构。后训练聚焦Agent能力，保留推理状态。开源沿用自定义商业许可，整体架构与Kimi K3趋于收敛。

Kimi K3 开源半个月后，8月13日，阿里Qwen也正式开放了Qwen3.8-2.4T的模型权重。



除去是2.4T的大参数模型，这次开源对于阿里而言还有另外的意义。

虽然之前Qwen曾经多次开源旗舰模型，但Qwen 很早就形成了两条线。一边是开放权重模型，一边是更大的闭源 Max模型。2024 年 Qwen 自己介绍第一代产品时就明确区分了“大型开源模型Qwen-72B”和“大型闭源模型”；后来 Qwen-Max-0428 也是只通过 Qwen Chat 和 DashScope API 提供，并没有释放权重。Qwen2.5-Max 到 2025 年依然如此，只开放 API，而同时拿 Qwen2.5-72B 作为自己的开放权重对照。

而这，是Qwen第一个开放权重的 Max 规模模型。

Qwen3.8本次的开源暂时没有对应的模型，只有简单的架构、后训练、推理Infra，以及开源规则。但从中我们已经可以获得不少信息了。

架构

Qwen3.8共有92层（K3 96层），总参数2.4T，每个Token激活95B。它使用512个专家（K3 896个），每次选择10个路由专家，同时还有1个共享专家。相比Kimi K3，每个专家更大，但总激活量稍小（Kimi K3为16专家，103B）。

- Language Model
 - Number of Parameters: 2.4T in total and 95B activated
 - Hidden Dimension: 8192
 - Token Embedding: 248,320 (Padded)
 - Number of Layers: 92
 - Hidden Layout: $23 \times (3 \times (\text{Gated DeltaNet} \rightarrow \text{MoE}) \rightarrow 1 \times (\text{Gated Attention} \rightarrow \text{MoE}))$
 - Gated DeltaNet:
 - Number of Linear Attention Heads: 128 for V and 16 for QK
 - Head Dimension: 128
 - Gated Attention:
 - Number of Attention Heads: 64 for Q and 4 for KV
 - Head Dimension: 256
 - Rotary Position Embedding Dimension: 64
 - Mixture of Experts:
 - Number of Experts: 512
 - Number of Activated Experts: 10 Routed + 1 Shared
 - Expert Intermediate Dimension: 2048

注意力机制上，Qwen3.8继承了Qwen3.5的混合架构。92层实际上由23组相同结构组成，每组包含3层Gated DeltaNet（门控Delta网络）和1层Gated Attention（门控全注意力），也就是69层线性注意力加23层传统注意力，比例正好接近3:1。

这和Kimi K3非常像。K3的93层里有69层Kimi Delta Attention（KDA，Kimi Delta注意力）和24层Gated MLA（门控多头潜在注意力），也是大约3:1。两者甚至属于相近的技术谱系，KDA可以看作对Gated DeltaNet遗忘机制进一步细粒度化的版本。

不过K3在层间信息流上还多做了一步。它引入AttnRes（Attention Residuals，注意力残差），允许模型重新组合多个历史层的输出。从config.json中看，Qwen3.8沿用了Qwen3.5的实现。目前Qwen 3.5公开代码里仍然是比较传统的Pre-Norm残差结构，每个子层完成以后，只和进入该子层之前的 residual 直接相加。

```

# Token Mixer
if self.block_type == "linear_attention":
    hidden_states = self.linear_attn(
        hidden_states=hidden_states,
        cache_params=past_key_values,
        attention_mask=attention_mask,
        **kwargs,
    )
elif self.block_type == "full_attention":
    # Self Attention
    hidden_states, _ = self.self_attn(
        hidden_states=hidden_states,
        attention_mask=attention_mask,
        position_ids=position_ids,
        past_key_values=past_key_values,
        position_embeddings=position_embeddings,
        **kwargs,
    )

hidden_states = residual + hidden_states

# Fully Connected
residual = hidden_states
hidden_states = self.post_attention_layernorm(hidden_states)
hidden_states = self.mlp(hidden_states)
# For the MoE layers, we need to unpack
if isinstance(hidden_states, tuple):
    hidden_states, _ = hidden_states
hidden_states = residual + hidden_states

```

Qwen3.8原生上下文为262,144 Token，并可以扩展到1,010,000 Token，同时进行了多步MTP（Multi-Token Prediction，多Token预测）训练。

Infra

这里首先要区分两种Infra。Training Infra（训练基础设施）回答的是“这个模型怎么训出来”，例如优化器、并行训练、通信、显存管理、Checkpoint和容错。Inference Infra（推理基础设施）回答的是“权重已经训完以后，怎么把它真正部署起来，并让每个Token足够快、足够便宜地吐出来”。

Qwen目前并没有像Kimi K3技术报告那样系统披露训练Infra，因此不能从这次发布判断它具体如何完成2.4T规模的训练。但推理侧的信息相对丰富。

首先是量化。Qwen官方提供BF16和FP8 checkpoint，Inferact进一步提供NVFP4和MXFP4量化版本。BF16/FP8完整版本至少需要两台NVIDIA B300或AMD MI355X节点，而FP4之后可以压缩到单节点部署。

第二则是并行。Qwen3.8 在推理阶段采用 TP（张量并行）、DP（数据并行）和 EP（专家并行）的组合。Attention 部分更依赖 TP，把矩阵计算拆开，MoE 部分则依靠 EP，把不同专家分布到不同 GPU。与此同时，推理框架还需要通过融合通信、专用 MoE Kernel（算子）以及高速互联网络，尽量降低专家调度带来的通信开销。

Kimi K3 面临的是同一个问题。在训练 2.8T 参数、896 专家的 Stable LatentMoE 时，Moonshot 并没有简单扩大传统 EP，而是提出 MoonEP，让热门专家根据当前负载动态复制到更多 GPU 上。

最后还有MTP。Qwen3.8训练了Multi-Token Prediction能力，示例配置一次预测3个候选Token。如果候选被主模型接受，相当于一次前向传播推进多个Token，从而减少自回归逐Token生成带来的串行延迟。值得注意的是，DeepSeek V4 在技术报告中也明确用了 MTP。

后训练

相比架构，Qwen这次对后训练具体技术披露得更少，因为config文档里也没这些。

但它的后训练目标非常清楚。

Qwen在模型卡里直接把Agent Execution列为核心升级方向，强调更强的autonomous planning（自主规划）、对environment feedback（环境反馈）的处理能力，以及更可靠的end-to-end task completion（端到端任务完成）。

但基本上现在所有的后训练都会强调这些点。

官方公布的成绩也能看到这种倾斜。在Qwen自己的对照中，从Qwen3.7-Max到3.8-Max，Terminal Bench 2.1从74.5升至86.6，PaperBench从64.8升至93.0，JobBench从31.3升至53.4，Toolathlon Verified从49.7升至72.5。



	Opus 4.8	Fable 5	GPT 5.6 Sol (max)	Qwen3.7- Max	Qwen3.8- Max
Coding Agent					
Terminal Bench 2.1	84.6	84.6	88.8	74.5	86.6
SWE-bench Pro	69.2	80.0	64.6	60.6	67.7
DeepSWE 1.1	59.0	70.0	73.0	21.6	56.6
NL2Repo-Bench	69.4	--	--	47.2	55.9
FrontierSWE	70.0	88.8	--	40.7	73.5
MLS-Bench-Lite	42.8	49.9	46.2	31.7	41.0
PaperBench	80.3	88.8	90.5	64.8	93.0
AndroidBench	69.8	84.5	74.0	56.5	75.1
QwenSWEBench	84.0	86.3	73.5	63.4	80.7
QwenQoderBench	62.7	63.1	53.8	36.8	58.4
QwenReactBench	1694	1770	1564	1538	1724
QwenSVGBench	1648	1690	1758	1499	1713
General Agent					
CoWorkBench	72.3	75.9	71.5	64.6	74.8
WorkSpaceBench	66.8	68.7	65.6	61.4	67.7
JobBench	48.4	57.4	45.4	31.3	53.4
SkillsBench	65.1	70.9	73.5	61.2	70.2
Agents' Last Exam (Pass / Score)	27.0 / 45.1	-- / --	30.6 / 53.6	11.8 / 31.1	27.0 / 52.4
Automation-Bench (Pass@1)	27.2	29.1	29.7	14.2	27.3
Toolathlon Verified (Pass@1)	76.2	77.9	74.9	49.7	72.5
WideSearch	72.9	81.2	--	75.2	81.9
HLE w/ tools	57.9	64.5	58.0	53.5	56.2
General Capabilities					
GPQA Diamond	92.0	92.6	94.1	92.4	92.6
HLE	45.7	53.3	47.2	41.4	43.6
IFBench	62.2	63.5	72.7	79.1	82.8
\$OneMillion-Bench (expert score)	41.8	55.9	53.8	44.4	52.5
HealthBench	52.4	--	55.3	54.5	60.2
PLawBench	69.6	70.2	72.3	58.9	73.2
PRBench-Legal	52.7	57.6	57.6	48.5	57.6
PRBench-Finance	51.9	55.8	55.5	46.8	58.3
MRCR v2 256K (8-needle)	83.2	--	93.8	86.7	92.9
LongBench v2	69.1	--	67.1	65.3	66.3

相比之下，GPQA Diamond只是从92.4变为92.6，HLE从41.4升到43.6。至少从官方评测呈现方式看，这一代最大的增量明显更多发生在Coding Agent、General Agent和专业工作，而不是传统单轮知识与推理Benchmark。

另外，Qwen3.8默认开启preserve_thinking，把之前轮次中的推理上下文继续保留下来。这样Agent在一次工具调用之后，不必只拿着最终答案和工具结果重新开始，而可以继续利用此前已经形成的推理状态。



Kimi K3也采取了几乎相同的方向。官方明确表示其后训练保留了推理历史。多轮交互和工具调用时，需要把此前的reasoning content和tool calls完整送回模型。

两家同时走到这里，说明“保留推理状态”正在从Harness的职责，逐渐转入旗舰Agent模型本身的训练与接口范式。

开源规则

这次开源的Qwen3.8-2.4T-A95B并不完全等同于云端Qwen3.8-Max。开放版本目前是text-only（纯文本），只能运行thinking mode，原生上下文为262K。而官方Qwen3.8-Max则建立在这一模型之上，额外提供视觉输入、non-thinking模式、默认1M上下文以及官方内置工具。

For users seeking managed, scalable inference without infrastructure maintenance, the official Qwen API service is provided by [Qwen Cloud](#). ↗

In particular, **Qwen3.8-Max** is the official version based on Qwen3.8-2.4T-A95B with more features, such as vision input & non-thinking support, 1M context length by default, official built-in tools, etc. For more information, please refer to the [Qwen3.8-Max Overview](#).

拆开增强版放云，这已经是一个目前开源模型的常见模式了，这样开源也可以保有部分商业能力。比如Minimax H3的开源，就把影响成片质量的素材理解、2K 重生成和稀疏注意力实现留在云端。

许可证同样发生了变化。Qwen3时代大量模型使用Apache 2.0，而Qwen3.8改成了专门的Qwen3.8-Max License。许可证仍允许使用、复制、修改、分发、微调、部署、托管甚至出售衍生产品，但如果商业产品超过1亿月活或月收入超过2000万美元，需要在界面显著展示模型名称。如果企业从事Model-as-a-Service或AI Work Assistant业务，并且连续12个月集团收入超过5000万美元，则商业使用前需要另外取得Qwen许可。

这和Kimi K3也非常类似。K3同样采用自己的Kimi K3 License，而不是Apache 2.0；同样允许广泛使用和修改，也设置了超大规模商业产品的署名要求以及MaaS业务的额外授权门槛。区别主要在具体阈值和覆盖业务范围。

换句话说，到了3T级旗舰模型，两家公司选择的都是open-weight（开放权重）+自定义商业许可，而不是过去小模型时代更加宽松的Apache式开放。

如果把Qwen3.8和Kimi K3放在一起看，反而可以看到2026年旗舰模型开始出现一种相当明显的收敛。

总参数都进入2—3T，激活参数都控制在100B左右。Attention不再全部采用传统Transformer，而是用大约四分之三的递归/线性状态层配合四分之一的全局Attention，上下文目标开始稳定在百万Token。后训练重点转向Coding、Research和长程Agent。最终能不能部署，则越来越依赖FP4/FP8、融合kernel、Expert Parallelism和机架级高速互联。

Kimi K3在模型架构上走得更激进一些，它同时引入KDA、AttnRes和Stable LatentMoE；Qwen3.8则更像一次把已经在Qwen3.5验证过的混合注意力架构直接Scale到Max级别，并围绕长程Agent和生产推理把整个生态补齐。

但无论如何，他们的架构选择都只是小优化差异，而非大区别了。infra方面反而可能不同更大，但各种并行之间的调剂依然是最重要的问题。



配方的底子已经开始收敛，下一个谁能打破这个底子做点新意，就更值得期待了。

本文来源：[腾讯科技](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 94  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论