

摘要：

Fable 5.1横扫8项基准测试登顶，科研能力翻倍，“缓存命中”环节降价75%；对于复杂Agent任务，降本最高达45%。同时宣布开放数据留存于客户自有云端，反蒸馏签名验证机制同步上线。分析认为，此番“性能+降本+数据松绑”组合拳，剑指上市前夕抢占企业市场。

Anthropic在IPO窗口临近之际，以一次全方位的产品更新向市场发出信号。

周二（9月1日），这家AI公司发布旗舰模型新版本Fable 5.1，在8项公开基准测试中全部夺冠，同步大幅削减企业使用成本，并推出针对模型蒸馏攻击的新安全机制，构成迄今最具分量的一次迭代升级。

性能层面，Fable 5.1在编程与科研两大核心场景上明显领先前代旗舰Fable 5及竞争对手OpenAI的GPT-5.6 Sol；以中低推理程度运行的Fable 5.1，表现已基本相当于此前的Mythos 5在极高推理程度下的水准。

成本层面，缓存读取价格削减75%，对于智能化程度较高的工作负载，整体使用成本最多可下降45%。

与此同时，Anthropic宣布允许企业客户将数据保留在自有云基础设施上，并新增对思维链签名验证的反蒸馏保护机制。邀请制高阶模型Mythos 5.1也于同日向部分预选用户开放。

上述调整落地之际，Anthropic据报正计划于下周美国劳动节后公开招股书，**最快有望在9月底登陆美股市场，目标估值达2万亿美元或更高**。分析指出，此番“极致性能+大幅降本+数据政策松绑”的组合，被市场解读为公司在上市前夕加速争夺企业客户、为高估值提供收入支撑的关键举措。

性能跃升：8项基准居首，“牢Fable”实力越级

Anthropic公布的数据显示，Fable 5.1在全部8项公开基准测试中均排名第一，尤其在编程和科研两项上与Fable 5及GPT-5.6 Sol之间的差距最为显著。

	Fable 5.1	Fable 5	Opus 5	GPT-5.6 Sol
Agentic scientific research Terminal-Bench-Science 0.1 [1]	52.6%	24.7%	29.0%	22.4%
Agentic coding Terminal-Bench 4.0	55.8% 60.9% (Mythos 5.1)	42.0%	52.3%	37.3%
Knowledge work GDPval-AA v2	1853	1723	1824	1711
Computer use OSWorld 2.0 [2]	77.9% partial	72.9% partial	75.4% partial	— partial
Computer use OSWorld 2.0	41.7% strict	36.1% strict	39.6% strict	— strict
Multidisciplinary reasoning Humanity's Last Exam	60.9% no tools	57.8% no tools	56.6% no tools	— no tools
	65.0% with tools	63.8% with tools	63.6% with tools	— with tools
Business workflows AutomationBench	31.4%	17.1%	26.9%	19.6%
Agentic coding CursorBench 3.2.0	73.4%	70.5%	70.0%	67.2%

科研能力方面，Fable 5.1在Terminal-Bench-Science上得分为52.6%，而前代Fable 5仅为24.7%，增幅超过一倍。编程方面，新模型更擅长处理跨越完整代码库的长链路任务，涵盖大型软件项目开发及系统性代码审查等场景。


Anthropic将这一跃升归结于模型在多步骤任务上稳定性的提升：在此类任务中，早期的微小错误往往会随步骤累积放大，导致最终输出崩溃；Fable 5.1被设计为能够全程维持稳定输出，遇到无法解决的问题时会主动告知用户已尝试的路径及卡点所在。

写作方面，研究员Flix Rieseberg指出，Fable 5.1减少使用粗体、标题、列表和引号，对风格提示词的遵循程度更高。此外，新模型本身经过优化，可在消耗更少token的前提下完成相同任务。

降价逻辑：缓存读取降75%，剑指企业智能体市场

定价调整是此次更新中最具直接商业意义的变化。Fable 5.1的输入和输出价格与前代保持不变，分别为每百万token 10美元和50美元；调整集中于“缓存命中”环节，即模型重新读取此前已处理内容时的计费，降幅达75%，降至每百万token 0.25美元。

Anthropic表示，对于典型工作负载，Fable 5.1的预期使用成本将比Fable 5低约25%；对于高度智能化的任务，节省幅度最高可达45%。



公司产品管理负责人Dianne Penn解释了这一调整的背景：**在软件开发、代码审查等需要模型遍历整个应用代码库的任务中，缓存读取往往消耗超过一半的token用量，是客户反馈最为集中的痛点之一。**

"这是我们希望改进的一个领域，也是在回应客户反馈。"

这一调整的背景清晰：模型竞争日趋激烈，企业买家在AI支出上愈发审慎，需要更可预期的成本结构。

数据政策转向：企业主权诉求获回应

Anthropic宣布的数据留存政策调整，或是此次更新中对企业客户吸引力最大的变化之一。

新政策允许企业用户在使用Anthropic最强能力模型时，将数据保留在自有云计算基础设施上，而非强制存放于Anthropic服务器——与此同时，Anthropic仍将对相关数据执行安全检查。

此前的政策设计初衷是降低网络安全风险，但也因此令部分对数据主权有严格要求的企业客户望而却步。新政策标志着公司对此前数据留存规定的重大转向。

安全更新：误报率大降，反蒸馏机制落地

安全机制方面，Fable 5.1的网络安全误报率比Fable 5降低了60%，现在允许用于发现软件漏洞，但仍禁止开发漏洞利用程序；基础生物学和医学问题的误报率降低了85%。

这意味着从事网络安全和生物学相关工作的用户将减少被系统误拦截的情况。

值得注意的是，美国政府此前因安全顾虑曾对Fable和Mythos两款模型实施访问限制，Fable 5在加入相关分类器后限制解除，Mythos 5的权限后来也得以部分恢复。

此次更新的一项重要新增是反蒸馏机制。从即日起，新注册的API账户无法在多轮对话中手动编辑Claude上下文的同时保留思维链记录——这堵住了一种此前已被公开记录的攻击手法：通过多轮对话中篡改历史上下文但保留思维链，在对抗性指令下重放模型此前的推理过程。

Preserved thinking

[Copy page](#)

Modifying a conversation now results in an error or a dropped block; how to check whether your integration does that and how to migrate.

On Claude Fable 5.1, changing prior turns in the conversation (the `system` prompt, the `tools`, or any earlier message) affects the API response. By default, it makes the API reject the request with an error, unless you opt to have the affected thinking blocks dropped from what the model sees instead (`prefix_mismatch_behavior: "drop_block"`). The check is enforced by default for new accounts created on or after August 31, 2026, 00:00 UTC. There are more details in [How it works](#) and [Who is affected](#).

具体实现方式是每个思维链区块加入签名（signature）验证，校验当前模型是否有权读取该区块，以及生成时的完整对话上下文是否保持一致。对话中任何内容被修改，签名校验即告失败。

失败后的处理方式由开发者通过参数`prefix_mismatch_behavior`控制：默认值`"error"`直接返回400状态码；`"drop_block"`则静默丢弃相关区块并继续执行请求，被丢弃部分不计费。

会触发校验失败的操作包括：编辑、重排或删除任何历史消息，改动顶层系统提示词，对工具列表做增删改名，以及从对话中间抽走思维链区块。追加新消息、修改请求参数、增减缓存控制标记等操作则不受影响。

Anthropic为直接调用Messages API的开发者提供了一系列替代方案，并建议将messages数组严格作为只追加（append-only）的结构来使用。使用Claude Code、claude.ai等官方产品的用户无需作出任何调整。

科研实战：蛋白质设计、金星地图与GPU加速

除基准测试外，Anthropic还展示了Fable 5.1和Mythos 5.1在科研场景中的实际应用成果。


蛋白质设计方面，Anthropic让Mythos 5.1使用开源工具设计高亲和力结合蛋白，并送至两家外部机构做实验验证。在三个靶标上，Mythos 5.1设计的结合亲和力是Adaptyv Bio蛋白质设计竞赛最佳方案的10倍；在全部12个靶标上，命中率接近50%，而当前该领域的典型命中率在10%至15%之间。高亲和力结合蛋白是许多常见药物开发流程的第一步，直接影响药物所需的有效剂量。




Latent GDF-8

Overall hit rate: 1/30 (3%)


Locking myostatin in its dormant form is a clinically tested strategy for building and preserving muscle.



天文学方面，Fable 5.1基于NASA麦哲伦号30多年前拍摄的雷达图像，训练神经网络为金星三分之一的表面生成了新的高分辨率地形图，分辨率从此前的10至20公里提升至2至3公里，高度精度提高了25%。该地图已以CC协议开源发布，供即将到来的NASA VERITAS和ESA EnVision任务参考。



计算生物学方面，Mythos 5.1通过编写自定义GPU内核并缓存中间结果，将7个开源深度学习模型的运行速度提升了最高2.5倍，可将GPU成本降低30%至60%。



这类优化通常需要一个性能工程团队花费数周完成，许多学术实验室无力负担，而Mythos 5.1仅用数天便完成，且仅依赖公开源代码。Anthropic计划近期将相关优化开源。

IPO前夕：收入扩张成估值支撑关键

Fable 5.1的发布，是Anthropic在IPO窗口临近之际一系列动作的缩影。据报道，Anthropic与OpenAI均已提交不公开上市申请文件，Anthropic计划在劳动节后公开招股书，最快有望于9月底登陆美股市场，目标估值为2万亿美元或更高。

Anthropic预计年化收入将突破650亿美元，较2025年底的运营节奏增长逾七倍。在上市窗口临近之际，持续扩大企业市场份额、将高估值转化为可见的收入增长，对公司至关重要。

Fable 5.1的发布是Anthropic争夺编程、网络安全、金融服务、科学及医疗健康等专业场景企业客户这一更宏观战略的组成部分。而此时，竞争对手OpenAI的新模型Astra尚未就绪，仅发出预告。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

861 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



见闻用户
6小时前 中国北京

封号等封死了，还抢市场

1 回复

