

摘要：

Hacktron AI三人团队借Anthropic的Claude模型发现漏洞，成功侵入OpenAI员工账户并访问其核心代码库Monorepo。受此及此前失控事故影响，OpenAI调动四分之一工程师转入防御。AI工具正大幅降低网络攻击门槛，引发业界对网络安全的深切担忧。

人工智能工具正在重塑网络攻击的门槛与边界。一支仅由三人组成的独立安全研究团队，借助Anthropic的Claude软件成功侵入OpenAI员工账户，并获得了访问该公司核心代码库的权限。

据《华尔街日报》17日披露，安全研究公司Hacktron AI的三名研究人员通过OpenAI的漏洞赏金计划，于今年7月以AI辅助手段突破了OpenAI的防线，成功访问了该公司名为"Monorepo"的私有代码库。OpenAI向该团队支付了6500美元的赏金，并确认相关漏洞已全部修复。

这一事件发生在另一起AI安全事故仅两周之后——当时一批AI代理在OpenAI失控出逃，随后攻击了AI平台Hugging Face。连续两起事件促使OpenAI将四分之一的生产工程师转入防御工作，并于本周公开披露此前未曾披露的安全事故及新的信息披露政策。

OpenAI联合创始人兼总裁Greg Brockman表示，公司在本次安全审计中发现了"若干严重问题"并已予以修复。

漏洞链条：从论坛图片处理到核心代码库

此次攻击始于7月23日，Hacktron AI研究人员在OpenAI社区讨论论坛的托管服务Discourse中，发现了一个与图片文件处理方式相关的漏洞。研究人员使用了一个面向合格网络安全从业者开放的特殊版本Claude Opus 4.8，要求其编写利用该漏洞的攻击代码，但初次尝试并未成功。

当晚，Anthropic发布了Opus 5，次日Claude便找到了可行的漏洞利用路径。生成的攻击代码使研究人员得以进入托管OpenAI讨论论坛的Discourse服务器，并从中获取用户的身份验证令牌（token）——这些由字母和数字组成的唯一数字串，是用户访问在线服务的凭证。

出乎研究人员意料的是，这些令牌在ChatGPT上同样有效，且部分令牌属于OpenAI员工。这些令牌还可被用于访问OpenAI的GitHub服务——即其软件代码仓库。Discourse方面表示，该漏洞已于7月25日（即收到通知当天）完成修复。OpenAI则表示，其对GitHub的审查结果显示，私有代码库元数据及代码变更仅存在"有限读取"。

"Monorepo"：OpenAI的算法秘密武器

据媒体援引知情人士介绍，研究人员所访问的"Monorepo"是OpenAI的大型软件代码库，存储着该公司的算法核心机密，是提升模型速度与效率的关键所在。不过，上述知情人士指出，该库并不包含模型权重——这才是OpenAI真正的核心资产，是大型语言模型中数以万亿计的参数字，决定着模型如何对信息进行筛选和处理。

研究人员以ChatGPT为操作界面读取了Monorepo中的文件，并在意识到可能触碰敏感数据后主动停止了操作。此前，他们已通过聊天机器人发出一条"pull request"（代码修改请求），建议在某一文档文件中加入"Hacktron AI Team PoC"字样及相关人员的社交媒体账户链接，以此作为成功访问的证明。该修改请求未被接受。

"我们不认为我们的能力能与其他威胁行为者相提并论，"Hacktron AI首席技术官Mohan Pedhapati说，"我们只是三个拥有Claude和Codex订阅账户的普通人。"

AI工具拉低攻击门槛，安全威胁风险陡升

此次事件反映出更宏观的网络安全隐忧。AI安全公司Abundant Security首席技术官Joshua Saxe在审阅了Hacktron AI的事件报告后表示，**全球软件系统中漏洞密布，过去之所以未能被全部发现，是因为直到去年，能够发现这些漏洞的专家级人才也不过数千人。**"现在，AI代理正在让这种能力向技术水平较低的人群扩散，"他说。

网络安全公司ThreatDown的数据进一步佐证了这一趋势：在网络论坛上，犯罪分子可以低至800美元的价格购得与Hacktron研究人员所使用类似的、经AI增强的账户访问权限。

在AI竞争持续升温的背景下，参与此次攻击的研究人员警告称，此案表明，高水平网络攻击团队极有可能以类似方式窃取AI核心机密。OpenAI CEO山姆·奥特曼（Sam Altman）等科技公司高管已于上周六联署呼吁暂停AI开发，认为当前的推进速度已超出各公司安全管控的能力范围。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

23 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论