

摘要：

苹果硬件主管指出，企业买断设备后无需按token付费，本地算力经济性或优于长期租用云端GPU。高盛认为若更多推理任务迁移至终端，英伟达在增量AI活动中的份额或低于市场预期。当前英伟达隐含波动率处于疫情前以来最低，期权定价几乎未为这一叙事转变预留风险溢价，高盛因此建议买入英伟达看跌期权，同时做多苹果。

苹果正以一套“本地推理”逻辑重塑AI硬件市场的竞争格局，将矛头直指英伟达在AI推理领域的潜在增量份额。

苹果最新发布的M5 Ultra版Mac Studio于9月22日开始交付，支持最高512GB统一内存，并可多机集群运行分布式推理任务，苹果此前已演示四台Mac Studio联合运行一个万亿参数模型。

苹果硬件主管Johny Srouji向路透社表示，企业一旦买断设备，便无需为每一次推理请求支付按令牌计费的云端费用，对于工作负载稳定的团队而言，本地算力的经济性或优于长期租用云端GPU。

这一叙事对英伟达的意义不在于直接抢走现有订单，而在于：若更多推理任务迁移至终端设备或企业自有机器，英伟达在AI推理增量活动中所能捕获的份额或将低于市场当前预期。

目前苹果股价技术面强势，英伟达则仍在宽幅区间内震荡、缺乏中期趋势，部分分析人士建议以期权表达苹果看多、英伟达看空的观点。



产品定位切换，从“用AI”到“跑AI”

苹果对Mac Studio的定位发生根本性变化，从卖“能使用AI”的机器，转向卖“能运行AI”的机器。

这一切换的核心是推理成本的结构差异：iPhone和Mac用户已经为芯片付过费，本地处理的任务不再需要额外的云端推理请求，而同样的逻辑正向企业端延伸。

M5 Ultra Mac Studio最高支持512GB统一内存，这一配置将于10月下旬到货。大内存让用户可以加载单块常规GPU装不下的模型，多台机器集群则能分担万亿参数模型的权重。

苹果此前演示了4台Mac Studio运行万亿参数模型，使本地推理在技术上具备了替代部分云端GPU集群的可行性。

不过，苹果演示之外的真正考验在于推理速度、并发用户数与总拥有成本相对云租赁的对比，这三项才是企业采购决策的关键变量。

英伟达仍在产业链，但增量份额存疑


Mac Studio不会在所有工作负载上取代数据中心GPU，苹果自身也在谷歌云上为部分高要求AI任务使用英伟达GPU。

但英伟达不必失去现有订单，其相对叙事就可能改变：一旦更多推理跑在设备端或企业自有机器上，英伟达在增量AI活动中的份额就可能低于市场假设。

英伟达股价仍无中期趋势，困于宽幅区间并交易在区间顶部附近，而隐含波动率处于疫情前以来最低。



低波动率通常反映市场对未来走势的高度确定，但推理叙事的潜在转变恰恰是一个变数，当前期权定价几乎没有为“推理向本地迁移”预留风险溢价。



正因如此，高盛认为在盈利预期被下修之前，买入英伟达看跌期权是用低成本表达这一转变的方式；相对视角上，其偏好苹果看涨对英伟达看跌。

分析认为后续可关注10月下旬512GB配置到货后的实测推理速度与总拥有成本数据，以及企业客户对本地推理方案的采购反馈。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

121 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

2 条评论



零一
3小时前 中国重庆

英伟达DGX和RTX Spark是摆设？营销就营销别拉踩，还叙事呢

1 回复



青山白釉
5小时前 中国河南省

中小企业的本地化部署很有诱惑力，而且数据还在本地存储

0 回复