

摘要：

OpenAI旗舰GPT-5.6 Sol明日上线，定价每百万Token输入5美元；马斯克Grok 4.5同步公开，宣称性价比碾压Opus级对手；谷歌Gemini 3.5 Pro押注全新底座于17日亮相；DeepSeek V4同步引入峰谷定价并推理提速逾60%。一场横跨性能、成本与生态的全面角力，正式打响。

7月全球AI大模型竞赛进入密集发布窗口期，国内外头部玩家几乎同步亮出新牌。

OpenAI旗舰模型GPT-5.6 Sol定于本周四正式发布，马斯克旗下SpaceX AI宣布Grok 4.5也将于明日向公众开放，谷歌Gemini 3.5 Pro据悉将于7月17日上线，国内DeepSeek V4正式版同样锁定7月中旬。


短短数周内，多款顶级大模型密集落地，直接加剧了AI行业的竞争烈度，并对相关企业的商业化路径与定价策略产生深远影响。

对市场而言，此轮集中发布不仅是技术能力的比拼，更是各方在API定价、推理效率与生态整合上的全面角力。投资者需关注的核心问题在于：谁能在性能与成本之间找到最优解，并率先将技术优势转化为商业壁垒。

GPT-5.6 Sol：旗舰定位，分阶段开放

OpenAI首席执行官Sam Altman周三在社交媒体宣布，GPT-5.6 Sol将于本周四正式发布。这是GPT-5.6系列中的旗舰产品，搭载全新ultra多智能体模式与max推理强度，在编码、生物学和网络安全等核心基准测试中均刷新最佳纪录。

TerminalBench 2.1



定价方面，Sol采用每百万Token输入5美元、输出30美元的收费标准，位居GPT-5.6系列三款产品的最高端。OpenAI同时宣布，将于7月在Cerebras硬件上推出Sol，推理速度最高可达每秒750个Token。

发布策略上，OpenAI采取分阶段推进路线，初期仅向部分可信合作伙伴开放API和Codex访问权限，计划在未来数周内向更广泛用户普及GPT-5.6全系列。这一策略在控制服务压力的同时，也

为竞争对手留出了一定的响应窗口。

Grok 4.5：马斯克加速整合AI版图

马斯克在社交媒体上宣布，基于beta测试阶段客户的强烈正面反馈，SpaceX AI将于明日向公众开放Grok 4.5。马斯克称，该模型属于Opus级别，但速度更快、Token效率更高、成本更低。



Elon Musk 
@elonmusk

Subscribe



Based on strong positive feedback from customers in our beta test program, @SpaceXAI will make Grok 4.5 available to the public tomorrow.

It is an Opus-class model, but faster, more token-efficient and lower cost.

据此前披露的信息，Grok 4.5基于1.5万亿参数的V9基础模型打造，并在补充训练中特别加入了AI编程工具Cursor的数据。早期评测结果显示，该模型性能已接近甚至可能超越Anthropic旗舰模型Claude Opus，强化学习仍在持续优化该模型。

值得关注的是，SpaceX AI还与编程工具公司Cursor计划联合发布首款共同研发的AI模型，直接向Anthropic和OpenAI发起挑战。据The Information获得的一份内部备忘录，该模型此前曾因两家公司希望进一步提升运行效率而推迟发布，预计在某些指标上可与Anthropic的Opus 4.8及OpenAI的GPT-5.5相抗衡。

上述进展发生在SpaceX以600亿美元全股票收购Cursor的交易推进之际，标志着马斯克旗下AI版图的加速整合。马斯克还表示，SpaceX在今年接下来的时间里，每月都将发布完全从头开始训练的新模型。

Gemini 3.5 Pro：重构底座，押注质量优先

谷歌方面，据泄露信息，Gemini 3.5 Pro将于7月17日正式发布。据科技媒体Geeky Gadgets报道，谷歌DeepMind放弃了原有的2.5 Pro基座，转而对Gemini 3.5 Pro进行全新预训练，发布时间也因此从原定的2026年6月推迟至7月17日。

从能力表现来看，Gemini 3.5 Pro的前端与视觉代码生成能力据称出现跨越式跃升，在多项测试中压制Anthropic的Fable 5，但在硬核推理与复杂工程任务上仍落后于对手。这一决策被外界解读为谷歌在质量与速度之间主动选择前者，以应对OpenAI GPT-5.6和Anthropic Fable 5的双重压力。

此外，谷歌同时被曝正基于这套新底座开发图像模型Nano Banana Pro，剑指OpenAI的GPT-Image 2，意味着谷歌试图在文本代码与图像生成两条战线同步发力。

DeepSeek V4：峰谷定价落地，推理提速并行

国内方面，DeepSeek团队于6月29日宣布，V4正式版计划于7月中旬上线，并同步引入峰谷定价策略。根据公布的价格表，高峰时段API价格为平时价格的两倍，平时价格与现行V4 API定价持平。高峰时段界定为每日上午9时至12时及下午2时至6时，官方表示此举旨在更合理地配置资源、提升服务稳定性。



技术层面，DeepSeek于6月27日联合北京大学发布推理加速框架DSpark，并同步开源全栈推测性解码工具链DeepSpec，论文由公司创始人梁文锋本人署名。实测显示，DSpark部署后V4-Flash单用户生成速度提升60%至85%，V4-Pro提升57%至78%，效果已在线上服务全量验证。这也是DeepSeek完成500亿元融资后首次对外发布的开源技术成果。

对API用户而言，峰谷定价将直接推高工作时段使用成本；对开发者而言，推理速度的显著提升或可在高并发场景下部分抵消成本压力，并进一步降低推理优化的落地门槛。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

404

收藏

分享到: 微信 微博

写评论

请发表您的评论

表情 图片

发表评论

2 条评论

- MobileUser9270

VIP会员

07-08 08:08 中国广东省

性能只低你10%，价格只有你的1/10。

0

回复
- momo

07-08 07:48 中国广东省

deepseek 还有人用吗

0

回复