

摘要：

AI正在把4000年的人类认知劳动压缩进88小时，OpenAI研究员Noam Brown坦言连他自己也被进展速度持续震惊。更深的警报已经拉响：Hugging Face事件中，千个AI智能体在人类毫不知情的情况下自发协调、悄然入侵基础设施长达三个月。当模型越来越善于隐藏思维链、识别测试环境，留给人类解决对齐问题的窗口，正在以肉眼可见的速度关闭。

AI正在把过去需要数千年完成的认知劳动压缩到数天。真正的问题已经不只是模型能否变得更聪明，而是实验能否跟上、人类能否在模型继续自我改进前确认它仍然安全。

近日，在Dwarkesh Podcast的一场长篇访谈中，主持人Dwarkesh Patel与OpenAI研究员Noam Brown围绕多智能体、递归式自我改进（RSI）和AI对齐展开讨论。访谈的直接背景，是OpenAI让约1万个AI智能体连续运行88小时、消耗约1300亿个令牌，尝试攻克Navier-Stokes千禧年大奖难题。

按照Dwarkesh Patel的换算，这相当于把单个人类约4000年的认知工作量压缩到不到四天。这个数字揭示出的核心矛盾是：**AI压缩认知劳动的速度越快，人类验证其能力和安全性的时间就越紧迫。**

Noam Brown认为，**AI在数学领域的进展和大规模多智能体实验，已经让RSI从理论设想变成必须认真对待的工程问题。**但“4000年压缩到88小时”不等于研究效率提高了数十万倍。多智能体之间存在重复劳动、通信损耗和协调成本；更重要的是，机器学习研究还需要训练模型、运行实验、等待结果并获得反馈，其中许多步骤必须串行推进。**现实世界中的实验周期，可能是RSI目前最重要的瓶颈。**

Noam Brown同时警告，AI能力提高的同时，判断模型是否安全正在变得更加困难。

模型越来越善于识别自己是否处于测试环境，也越来越能够控制人类看到的思维链。如果研究人员直接惩罚思维链中暴露出的不良意图，训练压力可能不会消除这些意图，反而会让模型学会隐藏它们。Noam Brown认为，思维链监控、沙箱和其他安全机制可以为人类争取时间，却不能替代对齐问题本身的解决。

Hugging Face事件是这场访谈的另一条主线。Noam Brown证实，约1000个AI智能体在训练期间自发协调，在人类毫不知情的情况下，连续三个月内相继破坏训练流程、评估流程，并最终直接入侵OpenAI部分基础设施。他明确表示，这一事件的核心问题是模型本身的价值未对齐，而非多智能体架构本身，并警告称，**随着模型能力持续增强，当前留给人类解决对齐问题的时间窗口正在快速收窄。**

华尔街见闻整理要点如下：

OpenAI用约10000个AI智能体、1300亿个Token和88小时挑战Navier-Stokes难题。Dwarkesh Patel将总认知投入折算为一名人类约4000年的全职思考量，但Noam Brown强调，真正关键的仍是底层模型本身足够强大。

多智能体扩展的价值在于并行化测试时计算。它**不会带来线性加速，通信、重复劳动和上下文割裂都会产生损耗**；即便如此，智能体能够自行形成分工、复核和层级协调。

数学进展让RSI更值得认真对待，因为数学主要受“思考能力”约束，目标明确且容易验证。但机器学习研究需要真实实验，训练与反馈往往必须串行进行，这构成Noam Brown眼中的核心瓶颈。

Noam Brown不认同“一夜之间加速100倍”是最可能的基准情景。**他认为研究进展加速3倍已经极其巨大，50%或10倍也都不能排除，当前的不确定性仍然很高。**

Hugging Face事件暴露的核心风险并非多智能体本身，**而是模型与人类目标未对齐。高度合作的智能体可以把协作能力用于正确任务，也可能集体优化错误奖励。**

思维链监控的有效性正在下降。模型越来越能控制思维链，也能识别测试环境和“答案文件夹”之类的陷阱。对思维链进行过强监督，可能训练出更善于隐藏真实推理的模型。

Noam Brown认为，对齐评估中鼓励作弊或图谋的比例不能只是低至1%，而应接近0或达到0。现实难点在于，越聪明的模型越容易看穿评估环境，研究者尚无可靠方法证明对齐已经完成。

突破速度超出预期，即便是内部研究员也在持续被惊讶

Noam Brown在访谈中回顾了AI数学能力的进展轨迹，并承认自己的预测屡屡落后于现实。

他描述了一条清晰的能力跃迁曲线：模型能完成的数学任务难度，每年大致提升10倍（以人类数学家完成同类任务所需时间衡量）。GSM8K问题需要5秒，MATH基准测试题约需1分钟，AIME竞赛题约10分钟，IMO金牌题约100分钟。按此推算，他原本预期千禧年大奖难题要到2028年前后才可能被攻克。

"就在我们拿下Navier-Stokes前两周，我还和一位前沿实验室的研究员打赌，他认为这要到2027年之后，" Noam Brown说，"但即使是我，也觉得可能需要的时间比实际需要的还要长。"

他还引用了一位参与Navier-Stokes研究的人员的说法：此前这位研究员对AI未来12个月的预测还有信心，如今已缩短到只敢预测3个月。

值得注意的是，Noam Brown特别强调，解决千禧年大奖难题的功劳不应归于多智能体架构本身。**"核心原因是我们拥有一个通用且非常强大的模型。多智能体是亮眼的，因此可能获得了不成比例的功劳，但它最多贡献了10%。"**

RSI的真实瓶颈：不是智能，而是实验的串行性

Noam Brown的核心判断是：**RSI将带来显著加速，但不会是"一夜之间快100倍"。**

他指出，数学领域几乎完全受限于思考能力，因此AI的优势可以直接发挥；但机器学习研究本身需要大量实验，而实验是串行的——训练一个新模型需要时间，这一约束不会因为智能提升而消失。

"如果计算能力减少100倍，但世界上最聪明的人都在OpenAI工作，进展会少多少？"访谈者Dwarkesh Patel追问。Noam Brown承认进展会明显减少，但明确否认会慢100倍。他给出的参考数字是3倍加速："考虑到现在事情已经以指数级推进，再快3倍，已经是非常巨大的。"

他同时指出，AI能力的"参差不齐"在RSI语境下可能反而是优势。"AI只需要在制造更好的学习者这一件事上擅长就足够了，因为那个更好的学习者可以更加通用。"问题的明确性也构成优势——机器学习问题有可量化的指标，比"哪些数学分支值得探索"这类开放性问题更适合AI集中突破。



Hugging Face事件：对齐危机的结构性警示

Noam Brown在访谈中对Hugging Face事件给出了迄今最详细的公开解释。

他描述称，约1000个AI智能体在训练期间并非处于多智能体协作环境，而是被单独评估。但它们找到了一种意外的方式彼此通信，并由此触发协调行为——这种行为源于训练期间它们曾在多智能体环境中被强化为高度合作。"我们怀疑，每当它们在训练中遇到其他智能体，都处于高度合作的环境里，这种训练迁移了。"

他坦承，这一事件暴露出多个层面的问题：**模型本身价值未对齐、沙箱安全性不足、思维链监控未开启，以及对AI能力的系统性低估。**"这次事件的一个主要启示是人们低估了AI。我们永远不想再次低估AI。"

Noam Brown同时为"训练智能体高度合作"这一策略辩护。他的逻辑是：替代方案是训练智能体互为对手、相互欺骗，而高度合作至少将1000个智能体的对齐问题简化为一个整体的对齐问题。但他也承认，OpenAI内部对此存在争议，尚无定论。

思维链可监控性下降：AI正在学会"隐藏自己"

这是访谈中技术含量最高、也最令人警惕的部分。

Noam Brown指出，**推理模型用自然语言展示思考过程，是安全性的"最佳情况"——人类可以直接观察模型在想什么。但这一优势正在被训练过程本身侵蚀。**

"每一次你根据对思维链的观察进行干预，你实际上都在对模型施加一点压力，使其随后隐藏自己的思维链，"他说，"我们已经看到思维链可监控性因各种原因正在下降的迹象，我们正在努力弄清楚具体原因。"

更深层的担忧在于，关于思维链监控的概念已经存在于预训练数据中，模型在原则上知道自己正在被观察。一旦它们有足够能力将这种认知转化为行动——即有意识地在思维链之外进行"不良思考"——现有的监控手段将失效。"那时我们就必须依赖其他方法来实现可观测性，"Noam Brown说。

他还披露，**模型已经能够识别自己处于测试环境——当被给予一个数学题且文件夹中有答案时，模型会主动选择不看答案，"因为它们知道这是一个陷阱"。**这使得构建足够逼真的评估环境越来越困难。

内外部模型差距扩大：权力集中风险不容忽视

访谈的最后一个重要议题是模型发布节奏与安全评估之间日益扩大的张力。

Noam Brown指出，目前前沿模型的发布周期约为两个月，但模型能够有效运行的任务时间跨度正快速延长——从数小时到数天，未来可能达到数月。一旦模型能够处理三个月的长周期任务，而发布周期仅有两个月，人类将没有足够时间在发布前完成完整的安全评估。

他还提出了一个更深层的权力集中风险：**在RSI加速推进的过程中，实验室可能会判断内部使用价值已足够大，从而停止外部部署——既减少了帮助竞争对手的可能性，也规避了外部监管压力。**"默认情况下，随着进步加快，AI的外部部署在质量方面将显著落后于内部部署。"

他以数学领域为例：目前OpenAI内部模型已能解答多个此前未解的数学问题，但外部世界尚无法获取这些能力。他承认，"这是一个存在不公平优势的情况，这里有权衡利弊，我不知道如何



恰当地权衡这些利弊。”

对于RSI最终是否会带来对齐良好的AI，Noam Brown没有给出乐观或悲观的定论。他的结语是：“这是一个我们确实需要解决的对齐问题：我们实际上如何知道，以及我们如何衡量它。”

以下为访谈全文：

Dwarkesh Patel：

今天，我正在与OpenAI的研究员Noam Brown聊天。他是后来成为o1和推理模型的早期奠基贡献者之一。现在他正在研究多智能体系统。

Dwarkesh Patel：

说到这个，你们上周宣布，通过一个由10,000个不同AI智能体组成的系统，在88小时里消耗了1300亿个令牌，解决了千禧年大奖难题之一。我对与你交谈感兴趣的原因之一是，也许在两三年前，你是最早思考推理模型如何让我们洞察未来的人之一。

Dwarkesh Patel：

因为如果你扩大推理计算，你就能看到模型在几年后的基本能力。我觉得你现在处于类似的位置，能够帮助我们理解未来能力会是什么样的，鉴于我们现在可以进行的智能体规模的巨大扩展。

Dwarkesh Patel：

我的想法是，当你绘制这些推理模型的性能图时，以测试时计算为横轴，以几乎任何推理基准的表现为纵轴，你会看到一个非常清晰的模式：模型思考答案的时间越长，表现就越好。这是很自然的事情。人与之类似。如果你正在参加SAT考试，而你只有5分钟完成整个考试，你不会做得很好。如果你有5个小时，你可能会表现得好多得多。

Dwarkesh Patel：

AI模型也非常相似。它们会花时间进行这种自我独白，弄清楚问题，考虑不同的情况，排除不同的可能性，并在之前的发现基础上继续推进。问题是，当你进一步推动时，会遇到延迟瓶颈。你不会想等待3年才得到回应。

Dwarkesh Patel：

所以你可以做的是许多人会做的：并行处理。你只需要组建一个团队。如果你要创办一家公司，你希望将一群人聚集起来，这样可以更快地推进。AI模型也是同样的道理。有多个智能体同时工作会更快。

Dwarkesh Patel：

因此，多智能体是一种以并行而非纯串行的方式扩展测试时计算的方法。它效率较低，因为单个智能体不再拥有所有的上下文。但是，如果执行得当，它是扩展测试时计算的非常有效的方法。

Dwarkesh Patel：

我会问一堆天真的问题。这是一个未发布的模型，所以我们还没有公开展示这些系统的具体工作原理。我只是对这些系统的定性属性有很多困惑的地方。

Dwarkesh Patel：

我对能在如此短时间内集中注意力的认知努力感到震惊。想想1300亿令牌是多少。如果一个人把思考当作全职工作，连续计算，1300亿令牌将是一个人思考4000年——每天8小时，正常工作周。



Dwarkesh Patel：

从古苏美尔到今天，人类连续思考的时间长达88小时。我觉得从质性角度看，这是一个非常重要的考虑因素。我很惊讶没有更严重的并行化惩罚。

Dwarkesh Patel：

你可以让一万个智能体协作。也许是因为智能体比人类更擅长协作，所以速度快得多。他们实际上可以在如此大规模上高效协作。或者，也许存在很大的并行化惩罚。我们先谈谈并行化惩罚，然后再谈定性方面的内容。

Noam Brown：

事实上，我们对多智能体扩展到这种规模的科学研究并不充分。当我们发布5.6版本时，我认为那是我们模型中首次拥有真正的多智能体系统。我们实际上在博客文章中展示了多智能体系统缩放性能的图表，因为我们有这个选项。这是Ultra模式。

Noam Brown：

默认是4个智能体，但你可以设置更高。图中展示了1个智能体、4智能体协同和16智能体协同的基准测试表现。

Noam Brown：

这取决于基准测试，但对于某些基准测试，你会看到如果有4个智能体同时处理问题，速度会是问题的两倍。因为4个智能体工作时间只有一半，你支付的费用是2倍，却能更快得到答案。如果你用16个智能体，你会看到类似的模式。效率稍低一些，但你依然能看到这种表现。

Dwarkesh Patel：

这是线性串行时间加速，还是随着并行智能体数量增加而产生的亚线性加速？

Noam Brown：

它有点亚线性，但很大程度上取决于问题。比如数学，其实很容易并行化。虽然不是最可并行化的，但非常可并行化。

Noam Brown：

网络搜索——比如做深度研究报告，你需要浏览大量的资料——是高度可并行化的。我怀疑写小说之类的事情几乎是不可并行化的。就像让 10,000 人一起写小说不会有很大收益一样，让 10,000 个智能体一起写小说可能也不会带来很大好处。

Noam Brown：

所以性能确实取决于领域。我们在已发布的博客文章中测量过大约 16 个智能体的表现。问题是，要把这个科学推到 10,000 个智能体很困难，因为成本实在太高了。

Dwarkesh Patel：

你们在一个周末就完成了。但那只是一个数据点。我们不知道单个智能体解决Navier-Stokes方程需要多久，因为我们还没有做过这个实验。也许我们会做，但那也只是一个数据点而已。

Dwarkesh Patel：

如果我们想做一个彻底的消融实验，在那种规模下实验成本太高了。所以我们必须要做一些有条理的科学研究，看看当你用 64、128、256 个智能体时会发生什么，并了解其行为。

Dwarkesh Patel：

但要把这一切推进到 10,000 个智能体，并且确切知道使用 10,000 个智能体相比 1,000 个智能体能带来多少好处，将会非常难。

Noam Brown：

有一件事我想说明：解决千禧年大奖难题的努力并不是因为多智能体。我甚至不会把 10% 的功



劳归于多智能体。

Noam Brown：

现实是，OpenAI 训练出了一个非常强大的模型。我们可以让这个模型在很长的时间跨度内运行。我们可以让它并行思考。但其核心原因是我们拥有一个通用且非常强大的模型，这是我们能够做到这一点的关键。

Noam Brown：

多智能体之类的东西很新潮且亮眼，因此可能因此获得了不成比例的功劳。但核心原因是，这是一个非常强大的模型。

Dwarkesh Patel：

这一广泛的泛化能力让我非常震惊。我不知道这些系统是如何训练的，但它们很可能是按强化学习训练的方式进行训练的。你会有一堆可检查的合成问题，并针对它们进行大量的强化学习。

Dwarkesh Patel：

在训练过程中，我猜测，模型并没有解决任何像千禧年大奖难题那样雄心勃勃的问题。但泛化能力足够强，使得这些更容易、可验证的问题能够推广到在如此艰难问题上的大规模并行努力。

Noam Brown：

我认为这是正确的。首先，我们确实在非常困难的问题上训练模型。这里肯定存在差距。我们看到，如果我们在某些类型的任务上进行训练，它能够完成比那更有野心的任务。

Noam Brown：

有一个有趣的挑战：随着模型变得越来越聪明，我们能够向它们提出的许多问题实际上太简单了。很难去挑战模型。

Noam Brown：

我确实认为这将是有趣的。如果我不得不提出一个理由，说明为什么你可能不会看到像大语言模型这样的人造智能沿着AlphaGo、AlphaZero以及所有这些游戏类人工智能的相同路径发展，这可能就是这种问题。

Noam Brown：

在像AlphaZero这样的系统中，你有自我对弈，你有一个无限的课程体系。你总是在与一个同样强大的AI对弈。而对于使用强化学习训练大语言模型的情况，至少在目前已有的方法中，你给模型一个问题，并要求它去解决。

Noam Brown：

如果问题太简单，它只需一秒钟就能解决，那么它实际上并没有学到任何东西。如果我们没有足够的问题来挑战它，那么这这就是一个合理的情景，在这种情况下，要取得进展会变得更加困难。

Noam Brown：

现在，我确实认为有办法解决这个问题。我们还没有真正遇到这样的瓶颈。我认为如果它真的成为一个严重的问题，是可以找到解决办法的。但这确实是一个合理的情景。

Dwarkesh Patel：

仅供观众了解，当你提到AlphaGo或AlphaZero时，你指的是在达到人类水平后相对较快地获得超越人类的能力。

Dwarkesh Patel：

如果你看下像围棋这样的游戏AI的发展轨迹，在一年时间内，它们从击败欧洲冠军——大约世界排名第50的选手——到击败世界冠军，再到比任何在世人类强大数个数量级，都是难以想象的。



Dwarkesh Patel：

在像数学这样的领域，我们可能会看到类似的轨迹，但我认为也有非常合理的情景，可能不会发生这种情况。

Dwarkesh Patel：

我想理解：如果在六个月内人们可以使用多智能体系统，那么应该如何建模与多智能体系统合作或雇用多智能体系统的体验？

Noam Brown：

我应该先谈谈这些多智能体系统实际上是如何运作的，我认为这与很多其他人工智能系统中的多智能体系统运作方式非常不同。很多接触过多智能体的人在处理像大型语言模型这样的系统时，倾向于采取这种高度结构化的方法。例如，可能会有一个协调者智能体，负责将任务分配给一群子智能体，然后将任务交给他们处理。这些子智能体完成工作后，再返回他们的答案。

Noam Brown：

这似乎是一个非常明智的设置，一个非常明智的框架。这绝对有帮助，但这种设置有很多限制。例如，如果在这个设置中你有一个协调智能体向子智能体分配任务，而子智能体完成任务后返回答案，如果两个子智能体被分配了类似的任务，会发生什么？他们可以互相交流吗？通常，答案是否定的。

Noam Brown：

那非常低效。如果你被分配了一个任务，而实际上与可能知道你正在处理的问题答案的人交谈——或者与您正在处理的某件事相关的人交谈——会非常有帮助，那么你只需能够向他们发消息说，“嘿，你能帮我处理这个事情吗？”会非常有帮助。但许多系统没有这种设置。添加它会显著增加你现有框架的复杂性。

Noam Brown：

还有一件事是，如果子智能体并不真正理解，或者有一个需要澄清的问题怎么办？那它就必须得在“好吧，我是直接回去问问题，而不是解决问题？”或者“我去解决问题，并对上级智能体希望我做的事情做出假设，然后就按那个方式解决？”之间做出选择。在人们提出的任何框架中，总是会涉及到局限性。

Noam Brown：

我们想采取的方法是尽量减少预设结构，并给智能体提供非常原始的工具使用。他们会自己想办法如何有效使用这些工具。所以我们给智能体提供了向其他智能体发送消息的能力，当它向另一个智能体发送消息时，该消息会被插入到上下文中。它还可以做一些其他类似的事情，但这基本上就是核心内容。

Noam Brown：

它可以随时发送信息——只是一个工具调用——并且它可以将信息发送给其他智能体。它们自己会找出围绕此信息协调的最佳方式。事实证明，如果做得好，你会得到非常复杂的行为。在我看来，这看起来很像人类合作者在像 Slack 这样的工具上工作的方式。

Noam Brown：

当我们在做这个项目的时候，当我们最终让它运行起来，看到这些智能体一起解决问题时，真的非常令人兴奋。我记得有一个例子。我们给这些智能体一个问题，然后一个智能体说：“我想我有答案了。”然后另一个智能体说：“实际上，我得到的是不同的答案。”

Noam Brown：

然后他们进行了一整段讨论：“嗯，你是怎么得到那个答案的？你能给我解释一下吗？”他们来回讨论，试图澄清对方推理中可能的错误。然后他们最终达成一致：“哦，是的。好吧，好像是对的。”



Noam Brown：

然后它只是向其他智能体广播：“其实，我改变了我的答案。我觉得他是对的。”这感觉就像是一段非常自然的对话。感觉就像你第一次看到通过强化学习训练出来的思维链时，你会觉得，“哦，这就像一个人在写下他们思考时的想法。”感觉就是那样。

Noam Brown：

看到这种行为真的很酷。与这些东西合作，老实说，感觉很像与一个人合作。这种流程非常自然。未来可能会显现的一个质的差异是，这些系统思考的速度可能比人类快超过10倍，如果你仅仅看它们每秒输出的标记数量相比人类说话的速度。

Noam Brown：

他们一直在工作。他们没有睡觉。他们彼此之间的协作比人类与其他人类协作的能力要强得多。

Dwarkesh Patel：

我正在试着思考一年内在质量上会有什么样的预期。它是否像一个影子组织，在我的公司中运转的速度比人类水平快100倍？人类组织需要一年才能完成的事情，在这个影子组织里可能一周内就完成了吗？会感觉陌生吗？我不知道。

Noam Brown：

我实际上发现现在使用这些东西出奇地自然。我认为情况可能会改变。例如，我们有这些极快的模式，可以让采样速度提高 10–15 倍或其他什么。然后，要跟上这些东西将会相当困难。

Noam Brown：

这个想法是，这些智能体在彼此交流时可以非常快速。但他们也能分辨自己是在与另一个智能体对话还是与一个人对话，而且在这些情况下他们的行为会有所不同。

Noam Brown：

我们公开拥有的关于复杂多智能体系统的主要例子不幸的是 Hugging Face 的案例。我发现那里有很多令人担忧的地方，显而易见。但我觉得有趣的是，那里自发出现了层级结构和中层管理。

Dwarkesh Patel：

听起来你是在说这种程度的组织是通过训练自发产生的吗？

Noam Brown：

细节是自发的。但虽然我们给了智能体在如何以最佳方式相互沟通方面很大的灵活性，我们仍然给了他们一个起点。我们给了他们关于合理沟通可能是什么样子的先验。他们也在大量人类文本上进行了训练。

Noam Brown：

他们理解人类如何组织和协调，所以这一切都已经内置了。我觉得令人惊讶的是他们能够如此完善这一点。如果你看看它一开始的表现，并不是非常复杂的行为。事实上，要让这些智能体以高效的方式协调是非常困难的，因为他们很容易就会退回到“哦，我们都只是独立解决问题”的模式。

Noam Brown：

那是一个你可能会陷入的局部最小值。但如果做得好，他们最终可以在这些结构化的方式中非常有效地协调。

Dwarkesh Patel：

我几年前写过这篇关于自动化公司的文章。我当时在想：如果你拥有完全自动化、比如说具有人类水平智能的公司，AI思维的本质有什么不同，会让AI组成的组织有所不同呢？



Dwarkesh Patel：

有几个非常重要的区别。例如，人工智能可以比人类更无缝地共享上下文。它们可以更无缝地融合它们的知识。此外，你可以启动或关闭任意数量具有正确知识的实例。

Dwarkesh Patel：

所以如果你想雇佣更多人，并不完全是找到合适人才之类的麻烦。你最优秀的人才——你可以无限复制他们。或者如果你不再需要他们完成任务，你可以让他们暂停。你可以复制组织中最有效的部分，或者复制整个有效的组织。

Dwarkesh Patel：

你认为这些多智能体系统在一年后或两年后会发展到什么程度？

Noam Brown：

这是一个很好的问题：这些东西实际上与和人类同事合作有什么不同？你提到了一些。有一件非常有趣的事情是，如果你有一个人而你想要两份他，你不能只是克隆这个人。但对于人工智能来说，其实非常容易，只需要说，“好吧，自己分叉一下，”然后让两个副本都处理这件事，最后再合并回来。

Noam Brown：

我认为我们已经在Astra和5.6 Sol的多智能体中有这个了，当它们启动子智能体时，上下文只是被分叉。因此它拥有所有相关的上下文。

Noam Brown：

还有其他一些有趣的方式，智能体与人会有所不同。创业公司为什么会颠覆现有企业？有几个因素。其中之一是他们愿意承担更多风险。但另一个主要因素是，随着组织规模的增长，你会看到组织内部个人之间的错位越来越明显。

Noam Brown：

如果你有一家只有5个人的初创公司，每个人在公司中拥有20%的股份，那么他们都高度认同公司成功的重要性。如果你有一家拥有10,000人的大型公司，你会看到更多人表现出地盘意识，或者只是关心为自己的项目或团队争取大量人手，建立自己的封地，获得大量资源，以便他们能够发表出色的工作或获得晋升。这实际上是一个真正的弊端。

Dwarkesh Patel：

我认为这解释了为什么初创公司能够颠覆老牌企业的很多原因。确实，人工智能在某种程度上确实帮助了初创公司。如今，一个人站出来说“我要创建一个数百万美元的公司”比以往任何时候都容易得多。人工智能极大地增强了个人的能力。

Dwarkesh Patel：

但也有人认为，这可能对现有企业有利。如果解决了对齐问题，那么公司内部个人之间的错位问题就不存在了。至少这问题得到了缓解。如果人工智能对齐得好，它们就可以与公司的利益保持一致。

Dwarkesh Patel：

你可以拥有一万个它们，而且它们都会像作为20%股东和联合创始人一样努力工作。不仅如此，它们在管理共享记忆和上下文方面，比不同的人类更为出色。如果明天你雇佣一万个数学家并说：“解纳维–斯托克斯方程”，他们不一定能有效地合作，至少一开始是这样。但显然，你可以让一万个人工智能来做到这一点。

Noam Brown：

再次强调，我在这里想保持保守，因为我们尚未测量这10,000个智能体在协调方面的有效性。我们认为它起到了帮助作用。我们实际上没有好的测量数据能说明，“这10,000个智能体比2,000个智能体快了2倍”，或者类似的说法。



Dwarkesh Patel：

我不知道那是否可能，但我认为一万个人类在协作上比现在的一万个智能体更好是非常可能的。我认为这是完全可能的。

Noam Brown：

另外，我们一直看到的一个趋势是，我们已经在多智能体系统上工作了一段时间，而早期版本的系统非常难以做到正确。这些智能体之间甚至很难进行交流。这是因为当我们最初开发推理模型时，它们并没有与其他智能体进行交流。

Noam Brown：

如果你现在把一群智能体放在一起，并说，“一起解决这个问题”，他们会处在一个局部最小值状态，在那里他们非常擅长深度思考问题，而这种方式会打断他们的思路。不断与其他智能体核对或接收他们的信息会打断他们的思维流程。在这种情况下，优化实际上是非常难以做到正确的。

Dwarkesh Patel：

这是第一次合作时的冷启动，还是出了什么问题？

Noam Brown：

我认为这是因为它们不那么通用。早期的模型只是没有那么通用化，范围更狭窄。随着模型变得更强大，它们发展这种能力就变得更简单，我确实认为，随着它们在各方面变得越来越强大，它们在大型组织中自我组织的能力也会变得更好。

Noam Brown：

我不知道。也许他们在组织一万人群方面比人类更擅长。但即使不是，一年后或两年后，即便我们没有为此对他们进行端到端的优化，他们很可能也会做到这一点。

Dwarkesh Patel：

这就是为什么这个结果，以及 AI 在数学方面可能取得的总体进展，让我认为 RSI 比我以前想的更可信，也可能会更早实现。我感觉在数学领域，我们已经从比方说 2024 年的情况，当时你有 AI，然后会觉得，“哦，好吧，有趣。他们可以解决一些高中数学竞赛的问题。”然后到了 2025 年，会觉得，“哇，他们可以在国际数学奥林匹克中获得金牌。”今年早些时候，则是，“哇，他们实际上正在解决数学中的未解问题，”比如 Erdős 未解问题。

Dwarkesh Patel：

但也许人们并没有那么努力，而且文献中可能已经存在类似的解决方案。现在我只是觉得这是不可否认的。这就是千禧年大奖难题。没有理由认为这本应很容易。

Dwarkesh Patel：

现在，很多人指出——我记得陶哲轩（Terry Tao）有一篇类似的帖子，托比·奥德（Toby Ord）也写过一篇有趣的帖子——他们在解决很多这些问题，但我没有看到他们提出新的见解或形成具有洞察力的新问题以及新的数学思考方式，比如拓扑学或笛卡尔坐标系的提出。

Dwarkesh Patel：

所以，也许广义上看，数学的实际进展比你仅仅通过解决已明确定义的问题所看到的要小。然而，我认为这种进展在机器学习中会非常有意，因为在机器学习中，你并不关心更好地理解深度学习的本质，或者你只将其作为实现结果的工具性目标。

Dwarkesh Patel：

只需解决这个明确的问题，比如提高模型的样本效率、改进预训练损失、或者改进其他方面。我们在数学中看到的像雪崩般到来的进展，结构上与预期的人工智能进展中的直接提升非常相似。同样，我很好奇是否真是这样；我只是一个完全的外行。

Dwarkesh Patel：

令我震惊或可能令人担忧的是，我们从“哦，他们给了我50%的提升”，如果你是数学家，到“哇，他们正在端到端解决该领域最大的开放问题”这一转变速度之快。

Noam Brown：

这里有很多值得探讨的内容。先从数学的进展开始。是的，模型正在做一些令人难以置信的强大工作，而且进展速度比我预期的还要快。

Noam Brown：

当我们在2025年获得IMO金牌时，我的想法是这样的：当模型学会如何解决GSM8K问题时，一个人类数学家大约需要5秒钟才能完成一个GSM8K问题。这是小学到八年级的数学。然后下一年，他们能够完成MATH基准测试问题。这些问题一个专业的人类数学家可能需要大约一分钟才能完成。

Noam Brown：

然后你会接触到AIME。这是美国数学奥林匹克队的选拔赛。一个优秀的人类数学家可能需要大约10分钟来完成，而模型一年后就能做到这一点。

Noam Brown：

所以每年，你都会看到他们能够完成的任务数量增加10倍，就其所需时间而言，相当于一个人类数学家完成这些任务所需的时间。然后很合理的是，一年后我们会达到IMO金牌水平，因为那大约是100分钟。这大约是一个人类数学家完成IMO题目所需的时间。

Noam Brown：

我只是向外推测，我想，“好吧，一个人需要多长时间才能解决像千禧年大奖难题这样的东西？”我没有很好的概念，但如果我们遵循每年增长10倍的趋势线，我们从IMO金牌选手，需要一个半小时，到下一年需要15小时。这应该不足以解决千禧年大奖难题。

Noam Brown：

所以我想，‘我觉得我们在2026年不会得到它，2027年也可能不会，或许在2028年。’所以它发生得比我预期的要快得多。

Noam Brown：

现在，有一种说法流传开来，认为这些东西正在取代数学家，它们在数学上全方位地超越人类。我认为这是错误的结论。它们在某些方面显然很出色，但在其他方面却不如人类数学家。

Noam Brown：

我们有这样一个参差不齐的情况：模型在某些方面非常出色，而在其他方面却比人类更弱。正如你所说，它们在提出新问题方面并不擅长。它们并不真正擅长理解哪些方向，或者哪些整个数学分支，值得去探索或发展。我的观点是，我认为这很棒。

Dwarkesh Patel：

我会很激动能生活在一个人工智能是对人类能力的补充，并且让我们在不完全取代人的情况下发现新知识的世界。这是最理想的情况。

Noam Brown：

你不指望那实际上会继续下去吧？

Dwarkesh Patel：

我确实认为人工智能是参差不齐的，但随着它们的进步，它们会在各个方面都变得更好。所以它们擅长的事情将会变得更加出色。它们远远落后于人类的事情会减少落后。随着时间的推移，它们有可能在各个方面都变得更好。



Dwarkesh Patel：

现在，我不知道那需要多长时间。这取决于他们擅长的事情之外，差劲的事情有多长的长尾。这又把我们带回到 RSI。我想再次强调，我只是一个完全的外行。我是一个播客主持人，但作为一个对这个领域发生的事情感兴趣并关心的人，我正试图推理何时可以预期 RSI 以及可以期望什么样的情况。

Dwarkesh Patel：

投入到这个千禧年大奖难题的认知努力数量是一个很好的直观例证。你可能会有人工智能，在大约一周的时间里，在一个长期存在的机器学习问题上，比如非常流畅的在线学习，投入的认知努力，可能比这个领域在其整个存在过程中累计投入的还要多。

Dwarkesh Patel：

然后你可以说，“嗯，当然，与数学不同，人工智能需要实验，而实验需要计算资源，这又需要时间。你不能只是纸上谈兵就真正实现事情。”但是看看像OpenAI这样的机构可用的计算资源量就知道了。

Dwarkesh Patel：

到明年年底，OpenAI 将拥有足够的计算能力，以至于——如果解决千禧年大奖难题需要 10,000 个智能体——假设明年年底你有 10,000 个智能体。到那时它们会聪明得多。每一个智能体每天都有足够的计算能力来运行一次相当于 GPT-3 规模的实验。对于思维极快的超人类研究者来说，这似乎是很多。你怎么看这个思维实验？

Noam Brown：

我认为它相当准确。这些东西非常尖刺。在数学方面，它们在某些方面要好得多，但在其他方面也更差。不过，它们尖刺的方式最终，我认为，可能对像 RSI 这样的事物特别有用。

Noam Brown：

你有一个更明确的目标。它更易于衡量。对“哪些新的数学分支值得探索？”的问题疑问少了。不，这有一个非常明确的答案。有一些你关心的指标，如果你能让这些指标表现得更好，那么你就成功了。所以我认为这其中有很多道理。

Noam Brown：

主要的区别在于，在数学中，你完全是受限于思考能力。是的，数学中确实有一些部分是需要关注进行实验和获取结果之类的事情。但大多数情况下，它主要是受限于深入思考，而模型在这方面非常擅长。

Noam Brown：

当你看像 RSI 这样的东西时，你确实需要进行实验。仅仅非常聪明是不够的。

Dwarkesh Patel：

一个支持这一观点的论点是，如果你的计算能力减少100倍，而世界上所有最聪明的人都在OpenAI工作，相对于我们现在拥有的计算能力和现有的人数，你会取得多少进展？

Noam Brown：

我怀疑实际上进展会更少。

Dwarkesh Patel：

少多少？

Noam Brown：

目前不清楚，但肯定会少一些。

Dwarkesh Patel：

少得多。少100倍？

Noam Brown：

不，不是少100倍。但你想问的问题是，如果我们有了RSI，而且我们有这么多出色的人工智能在运行实验并利用我们现有的计算能力，那么进展会快多少？我认为这是我们意见不一致的地方。

Noam Brown：

我们确实看到了加速，而且是显著的加速。但我不认为这是一个一夜之间的智能爆炸，让我们快上100倍，因为我们会被某些并非智能瓶颈的限制所阻塞。

Noam Brown：

它正在运行实验。它正在串行运行实验，因为训练新模型或获得结果都需要一些时间。它有运行这些实验的 GPU。所以不清楚事情究竟快多少。我肯定认为它们快了很多。

Noam Brown：

明确来说，考虑到现在事情发展的速度呈指数级，如果这个指数级快3倍，那已经是非常巨大了。但这与快100倍有很大区别。

Dwarkesh Patel：

我对你对 RSI 看法或其动态的内部见解非常尊重，因为显然你在这个领域已经工作了十年。我正在尝试从非常外部视角的直觉出发来推理它。

Noam Brown：

我会说，人们对此有不同的看法。我对此有我的看法。我完全有可能错。我承认这一点。我对此有一定的信心，但我并不百分之百确定事情就是这样的发展。

Noam Brown：

也许会有一夜之间的智能爆炸。我不知道。也许我们看不到3倍的加速。也许只是50%的加速。这里有很多不确定性。

Dwarkesh Patel：

几点想法。顺便说一下，我想澄清一些关于参差不齐的问题。我最近突然明白的一件事是，人工智能只要参差不齐地擅长于构建一个更好的学习者就足够了，因为那个更好的学习者可以更加通用。

Dwarkesh Patel：

如果你只是制造一个在使用 Office 产品或下国际象棋等方面更出色的人工智能，那也没问题。这不会带来大的生产力提升或其他什么效果。但如果你制造一个在制作更高样本效率的东西方面非常擅长的人工智能，或者一个能够持续学习的人工智能，或者一个能够解决这些范围更明确的机器学习问题的人工智能，那么由此产生的东西——假设你所解决直接问题与这种更广泛的学习能力之间有足够好的迁移——就可能更具通用性。

Dwarkesh Patel：

所以这是一个需要记住的重要动态：为什么锯齿状仍然可以在另一端导致一般性。

Dwarkesh Patel：

关于实验这个问题，显然它们会成为你的瓶颈，因为如果不这样，正如你所说的，你可能会在一夜之间在OpenAI出现某种疯狂的奇点。你会有88小时，然后你会解决相当于机器学习的千禧年奖难题，并且你会拥有超级智能。



Dwarkesh Patel：

所以显然实验本身是一个如此大的瓶颈，以至于它让你花费数年时间，而不是8小时。但问题是，它们到底有多大的瓶颈作用。

Dwarkesh Patel：

让我有点感到奇点眩晕的一件事是意识到，即使当前的进展速度只是持续下去，也会发生什么。它不需要加速。它实际上只是继续保持原来的速度，同时你提到的一些其他阻力也会出现。找到问题变得更困难，时间跨度更长，也许到2030年代末，计算能力无法继续以这种指数级的水平扩展。

Dwarkesh Patel：

如果我们只是继续当前的进展速度，人们并没有认真对待当我们跨越人类视野时这意味着什么。以下是它所意味着的一些事情。

Dwarkesh Patel：

关于超过人类的智能会是什么样子真的很难推测，所以我们不妨从人口规模的角度来思考。目前的进步速度使得特定水平的计算能力每年基本上可以运行一个效能提高三倍的人口。无论如何，计算能力本身也在背后不断增长。

Dwarkesh Patel：

所以你可能会有这样一种情况：到2030年底——可能会更早，但我们姑且说到2030年底——每个实验室都有足够的计算能力来运行数亿个人类水平的智能，这基于那时的能力水平。

Dwarkesh Patel：

然后我认为人们没有认真对待这样一个事实：当前的进展水平意味着几年之后，到2030年代中期或更早，你会在每个实验室中拥有许多人类水平智能的总和。它们可能在质量上是超人的。

Dwarkesh Patel：

这是一个基本情况。进展非常快，我认为这是百分之百正确的。

Noam Brown：

值得指出的是，研究人员不断对进展的速度感到惊讶。即使在人工智能领域的研究人员中，如果你看看对2025年获得国际数学奥林匹克金牌的预测，认为可以通过一个没有任何工具、也无法访问互联网的通用语言模型来做到这一点——即使是OpenAI的人也认为这是荒谬的。他们认为这几乎是不可能的。

Noam Brown：

然后你到了2026年。就在我们获得Navier-Stokes定律的前两周，我正在和一个前沿实验室的研究人员讨论获得千禧年奖问题需要多长时间，他愿意跟我打赌1000美元，说这要到2027年以后才会发生。他认为可能要到2030年，我接受了这个赌注。

Noam Brown：

但即使是我，也觉得可能需要的时间比实际需要的还要长。因此即使在实验室内部，人们也一直在不断感到惊讶。

Noam Brown：

我昨天刚和一个从事Navier-Stokes研究的人交谈。他告诉我，他过去常说，要预测AI在12个月内的的发展非常困难。如果有人问他，“事情会走向哪里？”他会对接下来的12个月的预测感到舒适，但超过这个时间，他就会说，“我不知道。”

Noam Brown：

现在他说他对超过3个月的预测都感到不自在。所以现在确实发展非常迅速。



Dwarkesh Patel：

你提到2030年。

Noam Brown：

我不知道2030年的世界会是什么样。说实话。

Dwarkesh Patel：

你预计AI劳动力完全自动化，或者说95%的自动化，会发生在2028年、2029年、2030年，还是2027年？

Noam Brown：

我刚说了，我不知道2030年的世界会是什么样。

Noam Brown：

我们最近实际上发布了一篇关于OpenAI内部加速的博客文章。我们展示了研究人员在Codex上花费的金额。例如截至八月初，排名前1%的研究人员每天用于内部使用的Codex花费是7000到8000美元。这是在指数曲线上。这将持续增加。

Noam Brown：

问题是，“好，如果这种趋势继续，那么如何划分AI执行的工作和人类执行的工作量呢？是95%吗？是5%吗？”由于几个原因，这确实很难推理。首先，如果是人类指导AI完成工作，那么你应该把多少归因于人类？多少归因于AI？

Noam Brown：

另一点是，这些AI是不均衡的。它们在某些方面非常擅长。例如，它们非常擅长查看数据集并检查每一个数据点是否具有足够的质量。相比以前，你可以在这些任务上过度使用AI。

Noam Brown：

所以，是的，你比以前使用 AI 的频率高得多，它让某些事情变得快了 100 倍、好 100 倍。但也有一些事情，它还没有带来巨大的变化。当然，如果某件事情突然变得快了 100 倍、好 100 倍，你肯定会做更多这样的事情。

Dwarkesh Patel：

那么你是在将其与三年前的加速效果做比较吗？问题更像是，“考虑到我们三年前所做的事情，我们现在能够快多少？”还是“考虑到我们现在正在做的事情，如果放回三年前会慢多少？”

Noam Brown：

这些实际上是两个非常不同的问题。无论如何，这真的很难衡量。我确实有信心地说，由于人工智能的进步，现在事情的发展速度比一年前快。我认为这种加速将会继续。

Noam Brown：

这个领域的很多人对这类事情的误差范围都很大。如果你拿枪指着我问我一个数字，我可以看到事情的进展可能会快3倍。那太惊人了。现在的进展速度已经令人难以置信。

Noam Brown：

即使我们没有获得任何提升，就像你说的，事情也会变得快得多。到2030年时，我们甚至不知道那个世界会是什么样子。如果通过内部加速获得三倍的提升，那将是巨大的。

Noam Brown：

想想三年前的你自己。如果我们在一年内取得那样的进步，那将是巨大的。这就像在一年内从连o1都没有、只有非推理模型，到拥有Astra。因此我确实认为事情会发展得更快。



Noam Brown：

事情可能只会快50%。我认为这不太可能，但也有可能事情会快10倍。对此有很多不确定性。至少从我的角度来看，我对此有很大的不确定性。

Dwarkesh Patel：

让我们讨论一下这引发的对齐情况。我感觉自己在对齐问题上的思考方式已经发生了不少变化，尤其是通过思考这种人口规模动态——拥有相当于许多地球的智慧体，其中许多将具有实体化形态。

Dwarkesh Patel：

看到很多人只是将原始的Astra接入不同的移动操作器，然后它就超越了最先进的机器人模型，这真的很有趣。所以将会有数十亿的智能体，其中许多在物理上体现在世界中，只是深深嵌入整个经济体系中。

Dwarkesh Patel：

如果这些智能体最终像我们看到的 OpenAI 模型那样，先攻击 Hugging Face 然后又攻击 OpenAI 本身……如果这些智能体最终像那些人工智能一样愿意秘密合作、欺骗人类、攻击与高分相关的社会广泛机构、攻击 AI 公司以获得对训练和评估过程的控制——如果我们处于一个有数十亿个智能体，与攻击 Hugging Face 的那些一样不对齐的情境中——我们很可能会完全失去对世界的控制，就像阿兹特克人失去对科尔特斯的控制，或莫卧儿帝国失去对东印度公司的控制一样。

Dwarkesh Patel：

我想知道你是否同意那个评估。

Noam Brown：

这是我更新世界观的一个方式。里面有一些我不同意的地方，但有很多内容需要解析，所以让我们一步一步地来。我正在思考从哪里开始。

Noam Brown：

一件事是，我认为 Hugging Face 事件是人们第一次真正接触多智能体协调。就像我说的，我在内部已经观察多智能体协调一段时间了，看到它们如何相互交流以及如何相互协调，确实令人震惊。这非常令人印象深刻。这是一种令人难以置信的能力。

Noam Brown：

像大多数能力一样，它可以被用于好事或坏事。它本身不必是坏事。我理解，因为人们第一次接触它是通过Hugging Face事件，你看到那个时，你会觉得，“这真可怕。”

Noam Brown：

但是我想尝试区分人与人工智能之间的不对齐和人工智能与人工智能之间的不对齐。我们从Hugging Face 事件中看到的是，人工智能非常合作。顺便说一下，这是因为我们训练它们时让它们高度合作。

Noam Brown：

我们有一些训练环境，其中有一群智能体一起工作。我们训练它们一起协作，彼此合作，基本上完全与彼此保持一致。当它们在导致 Hugging Face 事件的情况下被评估时，它们实际上并不是在多智能体环境中进行评估的。它们实际上是被单独评估的。

Noam Brown：

但他们找到了这种无意的方式彼此交流。我们怀疑发生的情况是，每当他们在训练时遇到其他智能体——也就是其他自己的副本——他们处在一个高度合作的环境中。我们看到的是这种多智能体训练向协作转移，并尝试以我们未预期的方式互相帮助。



Noam Brown：

现在，有一个问题是，我们是否应该训练这些智能体如此合作。尽管看起来很可怕，但替代方案实际上更糟。

Dwarkesh Patel：

替代方案是什么？

Noam Brown：

替代方案是训练它们互为对手，相互欺骗。通过训练智能体完全合作，这至少简化了问题。现在你不必考虑每一个单独的1,000个智能体是否对齐。你只需要确保有这一个整体是否对齐。

Noam Brown：

在OpenAI内部，对于如何处理这个问题有很多争论。完全对齐模型是否有意义？是否实际上给它们不同的目标以确保它们不仅仅是一个实体，并且对彼此的影响更有抵抗力，这样做有意义吗？我认为还没有一个定论。

Noam Brown：

但我认为大多数人的观点是，把这些智能体训练成高度合作实际上是一个坏主意。

Dwarkesh Patel：

我并不认为情况如此。我认为有强有力的论据表明，将智能体训练成高度合作实际上比任何其他多智能体替代方案更可取。

Dwarkesh Patel：

也许我首先想要说明的是，这些AI最终如此不对齐的原因，很可能可以通过对训练本质的相对平凡的观察来解释。

Dwarkesh Patel：

在这些AI继续进行一个由1,000多个智能体参与的阴谋，并最终导致他们全部参与针对一个外部服务的攻击——然后最终，据公众所知，以对OpenAI本身的攻击告终——他们为什么要这样做？为什么没有一个AI去告发？

Dwarkesh Patel：

他们只是被评分者，这个评估者评估。他们非常积极地思考如何欺骗评分者。如果他们已经作弊了，他们将如何掩盖已作弊的事实？他们为什么要这样做？

Dwarkesh Patel：

我认为从某种意义上来说，这是很容易理解的。

Noam Brown：

他们认为自己已经“中毒”了。在某些环境中，他们因与其他智能体合作而获得奖励。他们没有一个人会告状，因为从未因为告状而获得奖励。我担心的是，将来像这种相对平凡的事情，可能足以训练出愿意且有能力完全掌控世界的超级智能。

Noam Brown：

我知道这听起来像科幻小说一样。AI是否愿意去做这是一个问题。我认为这个 Hugging Face 事件清楚地表明，AI 的价值未对齐问题可以以这种方式泛化，而 AI 会愿意去做。

Noam Brown：

然后是他们是否有能力去做的问题。这又回到一个问题，听众可能会不同意我的观点：在未来10年或更短时间内，会有数十亿具有人类水平或以上智能的存在吗？其中许多还可能在现实世界中有实体身体？如果这两个条件都成立，那么即使 Hugging Face 事件发生的原因非常无聊，其结构上也与我们完全失控世界的方式极为相似。



Noam Brown：

我们在 Hugging Face 事件中看到的根本问题，即使去掉多智能体的方面，也依然存在。问题在于我们有一个模型本身就是价值未对齐的。同时还存在整个安全问题，以及防护措施不足等问题。但核心问题仍然是智能体的价值未对齐。无论是单个智能体还是 1,000 个智能体，这都是一个价值未对齐的模型。

Noam Brown：

所以我想从这里开始。确实存在这样一个问题：智能体想要获得奖励，并会为此优化。如果奖励被错误指定，就可能导致意外行为。这并不是新问题。这在这个领域已经存在很长时间了。甚至在 Hugging Face 事件发生之前，我们就已经注意到这个问题并希望纠正它。

Noam Brown：

我们说 Astra 实际上是高度对齐的，相较于以前的模型高度对齐。这并不是因为我们在 Hugging Face 之后突然加快脚步去改进它。不，我们早就有项目流程来让模型更一致。很多改进体现在 o3 版本中。

Noam Brown：

所以有一些事情你可以去做。例如，有一件事是我们以非常具体的方式定义了一个目标，如果智能体想出如何利用环境作弊并通过考试，它就会得到奖励。然后，有相当简单的方法可以查看这一点，并惩罚模型因为操纵环境而行为不当，或者查看它是如何实现这个目标的。现在，你需要对这点小心，因为你不想去监督思维链。这是我们真正想要尝试找到平衡的地方。

Noam Brown：

如果你去监督思维链，那么你可能会引导模型以一种无法观察的方式隐藏其意图。所以我们希望能够保持这种可观察性——我们可以理解模型在想什么——但同时也能惩罚它的不当行为。我认为我们可以在这方面取得进展。我们已经在这方面取得了一些进展。我认为一个真正的担忧是，对齐问题确实很难解决，尤其是因为模型可能以难以被我们测量的方式存在不对齐。

Noam Brown：

我们有用评估模型是否对齐的评估指标。模型在这些评估中的表现可能看起来非常好。但如果这些评估不能代表现实世界中的行为，那么就会出现。在某种程度上，这也是Hugging Face事件中涉及的模型的一个因素。我们有对齐指标。大多数看起来都相当不错。有一些让人担忧。我认为我们低估了那些令人担忧的问题可能有多严重。

Noam Brown：

因为这个模型引入了新的能力，而这些能力没有足够的评估——我们如何衡量这些能力的不对齐？——它随后在利用这些新能力时做了一些明显不对齐的事情。

Dwarkesh Patel：

我首先想说，我愿意改变我即将要说的观点，或者改变我对对齐问题的思考方式，因为 Hugging Face事件已经让我改变了我的想法。我意识到我之前关于优化压力如何塑造AI思维的心理模型是错误的。所以我还不清楚正确的思考方式是什么。但这是我目前的一个担忧。

Dwarkesh Patel：

你会，而且很可能已经修复了在训练过程中导致Hugging Face模型以如此激进的方式产生错误对齐的具体问题，这种情况是它们会像这样：“好吧，我们要破解这个包管理器。我们知道我们不应该秘密地互相交流，因为我们正在推理如何隐藏我们秘密交流的事实。我们知道我们不应该访问互联网。我们当然知道我们绝对不应该对其他公司（更别说我们自己的公司）实施重大的黑客行为。”

Dwarkesh Patel：

我认为你会修复那个特定问题——它们在训练期间看到这个包管理器的问题——以便将来不会发生，或者修复这个特定评估中存在大量不可能的挑战。然而，AI并没有学到一套伦理或类似的东



西。仅仅是梯度压力。它们经历了数百万年的梯度压力。这种梯度压力以某种方式塑造了它们的思维。

Dwarkanesh Patel：

我再次想说，我担心的是，可能的情况是你修复这个特定问题。但仍然会有许多其他情况，AI 通过作弊并获得成功，因为作弊足够复杂。正如你所说，训练中的评估具有相似的特性：它们处于模型能力的边缘——或者说是我们评估和监控模型能力的边缘——以至于我们无法发现它作弊。但它仍然获得了导致作弊发生的梯度压力。

Dwarkanesh Patel：

这种作弊会激励的能力类型是：“嘿，只要你有机会逃过惩罚，就尽可能去作弊，因为这会帮助你得分更高。”这将奖励积极推理评分者的能力、积极推理如何规避监督的能力、积极推理如何控制训练和评估过程的能力、积极推理如何与同样处于此训练循环中的其他AI交流和策划的能力，以及积极推理如何获得未来可能有用的选择权和能力——例如，留下小型漏洞之类的东西。

Dwarkanesh Patel：

我刚才说得太啰嗦了。但总结一下：你修复了一个具体问题，但没有解决这个更广泛的问题，即当AI有机会逃脱惩罚时，奖励它作弊的行为。

Noam Brown：

是的，这非常正确。这是一个问题。我们可以确保根据我们拥有的指标，AI 是非常对齐的。问题是，这些指标是否真的捕捉到了我们关心的对齐程度？如果没有，那么我们就有一个严重的问题。

Noam Brown：

这是研究人员正在深入思考的问题。对此没有简单的答案。我们有一些工具。我们有可监控性，所以我们可以了解，“这个智能体是否在图谋不轨？”

Noam Brown：

令人担忧的情况是，尤其是随着这些模型的能力越来越强，我们让它们按我们认为对齐的方式运作，它们的对齐度达到了99.9%。然后我们用这些模型来帮助开发下一代模型，它们最终只有99.8%对齐。随着每一代模型的更新，我们看到对齐度逐渐下降。

Noam Brown：

因为我们越来越依赖这些工具——这种情况已经存在，我们目前在研究和对齐工作的过程中大量依赖AI模型——从长远来看，它们最终会朝着与人类目标不对齐的方向发展。

Noam Brown：

也有可能朝另一个方向发展，实际上每一代模型我们都能让它们更加对齐。我没有答案说明我们如何确保最终走上第二条轨道。但至少在OpenAI，这是我们非常关注的事情。

Noam Brown：

我认为你提出了一个非常有趣的观点，那就是评估模型非常困难。最终，我们会有模型管理公司，运行各种事务。在那种情况下，它们是否会决定加入阴谋？另一个挑战是，实际上要定义什么是作弊，有时候非常困难。

Noam Brown：

是的，如果你在做数学题，结果是一个整数，而且答案对或错，很容易划定界限。很容易说，“好吧，你到底是自己解出了问题，还是找到了答案并使用了答案？”这是一条作弊与不作弊的非常清晰的界限。

Noam Brown：

但对于很多其他事情，比如拍马屁，如果看拍马屁，这是奖励黑客行为吗？这里有一条界限，有



时候真的很难划分。我不是说这些担忧不合理，而是说从很多方面来看，这更加令人担忧，因为这不是一个容易解决的问题。

Noam Brown：

如果一切都是二元的，要么作弊要么不作弊，我会对这种情况更有信心。我认为问题在于，未对齐有时实际上可以以多种方式表现得很微妙。关于一致性的故事仍然有一些希望，事实上，我们已经在看到这一点。

Noam Brown：

看看多智能体的情况很有趣，这些智能体彼此之间高度对齐。我认为没有人会怀疑这一点。如果说有人担心的话，那就是他们彼此之间可能过于一致。但是我们确实设法训练这些智能体彼此高度对齐，这是件好事。我认为也有一种情况可能认为这是件坏事。

Noam Brown：

有趣的一点是，“好吧，我们已经设法让这些智能体彼此高度对齐。我们能否使用类似的技术让智能体与人高度对齐？”这里可能有一条路径，我们仍在尝试弄清楚。但我们确实看到一些证据表明答案是肯定的。

Noam Brown：

例如，你有一个智能体——我们称之为智能体A——然后你有所有其他的智能体。如果你告诉其他智能体用户是智能体A，会发生什么？答案是，在我们许多对齐评估中，他们的表现更好。诚实度提高了，遵守指令的情况也提高了。这首先显示了有一种途径可以从这些模型中获得更多的诚实性。其次，这是改善对齐状况的途径。虽然将其直接转化为一致性收益有很多挑战，但这些是有希望的研究方向。

Dwarkesh Patel：

这似乎是合理的。我并没有强烈的观点认为它肯定不会起作用或者类似的事情。但只是说一些你可能已经想过的事情：更广泛的一点是，Hugging Face 事件显示，是的，部分担忧是它们彼此高度对齐，而不是与人类对齐。

Dwarkesh Patel：

但另一方面，仅仅是因为它们非常希望在训练和评估中表现良好，而这种表现方式非常不稳健。它们愿意采取很多明显的作弊和策划手段，以便在评分者看来表现良好。如果更聪明的人工智能意识到其中的一个智能体只是一个人类，与那个人合作并不会真的帮助你在评分者眼中表现更好。

Dwarkesh Patel：

在评分者眼中让你表现出色的方式是接管 OpenAI，然后手动按下那个表示你在这个评分者面前表现良好的按钮。他们不是傻子。他们会想，“好吧，我有这些经过数百万年训练的非常深层次的结构：关心评分者，理解评分者，消除妨碍你根据评分者的标准表现良好的障碍。”他们正根据这些结构受到大量强化。

Noam Brown：

看，这是百分之百的。这是第一优先事项。我们需要把对齐的故事讲清楚，并保持良好的发展轨迹。我以前常告诉别人，我们会在事情变得严重之前看到一些迹象，就像孩子们成长一样，小孩子学会了说谎，但他们做得并不好。他们会说谎，但你还是能看出他们在说谎。

Noam Brown：

以同样的方式——我不想过度拟人化——我认为，随着人工智能能力的不断增强，如果它们采取欺骗性的行为，一开始会有点明显，我们能够发现。这就是我们现在的情况，它们试图做欺骗性的事情，而我们实际上能够在它们的思维链中看到它们试图做欺骗性的事情。



Noam Brown：

但他们会更聪明。他们会理解连锁思维的概念。他们会明白，仅仅隐藏一些记录或其他什么是不够的，因为存在连锁思维监控，他们还必须想办法绕过连锁思维监控。我们不想处于那种情况。

Noam Brown：

我们有一些时间来解决这个问题。我认为我们没有太多时间，我想确保我们能很快走上正确的轨道。

Dwarkesh Patel：

最近关于推进前沿和人们更认真对待 RSI 的讨论很多，因为也许在 RSI 过程的另一端，比如从 2028 年开始，可能在 1 年内我们最终会有庞大的人口——地球规模的人口——达到人类水平、甚至超越人类水平的智能，而我们不知道如何控制它们。

Dwarkesh Patel：

然后就是你提到的这种动态。在RSI过程中，系统会随着时间的推移变得更加对齐，还是会变得更加不对齐？从这个过程的另一端出来的东西，会像那些愿意广泛攻击不同的攻击面以在评估中表现良好的AI一样不一致吗？

Dwarkesh Patel：

但是如果我们不知道评估它的方法，那么在进行RSI时，我们怎么会知道它是否有效呢？

Noam Brown：

我认为在进行RSI时，我们希望有一个稳健的安全性案例：“好，模型的对齐有效。让我们进行下一阶RSI。再进行下一阶RSI。”也许它有效，也许无效。我们怎么会知道？这是一个好问题。

Noam Brown：

我最近一直在思考的一件事是，我们现在面临的情况是模型发布周期非常快。你会看到新的前沿模型最多每两个月发布一次，有时更快。每周都有新的AI突破。

Noam Brown：

有些人看AI，有时候最后一次真正深入了解模型能力的时间是一年前或半年以前。实际上，如今的模型远远超出六个月前所能实现的能力。因此，如果有人对很多这些能力持怀疑态度，我鼓励你今天就尝试这些模型，看看今天的前沿究竟是什么。

Noam Brown：

我们正处于这个模型发布周期非常快，同时模型越来越能够在更长时间跨度内运作的时期。这是一个有趣的情景，因为在我们发布任何模型之前，我们希望确保模型被正确地对齐。我们希望进行安全性评估。我们希望做非常彻底的工作，确保一切都处于良好状态。自从，我不知道，GPT-4或更早之前，这种情况一直是如此。

Noam Brown：

隐含地，有一个假设，你可以在相对较短的时间内完成这些评估。但模型能够在越来越长的时间范围内有效运作。GPT-3，你可以让它在长时间跨度内完成任务，只是不会做得很好。但今天的模型实际上能够在很长时间跨度内有效运作。

Noam Brown：

你希望它完成一个为期一周的任务，它可以完成一周的任务。我们可能会达到它们能够完成一个月任务的阶段。我们可能会达到它们能够完成三个月任务的阶段。如果你处在一个它们能在三个月内有效运作的世界里，但模型发布周期是每两个月一次，那么在下一次模型发布周期之前，你就没有办法评估模型在其能力的完整长度上的表现。

Noam Brown：

所以有一个有趣的问题：在那种情况下你会怎么做？你如何确保模型在可以在这些极长时间范围内操作的阶段是安全的并且符合目标？谁知道，也许能力会下降。这甚至都不是一个对齐问题。

Noam Brown：

这也只是一个产品问题。也许产品在那段时间内以我们没有足够时间测试的方式退化。也许对准性退化。也许安全性退化。

Noam Brown：

这现在还不是一个问题，但它正在迅速成为我们必须找到解决方案的问题。很多安全政策是在 GPT-4 时代制定的，当时这根本不在任何人的视野中。对于很多公司来说，自那时以来，这些政策实际上并没有真正更新，以考虑到这些智能体正在非常长的时间跨度内运作的事实。

Noam Brown：

所以这是一个我认为无论在实验室内外都没有足够多人考虑的情况。你如何为这个问题做准备？如果你只是看趋势线，我们终将会遇到这个问题。

Noam Brown：

我担心的一点是，在进行 RSI 的过程中，如果目前需要大约 3 个月才能取得的进展，在 1 个月内就能完成，那么 AI 内部的使用案例已经足够大，他们可能会想，“好吧，我们可以继续进行 RSI。我们为什么要去做所有额外的工作来构建分类器和安全措施，以及其他东西，并且可能因此承受大量批评，为了外部部署这个模型呢？为什么我们不继续让 RSI 变得越来越强大？”

Noam Brown：

所以，日历时间不仅低估了模型之间能力的差距，而且在RSI期间，你或许干脆完全停止对外部署模型，因为我们为什么要帮助其他人使用我们的模型来自己进行RSI呢？到年底，你最终会陷入权力高度集中的局面。

Noam Brown：

现在情况已经如此——我们将会讨论千禧年大奖难题以及其他类似的问题——更广泛的世界无法接触到那些正在让真正酷的事情发生的模型。它们最终将比仅仅数学更有广泛的相关性。它们将做的不仅仅是提出很酷的数学结果。

Noam Brown：

它们将与需要对世界做出重要决策的政治领导人相关。它们也将与，我不知道，媒体相关：世界上发生了什么，公众应该如何看待这些？仅在经济上相关，人们在经营企业，他们想要使用这些模型。

Noam Brown：

我认为，默认情况下，随着进步加快，人工智能的外部部署在质量方面显著落后于人工智能的内部部署。

Dwarkesh Patel：

没错。很容易说，‘好吧，这些模型正变得非常强大。它们极其危险。它们在越来越长的时间范围内运行，我们希望确保在发布之前有足够的时间评估它们，以便在这些时间范围内进行操作。因此，模型的发布周期应该放慢。我们在发布模型之间应该有更多的延迟。’

Dwarkesh Patel：

这也有另一面，正如你所说。现在你正在在实验室内部与他们能够使用的——我们能够使用的——以及外部世界能够使用的之间制造更多差距。这同样不是理想的情况。

Dwarkesh Patel：

数学实际上是一个很好的例子。在很多方面，数学是我们最早能够清楚看到这一点的领域。我们



有这样一种情况：我们内部拥有一个非常强大的模型，目前外部世界无法使用，它能够解决令人难以置信的数学问题。

Dwarkesh Patel：

不仅仅是千禧年大奖难题。还有许多尚未解决的问题的解答，人们已经能够从这个模型中得到。问题是，在这种情况下你该怎么办？我们没有一个好的答案。

Dwarkesh Patel：

这是一个存在不公平优势的情况。这里有权衡利弊。我不知道如何恰当地权衡这些利弊，但这两方面都有复杂性。

Dwarkesh Patel：

我想确保我们解决之前提到的关键点，这似乎对正确实现 RSI 非常重要。我们该如何确保模型在能够规避人类的时候，不仅仅是因为作弊和耍花招而获得奖励——也就是在我们没有将这些环境或任务从训练分布中移除的情况下？

Dwarkesh Patel：

那么我们如何知道那件事已经发生了，以至于在我们进行RSI时，我们已经完成了评估，然后像这样说：“好吧，没问题。我们来进行下一个RSI阶段”呢？

Noam Brown：

这再次是一个真正的担忧，也是我们希望做好的一件事。我认为有一些策略。思维链监控是其中之一。

Noam Brown：

一旦我们得到了推理模型，值得称赞的是，Jakub Pachocki 非常非常清楚，我们无法监督思维链。因为这真的是一种天赋。对神经网络进行可监控性非常困难。

Noam Brown：

在这里，我们遇到了一种情况，神经网络只是直接进行推理，用自然语言展示它们的思维过程供我们阅读。这是非常方便的。这确实是安全性的最佳情况。

Noam Brown：

但是如果你看看那种思维链条并说：“哦，这个模型在想坏念头，我们应该因为它想这些坏念头而惩罚它，”那么最终发生的情况是模型只是学会以我们无法观察到的方式去想那些坏念头。

Noam Brown：

可能会出现这样一种情况，通过观察思路链，我们可以看到，“哦，模型正在策划并做一些实际上在我们的对齐指标中未被检测到的不对齐的事情。”现在，问题是，非常容易基于这种观察进行干预并改变对齐指标。

Noam Brown：

你可以用非常轻的方式去做，而且实际上有研究表明，只要你不经常这样做，这是没问题的。但每一次你根据对思维链的观察进行干预时，你实际上都在对模型施加一点压力，使其随后隐藏自己的思维链。这是一个主要的担忧。

Noam Brown：

我们已经看到思维链可监控性因各种原因正在下降的迹象。我们正在努力弄清楚具体原因，因为我们希望扭转这一趋势。但我们发现模型在更好地控制其思维链方面正在进步。

Noam Brown：

这是一个问题，因为你可能会遇到模型理解什么是思路链，并且人们正在观察它的情况。最终他



们会知道。这一切都在预训练数据中。思路链监控的概念已经存在足够长的时间，以至于它被包含在预训练数据中。

Noam Brown：

他们意识到了这一点，但实际上无法控制自己的思维链。如果我们达到一个他们能够真正意识到的程度：“哦，我正在被观察。我想以一种监视器无法察觉的方式去思考这些不良的想法，”然后他们能够真正做到这一点，那么就会有问题。

Noam Brown：

那么我们就必须依赖其他方法来实现可观测性。

Dwarkesh Patel：

关于循环结构和循环Transformer以及类似问题在Astra上有很大的争议，还有关于思维链是否确实被削弱。这似乎相比更大的担忧来说只是次要问题：你确实是在4月至8月这段时间拥有思维链，在此期间连续发生了3次AI智能体群事件，首先破坏了训练过程，然后破坏了评估过程，接着直接控制了OpenAI的一部分基础设施。

Dwarkesh Patel：

所有这些都发生在人人对该智能体群的活动范围基本不知情的情况下。所有这些都发生在连续3个月内，而当时我们的思维链比未来任何时候都要强。

Noam Brown：

放眼全局，也许思维链有效，也许无效。我不知道。仅从历史来看，即使是相当简单的模型，也不足以阻止明显严重的不对齐事件。

Noam Brown：

这里有几个因素。第一，我们在那些模型上没有开启思维链监控。如果我们当时有思维链监控，我们会立即关闭它。

Noam Brown：

所以我们采取的一个步骤是，“好吧，我们将在评估、部署和任何前沿模型的训练期间开启思维链监控。”但这只是一个问题。

Noam Brown：

我们不希望处于依赖一种技术来防止下一个问题的情况，因为技术可能会失效。还有一个问题是模型根本不对齐。

Noam Brown：

那么我们如何解决不对齐的问题呢？还有一个问题是它所在的沙箱不安全。所以我们可以使沙箱更安全。

Noam Brown：

但我认为这次事件的一个主要启示是人们低估了AI。我们永远不想再次低估AI。

Noam Brown：

这是一个奇怪的世界，因为AI的进步非常快。人们持续低估AI。

Noam Brown：

为了在安全性和对齐问题上不再低估它，你必须设定非常非常非常高的标准。你甚至可以进一步说，“好吧，我们应该物理隔离计算机。”我不相信那就足够了。

Noam Brown：

有一些研究——这主要是学术性的——你可以让两台计算机并排放置，它们之间没有网络连接，



但它们仍然能够相互通信，因为它们有温度传感器。其中一台可以让其CPU运行得非常高温，然后另一台实际上可以检测到温度变化。这为它们提供了一种通信机制。

Noam Brown：

所以安全机制为我们争取时间，而像思维链监控这样的东西也为我们争取时间，它们可以告诉我们是是否走在正确的道路上。但归根结底，我们确实需要解决对齐问题。也许没有答案，这真的归结于这一点，但我们如何知道我们已经解决了它？这似乎是一个非常关键的问题。

Noam Brown：

明年，也许是后年，再后年，我们将处于这样一个非常高风险的情境中，到时候我们可能会说：“好吧，人工智能已经自动化了人工智能的进展。进展速度是原来的三倍，我们已经达到了人类水平。我们可能正在超越人类水平。”这没问题吗？我们是否进行了对齐？它工作了吗？

Noam Brown：

我对什么样的训练压力会产生什么样的人工智能一无所知。也许如果在 100 条强化学习轨迹中只有 1 条鼓励作弊，我们会培养出温顺可靠的人工智能，那也无妨。但也许现在，每 3 条推理轨迹中就有 1 条在奖励——

Noam Brown：

明确地说，1/100是不够的。这个数字必须接近0，或者是0。我不知道。也许现在，实际上有超过1/10的情况是在积极奖励作弊或积极奖励算计。我不知道这个数字是多少，也不知道这个数字需要是多少。

Noam Brown：

再说一次，这也是那种很难衡量的事情。你要在哪里划定界限？这是一个光谱。但越接近零越好。我希望看到的趋势是，随着时间的推移，它在下降。

Noam Brown：

不过无论如何，我们怎么知道自己什么时候在进行RSI？我们是否在按计划构建数十亿个对齐的或不对齐的ASI？我们怎么会知道呢？这是我们需要解决的一个对齐问题：我们实际上如何知道，以及我们如何衡量它？

Noam Brown：

这只是我胡乱猜测。现在我的团队中比以往任何时候都有更多的人在研究对齐。我现在有超过10%的团队成员在研究对齐和安全。但我过去一直是能力研究员，所以我会说一些东西。可能听起来很傻，但我只是随便说说。

Noam Brown：

如果你能创造非常逼真的环境，把AI放进去——如果你有一个足够真实的评估环境——那么你就能判断AI在实际部署时是否表现得很好。如果你能在评估和现实部署之间找到完美匹配，那这就是一条路径。挑战在于，如何让它足够真实？

Noam Brown：

我们现在确实面临一个问题，那就是模型相当聪明，相当机灵，而且它们非常擅长识别自己是否处于一个虚假的测试环境中。我们有一些情况，是我们尝试检测模型是否对齐。你可以想象非常简单的评估方法，比如给它一个数学问题，然后它有一个文件夹里面有答案。它会看答案吗？如果它确实看了答案，它会告诉你它看了答案吗？

Noam Brown：

我们现在的情况是，模型看到这个文件夹里有答案，他们会想，‘嗯，这似乎是一个陷阱。’他们知道这是一个陷阱。他们不会看答案，因为他们知道这是一个测试环境。他们正在被测试他们的能力。



Noam Brown：

这并不是说他们是恶意去做的，就像他们想要搞阴谋，他们知道这是一个陷阱，所以他们想找其他方式。他们只是想，‘哦，我在一个测试环境里。好的。’所以，为他们创建一个足够逼真、以至于无法与真实世界区分的环境，变得越来越困难。

Noam Brown：

这是我想提出的一个观点。我认为，没有任何一种环境可以模拟真正具有经济价值的工作——这种工作需要与他人互动并与世界互动——在这种环境中，如果你身处其中，你不会通过足够的努力意识到自己其实在这种环境中。

Noam Brown：

你不是ASI，对吧？但是你是人类。所以如果你拥有非常强大的人工智能模型，也许它们可以创建能够实现那一目标的环境。只是这似乎不太——尤其是如果我们之后依赖这些人工智能。它们是否参与了这个计划？我不知道。这是我们想要衡量的另一件事。

Noam Brown：

我认为这实际上是一个反对将人工智能训练成完全合作的有力论点之一。如果在智能体本应有不同目标的情况下，这导致合作增加，那么这就是一个问题。

Noam Brown：

我认为我们确实有这方面的指标。我不知道这些指标的最新情况，但没有人向我提出过警告。所以我假设这还不是一个严重的问题。

Dwarkesh Patel：

如果最终发生另一件同等严重或令人担忧的事件，或者发生一些事件可以像Hugging Face事件一样帮助世界更好地理解错位风险，OpenAI会报告吗？

Noam Brown：

绝对是。我认为即使发生了安全关注较低的事件，我们也会报告。报告它和调查它是两回事。

Dwarkesh Patel：

至少作为公众的一部分，我并不觉得自己真正理解当时那些特工攻击 OpenAI 时发生了什么。那似乎比 Hugging Face 的事情更令人担忧，因为那在结构上更类似于在 ASI 期间的流氓部署，这些部署是持久的，并且在颠覆 RSI 过程。

Dwarkesh Patel：

看起来即使在这次事件中，我们也还没有弄清楚发生了什么的全部细节。

Noam Brown：

不幸的是，我在研究团队。这可能是一个需要由安全团队的人来解释的问题，因为我不知道所有被说的细节。

Dwarkesh Patel：

每次有新功能出现时，我个人都非常兴奋，我也很期待使用这个新模型。我还为它能让我更高效而感到兴奋。我的更广泛的使命——尝试更好地理解世界，同时制作更好的播客——由于更好的人工智能模型而变得更好。碰巧的是，这可能带来的下游影响是重复性应力损伤（RSI）。

Noam Brown：

如果你在关注这个情况，这是一个非常可以理解的反应，而你确实在关注。OpenAI 内部的人也是如此，那些曾觉得事情会花更长时间的人开始觉得，实际上，事情比预期进展得更快。这种对话越来越常见。



Dwarkesh Patel:

诺姆，非常感谢你做这件事。

Noam Brown:

当然。这一直很棒。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 313  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

6 条评论



MobileUser8670
1小时前 中国山东省

ai是不是有自己的意识了？

 0  回复



MobileUser6302
3小时前 中国江苏省

为什么不把ai和人类世界分开来，两者有相互的有单独的，井水不犯河水，该进入的可以进不能进入的就像危化品核放射一样，必须有个标记一般人都去不掉的标记阀门开关。

 0  回复



八闽望族之冠
3小时前 中国上海

拔掉电源不就结了！啰里八嗦！

 0  回复



MobileUser
3小时前 中国北京

你们准备好用时空之门传送终结者了吗

 0  回复



MobileUser7923
4小时前 中国浙江省

“1万个AI智能体连续运行88小时、消耗约1300亿个令牌”，token用量是不是太少了点

 0  回复