

摘要：

这笔交易买的并非一家普通AI软件公司，而是一套已深度嵌入开发者工作流的开放模型基础设施。Hugging Face从聊天机器人起步，凭借Transformers开源库和Hub，逐步连接模型、数据、应用与工具，形成围绕开放模型运转的开发者网络。交易完成后，其能否继续保持开放，将成为关键看点。

9月3日，英伟达宣布将以129.3亿美元收购Hugging Face。

这不是一笔只看收入和估值就很容易理解的交易。Hugging Face没有训练出GPT、Claude或DeepSeek这样的前沿大模型，不造GPU，也不是一家大型云厂商。对于大多数普通用户来说，它甚至算不上一个会被直接使用的AI产品。但英伟达却愿意为它支付接近130亿美元。

黄仁勋在宣布交易时给出了一组数字：Hugging Face已经聚集了超过1800万开发者、300万个模型、50万个数据集和100万个AI应用，超过20万家公司通过这个平台寻找、评估、定制和部署AI。英伟达还特意强调，交易之后Hugging Face仍将面向整个AI生态保持开放，开发者可以继续选择不同的模型、框架、云、推理服务和计算平台，使用Hugging Face并不要求采用英伟达的计算平台。

这些承诺本身已经透露出Hugging Face的重要性。如果英伟达买下的只是一家普通AI软件公司，它没有必要在交易宣布之初就专门解释，未来是否还会继续支持其他硬件和云。真正敏感的是，过去几年里，Hugging Face已经进入了太多AI开发者的日常工作流。

现在的Hugging Face已经不能被简单理解成一个“模型网站”。它所扮演的角色，越来越接近GitHub之于软件开发：成为开发者发现、获取、修改和分发技术资产的一层基础设施。

但十年前，这家公司和“基础设施”几个字几乎毫无关系。

真正改变命运的，是一个开源库

2017年，TechCrunch第一次报道Hugging Face时，它还是一款面向年轻用户的聊天机器人。那时候Hugging Face想做的是一个“人工智能好朋友”，用户可以给机器人取名字、和它聊天、交换自拍和表情。创始人Clément Delangue还特意解释，他们既不是想做客服，也没准备拿它提高生产力，只是希望做一个跟人聊聊天、能让人开心的AI伙伴。

这个方向一度还算是个热门赛道。2018年，Hugging Face的聊天机器人每天需要处理大约100万条消息，累计收到超过1亿条消息，公司也完成了400万美元融资。但今天，几乎没有人因为那个聊天机器人认识Hugging Face。真正改变这家公司命运的，是另一条技术线上的变化。

2017年Google发表《Attention Is All You Need》，Transformer架构随后迅速改变自然语言处理。BERT、GPT、GPT-2、XLNet、T5等预训练模型接连出现。模型越来越强，一个很现实的问题也越来越突出：论文出来了，不等于普通开发者就能把模型顺利用起来。

不同模型有不同的代码实现、配置、预训练权重和调用方式。开发者从BERT换到GPT，再去尝试XLNet，经常意味着重新理解一套工程实现。Hugging Face最初为BERT做了一套PyTorch实现，项目最早叫pytorch-pretrained-BERT，后来支持的模型越来越多，逐渐演变为pytorch-transformers，最终成为今天的Transformers开源库。

它看起来只是一个开源库，却改变了 Hugging Face 和 AI 行业发生关系的方式。Transformers 开源库开始把越来越多模型纳入一套相对统一的接口，加载预训练模型、微调、文本分类、问答、摘要、生成，逐渐可以在相似的开发方式下完成。模型本身没有因此变简单，但开发者不必再为每个新模型重新搭一遍轮子。

这是 Hugging Face 第一次真正进入开发者工作流。它原本想自己做一个 AI 产品，后来却走到了另一条路上：自己不必训练最强的模型，但可以让别人更容易地使用模型。


不过，这个阶段的 Hugging Face 仍然更像一个非常成功的开发工具。真正把它推向基础设施的位置，是模型数量爆发以后发生的另一件事。

为什么最后跑出来的是 Hugging Face？

Hugging Face 后来回顾 Hub 的发展时，描述过一个今天看来已经有些久远的场景。早期研究者训练出一个模型，它可能就放在实验室服务器上，也可能上传到 Google Drive，然后把下载链接贴到论文、README 或论坛里。链接失效、版本混乱、模型来源不清晰，不同团队重复训练相近的模型，都很常见。

于是，一个问题自然出现了：如果分享机器学习模型，也能像在 GitHub 上分享代码一样方便呢？

最早的 Hugging Face Hub 很朴素，主要用于分享能够被 Transformers 开源库使用的模型检查点，与 Hub 交互的能力甚至直接写在 Transformers 开源库里面。直到 2020 年底，这部分功能才被拆出来，成为独立的huggingface_hub。



但模型毕竟不是普通源代码。一个模型除了代码，还有权重、配置、分词器、训练数据、许可证和评测结果；使用者需要知道它适合做什么、从哪里来、怎么运行，又有哪些人已经在它的基础上做出了新版本。模型越来越多以后，一个下载链接显然不够用了。

Hugging Face 开始沿着模型的开发和使用过程往外扩展。模型之外有数据集；发布模型需要模型说明、许可证和版本管理；开发者希望直接展示模型效果；企业需要私有模型、权限和团队协作；上游模型出来后，下游训练、量化和推理工具又要尽快知道如何加载和运行它。

Hub 从模型仓库慢慢变成连接模型、数据、应用和工具的一层平台。2022 年是一个很有代表性的节点，huggingface_hub 引入 HTTP Commit API，开发者不再必须安装 Git 和 Git LFS 才能上传大型机器学习文件。Hugging Face 后来把这看作一次理念上的转折：它已经不只是在给 Transformers 开源库做一层 Git 封装，而是在建设更适合机器学习制品的基础设施。



与此同时，Transformers 开源库也从最初的自然语言处理库一路扩展到视觉、音频、视频和多模态。真正值得注意的是，当 Hugging Face 开始做 Hub 时，它并不是一个刚刚上线、需要从零寻找用户的“模型网站”。Transformers 开源库已经先替它聚集了一批模型开发者。

这是 Hugging Face 和后来出现的很多模型平台之间一个很重要的差别。

市场上不缺相似的平台。阿里的 ModelScope 同样提供模型、数据集、Studio 和开发工具，也在不断强化 Hub 能力；Replicate 的优势则更偏向模型托管和推理，让开发者可以很快把模型跑起来并通过 API 调用；GitHub Models 上线得更晚，更多依托 GitHub 原有的开发者生态，主打模型试用、对比和调用。

这些平台解决的都是模型时代真实存在的问题，也都有自己的优势。Hugging Face 特殊的地方，并不是它比别人多做了一个“模型仓库”，**而是它更先把模型使用和模型分发接进了同一条开发工作流。**

Transformers 开源库已经让开发者习惯通过 `from_pretrained()` 一类接口加载模型，训练完成后又可以通过 `push_to_hub()` 把模型推回 Hub。Hugging Face 还不断让第三方机器学习库接入这套机制。开发者不是逛完一个“模型商店”再回到自己的开发环境，Hub 本身已经嵌进了代码和工具链。

这件事后来带来的影响越来越明显。今天很多开放模型发布时，Hugging Face 已经成为首批公开入口之一。模型团队会同步把权重、配置和模型说明放上 Hub，下游工具很快跟进适配，开发者开始下载、测试、微调，社区随后又会出现量化版、蒸馏版和各种衍生模型。

Hugging Face 当然不是唯一发布渠道，模型团队仍然可以把权重放在自己的官网、GitHub、ModelScope 或其他平台。但对不少开放模型来说，“**在 Hugging Face 上线**”已经越来越接近**发布动作本身的一部分**。

一旦这种习惯形成，平台网络效应就开始出现：开发者已经在这里，模型团队就更愿意把新模型放进来；新模型都在这里，下游训练、量化和推理工具就会优先做好兼容；工具越齐全，开发者越习惯从这里找模型；用户和工具越集中，下一个模型团队越没有理由缺席。

后来者可以复制 Hugging Face 的很多功能：模型托管可以做，版本管理可以做，在线 Demo 可以做，API 也可以做。难复制的是，这套循环已经运转了很多年。

这正是 Hugging Face 和普通模型托管平台的区别。模型和代码并不一样，代码主要是文本，而模型还有许多额外资产和属性。Hugging Face 很早就抓住了一个真正存在的需求：怎么分享模型、基于一个模型继续修改，再形成新的下游版本。也正因为它从一开始就在解决“模型周围如何协作”的问题，最后规模远远超过了很多同类选择。

所以，Hugging Face 今天的优势不能简单概括成“模型最多”。更准确地说，它是**先用 Transformers 开源库抢到了模型使用入口，又用 Hub 把模型的发布、发现、下载、修改和再分发接了起来**。模型团队、开发者和工具链随后彼此强化，最后形成的不只是一个模型网站，而是一张围绕开放模型运转的开发者网络。

这也解释了为什么很多人喜欢把它称作“AI 的 GitHub”。只是这个比喻，并没有看上去那么简单。

“AI 的 GitHub”，这个说法只对了一半



微软 2018 年以 75 亿美元收购 GitHub 时，开发者社区同样有过强烈的不安。一个已经成为全球软件协作基础设施的平台进入科技巨头旗下，会不会逐渐只服务于母公司的战略？

八年之后回头看，这个问题依然没有简单答案。GitHub 被微软收购后的很长一段时间里，仍然服务 AWS、Google Cloud 等微软的直接竞争对手，也没有变成 Azure 的附属代码仓库。

这里有一个很重要的前提：GitHub 背后还有 Git。

Git 本身是开放、分布式的。代码托管在 GitHub，并不意味着代码和完整提交历史只能存在于 GitHub。仓库可以完整克隆，也可以迁到其他托管平台。换句话说，GitHub 很重要，但 GitHub 并不等于 Git。

这也提供了一种比“平台到底属于谁”更实际的判断方式：如果外部环境发生变化，用户原来依赖的能力，能不能在另一个环境里重新建立？

对 GitHub 来说，这个答案相对清晰。代码、提交历史和分支关系都可以随着 Git 仓库一起迁移，开发者即便离开 GitHub，也不意味着此前积累的软件资产就被锁死在平台里。

把同样的问题放到 Hugging Face，情况要复杂一些。

模型和代码并不完全相同，也很难找到一个能与 Git 一一对应的底层机制。好在模型权重归根到底仍然是可以复制的文件，很多主流开放权重模型也会同时出现在 Hugging Face、ModelScope、GitHub 或其他镜像和分发渠道。即使 Hugging Face 有一天停止服务，一个足够流行的模型通常也不会因此从互联网上消失。

真正没那么容易复制的，是模型周围逐渐形成的那张关系网。

一个模型被上传到 Hugging Face 之后，周围往往会继续长出模型说明、讨论、下载数据、微调版本、量化版本、应用 Demo 和第三方工具支持。再往外，它还可能成为其他几十甚至上百个模型的基础模型。开发者怎么发现一个模型，怎么基于它做微调和量化，怎么发布新的版本，不同工具怎样识别它，其他开发者又怎样继续在这些成果上工作，这些能力并不等同于“把一个模型文件下载下来”。

因此，**单个模型并没有那么难迁移，真正难迁移的是围绕模型形成的协作关系和工具链。**

当几百万个模型、数据集、工具和开发者开始互相引用以后，搬走一个 safetensors 文件很容易，复制整张关系网就没那么容易了。

这也是为什么，Hugging Face 的价值远远不止“300 万个模型”。这些模型本身并不是它的资产，绝大多数也不是它训练的。真正值钱的是，行业逐渐形成了一种共同习惯：模型来到这里，工具往往也会跟过来；工具越来越齐全，下一批模型团队又更愿意继续把这里作为重要的发布和分发入口。

这层连接关系一旦形成，Hugging Face 才真正从“一个很好用的平台”走到了基础设施的位置。而当这样一个位置被一家芯片巨头买下，问题自然也就不再只是一次普通的公司收购。

英伟达会成为 Hugging Face 的“好归宿”吗？

其实早在英伟达决定收购 Hugging Face 之前，科技巨头们已经用钱给这个平台的价值投过一次票。



2023 年，Hugging Face 完成 2.35 亿美元 D 轮融资，估值达到 45 亿美元。那轮投资人的名单很特别：谷歌、亚马逊、英伟达、英特尔、AMD、Qualcomm、IBM、Salesforce 等公司同时出现，其中很多公司彼此正面竞争。

英伟达 和 AMD 争夺加速器市场，Google 和 Amazon 都有自己的云和 AI 芯片。这样一批竞争者同时投资 Hugging Face，本身就很能说明它当时的位置：它不是哪一家公司的附属工具，而是所有人都希望接入的一层公共平台。

三年之后，45 亿美元估值变成了英伟达愿意支付的 129.303 亿美元。不过这笔交易并不是英伟达单方面找上门的。



交易官宣当天，Hugging Face CEO Clément Delangue 与黄仁勋一起接受 CNBC 采访时透露，今年夏天，Hugging Face 团队逐渐意识到，开放 AI 已经到了一个需要继续扩大规模的节点。如果想把这套生态继续往前推，他们需要更多算力、支持和生态协作资源，也需要更大的影响力。

于是 Hugging Face 主动找到了黄仁勋。Delangue 对那次沟通的概括很简单：“我们想把开源 AI 做大。”黄仁勋的回应是：“那就一起做。”

按照 Delangue 的说法，Hugging Face 希望从这场交易里得到的是更多计算资源、更多支持和更大的规模，而不是把自己变成一个英伟达专属模型平台。双方目前承诺，Hugging Face 会继续保持开放和相对独立，不绑定某一种计算平台，现有创始团队也会留下。Delangue 给出的长期目标，是让开放源码成为构建 AI 更普遍的方式，让更多开发者可以真正拥有和控制自己使用的模型，而不是只能从封闭 API 获取能力。

黄仁勋给出的解释则直接落到了英伟达自己的生意上。开放模型对英伟达很重要，因为很多企业希望掌握模型本身，也希望把自己的数据、知识产权和部署方式留在内部，而不是把全部 AI 能力绑定到一家封闭服务商。对于一家靠芯片和计算平台生意赚钱的公司，这套逻辑并不难理解：**模型越多、运行模型的人越多，对英伟达可以服务的计算需求也越有利。**

开源行业过去并不少见另一种剧情：一家公司收购另一家围绕开源项目建立起来的公司，随后逐渐降低对原有开源项目的投入。但也有行业人士向 InfoQ 表示，考虑到英伟达一直以来对开源和开放模型的支持力度，Hugging Face 不会重演这条路径，他更倾向于认为，英伟达会投入更多资源，把 Hugging Face 继续做大。

至少在交易官宣的这一刻，几方的利益看起来确实高度一致。Hugging Face 需要更多资源继续扩大开放模型生态；开放模型越繁荣，英伟达 可以服务的训练和推理需求就越多；开发者则希

望，这个已经成为公共入口的平台不要因为易主而改变原来的位置。

真正难回答的是，这种一致能维持多久。

GitHub 提供了一个现成的参照。微软收购 GitHub 后，相当长时间里确实保持了它较强的独立性。但从 2025 年开始，GitHub 与微软 AI 战略之间的组织边界明显变薄。CEO Thomas Dohmke 离任后，微软没有再设置一位独立的 GitHub CEO，GitHub 领导团队转而进入 CoreAI 的管理体系。

我们可能无法简单下判断说 GitHub 已经“不开放”了，但这是一个提醒：一个行业基础设施进入科技巨头旗下以后，开放不是交易完成时就能确认、并且永久不变的状态。

对于 Hugging Face，我们真正需要持续跟踪的是几个更具体的问题：几年以后，新模型是不是仍然能同样顺畅地运行在英伟达之外的硬件上？Hugging Face 与 AMD、其他加速器和不同云厂商的合作是不是还和今天一样自然？开发者如果想把模型、元数据和开发流程迁出去，成本有没有明显变高？那些和英伟达直接竞争的公司，还愿不愿意把 Hugging Face 当成一个共同参与的平台？

这些问题现在都还没有答案。

Hugging Face 花了近十年时间，才从一个开发工具走到开放模型生态的关键入口。交易如果顺利完成，这个入口将第一次拥有一个如此强势、又深度参与 AI 计算产业链的主人。或许再过十年，我们才能知道，英伟达到底是不是一个“好归宿”。

本文来源：[AI前线](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

**限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 29  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

