

2027年SRAM中心高階雲端AI加速器將崛起 NVIDIA Groq 3 LPU出貨量估達百萬顆 非HBM架構新供應鏈成形

2026/05/13-IC設計- 翁書婷



DIGITIMES觀察，受運算轉向推論、模型技術成熟與HBM供應偏緊影響，高階雲端AI加速器市場2026年起，將由HBM中心轉向HBM與SRAM中心雙軌分工路線。Groq、Cerebras與Graphcore三大SRAM中心加速器業者以不同架構切入市場，其中，Groq 3 LPU憑藉與NVIDIA Vera Rubin整合優勢，估將率先放量，2026年出貨上看50萬顆、2027年將達100萬顆，帶動FPGA、高階PCB與Q-Glass等新供應鏈成形。值得注意的是，SRAM中心並不會取代HBM中心架構，其定位為特定推論負載的專用加速層，將與HBM平台及外部大容量記憶體協作分工。

2026年起高階雲端AI加速器市場將由HBM單一路線，逐步走向HBM與SRAM雙軌分工。HBM中心架構仍主導訓練、長上下文與高吞吐通用推論；SRAM中心架構則憑藉低延遲、低尾延遲與較佳推論經濟性，切入decode、小Batch與互動式推論場景，其興起背後，反映運算需求結構改變、模型技術成熟，以及HBM供應偏緊三大因素。

在此趨勢下，SRAM相關路線的技術分化亦逐步清晰，SRAM中心AI加速器由概念探索走向多路線，Groq、Cerebras與Graphcore三大新創團隊分別以確定性管線、晶圓級整合與SRAM豐富型等不同架構路線切入市場。這些新創價值不在複製HBM主流路線，而在驗證低延遲、低功耗與推論經濟性的新解法，為雲端客戶提供技術選項、供應鏈備援與議價空間，並成為推動非HBM加速器發展、合作授權與產業整併的力量。

而市場焦點也開始轉向量產時程。DIGITIMES分析，2026年SRAM中心高階雲端AI加速器雖仍處導入初期，但Groq LPU憑藉與NVIDIA Vera Rubin整合優勢，最有機會率先放量，2026年出貨量將達50萬顆、2027年則將達100萬顆，預期帶動FPGA及高階PCB與Q-Glass等材料需求。

值得注意的是，SRAM中心高階雲端AI加速器並非取代HBM中心高階雲端AI加速器，而是作為特定推論工作負載的專用加速層，並與HBM平台或外部大容量記憶體協同分工，才能發揮真正價值。

SRAM中心高階雲端AI加速器興起 推動市場由單一路線走向雙軌分工

DIGITIMES觀察，有別於2022~2025年間高階雲端AI加速器市場，以HBM為主記憶體架構(HBM-Centric)的高階雲端AI加速器作主導，2026年起，SRAM為主記憶體架構(On-Chip SRAM Centric)的高階雲端AI加速器亦將興起，並於雲端推論市場中扮演重要角色，使高階雲端AI加速器市場從單一性主記憶體架構，走向分層與異質記憶體架構，不同架構的高階雲端AI加速器協同運算分工，各司其職。

本文所稱HBM中心(HBM-Centric)的高階雲端AI加速器，係指以HBM為主記憶體的高階雲端AI加速器，如NVIDIA Blackwell Ultra B300每顆加速器搭載288GB HBM3E、Google TPU Ironwood每顆加速器搭載192GB HBM3E。

而SRAM中心(SRAM Centric)高階雲端AI加速器，係指以晶片上SRAM (On-chip SRAM)為主記憶體的高階雲端AI加速器，如NVIDIA Groq 3 LPU每顆搭載500MB SRAM與Cerebras WSE-3搭載44GB SRAM。

內SRAM僅做為快取使用。這類記憶體架構擁有強大擴充性，是模型訓練、長文本處理及大Batch雲端推論等上工作負載的首選，但其缺點在於HBM成本與功耗高，且推論解碼(decode)時易受外部記憶體頻寬與晶片對外互連頻寬限制。

而SRAM中心高階雲端AI加速器則採用「近端記憶體運算」設計，先優化資料搬移，將權重保留在運算核心旁，其優勢在於低延遲與低尾延遲(low tail latency)與較佳的回應時間一致性，非常適合小Batch與decode階段的互動式推論、Speculative Decoding及對時間敏感的記憶體受限任務；然而，其缺點是SRAM本身密度較低、成本高且容量受限，面對超大型模型時仍需將同一模型權重、KV cache或運算工作拆分至多顆晶片共同處理，且高度依賴編譯器與軟硬體協同設計。

HBM中心與SRAM中心記憶體高階雲端AI加速器比較

主記憶體類別	高階雲端AI加速器	
	HBM-Centric	SRAM-Centric
設計方法	遠端記憶體運算：主記憶體位於晶片外、封裝內，以HBM堆疊提供大容量與高頻寬，晶片上SRAM負責快取與暫存。	近端記憶體運算：資料、權重或工作集盡量放在晶片上SRAM或近運算位置，以降低資料搬移與延遲。
程式模型與軟體	依賴成熟加速器軟體生態，如CUDA、XLA/JAX與PyTorch等框架與編譯堆疊。	更依賴編譯器驅動排程、memory mapping與軟體硬體共同設計。
特點	大容量、高吞吐、擴充性強、適用面廣。	小batch低延遲、高內部頻寬、延遲穩定；部分架構具備細粒度平行優勢。
缺點	decode易受HBM頻寬、KV cache與對外互連制約。	SRAM密度低、容量受限且成本高；模型過大仍需外部記憶體或跨晶片切分。
應用場景	較適合訓練、prefill、大batch、高資料重用、長文本與通用雲端推論。	小batch與decode階段的互動式推論、預測解碼(Speculative Decoding)及對時間敏感(低首字延遲 / 低每字生成延遲)的記憶體受限任務。
代表業者	NVIDIA B300、Google TPU Ironwood等。	Groq 3 LPU、Cerebras WSE-3、Graphcore IPU等。

資料來源：DIGITIMES，2026/5

DIGITIMES分析，由於雲端運算需求結構變遷、模型與系統技術條件成熟、HBM供給受限等三大因素，促使SRAM中心高階雲端AI加速器市場順勢成形。

首先，近年生成式AI應用已走向更高互動頻率、更多任務拆分與更強即時回應需求的系統型態，尤其在Agentic AI與Disaggregated推論逐步成形下，資料中心推論負載不只追求峰值算力，亦重視decode階段的低延遲、可預測性、token功耗效率(tokens per watt)與系統整體成本(TCO)，推動不同記憶體架構與不同加速器設計的分工趨勢。

其次，由於模型技術的演進，亦降低部分推論場景對HBM的依賴。混和專家模型(Mixture of Experts；MoE)、模型蒸餾(distillation)與量化(quantization)與KV cache壓縮等技術，減少單次推論所需模型參數與記憶體容量，使部分推論負載在SRAM架構下，仍維持一定的效能與延遲表現。

最後，在HBM供給偏緊與成本偏高的條件下，HBM資源將優先配置於高價值、高效能密度的訓練與推論工作負載。相對而言，對於強調低延遲與推論經濟性的場景，SRAM中心架構的商業可行性隨之提升。

SRAM中心高階雲端AI加速器興起的三大因素

運算需求改變

- 需求變遷：Disaggregated Inference與Agentic AI等需求興起。
- 指標變革：系統不只看峰值效能，亦重視Tokens per Watt、Latency與TCO。

模型技術演進

- 負載優化：MoE、量化與蒸餾等技術讓模型減少單次運算所需的記憶體資源。
- 硬體適應性：當記憶體需求降低，速度快的SRAM可勝任，達成低延遲推論表現。

HBM供不應求

- 資源分擔：受限於產能與成本，HBM將集中在追求極致效能的訓練任務。
- 商業考量：隨AI應用普及，推論經濟性成關鍵，讓成本優勢的替代架構獲市場關注。

SRAM中心高階雲端加速器興起



- ①推論負載走向分散化，運算追求最佳化配置-依任務性質拆分，將資源精準對應負載。
- ②市場呈現雙軌格局，兩大儲存架構同步拓展-雲端市場分流，推動雙重記憶體技術成長。
- ③SRAM架構並非替代HBM，將滿足推論子市場-針對低延遲需求，補足特定應用場景空缺。

DIGITIMES認為，AI推論市場的競爭核心，正由單一架構性能極大化，轉向不同工作負載下的最佳化配置。2026年起，高階雲端AI加速器市場的主要分野，除涉及GPU與ASIC AI加速器市場的競爭外，亦涉及HBM中心主市場與SRAM中心子市場的同步拓展；然SRAM中心高階雲端AI加速器的崛起並非替代HBM中心高階雲端AI加速器，而是協作與分工。

總體而言，2026年起高階雲端AI加速器市場將由HBM單一路線，朝HBM與SRAM並行的雙軌分工格局發展。HBM中心架構的大容量、高頻寬與較佳通用特性，仍將主導模型訓練、長上下文及高吞吐雲端推論；SRAM中心架構則以低延遲、低尾延遲與較佳推論經濟性，切入decode、小Batch、互動式推論與時間敏感型工作負載。

這也顯示，AI推論市場競爭核心正由峰值算力比拚，轉向延遲、能效、TCO與工作負載適配能力的綜合競爭，而模型技術成熟與HBM供給偏緊，則進一步加快形成此一分工趨勢。

SRAM中心AI加速器設計路線逐步成形 新創為重要推手

DIGITIMES觀察，以SRAM中心為設計思維的AI加速器，代表性業者包括Groq、Cerebras與Graphcore。三者雖同樣重視SRAM、資料搬移效率與低延遲推論，但技術路線並不相同，分別走向確定性管線式(deterministic pipeline)、晶圓級整合(wafer-scale integration)與SRAM豐富型(SRAM-Rich centric)等不同方向。

■ 確定性管線式架構Groq LPU

Groq近期最受市場關注，2025年12月Groq與NVIDIA簽署非獨家推論技術授權協議，Groq仍維持獨立公司身分，由Simon Edwards接任CEO，GroqCloud亦持續營運。此前，Groq亦獲沙烏地阿拉伯15億美元承諾，用於擴大AI晶片出貨與部署。

Groq LPU所代表的確定性管線式架構，不同於傳統GPU追求最高通用型的算力，其核心在於提供高度可預測、低延遲的推論效能。LPU透過專用編譯器，在程式執行前即完成靜態排程(static scheduling)，預先安排各運算步驟的執行順序、資源配置與時間點，並以deterministic execution方式執行，使相同輸入與工作負載下的運算路徑、時間與結果皆具高度一致性，藉此降低動態排程與同步等待造成的延遲波動。

在記憶體設計上，LPU以On-chip SRAM作為主要權重儲存，而非僅作快取，藉此縮短資料搬移路徑並提高張量平行化效率。NVIDIA於2026年公布的NVIDIA Groq 3 LPU規格顯示，單顆Groq 3 LPU搭載500MB SRAM。

在機架級NVIDIA Groq 3 LPX中，每櫃配置256顆LPU 3，整櫃合計達128GB SRAM、12TB DDR5與640TB/s Scale-up頻寬，並與NVIDIA Vera Rubin NVL72協作運算，支援長上下文與低延遲decode工作負載。

DIGITIMES分析，Groq路線的優勢在於可預測延遲，以及在解碼階段穩定性與每秒token產出效率，特別適合互動性高、且prefill與decode已分工的推論場景然其限制則在於，高度依賴編譯器與靜態排程的設計，對快速變動的模型結構與更高通用性的支援彈性相對有限。

DIGITIMES認為，Groq對NVIDIA的意義，在於回應推論需求快速升溫下，NVIDIA既有GPU架構在低延遲、低尾延遲與推論經濟性上的相對不足，替Vera Rubin平台建立異質推論分工模型。換言之，Groq路線補強NVIDIA在推論運算，尤其是decode階段的不足，使其平台不只適合訓練與高吞吐推論，也能更完整覆蓋即時互動式推論需求。

若架構順利落地，NVIDIA未來在資料中心AI競爭的核心，將是能否以更完整的平台化方式，同時覆蓋訓練、prefill、decode、機櫃級互連與記憶體分層配置，鞏固其在Agentic AI基礎設施中的主導地位。

另一條技術路線方面，Cerebras於2026年重新推進IPO計畫，市場關注度明顯升高，同時，Cerebras於2026年3月宣布AWS將在其資料中心部署Cerebras CS-3，並透過AWS Bedrock提供高速推論服務；此外，Cerebras亦與AWS合作推動Trainium負責prefill、WSE/CS-3負責decode的異質推論架構，凸顯其由原本偏訓練的大型系統供應商，轉向推論市場。

相較於Groq採取確定性管線式架構，Cerebras則走向更極端的晶圓級整路線，其代表產品WSE-3並非將晶圓切割成多顆獨立晶片後再透過封裝互連，而是直接將整片晶圓製作成單一大型處理器。據Cerebras官方資料，WSE-3面積達46,225平方毫米，為目前最具代表性的wafer-scale AI處理器。

Cerebras晶圓級整合架構的最大優勢，在於把原本分散於多顆晶片之間的運算、記憶體與互連，收斂至單一巨型處理器內部完成，從而降低跨晶片通訊延遲與系統同步成本，用單一系統映像承載更大規模模型與更高密度平行運算，特別適合需要超高內部頻寬、大模型整體映射與大規模訓練或推論整合的工作負載。

Cerebras WSE-3以2D mesh network排列，並配備44 GB的SRAM，可提供21PB/s內部頻寬，其架構允許大型模型在單一系統程式模型下運作。CS-3則是以WSE-3為核心的系統，可透過SwarmX fabric支援多晶圓擴展，最多可連到2048台CS-3。CS-3可搭配MemoryX外部記憶體，採用NAND Flash搭配DRAM的外部記憶體架構，其容量配置為1.5TB、12TB或1.2PB。

DIGITIMES分析，WSE-3晶圓級整合架構的優勢，可大幅降低晶片對晶片間通訊開銷、提升資料傳輸效率，但其挑戰亦相當多，包括WSE-3製造複雜度、良率控制、封裝與散熱管理。

DIGITIMES認為，晶圓級整合架構這類巨型晶片短期內不太可能成為資料中心AI加速器的主流，但在追求高內部頻寬、降低跨晶片通訊延遲，並希望以單一系統映像承載大模型的高價值場景中，仍具高度吸引力。其未來接受度，將取決於客戶是否願意以更高的製造與系統複雜度，換取更簡化的軟體映射與更高的整體效率。晶圓級整合較可能先在少數CSP、主權AI與研究型客戶中擴散。

■ SRAM豐富型架構Graphcore

最後在Graphcore方面，Graphcore已於2024年7月被日本軟銀集團(SoftBank Group)收購，成為其全資子公司，並繼續以Graphcore品牌運作。收購後，Graphcore官方表示將持續投資下一代AI compute stack。

Graphcore代表另一類設計路線。相較於Groq著重確定性管線、Cerebras強調晶圓整合，Graphcore則重視將記憶體分散配置在大量運算單元週邊，透過細粒度平行處理(Fine-grained Parallelism)，將運算拆解為大量的子任務，分配至多個運算單元執行，藉此提升不規則工作負載的執行效率。

Graphcore第二代GC200 IPU採用台積電7奈米製程，內建1,472個tiles、含9,000個獨立平行程式執行緒，並配置900MB On-Chip SRAM。IPU-M2000系統除每顆IPU搭配900MB SRAM外，亦可支援高容量外部Streaming Memory，並透過低延遲IPU-Fabric連結大量IPU系統，形成更大規模的AI運算叢集。這使Graphcore架構在小batch、稀疏資料、或較不規則的AI模型中，具備一定技術特色。

DIGITIMES分析，Graphcore路線的優勢在於細粒度平行處理與不規則模型；其限制則在於單顆裝置記憶體容量仍有限，若缺乏足夠成熟的模型平行化與系統擴展策略，面對大型基礎模型時仍有挑戰。

代表加速器	Groq 3 LPU	Cerebras WSE-3	Graphcore GC200
SRAM規格	Groq 3 LPU單顆含500MB SRAM，單一機櫃含256顆LPU，共128GB SRAM。	WSE-3單顆含44GB SRAM，單一機櫃含1顆WSE-3，共可擴展至2,048台。	GC200單顆含900MB SRAM，單一機櫃含4顆GC200，共3.6GB SRAM。
近期市局	NVIDIA已整合至Vera Rubin平台，並獲沙隆15億美元資金支持。	2026年重啟IPO進程，並獲AWS導入、主攻異質推論。	2024年被軟銀集團全資收購後，仍維持獨立運作，並持續研發次世代堆疊。
主要優勢	可預測延遲與高效的token產出，適合互動性高的推論場景。	降低晶片間通訊延遲，提升資料傳輸效率，支援大規模模型運算。	細粒度平行處理與記憶體鄰近運算對不規則模型的適應性。
挑戰限制	對編譯器與靜態排程的依賴，對快速變動的模型支援彈性有限。	晶片製造複雜度極高，面臨封裝與散熱挑戰。	單顆裝置記憶體容量受限，超大模型擴展性面臨考驗。

資料來源：AI Accelerators for Large Language Model Inference: Architecture Analysis and Scaling Strategies，DIGITIMES整理，2026/5

■ 新創業者成為非HBM中心加速器重要設計推手

上述業者多為新創。DIGITIMES觀察，AI晶片新創在非HBM型雲端加速器市場中的角色，並非複製NVIDIA既有路線，而是針對推論工作負載的低延遲、低功耗與經濟性需求，提出不同於HBM-centric的設計架構。

若進一步解讀，這些新創的產業價值可歸納為四點，首先是「技術選項價值」，亦即替市場驗證SRAM-first、分層記憶體與資料流架構等不同於HBM主流路線的方法學；第二是供應鏈避險價值，在HBM供應緊張的背景

下，非HBM或路線可望替雲端客戶提供第二條加速器供應來源。第三是議價權價值，即便新創未必取代既有主流平台，仍可迫使NVIDIA與Google等供應商加快調整推論產品策略、改善成本與交期；第四則是併購與授權價值，當推論成為新一輪AI基礎設施競爭核心時，新創累積的架構、人才與系統能力，本身就具備被投資、合作、授權甚至收購的意義。

整體而言，SRAM中心AI加速器的發展已由概念驗證走向產品化與商業化，且其技術路線分化為Groq所代表的確定性低延遲推論、Cerebras所代表的晶圓級整合，以及Graphcore所代表的細粒度平行處理等多元架構。

另外，對產業而言，這些新創的真正意義，在於替市場驗證不同於既有GPU路線的架構選項，並在HBM供應緊張、推論工作負載分層化的趨勢下，提供雲端與主權AI客戶更多技術、供應鏈與採購談判上的彈性。

Groq可望率先放量主導市場 2026年出貨上看50萬顆 2027年將達100萬顆

就主要供應商表現觀察，Groq、Cerebras與被軟銀購併的Graphcore雖同屬SRAM中心加速器陣營，但在產品成熟度、需求來源與量產進度上差異明顯。Groq LPU因已與NVIDIA形成非獨家技術授權合作，且新一代產品直接嵌入Vera Rubin平台架構，因此NVIDIA Groq 3 LPU在系統定義、客戶導入與商業化推進上，最具率先放量條件，

依目前產品導入時程推估，Groq LPX Rack機櫃將於2026年第4季至2027年第1季放量，2026全年LPU出貨量約50萬顆，有望居市場首位；若產品效能、穩定性與總持有成本優勢獲得客戶肯定，2027年出貨量則有機會達100萬顆。整體而言，未來1~2年SRAM中心高階雲端AI加速器市場，預期將呈現Groq率先放量，其他業者跟進的格局。

2026~2027年SRAM中心高階雲端AI加速器出貨量預測暨NVIDIA Groq 3 LPU供應鏈類型



資料來源：DIGITIMES，2026/5

另從供應鏈角度觀察，NVIDIA Groq 3 LPU亦代表一種不同於HBM中心加速器的供應鏈組合。首先，在晶圓代工層面，Groq 3 LPU採用三星電子4奈米製程，並非台積電先進製程。

其次，在記憶體與封裝層面，NVIDIA Groq 3 LPU以大容量On-chip SRAM作為記憶體核心，而非採用HBM。使其降低對HBM供應鏈的依賴，而後段封裝主軸採用FC-BGA，亦可避開CoWoS先進封裝供給緊張的瓶頸。

最後，在系統層面，NVIDIA Groq LPX每1U compute tray除整合8顆LPU與主機處理器外，另搭載fabric expansion logic，fabric expansion logic核心角色在於協定橋接、系統控制與外部記憶體最高256GB DRAM的擴充。LPU fabric expansion logic由Altera FPGA承擔，使LPX成為少數在AI伺服器中，將FPGA拉升為關鍵系統元件的案例。

另外，PCB與材料層面，由於LPX採用32個液冷1U compute trays組成的無纜線機櫃級設計(cableless rack-scale design)，原由線纜、連接器或獨立模組承擔的高速連線，收斂到主板、背板與tray級PCB內部完成，此種架構顯著提高板層數、走線密度、訊號完整性與材料等級要求，因此LPX機櫃將導入52層設計PCB與M9等級CCL，並搭配低介電石英玻纖布(Q-glass)，而訊號層銅箔亦同步升級至HVL P4，支援整櫃級低延遲互連需求。

總結而言，SRAM中心高階雲端AI加速器市場雖仍處導入初期，但隨低延遲推論、長上下文與Agentic AI需求升溫，Groq LPU憑藉與NVIDIA Vera Rubin平台整合優勢，有機會率先放量，預估NVIDIA Groq 3 LPU 在2026年出貨上看50萬顆、2027年有望達100萬顆。

更重要的是，Groq 3 LPU不僅象徵SRAM路線走向初步商業化，也意味高階雲端AI加速器的供應鏈重心，正由HBM與CoWoS主導的既有模式，逐步延伸至FPGA橋接元件，以及高階PCB與Q-Glass等關鍵材料等新環節。

結語：高階AI推論走向分層配置 SRAM與HBM協同並進

DIGITIMES認為，SRAM中心高階雲端AI加速器的興起，反映AI推論市場正由單一路線追求最高性能，轉向依照工作負載進行最適化配置。SRAM架構在decode、小Batch與高互動性推論場景中，具備低延遲、低功耗與較佳回應一致性的優勢。

然而，其限制性亦不少，包括SRAM bitcell縮放趨緩、先進節點製程良率與成本升高，以及晶片上SRAM容量其實難以滿足現今大型語言模型的權重、KV cache與長上下文需求。

這也表示僅，不論Groq LPU或Cerebras WSE-3，最終皆需導入外部DRAM或分層記憶體架構，補足晶片上SRAM容量不足的問題。當AI加速器補上外部記憶體後，雖然可提升模型承載能力與商業部署的彈性，但是也重新引入資料搬移、延遲與系統複雜度等因素的權衡。

整體而言，SRAM中心高階雲端AI加速器，並非取代HBM中心架構，而是作為特定推論工作負載下的專用加速層，與HBM平台或外部大容量記憶體協作分工，方能在未來高階雲端AI市場中發揮真正價值。

為協助我們做得更好，請幫我們評分 😊

	非常不重要		非常重要
		5	
請問這篇報告主題的重要性：		▼	
	1		10
	沒有幫助		非常有幫助
		5	
請問這篇報告內容對工作的幫助：		▼	
	1		10

送出評分

相關報告

[2026年高階雲端ASIC加速器出貨量將增至723萬顆 Google外賣TPU領跑 市場呈多方並起格局](#)

[伺服器機櫃走向多元專用設計 需求量與複雜度增加 帶動機櫃地位提升](#)

[產銷調查：Agentic AI引爆通用型機種需求 2Q26全球伺服器出貨將破500萬台大關](#)

[展會觀察：GTC 2026 NVIDIA高階AI機櫃持續升級 帶動供應鏈價值提升 積極布局AI推論運算解決方案](#)

關鍵字

☐ NVIDIA

☐ Groq

☐ Graphcore

☐ Cerebras

☐ PCB

☐ 記憶體

☐ SRAM

☐ HBM

☐ AI

☐ 加速器

☐ 供應鏈

加入已選取到「關鍵字追蹤」 什麼是「關鍵字追蹤」

熱門報告 - Research

- [OpenClaw熱潮加速邊緣AI Agent個人化應用 帶動VPS與個人工作站需求](#)
- [產銷調查：Agentic AI引爆通用型機種需求 2Q26全球伺服器出貨將破500萬台大關](#)
- [解決銅導線在訊號高速傳輸瓶頸 IC製造業者將以矽光子與CPO技術突圍](#)
- [2026/1 NB產業觀察：受記憶體價格飆漲與處理器供應吃緊影響 前五大NB品牌出貨月減近4成](#)
- [2026/2 NB產業觀察：春節期間產能銳減日零組件短缺問題持續 五大NB品牌出貨月減5%](#)

AI時代 重組產業秩序

立即訂閱



- 1 [產業趨勢不變加上算力需求分散 伺服器OEM加入AI基礎設施戰局](#) (2026/05/26)

- 2 [2027年SRAM中心高階雲端AI加速器將崛起 NVIDIA Groq 3 LPU出貨量估達百萬顆 非HBM架構新供應鏈成形](#) (2026/05/26)

- 3 [產銷調查：CPU運算力躍升AI要角 全球伺服器2026年出貨將顯增19.2%](#) (2026/05/26)

- 4 [產銷調查：Agentic AI引爆通用型機種需求 2Q26全球伺服器出貨將破500萬台大關](#) (2026/05/26)

- 5 [產銷調查：全球智慧型手機1Q26出貨2.783億支 預估2026全年出貨跌破11億支](#) (2026/05/22)

- 6 [1Q26兩岸晶圓代工淡季不淡 漲價效應將推升2Q26及2026全年兩岸產業營收](#) (2026/05/22)

- 7 [全球GaN功率元件市場競合關係趨於複雜化 產能外的勝出關鍵仍在設計能力](#) (2026/05/22)

- 8 [2027年SRAM中心高階雲端AI加速器將崛起 NVIDIA Groq 3 LPU出貨量估達百萬顆 非HBM架構新供應鏈成形](#) (2026/05/22)

- 9 [2025~2026年高階AI ASIC出貨量成長性優於GPU 推升AI伺服器供應鏈下一波成長動能](#) (2026/05/22)

- 10 [OFC展會觀察 CPO從技術狂熱回歸量產課題討論 反映業者更務實布局中長期商機](#) (2026/05/22)

- 11 [台積電AZ廠實現全年獲利逾160億 其他業者更難抵禦美政府施壓赴美](#) (2026/05/22)

- 12 [世界模型具備空間與時間認知能力 加速自駕AI系統理解及預測功能發展](#) (2026/05/22)

- 13 [HBM成關鍵戰場 NVIDIA恐失中國訓練市場主導權](#) (2026/05/20)

- 14 [伺服器機櫃走向多元專用設計 需求量與複雜度增加 帶動機櫃地位提升](#) (2026/05/20)

- 15 [政策加速中國半導體自主化 2026年中系高階雲端AI加速器出貨將逾212萬顆 華為市佔估過半](#) (2026/05/20)

- 16 [2026年全球晶圓代工產值估年增23.5% 上看2,500億美元](#) (2026/05/20)

- 17 [新華三伺服器出口金額擴大 挾二大出口路徑布局東協、中亞市場](#) (2026/05/20)

- 18 [企業導入LLM初期偏重資料「處理」應用 2026年後聚焦用戶「互動」與任務「執行」](#) (2026/05/20)

- 19 [展會觀察：2026年北京車展 車企以實體AI搶進Robotaxi賽道 海外車廠深化「在中為中」布局](#) (2026/05/20)

- 20 [2024年全球電動車銷量將逾1,800萬台 預期增速趨緩](#) (2026/05/20)

- 21 [邊緣生成式AI推論運算以70億個參數量語言模型為主流](#) (2026/05/20)

- 22 [產銷調查：記憶體漲價壓力浮現 2Q26全球手機AP出貨估年減15.2%](#) (2026/05/20)

- 23 [產銷調查：預估2Q26中企智慧型手機出貨年減17.8% 中國市場智慧型手機出貨將年減5.4%](#) (2026/05/20)

- 24 [展會觀察：2025年上海國際數據中心展 NVIDIA RTX解決方案在中國仍具可見度 L2L為中國主流直接液冷技術](#) (2026/05/20)

- 25 [美對中晶片禁令反覆多變 華為CloudMatrix 384以兩層Scale up架構堆疊系統運算力](#) (2026/05/20)

- 26 [產銷調查：Agentic AI引爆通用型機種需求 2Q26全球伺服器出貨將破500萬台大關](#) (2026/05/20)

首頁	科技網			Research	橡經閣	活動家	DIGITIMES
晶片戰升溫	產業	區域	議題	車用零組件	Colley & Friends	首頁	關於我們
未來車供應鏈	● 半導體・零組件	● 東南亞	觀點	HPC關鍵零組件	名家專欄	DIGITIMES 主辦	新聞發布
蘋果供應鏈	● CarTech・綠能	● 印度	報導總覽	邊緣運算	科技行腳	智慧應用	會員服務
產業九宮格	● 行動・通訊・XR	● 東亞/中國	影音	化合物/功率半導體	作者群	雲端 & 資安	科技橡送門
科技橡送門	● AI・智慧應用・電商物	● 國際	商情	Green Tech	關於專欄	產品 & 研發	科技產業報訂閱
展會	流	● 圖表	展會專區	EV Focus		AI & 創新	訂閱DIGITIMES行動版
影音	● 航太・衛星・軍工			新興科技		其他	整合行銷服務
修訂與更新	● IT・系統供應鏈			亞洲供應鏈		AI EXPO Taiwan	人才招募
	● 光電・顯示・光學			智慧製造			聯絡我們
	● 物聯科技・智慧製造			智慧家庭			
	● 科技政策			物聯網			
	● 圖表			寬頻與無線			
				次世代行動通訊			
				Cloud			
				電腦運算			
				伺服器			
				行動裝置與應用			
				智慧穿戴			
				CarTech			
				IC設計			
				IC製造			
				顯示科技與應用			

