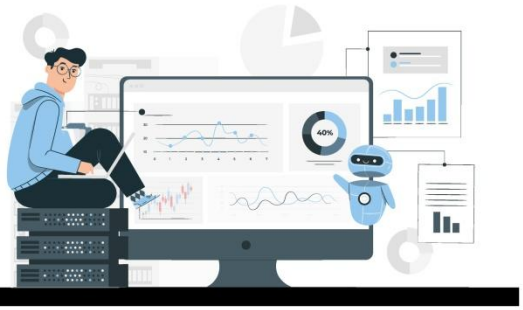
DS INVESTMENT & SECURITIES

2026.10.14

US Issue Analysis

DS 미국주식



이규원 해외주식/ETF
02-709-2674
kw.lee@ds-sec.co.kr

강근재 연구원
02-709-2667
Kgg812@ds-sec.co.kr

기세 좋은 엔비디아와 부진한 메모리, 바뀐 무게중심에 주목

NVIDIA의 신고가, Memory에 막혔던 GPU 연산 성능의 재평가

10월 5일, NVIDIA는 5개월 만에 신고가를 경신했다. 압도적인 GPU 경쟁력과 CPU/네트워킹 판매 확대, 밸류에이션 매력, 주주환원 강화 등 여러 요인이 거론되지만 본 리포트는 GPU 등 AI가속기의 Compute 성능이 중요해지는 흐름에 주목한다. 지금까지 추론 성능 향상의 주된 방식은 Reasoning 토큰을 늘리는 CoT였다. 반면 최근 출시된 GPT-6.1 Sol은 유사 성능 모델 대비 적은 Reasoning 토큰을 생성하는 특징을 보이는데, 이는 토큰 생성량보다 토큰당 내부 연산량을 늘리는 Recurrent Depth 방식의 영향으로 해석된다.

Recurrent Depth는 Reasoning 토큰 생성을 줄이면서 연산량을 확대할 수 있으며, 그 결과 KV Cache 증가에 따른 메모리 부담도 완화할 가능성이 있다. 그 동안 추론 과정에서 KV Cache 누적으로 인한 메모리 용량 및 대역폭 병목이 GPU의 연산 성능 활용을 제약해왔다. 그러나 Recurrent Depth와 같은 연산 방식이 확산되면 Memory 병목을 완화하는 동시에 Compute의 상대적인 중요도를 높이는 변화로 이어질 수 있다. 이는 AI시스템의 3요소 Compute, Memory, Networking 간 상대적 중요도가 달라질 가능성을 시사한다.

2027년의 핵심 화두는 '재귀적 자기개선'. 추론에 가려진 학습이 중요해질 타이밍

재귀적 자기개선(RSI)는 AI가 모델 개발 및 학습을 자동화하고, 개선된 모델을 다시 모델 학습에 활용해 성능 향상을 반복하는 선순환 구조이다. AI산업은 모델을 개발하는 학습과 이를 서비스로 제공해 수익을 창출하는 추론으로 구분되며, AI산업이 발전할수록 서비스의 확산에 따라 추론 인프라의 중요성이 높아지는 흐름이 자연스럽다. 그러나 재귀적 자기개선이 고도화되면 학습 인프라 투자 시 지능의 개선폭이 확대되면서 학습 인프라 투자의 경제성이 다시 높아질 수 있다. 내년 재귀적 자기개선의 고도화를 계기로 학습 인프라의 중요도가 재차 부각될 것으로 기대하며, 수혜 분야로 GPU, 파운드리, 네트워킹과 메모리 중에서는 HBM에 주목한다.

마지막으로 최근 OpenAI ARR 논란은 AI모델사의 수익성 우려가 여전함을 보여줬다. 연내 상장을 추진중인 Anthropic 이 조만간 주요 사업 지표를 공개할 전망인데, 최근 한달 이상 ARR이 정체된 상황에서 투자자의 우려를 해소하지 못한다면 AI산업을 넘어 증시 전반에 투자 심리를 악화시킬 수 있다.

DS투자증권
리서치센터

NVIDIA의 신고가, Memory에 막혔던 GPU의 성능이 재평가된다

왜 하필 지금 신고가를 찍었을까?

신고가를 돌파한 NVIDIA.
(1) GPU 경쟁력
(2) CPU/네트워킹 매출

NVIDIA는 10월 5일 약 5개월 만에 신고가를 경신했다. 신고가를 뒷받침할 근거는 충분하다. 우선 본업을 살펴보면 신제품 Vera Rubin NVL72는 기존 Blackwell 대비 추론 토큰당 비용을 최대 90% 절감할 수 있어 추론 영역에서 기술 우위를 입증했으며, GB300 기반 사전학습이 추정되는 GPT-6 Astra 등 OpenAI 프론티어 모델의 성능 도약은 학습 영역에서 고성능 GPU의 중요성을 재확인시켜 주었다. 이에 더해 Vera CPU, NVLink 6, Spectrum-X 등 CPU 및 네트워킹 제품으로 사업 영역을 확대하면서 GPU를 넘어 AI 인프라 전반에서 성장 동력을 확보하고 있다는 점도 긍정적이다.

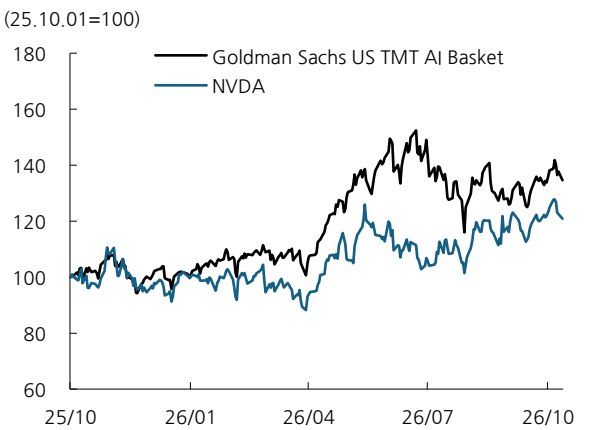
(3) 주주환원 확대
(4) 중국 수출 기대
상승할 이유는 많은데…
대부분 새롭지는 않은 내용

본업 경쟁력에 더해 주주환원 확대와 중국 수출 기대도 주가 상승을 뒷받침한다. NVIDIA는 9월 28일 1,500억 달러의 추가 자사주 매입을 승인했으며, 최근 중국 정부가 RTX PRO 5500의 수입을 허용할 가능성도 제기됐다. 가파른 이익 성장에도 주가 상승이 제한되면서 12MF PER이 16.3배 수준까지 낮아졌다는 점에서 밸류에이션 매력 또한 높아진 상황이었다.

GPU 등 Compute 자원의 상대적 중요도가 높아지는 흐름에 주목

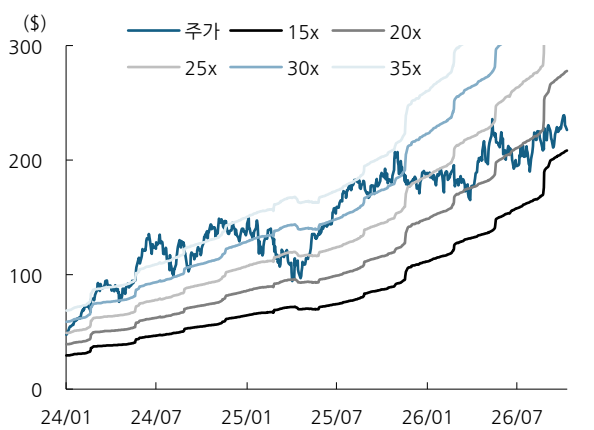
그러나 위 요인만으로 신고가를 설명하기에는 다소 부족한 부분이 있다. NVIDIA는 최근 분기 EPS 성장률 120%를 기록하는 등 꾸준히 높은 실적 성장세를 보여왔으며, AI 생태계를 주도해온 기업인 만큼 호재도 지속적으로 있었다. 그럼에도 Goldman Sachs AI Basket Index가 최근 1년간 35% 상승하는 동안 NVIDIA는 21% 상승에 그치는 등 상대적으로 부진한 시기를 보냈다. 이러한 점에서 최근 주가 강세의 배경에는 NVIDIA와 GPU를 바라보는 시장의 시각에 근본적인 변화가 나타나고 있을 가능성이 있다. 특히 GPU를 비롯한 AI 가속기의 Compute 성능이 상대적으로 중요해지는 흐름에 주목하는데, 이는 Memory의 상대적 중요도와도 관련있다는 점에서 투자 전반에 중요한 변화로 판단한다.

그림1 최근 1년간 타 AI인프라 기업 대비 부진했던 NVIDIA 주가



자료: Bloomberg, DS투자증권 리서치센터
주: Goldman Sachs US TMT AI Basket은 미국 상장된 AI 관련 기업 100여개를 지수화

그림2 강한 실적 성장과 이에 따라 12MF PER은 16.3배까지 하락



자료: Bloomberg, DS투자증권 리서치센터

GPT-6.1의 특별함은 저렴한 '작업당 비용'. 그 이유는 토큰을 덜 생성하기 때문

OpenAI GPT-6.1 Sol의 강점은 압도적으로 낮은 '작업당 비용'

OpenAI가 최근 출시한 GPT-6.1 Sol은 절대적인 지능에서 가장 높은 성능을 기록한 모델은 아니다. Artificial Analysis Intelligence Index에서 GPT-6.1 Sol은 52점을 기록해 53점을 기록한 GPT-6.0 Astra는 물론 각각 58점, 53점을 기록한 경쟁사 모델 Claude Opus 5.5, Gemini 4 Argon 보다 열위에 있다. 그럼에도 Sol의 경쟁력은 압도적으로 낮은 '작업당 비용'에 있다. 실제로 OpenAI 역시 GPT-6.1 Sol을 Astra에 근접한 성능을 훨씬 낮은 비용에 제공하는 모델로 소개했다.

GPT-6.1 Sol의 저렴한 '작업당 비용'은 벤치마크 수치에서도 확인된다. 종합적인 지능을 평가하는 Artificial Analysis 기준 Sol의 작업당 평균 비용은 $0.72로, 비슷한 시기에 출시된 Claude Opus 5.5($5.98), Claude Sonnet 5.5($5.46), Gemini 4 Argon ($1.99) 대비 약 60~90% 낮다. 이러한 비용 경쟁력은 코딩 분야에서도 확인되는데, 실제 터미널 환경에서의 코딩 능력을 평가하는 Terminal-Bench 4.0에서 Sol은 Opus 5.5보다 성능에서 열위가 있긴하나(Sol 56.1% vs Opus 59.6%) 작업당 비용이 약 86% 낮은 것으로 나타났다.

'작업당 비용'이 낮은 이유는 토큰을 덜 생성하기 때문

Recurrent Depth로 인한 연산 방식의 변화에 주목

여기서 중요한 부분은 GPT-6.1 Sol의 토큰당 가격이 경쟁사 모델과 유사함에도 작업당 비용이 크게 낮다는 점이다. Sol의 API 가격은 입력 $2, 출력 $10/백만 토큰으로 Sonnet 5.5 및 Gemini 4 Argon(프로모션 가격)과 동일하다. 그럼에도 앞서 설명했듯이 작업당 비용이 현저하게 낮은 주요 이유는 동일한 작업을 수행하는데 필요한 출력 토큰 수가 적기 때문인데, AI 추론 서비스는 입력, 출력 토큰 사용량에 따라 과금되므로 특정 작업을 수행하는데 더 적은 토큰을 생성한다면 작업당 비용도 낮아지게 되는 것이다. 당사는 이러한 토큰 효율성 개선이 GPT-6 계열부터 도입되었을 것으로 추정되는 Recurrent Depth 등 내부 연산 방식의 변화와 관련됐을 가능성에 주목하는데, 이 변화는 GPU 등 AI가속기 Compute 성능의 중요도를 높이는 방향으로 판단된다.

표1 경쟁사 모델 대비 성능은 열위에 있으나, 작업당 Reasoning 및 출력 토큰을 현저하게 덜 생성하여 작업당 비용이 압도적으로 저렴

구분	GPT-6.1 Sol	Claude Opus 5.5	Claude Sonnet 5.5	Gemini 4 Argon
모델 출시일	2026-09-29	2026-09-22	2026-09-28	2026-09-30
Intelligence Index	52	58	56	53
Terminal-Bench 4.0 (코딩 벤치마크)	56%	60%	64%	57%
Humanity's Last Exam (추론 벤치마크)	53%	61%	55%	57%
작업당 평균 Answer 토큰	13K	35K	50K	26K
작업당 평균 Reasoning 토큰	25K	84K	147K	36K
작업당 평균 비용	$0.72	$5.98	$5.46	$1.99
입력 API 단가 ($/100만 토큰)	$2	$4	$2	$2
출력 API 단가 ($/100만 토큰)	$10	$20	$10	$10

자료: 각 모델사, Artificial Analysis, DS투자증권 리서치센터

주: 각 모델의 최고 추론 설정(GPT와 Claude는 Max, Gemini는 High)

주: 작업당 비용, 출력 토큰, Reasoning 토큰은 Artificial Analysis 기준

Recurrent Depth, 토큰을 많이 생성하기보다 토큰당 투입되는 연산량을 늘리는 방식

AI모델의 성능 향상은 학습,추론 연산량 확대로 달성

최근까지 추론 연산량 확대는 CoT로 더 많은 Reasoning 토큰을 생성하는 방식

앞서 살펴본 GPT-6.1 Sol의 토큰 효율성 개선을 이해하기 위해서는 AI모델의 성능을 높이는 연산 방식을 구분할 필요가 있다. AI모델의 성능 향상에 투입되는 컴퓨팅은 (1) 학습 과정에서 모델의 지능을 향상시키는 Train-time Compute(학습 연산량)와 (2) 학습을 마치고 파라미터가 확정된 모델이 문제를 해결하는 과정에서 추가 연산을 투입하는 Test-time Compute(추론 연산량)으로 구분된다. 그리고 현재까지 Test-time Compute를 확대하는 대표적인 방법은 추론 과정에서 Chain-of-Thought(CoT, 생각의 사슬)를 통해 더 많은 Reasoning 토큰을 생성하는 방식이었다.

Reasoning 토큰이 생성되면 KV Cache도 누적되어서 GPU 추론 효율에 제약 발생

CoT는 ChatGPT 등 AI서비스가 복잡한 문제를 해결할 때 곧바로 최종 답변을 생성하는 대신, 여러 단계의 내부 추론을 거쳐 답변을 도출하는 방식이다. 일반적인 CoT 기반 추론에서는 이러한 중간 추론 과정이 Reasoning 토큰 생성으로 이어지며, 해당 토큰은 사용자에게 표시되지 않더라도 연산과 메모리 자원을 사용한다. 더 나아가 Reasoning 토큰이 증가하면 토큰의 KV Cache도 함께 누적되며, 이는 메모리 부담을 높이는 동시에 처리 가능한 요청 수(Batch Size)를 제한해 GPU의 추론 효율을 제약하는 요인으로 작용해 왔다.

Astra 부터 도입이 추정되는 Recurrent Depth는 토큰을 많이 생성하기보다 토큰당 투입되는 연산량을 늘리는 방식

반면 2025년부터 주목받기 시작한 Recurrent Depth는 CoT와 다른 Test-time Compute 확대 방식으로 Reasoning 토큰을 추가 생성하지 않고도 모델 내부에서 동일한 연산 블록을 반복 실행해 토큰당 투입되는 연산량을 확대한다. 쉽게 말해 CoT가 추론 과정을 토큰 형태로 생성하면서 답을 찾아간다면, Recurrent Depth는 새로운 토큰을 생성하기 전에 모델 내부에서 연산을 반복하며 답을 정교화하는 구조이다. 따라서 더 많은 토큰을 생성하지 않더라도 내부 연산의 반복을 통해 추론 성능을 높인다는 점에서 CoT와 차이가 있다. 당사는 9월 7일 발간한 'GPT-6 Astra: OpenAI가 최고 성능을 찍은 진짜 배경' 리포트에서 Astra가 Recurrent Depth라는 스케일링 법칙을 제시했음을 짚었는데 Sol이 Reasoning 토큰을 적게 생성하고 작업당 비용이 저렴한 것이 이에 따른 효과로 보인다.

표2 AI모델의 성능 향상 방식: 모델의 지능을 향상시키는 Train-time Scaling, 추가 연산을 통해 문제해결력을 높이는 Test-time Scaling

구분	Train-time Scaling(학습 연산량 확대)	Test-time Scaling(추론 연산량 확대)
정의	학습 과정에서 더 많은 연산을 투입해 모델 자체의 지능을 향상	학습을 마치고 파라미터가 확정된 모델이 복잡한 문제를 해결할 때 추가 연산을 투입해 추론 성능을 향상
목표	더 높은 지능의 모델 개발	확정된 모델로 더 복잡한 문제를 해결
대표 기술	Pre-training, 강화학습 등	Chain-of-Thought(CoT), Recurrent Depth 등
연산 시점	사전학습, 사후학습 과정	추론(Inference)서비스 과정
모델 파라미터	학습 과정에서 업데이트	일반적으로 고정
성능 개선 방식	파라미터의 크기, 학습 데이터의 양, 학습 컴퓨팅 확대	추론 시간, 추론 단계, 내부 연산량 확대
컴퓨팅 수요	모델 학습에 필요한 대규모 고성능 GPU클러스터	개별 요청 처리에 필요한 GPU 연산

자료: DS투자증권 리서치센터

그림3 Test-time Scaling의 두 방식: CoT와 Recurrent Depth 비교



자료: DS투자증권 리서치센터

AI 시스템의 3요소 Compute, Memory, Networking 내 상대적 중요도에 변화 발생

NVIDIA는 AI시스템의 3요소로 Compute, Memory, Networking을 제시

Recurrent Depth는 '작업당 비용' 절감에 그치지 않고 AI시스템을 구성하는 핵심 3요소 Compute, Memory, Networking 사이의 상대적 중요도를 변화시킬 수 있다는 점에서 매우 중요하다. NVIDIA는 AI시스템의 성능이 (1) 연산을 수행하는 Compute(=GPU) (2) 연산에 필요한 데이터를 저장 및 공급하는 Memory (3) GPU 간 데이터를 전달하는 Networking(정확히는 'Communication'으로 표현)의 균형에 의해 결정된다고 설명한다. 이는 세 자원 중 하나라도 병목이 발생하면 AI시스템 전체의 성능이 제한된다는 의미로 (1) 메모리 대역폭이 부족하면 GPU가 데이터를 적절한 시점에 공급 받지 못해 연산 성능을 충분히 활용하지 못하는 사례와 반대로 (2) GPU가 연산 능력이 부족하면 메모리, 네트워킹 대역폭이 충분하더라도 전체 처리량을 확대하기 어려운 사례가 이를 뒷받침한다.

Reasoning 토큰 증가로 KV Cache가 누적되면 메모리의 중요도가 높아지는 흐름

현재 추론에서는 3요소 중 Memory가 Compute(=GPU)의 연산 성능을 충분히 활용하지 못하게 만드는 대표적인 병목으로 작용해 왔다. 대규모 행렬 연산을 수행하는 Prefill과 달리, 토큰을 하나씩 생성하는 Decode에서는 연산 자체보다 모델 가중치와 KV Cache 등을 메모리에서 가져오는 시간이 성능을 좌우하는 경우가 많기 때문이다. 특히 CoT를 통해 Reasoning 토큰이 증가하면 KV Cache가 누적되어 메모리 용량과 대역폭 부담이 더욱 높아진다. 추론 수요가 확대되는 과정에서 메모리가 핵심 병목으로 부각된 것도 메모리 대역폭 부족이 GPU의 연산 자원 활용률을 낮추고, 용량 부족이 동시 처리 가능한 요청 수를 제한하면서 GPU의 높은 연산 성능을 충분히 활용하지 못했기 때문이다.

Recurrent Depth는 토큰 생성량 감소로 Memory 부담을 완화시키고

반대로 토큰당 연산량을 늘려 Compute의 상대적 중요도를 높이는 방향

이러한 상황에서 Recurrent Depth는 Memory에 집중되었던 병목을 일부 완화하고 Compute의 상대적 중요성을 높일 가능성이 있다. 기존 CoT와 비교하면 Reasoning 토큰 생성량을 줄여 KV Cache 누적에 따른 메모리 부담을 완화하는 반면, 동일한 파라미터를 반복 연산하는 등 토큰당 연산량을 늘려 Compute 성능에 대한 의존도를 높일 수 있기 때문이다. 물론 CoT와 Recurrent Depth는 상반되거나 서로를 완전히 대체하는 개념이 아니며 모델 간 성능 경쟁이 극심하기에 두 방식을 병행할 가능성이 높다. 다만 GPT-6.1 Sol의 Reasoning 토큰 생성량이 현저히 적다는 점은 메모리 부담을 줄이는 대신 GPU의 내부 연산을 확대해 추론 성능을 개선하려는 기술적 변화의 가능성을 시사한다.

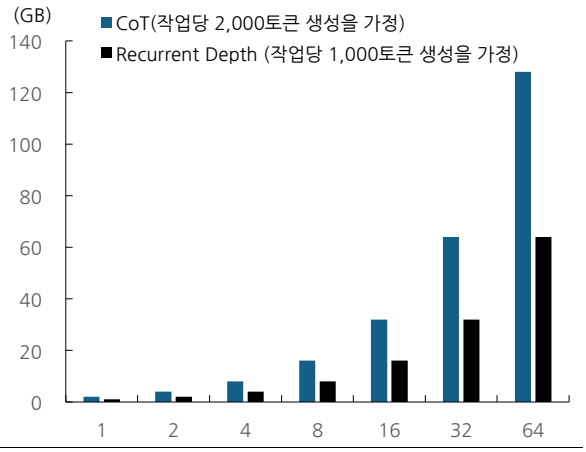
이러한 변화가 GPU의 연산 효율 개선으로 이어지는 핵심 경로는 Batch Size(GPU가 동시에 처리하는 요청 수) 확대다. 병렬 연산에 특화된 GPU는 여러 요청을 동시에 처리할수록 한 번 불러온 모델 가중치를 더 많은 연산에 활용할 수 있어 연산 효율이 높아진다. 그러나 이제까지 CoT를 통해 Reasoning 토큰이 증가했을때는 요청당 KV Cache가 누적되면서 메모리 용량 부족으로 Batch Size 확대가 제한되었고, 이는 추론 과정에서 메모리 용량 부족이 GPU의 최대 연산 성능을 제약했던 대표적인 사례다. 반면 Recurrent Depth로 인해 KV Cache 저장 부담이 완화된다면 상대적으로 여유가 생긴 메모리 공간을 활용해 Batch Size를 확대할 수 있다. 결과적으로 메모리 병목으로 인해 충분히 활용하지 못했던 GPU의 연산 성능을 더욱 적극적으로 활용할 수 있게 된다.

그림4 NVIDIA가 언급한 AI시스템의 3대 핵심 자원

핵심 자원	주요 역할	성능 병목 발생 시 제약 사항
Compute (연산)	AI 모델의 행렬 연산, 추론 수행	연산 처리량 부족으로 전체 처리 속도 제한
Memory (메모리)	모델 가중치와 KV Cache 저장, 연산에 필요한 데이터 공급	데이터 공급 지연, Batch Size 확대 제한
Networking (통신)	GPU 간 데이터 전송, 연산 결과 교환	통신 지연으로 GPU 대기 시간 증가

자료: NVIDIA, DS투자증권 리서치센터
주: NVIDIA는 Networking을 Communication으로 표현

그림5 토큰 생성량 및 Batch Size에 따른 KV Cache 저장량 비교



자료: DS투자증권 리서치센터
주: X축은 Batch Size(한 번에 처리하는 요청의 수)

주가는 이미 Compute 자원을 재평가하고 있는 것일 수 있다

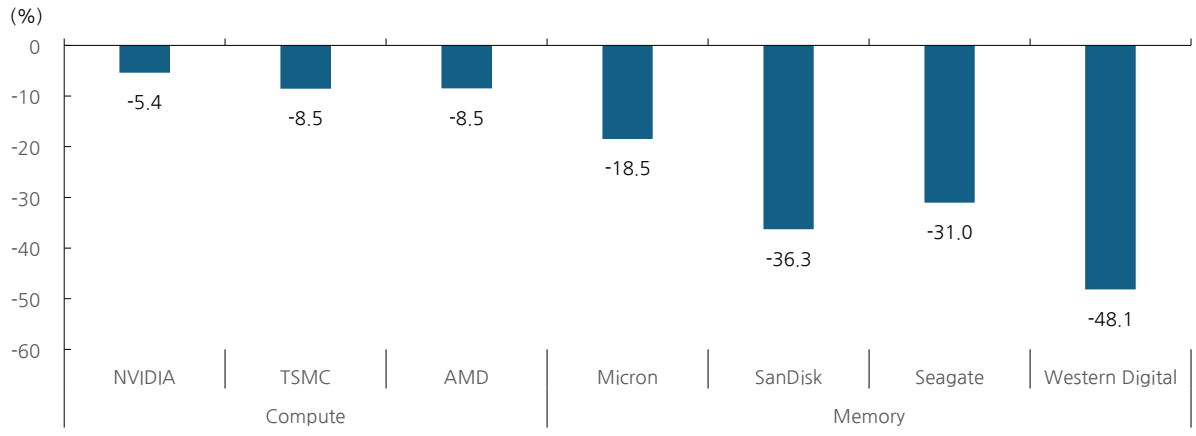
고점대비 격차가 크지 않은 GPU, AI가속기 관련 기업

AI 하드웨어 기업들의 고점 대비 주가 격차는 Compute 자원의 재평가 가능성을 시사한다. 대표적인 Compute 관련 기업으로는 GPU 등 AI 가속기를 공급하는 NVIDIA와 AMD, 첨단 AI 가속기 생산을 담당하는 TSMC가 있다. 10월 12일 기준 이들 3사의 주가는 52주 최고가 대비 평균 7.5% 낮은 수준으로, 후술할 메모리 기업보다 상대적으로 양호한 흐름을 보이고 있다. AMD는 CPU 수요 확대 등 개별 호재가 동시에 반영된 결과이므로 이를 Compute 자원의 재평가로만 설명하기 어렵다. 그럼에도 NVIDIA와 AMD의 AI 가속기, TSMC의 첨단공정 및 패키징에 이르기까지 Compute 관련 밸류체인 전반에서 상대적인 주가 강세가 나타나고 있다는 점은 Compute 자원의 중요도가 높아졌을 가능성을 암시한다.

고점대비 격차가 많이 벌어진 메모리 관련 기업

반면 미국 메모리, 스토리지 기업의 주가는 고점 대비 격차가 여전히 크다. 대표적으로 Micron, SanDisk, Seagate, Western Digital은 고점 대비 평균 33.5% 낮은 수준에 거래되고 있다. 최근까지도 DRAM과 NAND 가격이 견조한 수요를 바탕으로 높은 수준을 유지하고 있으며, Agentic AI의 확산 역시 CPU와 함께 메모리, 스토리지 수요 확대를 뒷받침할 전망이기에 고점 대비 주가가 메모리 수요 약화를 의미하지는 않는다. 다만 그동안 메모리 병목이 GPU의 연산 성능을 제약하면서 Memory의 상대적 중요도를 높여왔다면, Recurrent Depth와 토큰을 적게 생성하는 GPT-6.1 Sol의 방식은 고성능 GPU의 가치를 재평가하는 계기가 될 수 있다. 이는 메모리 수요가 견조하더라도 시장의 관심과 투자 프리미엄이 Memory에서 Compute로 일부 이동할 가능성을 시사한다.

그림6 Compute 관련 기업(NVDA, TSM, AMD)과 Memory 관련 기업(MU, SNDK, STX, WDC)의 고점 대비 격차



자료: Bloomberg, DS투자증권 리서치센터

27년의 핵심 화두는 재귀적 자기개선. 추론보다 학습이 중요해질 타이밍

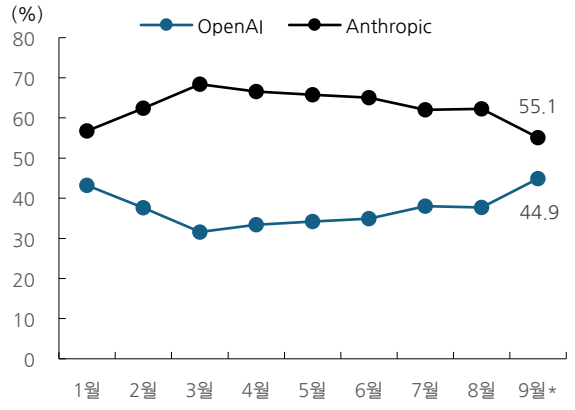
모델 학습 영역에서 리더십을 되찾은 NVIDIA

NVIDIA GPU로 프론티어 모델을 학습시키는 OpenAI, Meta, xAI의 약진

미국 AI모델 개발사를 성능과 점유율 등을 중심으로 구분하면 OpenAI와 Anthropic을 1티어, Google, Meta, xAI를 2티어로 분류할 수 있다. 1티어는 프론티어 모델의 성능뿐 아니라 실제 서비스와 개발자 생태계에서 강한 입지를 구축한 기업이며, 2티어는 잠재력을 바탕으로 이들을 추격하는 기업이다. 최근 1티어에서는 OpenAI가 Anthropic 대비 API 시장 점유율을 회복하고 있으며, 2티어에서는 뒤처졌다고 평가받던 Meta와 xAI의 모델 성능 개선이 두드러지고 있다. 여기서 주목할 부분은 OpenAI, Meta, xAI 모두 NVIDIA GPU를 핵심 학습 인프라로 활용하고 있다는 점이다.

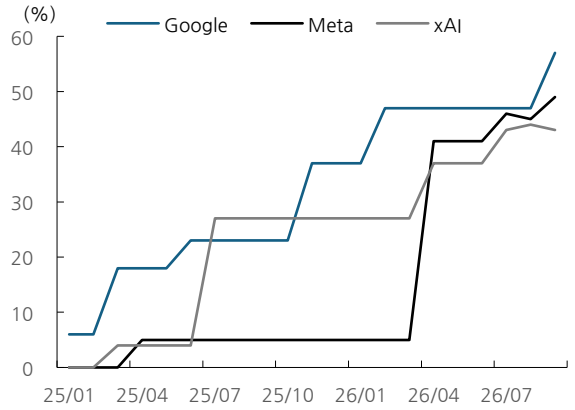
앞서 언급했듯 최근 프론티어 모델의 학습 영역에서 NVIDIA GPU가 리더십을 되찾고 있는 것으로 보인다. Anthropic은 AWS Trainium을 중심으로 대규모 학습 클러스터를 구축했고, 여기서 개발된 Claude가 최고 성능을 한동안 기록하면서 범용적인 특성의 GPU 대비 특정 영역에 특화된 AI가속기도 충분한 경쟁력을 확보할 수 있다는 점을 입증했다. 그러나 OpenAI가 GB200, GB300으로 구축된 Stargate Abilene에서 학습된 GPT-6.0 Astra가 최고 성능을 탈환했고, 이에 더해 NVIDIA GPU를 기반으로 학습 클러스터를 확장해온 Meta, xAI의 성능 개선이 두드러지면서 GPU 기반 학습 인프라의 경쟁력을 다시 확인시켜 주었다. 내년부터 GB300보다 한 단계 발전한 Vera Rubin NVL72를 통해 학습된 모델이 출시되면 학습 영역에서의 리더십을 되찾을 것으로 기대되며 이 또한 최근 NVIDIA 주가 강세를 뒷받침했을 것으로 판단된다.

그림7 OpenAI와 Anthropic의 API 지출액 점유율



자료: FourWeekMBA, DS투자증권 리서치센터
주: 두 기업의 API 합산을 100으로 가정

그림8 Google, Meta, xAI 프론티어 모델 HLE 벤치마크 정답률



자료: DS투자증권 리서치센터
주: HLE(Humanity's Last Exam)는 인간 전문가 수준의 고난도 문제 해결 능력을 평가

표3 주요 모델사 별 프론티어 모델 학습 클러스터: OpenAI, Meta, xAI는 NVIDIA GPU 사용

모델사	프론티어 모델 학습 클러스터	현재 배치된 AI 가속기	최종 배치 예정 AI 가속기	구축 완료 시점
OpenAI	Stargate Abilene	NVIDIA B200: 100.8K NVIDIA B300: 100.8K	NVIDIA B200: 100.8K NVIDIA B300: 302.4K	4Q26
Anthropic	Project Rainier (New Carlisle + Madison)	AWS Trainium2: 1,371.6K	AWS Trainium2: 1,828.7K AWS Trainium3: 도입 예상	1Q28
Google	Google Columbus	Google TPU v5e: 193.9K Google TPU v5p: 28.2K Google TPU v6e: 204.6K Google TPU v7: 38.9K	미공개	3Q27
Meta	Prometheus	NVIDIA B300: 166K	NVIDIA B300: 362.6K	3Q28
xAI	Colossus 2	NVIDIA B200: 110K NVIDIA B300: 330K	NVIDIA B200: 110K NVIDIA B300: 612.2K	1Q27

자료: EpochAI, DS투자증권 리서치센터

27년에 기대되는 재귀적 자기개선 고도화. 학습 인프라가 또 한번 중요해진다

재귀적 자기개선(RSI)
: AI가 모델 학습을 자동화하고, 개선된 모델이 다시 모델 학습에 활용되는 선순환

최근 AI산업의 다음 변곡점으로 재귀적 자기개선(Recursive Self-Inprovement, RSI)를 언급하는 목소리가 많다. 재귀적 자기개선은 AI가 모델 구조와 학습 알고리즘을 개선하고 실험을 수행해 후속 모델의 성능을 높이며, 개선된 모델이 다시 AI 연구를 가속하는 선순환 구조를 의미한다. 실제로 Anthropic은 이르면 2027년 초부터 AI가 최상위 연구팀의 업무를 자동화하거나 크게 가속할 수 있다고 전망했으며, OpenAI 역시 AI 연구 자동화와 자기개선 체계 구축을 핵심 과제로 제시했다. 현재로서 완전한 재귀적 자기개선의 구현 시점은 불확실하지만, AI모델사와 주요 인력의 전망을 종합하면 내년부터 AI 연구 자동화가 모델 성능 개선의 새로운 동력으로 부상할 가능성이 있고 최근 그 목소리가 더욱 강해지고 있다.

재귀적 자기개선이 본격화되면 학습 인프라가 다시 주목받을 수 있음

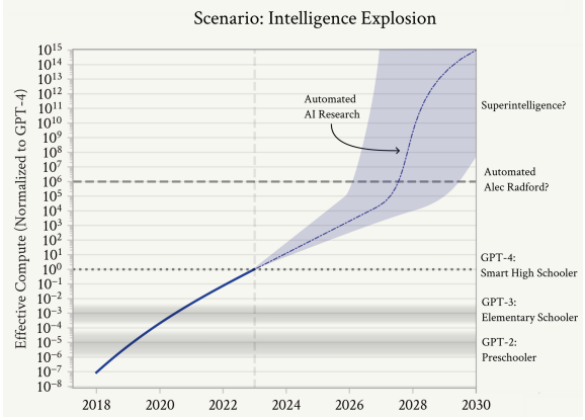
AI산업은 크게 모델을 개발하는 학습과 이를 서비스로 제공해 수익을 창출하는 추론으로 구분된다. 궁극적으로 모델 학습의 목적은 추론 성능을 높이는 데 있는 만큼 AI산업이 고도화될수록 학습 대비 추론 인프라의 중요성이 높아지는 것은 자연스러운 흐름이다. 또한 모델 학습 인프라에 대한 컴퓨팅을 늘릴수록 성능 개선의 한계효용이 체감할 가능성이 높다. 그러나 재귀적 자기개선이 본격화되면 AI가 스스로 새로운 모델 구조와 학습 알고리즘을 발견하면서 모델 개발 속도가 가속화될 수 있다. 이 과정에서 학습에 투입하는 컴퓨팅의 생산성이 개선되면 기존보다 훨씬 강력한 차세대 모델을 개발하기 위한 대규모 학습 인프라 투자의 경제성도 높아질 수 있다. 이는 추론 대비 중요도가 낮아지던 초대형 학습 인프라가 2027년부터 재차 주목받는 계기가 될 것으로 기대한다.

그림9 재귀적 자기개선에 대한 주요 기업 및 인물의 전망

기업, 인물	언급 시점	전망 및 핵심 내용
Anthropic	26.07	2027년 초 AI가 세계 최고 수준의 연구팀이 수행하는 작업을 완전히 자동화하거나 연구 속도를 획기적으로 높일 수 있음
OpenAI	26.09	AI의 연구개발 기여가 RSI로 이어질 가능성이 높음 2028년 3월까지 인간 감독 아래 자동화된 AI 연구자를 개발하는 것이 다음 목표
다리오 아모데이 (Anthropic CEO)	26.09	RSI의 초기 단계가 Anthropic을 포함한 업계에서 이미 시작되고 있으며, 발전 속도가 빨라질 수 있음
제이콥 콕슨 (前 OpenAI 연구원)	26.10	OpenAI 재직 당시 AI 연구 자동화의 목표 시점이 27~28년이었으며, 현재 개발 속도가 당시 예상에 부합하거나 앞서고 있음

자료: 각 회사 및 인물, DS투자증권 리서치센터

그림10 체감하던 학습 컴퓨팅 규모가 RSI를 기점으로 가속화(추정)



자료: SITUATIONAL AWARENESS, DS투자증권 리서치센터
주: 레오폴드 아센브레너가 추정한 자동화된 AI연구로 인한 지능 가속화
주: Y축은 GPT-4 학습에 사용된 컴퓨팅을 1로 환산하여 가정한 유효 학습 컴퓨팅 규모.

학습 인프라 투자 확대 시 수혜 분야

: GPU/AI가속기, 네오클라우드, 파운드리, 네트워킹, HBM

고도화된 재귀적 자기개선이 본격화되면 차세대 모델을 개발하는 과정이 가속화되면서 대규모 사전학습을 포함한 AI 학습 전반의 컴퓨팅 수요가 큰 폭으로 증가할 것으로 예상한다. 가장 직접적인 수혜 분야는 고성능 GPU와 이를 생산하는 선단 파운드리 및 첨단 패키징이며, 최근 학습 영역에서 경쟁력을 재확인한 NVIDIA의 직접적인 수혜가 기대된다. 메모리에서는 대규모 학습에 필요한 모델 가중치, 활성값(중간 연산 결과) 등을 처리하기 위한 HBM 용량과 대역폭의 상대적인 중요성이 높아질 전망이다. 또한 학습 클러스터가 점점 대형화되고 병렬 연산이 확대되면서 GPU간 통신을 담당하는 Scale-up 및 Scale-out 네트워크와 단일 클러스터의 크기를 확대하는데 한계가 있기에 다수의 분산된 클러스터를 하나의 학습 인프라로 연결하는 수요가 확대되면서 데이터센터 간 네트워크(DCI) 분야의 수혜도 전망된다.

표4 재귀적 자기개선에 따른 수혜 AI 분야

분야	수혜 정도	내용
고성능 GPU 및 AI가속기	매우 높음	AI 연구 자동화와 차세대 모델 학습 가속화로 연산 수요 증가 차세대 모델 학습을 위한 클러스터 구축에 따른 수혜 기대
네오클라우드	매우 높음	재귀적 자기개선은 모델 학습을 위한 컴퓨팅 수요를 크게 높이며, GPU 기반 컴퓨팅의 가치가 상승할 가능성 높음
파운드리	매우 높음	고성능 GPU, AI 가속기 생산량 증가에 따른 선단 공정, 첨단 패키징 수요 확대
Scale-up/out 네트워크	매우 높음	차세대 모델의 대형화 및 분산 학습 확대로 GPU 간 데이터 교환 및 통신 수요 증가 가능성 초대형 학습 클러스터의 연산 효율을 높이기 위한 네트워크 대역폭 확대
HBM	높음	모델 규모와 학습 연산량 증가에 따른 가중치, 활성값 등을 처리하기 위한 메모리 용량 및 대역폭 수요 확대
Scale-Across 네트워크(DCI)	높음	초대형 학습 클러스터를 단일 사이트에 구축하기는 공간, 전력, 제도적인 제약 사항 존재 분산된 데이터센터를 하나의 학습 인프라로 연결하는 방향 속에 고속 네트워크 연결 수요 확대

자료: DS투자증권 리서치센터

OpenAI ARR로 한대 맞은 미국 증시. Anthropic 상장의 복선일수도?

확인된 것은 AI 수익성에 대한 여전한 우려. ARR 정체된 Anthropic 상장 은 괜찮을까?

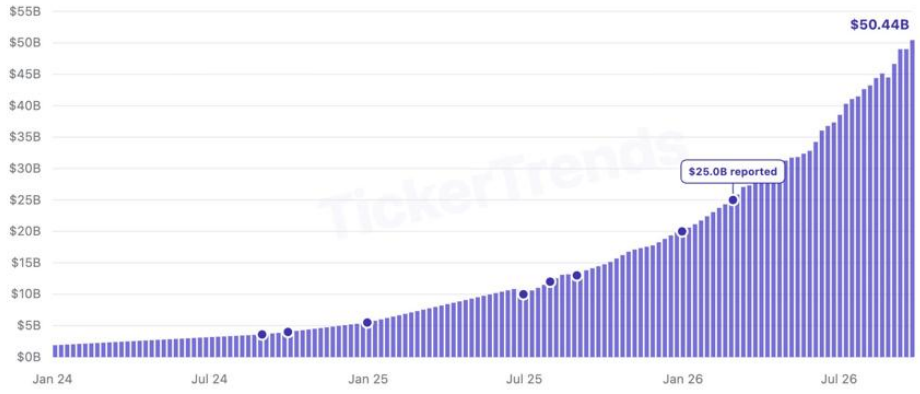
OpenAI ARR 사태는 AI모델사의 수익화 우려가 여전함을 보여줌

10월 8일, OpenAI의 ARR(연환산 매출)이 일각에서 보도한 $70B가 아닌 약 $50B수준이라는 보도로 인해 AI 관련주를 중심으로 미국 증시의 매도세가 확대되었다. 그러나 이는 Anthropic과 비교를 위해 동일한 방식(클라우드 파트너 매출을 포함)으로 산출된 수치($70B)와 OpenAI의 기존 매출 집계 방식($50B) 간 차이에서 비롯된 것으로 실제 매출 감소를 의미하지 않는다. AI모델사 ARR 추정에 주로 인용되는 Ticker Trend 역시 9월 말 ARR을 $50B로 추정해왔다는 점에서 일종의 해프닝으로 볼 수 있다. 그럼에도 시장의 민감한 반응은 AI모델사의 수익화에 대한 우려가 여전히 높음을 재확인시켰다는 점에서 의미가 있다.

상장이 예정된 Anthropic의 ARR은 한달 이상 정체 중

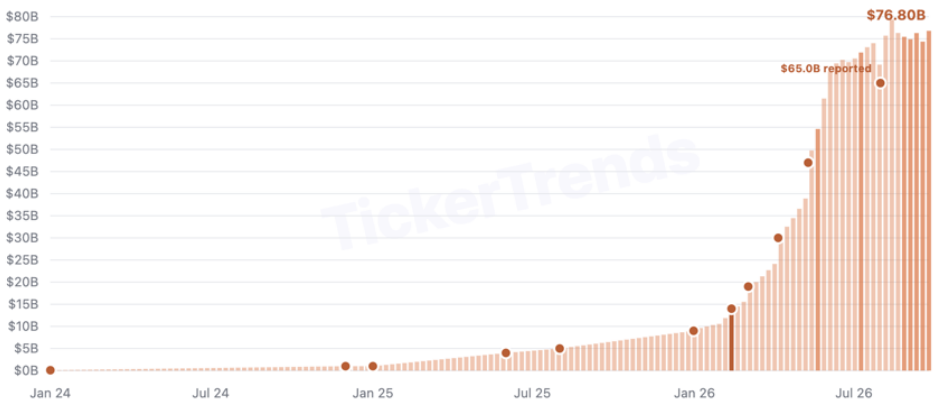
OpenAI가 Anthropic의 방식으로 ARR을 집계 시 $20B가 증가한다는 것은 Anthropic이 OpenAI의 방식으로 ARR을 집계 시 매출 전망의 일정 부분이 감소할 수 있음을 의미한다. 최근 한달 이상 ARR이 정체중인 Anthropic의 기업 공개 과정이 AI산업은 물론 미국증시 투자 심리를 훼손시킬 가능성을 경계한다.

그림11 OpenAI ARR 추정치(가장 최근 추정값: 9월 24일 $50.44B)



자료: Ticker Trend, DS투자증권 리서치센터

그림12 Anthropic ARR 추정치(가장 최근 추정값: 9월 24일 $76.80B)



자료: Ticker Trend, DS투자증권 리서치센터

곧 공개될 AI모델사 비즈니스 관련 숫자들

수 많은 우려를 해소시키지 못하면 AI산업은 물론 증시 전반에 부정적 결과 예상

Bloomberg에 따르면 Anthropic은 추수감사절 이전 상장을 추진 중이며, 머지 않아 Pre-IPO Investor Day를 개최할 예정이다. Anthropic 상장은 AI산업의 성장성을 재확인하는 계기가 될 것이라는 낙관론과 AI모델사의 취약한 사업구조를 부각시킬 것이라는 비관론이 공존하는데, 최근 OpenAI ARR 논란을 통해 시장이 AI모델사의 매출 신뢰성과 수익성에 여전히 민감하다는 점이 확인된 만큼 Anthropic이 높은 기대를 충족할 수 있을지가 관건이다. 특히 (1) 최근 거론되는 분기 흑자의 지속 가능성, (2) 상위 2개 고객이 2025년 매출의 약 25%를 차지하는 고객 집중도, (3) 향후 10년간 $518B에 달하는 컴퓨팅 지출 약정 중 약 80%가 실제 사용량과 무관하게 지급되는 계약 구조 등에 대해 투자자의 우려를 해소할 만한 구체적인 근거를 제시할 수 있을지가 관건이다. 이러한 우려를 충분히 해소하지 못한다면 이번 IPO가 오히려 AI 산업 전반의 구조적 취약성을 재차 부각시키는 계기가 될 가능성도 있다.

그림13 Anthropic IPO 타임라인

시점	내용
5월 28일	Series H $65B 조달 (기업가치 $965B)
6월 1일	SEC에 비공개 S-1 제출
9월 28일	S-1 초안 제출 보도 (Reuters 보도)
10월 14일	pre-IPO Investor Day (Bloomberg 보도. 확정은 아님)
11월 9일 주	공식 마케팅 및 로드쇼 시작 (Bloomberg 추정. 확정은 아님)
11월 26일 이전	추수감사절 이전 상장 추진 (Bloomberg 보도)

자료: 국내외 언론 취합, DS투자증권 리서치센터

그림14 Anthropic IPO에서 부각될 수 있는 핵심 우려

핵심 우려	내용
고객 집중도	상위 2개 고객이 25년 매출의 25%를 차지 주요 고객 상당 수가 장기계약을 체결하지 않았다면 추후에 매출 이탈 및 경쟁사 전환 가능성
클라우드 파트너 의존도	25년 매출의 약 50%가 AWS, Google Cloud를 통해 발생 클라우드를 통한 매출은 유통 수수료가 발생하며, 이들 중 일부는 경쟁사가 될 수 있다는 점에서 장기적인 수익성 및 협상력에 대한 우려
컴퓨팅 지출의 경직성	향후 10년간 컴퓨팅 지출 약정이 $518B에 달하며 약 80%가 사용 여부와 관계 없이 지급해야하는 구조로 알려짐 AI 수요 부진 시 막대한 고정비 부담으로 이어질 수 있음
분기 흑자에 대한 정보	Anthropic이 26년 2분기부터 분기 흑자를 달성했다는 보도가 많았는데, 실제 지속성이 있고 흑자 폭이 확대될 수 있는 구조인지 확인 필요

자료: DS투자증권 리서치센터

Compliance Notice

- 동 자료는 기관투자가 등 제 3자에게 사전 제공한 사실이 없습니다.
- 동 자료에 게시된 내용들은 본인의 의견을 정확하게 반영하고 있으며, 외부의 부당한 압력이나 간섭 없이 작성되었음을 확인합니다. (작성자: 이규원, 강근재)
- 동 조사자료는 고객의 투자에 참고가 될 수 있는 각종 정보제공을 목적으로 제작되었습니다. 이 조사자료는 당사의 리서치센터가 신뢰할 수 있는 자료 및 정보로부터 얻어진 것이나, 당사가 그 정확성이나 완전성을 보장할 수 없으므로 투자자 자신의 판단과 책임하에 종목 선택이나 투자시기에 대한 최종 결정을 하시기 바랍니다. 따라서 이 조사자료는 어떠한 경우에도 고객의 증권투자 결과에 대한 법적 책임소재의 증빙자료로 사용될 수 없습니다.
- 동 조사자료의 지적재산권은 당사에 있으므로 당사의 허락 없이 무단 복제 및 배포 할 수 없습니다.