

摘要：

AI Agent操控电脑的能力已在2026年越过两条关键红线：最优模型在标准桌面任务中完成率达85%，超越人类的72%；运行成本降至每小时6至8美元，低于印度离岸人力的10美元。技术与经济的双重拐点正在颠覆BPO市场，而真正的护城河已从“谁的模型更强”转移至“谁更懂企业内部流程”。


AI Agent操控电脑完成实际业务流程，正从概念演示走向规模化生产部署，并在成本与准确率两个维度同时越过关键阈值。

据a16z早期AI投资合伙人Fabrizio Serafini发布的最新研究，**当前最优AI Agent在标准电脑操作基准测试中的完成率已达85%，超越人类测试者约72%的水平。**与此同时，成本数据显示，运行一个AI Agent的全成本约为每小时6至8美元，已低于印度离岸BPO人力的约10美元，较美国本土后台员工的30至45美元则低出逾70%。

这一技术与经济的双重拐点，正在重塑企业后台流程外包（BPO）市场的底层逻辑。对于投资者而言，真正的价值洼地已从模型层上移至应用与上下文层——**谁能将 workflow 知识、验证机制与企业内部流程深度整合，谁就掌握了下一代AI自动化的护城河。**

准确率越过人类基准线

根据Serafini援引的llm-stats.com排行榜数据（截至2026年6月），AI Agent在OSWorld-Verified基准测试中的表现在过去一年发生了质变：一年前最优模型得分为42%，如今最优模型Claude Fable 5已达85%，超过人类测试者在同一任务集上约72%的完成率。



这一基准测试模拟真实桌面环境，覆盖Ubuntu、Windows和macOS工作流，考察Agent能否独立完成浏览器操作、表单填写、按钮点击等任务。Serafini指出，在生产环境中，企业和开发者几乎不使用Claude、ChatGPT等消费级产品，而是直接调用原始API，并在此基础上自行构建沙箱虚拟机、编排逻辑、验证与重试机制。

一位在该领域创业的创始人表示，“直到2026年2月Opus 4.6发布之前，这些模型还不够好，无法独立用于生产环境。”这一表述印证了能力跃升的时间节点。

值得注意的是，85%的完成率意味着每100个任务仍有15个失败，而后台业务流程要求每一步都必须成功。Serafini强调，基准分数并非生产可行性的充分条件，真正决定部署成败的是模型之外的一切：验证机制、异常上报、错误处理，以及当零售商门户一夜之间改变页面布局时系统能否修正。

成本曲线触发经济拐点

Serafini援引多方数据对三类劳动力的全成本进行了横向比较。AI Agent每小时推理成本约为6至8美元，实际区间为3至15美元，取决于截图频率、上下文长度及确定性代码的复用比例；印度离岸BPO人力全成本约为每小时10美元，区间为8至15美元（数据来源：Globalify、HiveDesk及1840 & Co的2026年外包定价报告）；美国本土后台员工全成本约为30至45美元（基于美国劳工统计局客服代表中位时薪20.59美元，叠加约30%的福利与管理费用）。

Serafini提示，上述数字应作为数量级参考而非精确报价。他指出，上述Agent成本描述的是“最贵模式”——以前沿模型逐帧截图方式运行。经过优化的执行框架会将可重复部分交由确定性代码处理，仅在必要时调用模型，由此可大幅压低混合成本。

从卖方视角看，单位经济模型更为复杂：推理成本加上重试成本（失败的运行同样消耗token）构成主要变动成本，当上下文增长或截图频率上升时，利润空间随之收窄。目前市场上存在按任务、按小时、按结果三种定价模式，各自对应不同的风险分布，尚无统一标准。

协议遵循型任务是当前主战场

Serafini团队与多个生产环境团队的访谈揭示了一个清晰规律：AI Agent在标准化、可重复、路径明确的任务上表现最佳，在需要判断“什么是正确结果”或无法即时验证成功与否的任务上则容易失效。

具体案例包括：一家消费品数据平台每月运行约1500万至2000万次自动化门户交互，将Agent用作自愈式备用方案——当零售商门户UI变更时，Agent自动诊断并修复抓取逻辑，工程团队的爬虫维护人员因此缩减一半；一家全球系统集成商部署了27个实时工作流，每天处理约1500至2100张IT工单，目标是将低利润托管服务合同中20%至25%的人力重新部署；一家招聘机构将候选人面试结束后的数据录入流程完全自动化，使用的是非前沿轻量模型，“它能做我们需要的一切，而且做得很好”。

失效场景同样典型：若Agent将合同中的“net 60”误读为“net 30”录入ERP系统，记录外观完全正常，直到错误发票发出才会被发现；若Agent提交保险理赔后系统显示“已收到”，但两天后理赔员致电要求确认保单号，Agent对此毫无感知，理赔悄然搁置。Serafini指出，更智能的模型无法修复一个“真相以一周后某人桌上的电话形式出现”的流程，除非执行框架从一开始就针对这类边缘情况进行设计。

护城河已从模型层上移至上下文层

Serafini认为，随着UI导航能力逐渐成为模型层的标准功能，“能否点对按钮”不再是竞争壁垒。真正持久的优势在于对特定企业工作流的深度理解：内部术语、偏好格式、上报路径、失败处理方式，以及如何可靠地验证输出结果。这些知识存在于操作手册、访问凭证、测试用例中，往往也存在于一段员工实际操作的录屏里。

受访买家的反馈印证了这一判断：他们选择供应商的标准是“产品能否无需额外工作就报告节省了多少小时”，以及“初级工程师能否独立运行”。一位每月运行数百万次自动化任务的运营商表示，他甚至不知道底层调用的是哪个模型——供应商像云服务商更换硬件一样在底层切换模型，而他信任的是整个系统能可靠完成任务。

Serafini据此判断，下一代AI自动化的核心竞争将发生在应用层与上下文层，而非模型层。专注于特定垂直场景的初创公司，在解决这类具体而繁琐的问题上，往往比模型提供商更具优势。

基础设施投入与架构演进

Serafini指出，过去一年，各大实验室与一批初创公司已向计算机使用强化学习训练环境投入数亿美元，相关公司包括Mechanize、Habitat、Fleet、Chakra、Deeptune、Matrices和Originator，这些公司正在为前沿模型构建训练与评估基础设施。这一投入直接转化为模型在推理、状态追踪和容错方面的能力提升。

在架构层面，当前生产环境中的大多数系统仍为单Agent模式：一个模型、一个任务、一个会话。随着工作流复杂度上升，多Agent架构开始显现必要性——规划Agent分解任务，执行Agent并行处理子任务——但长时运行Agent带来的记忆管理、信任机制与复合失败率问题，目前尚无标准框架解决，各团队均在构建定制化编排方案。

Serafini认为，未来发展将沿三条主线推进：准确率（捕捉异常、自我核查、按需上报）、延迟（部分团队已通过基于可访问性树而非截图的方式显著降低延迟，Standard Intelligence基于1100万小时视频数据集、以30帧每秒运行的通用计算机动作模型是早期信号）以及成本（推理持续降价，轻量开源模型承接更多常规操作）。安全与治理——包括凭证管理、审计日志、数据留存、提示注入防护与权限管理——也被列为同等重要的发展维度。

本文来自微信公众号「[AI原生Lab](#)」，持续拆解真实AI落地案例，分享企业AI实践与方法论。

AI原生Lab

研究 AI 原生实践，重构组织与工作

拆解 AI 实践， 重构企业能力。

真实案例 | 方法提炼 | 落地复用



关注 AI 原生 Lab
获取更多 AI 原生实践

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

14 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论