

摘要：

开源Kimi K3打破硅谷双头垄断，引爆AI界“斯普特尼克时刻”！大模型以1%成本步入“精密制造”时代。未来推理成本将暴跌50倍，端侧智能全面爆发。前沿模型加速沦为“易耗品”，应用接口层成最大赢家，企业资产迎来重估风暴。

随着月之暗面（Moonshot AI）发布拥有 2.8 万亿参数的开源模型 Kimi K3，硅谷迎来了 AI 领域的“斯普特尼克时刻”。

在最新一期《Moonshots》访谈中，Peter Diamandis、Emad Mostaque（前 Stability AI 联合创始人）等五位科技领袖深入探讨了 Kimi K3 打破传统闭源双头垄断的行业震动，指出大模型演进已进入“前沿制造业”阶段，并预测在硬件适配、软件优化与极端量化（如三元量化、亚比特量化）的推动下，未来几个月内 AI 推理成本将迎来 10 至 50 倍的爆发式下降，最终加速高阶智能在私有化部署与端侧设备上的全面普及。

核心要点

- **AI“斯普特尼克时刻”降临：**AI 实验室月之暗面（Moonshot AI）发布拥有 2.8 万亿参数（2.8 Trillion）的开源权重模型 Kimi K3，在前端代码竞技场（Front-end Code Arena）力压 Claude Fable 5 登顶第一，打破了硅谷此前由 OpenAI 与 Anthropic 主导的前沿模型双头垄断。
- **“造模型就像精密制造业”：**Kimi K3 依然基于标准的 Transformer 架构，其成功在于极致的数据精炼与工程制造能力。开源社区已证明，通过内核优化与数据清理，能够以传统成本 1% 的资金逼近顶尖前沿模型性能。
- **推理成本将暴跌 10 至 50 倍：**前 Stability AI 联合创始人 Emad Mostaque 表示，K3 目前每百万 Token 售价约 15 美元，但随着模型针对下一代硬件的适配以及开源推理服务商的极限优化，未来几个月内其推理成本还将迎来 10 到 50 倍的下行空间。
- **端侧智能与极端量化革命：**随着三元量化（Ternary, 1.58 bit）、二进制量化（Binary）及亚比特量化（Sub-one bit）技术的突破，到明年底，具备 K3 级别智能的模型将能够直接在 16GB 内存的手机或车载端侧设备上离线运行。
- **前沿智能变为“易耗品”：**前沿 AI 的“保鲜期”缩短至数周，企业评估模型的速度已跟不上迭代速度。未来的核心资产将从单一依赖闭源 API，转向可自由切分、微调开源模型的“架构接口层”。

Kimi K3横空出世：2.8万亿参数打破硅谷双头垄断

日前，AI 实验室月之暗面（Moonshot AI）突然发布了新一代前沿模型 **Kimi K3**，给硅谷及美国前沿实验室带来了如同“四倍浓缩咖啡”般的震撼。

Kimi K3 拥有高达 **2.8 万亿参数（2.8 Trillion Parameters）**，在性能上实现跨越式突破：不仅在前端代码竞技场（Front-end Code Arena）击败了 Claude Fable 5 斩获全球第一，还在品牌营销、设计、数据分析、消费品模拟及内容创作等 6 大领域登顶。更令行业震动的是，该模型

的完整权重定于 7 月 27 日全面开源，意味着全球任何企业与开发者均可免费下载并在本地（On-Prem）部署。

Alex Wieser-Gross 在分析人工智能指数（Artificial Analysis）的最新帕累托前沿图（Pareto Frontier）时指出：

“此前，前沿 AI 领域基本上被 OpenAI 和 Anthropic 双头垄断。而现在，随着 Meta、SpaceX AI 的加入以及中国 Moonshot 跻身帕累托最优前沿的第三名，**前沿 AI 竞争已全面演变为自由混战**。这对于希望通过开源模型掌握自身数据主权的企业而言，是巨大的福音。”

“做模型就像精密制造业”：用1%的相对成本逼近前沿

面对 Kimi K3 的性能跃升，美国前沿实验室不得不面对一个严峻的问题：**如果不用打破 Transformer 框架，就能达到逼近 GPT-5.5 Max 的水平，美国实验室每年烧掉的数十亿美元到底花在了哪里？**

Alex Wieser-Gross 补充道，K3 的已公开架构并没有“黑魔法”，本质上依然是标准的 Transformer，结合了专家混合（MoE）与线性化注意力（Linearized Attention）等成熟技术的精妙组合。

前 Stability AI 联合创始人 **Emad Mostaque** 提出了一个极其深刻的视角：

“打造顶尖模型，本质上是**前沿制造业**。他们极其清楚原材料（数据）与制造流程，并在现有的硬件约束下将工程化与易用性发挥到了极致。”

针对训练成本，**Dave Blundin** 举例说明，GitHub 上的开源加速项目（如 Keller Jordan speedrun）此前已成功将 GPT-2 级别的训练成本削减了 99%。而 Kimi K3 的出现，正式验证了这些软件栈优化、内核重构与数据去糙取精（如使用 Muon 优化器剔除无用 Token）的思路在**前沿超级大模型规模下完全成立**。

极端量化与端侧智能：推理成本还将暴跌10至50倍

在谈及 AI 的商业化落地与成本曲线时，**Emad Mostaque** 给出了极其乐观的预测。

目前，Kimi K3 的每百万 Token 调用成本约为 15 美元，虽高于普通开源模型，但考虑到其在本土芯片上运行且已具备极高利润率，未来的下行空间极为惊人：

“一旦将 K3 这种模型部署在下一代芯片或专用光子芯片上，并经过全行业的极限优化，**未来几个月内，其推理成本将再降 10 至 50 倍（乃至百倍）**。”

与此同时，**端侧智能（Edge AI）** 正迎来量化技术的暴风雨。

◦ **Prism ML 发布的 Bonsai 27B**：作为首个在智能手机本地完整运行的 270 亿参数模型，通过三元量化（Ternary, 1.58 bit），将模型体积压缩至 6GB（精度仅损失 5%），在完全离线状态下赋予手机 110-120 IQ 的智能。



- 三星与腾讯的极度量化：三星最新的 Nano Quant 已经突破了“每权重 1 个比特”的界限（Sub-one bit）；腾讯团队则实现了 3000 亿参数模型的二进制压缩（Binary Compression）。

Emad Mostaque 强调：

“到明年年底，一个仅需 16GB 内存的普通设备，就能运行达到今天 Kimi K3 级别的模型。这意味着世界上每一辆汽车、每一个机器人、每一台智能设备都将拥有内置的持久智能，可以在边缘侧进行自主决策。”

前沿智能变成“易耗品”：企业资产重估与开源大势

随着模型发布频率从过去的每 60 天缩短至每 10 天，甚至即将在明年初实现“日更”，前沿智能的商业形态发生了根本性转变。

OpenExO 创始人 Salim Ismail 提出：

“前沿智能（Frontier Intelligence）现在变成了一项完全易过期的资产，其保鲜期只有区区几周。任何企业如果要经过层层审批、内部开会来评估是否部署某款模型，等评估完成时，该模型在技术上已经落后了三代。”

这一趋势对企业资产定价与科技巨头估值带来了深刻重塑：

- 基础模型厂商估值承压：如果企业可以直接免费在本地运行性能媲美顶级闭源模型的开源权重，闭源 API 服务的溢价空间将被大幅压缩。
- 应用与架构层成为最大受益者：知名投资者 Gavin Baker 指出，除了基础模型厂商外，几乎所有的实体企业、软件公司与传统行业都是 AI 成本暴跌的巨大受益者。未来的核心竞争壁垒在于能否将模型灵活无缝嵌入自身业务流程的“架构接口层（Interfaces）”。

以下为访谈全文，由AI辅助翻译：

Peter Diamandis: 今天我们发出了紧急信号，召开这场紧急播客，因为美国刚刚经历了 AI 领域的“斯普特尼克时刻”。Kimi K3 于昨天发布，以有史以来最大的开放模型震惊了整个 AI 界，并直接登顶第一。

Emad Mostaque: 这个星期他们不仅缩小了差距，而且直接翻过了篱笆。Kimi 一直是一个感觉有点不一样的模型，这就是为什么它一直在写作基准测试中名列前茅。例如 K3 实际上是一个多模态模型，因此它可以接收各种输入并做出理解，这也是它在前端领域如此出色的原因之一。

Alex: 现在美方是 Meta 和 SpaceX AI 之间的自由竞争，而中国和 Moonshot（月之暗面）则成为了帕累托最优前沿上的第三名。前沿智能现在成了一项完全易过期的资产。

Peter Diamandis: 美国的前沿实验室把钱都花到哪里去了？

Salim Ismail: 在互联网世界我们一直有这个信念，即信息渴望自由，基本上智能也渴望自由。



Peter Diamandis: 我们现在需要的是某种全球性的……现在，那可真是个月球采样（Moonshot），女士们先生们。

Peter Diamandis: 欢迎来到《Moonshots》，所有人！全网关于 AI 与指数级技术第一的播客，您通往即将到来的奇点的前排座席——也许我应该说，通往现在的奇点、通往当下的奇点、通往持续的奇点。今天我将……今天我们发出了紧急信号并召集了紧急播客，因为美国刚刚经历了 AI 的斯普特尼克时刻，不过稍后会详细介绍。请允许我欢迎我优秀的 Moonshot 伙伴们，今天我们五人组全员到齐：Alex Wieser-Gross、Dave Blundin、Salim 和 Emad Mostaque。我是你们的主持人兼丰盈倡导者 Peter Diamandis。如果奇点的速度让你头晕目眩，很好，我的也是，而这正是重点。我们 Moonshots 的使命就是让您随时了解最新动态、跟上正在发生的事情，最重要的是，在非凡的变革速度与即将到来的丰盈时代中保持乐观。各位，欢迎，感谢大家大老早起床，或者对 Emad 来说是在下午。

Emad Mostaque: 我今天早上 4 点就起来了，时差的好处，不过我确实还能再睡一小时。

Salim Ismail: 欧洲午睡时间。

Emad Mostaque: 对，这之后我还安排了健身。

Peter Diamandis: 很多事情正在发生，各位，非常感谢大家的时间。在开始之前，我想亲自向我们所有的订阅者和观众说声谢谢。我不知大家最近有没有机会看看和阅读 YouTube 的聊天记录，我能说的就是我们也非常爱你们。我们的使命是传递新闻，我们花了难以置信的时间进行审查。Salim、Alex 和 Emad，我今天早上收到了你们的短信，“添加这个，添加那个”，有太多事情在发生。我也必须说，所有 Alex 解释 JSpace 的梗图都很棒，所以继续制作 Alex 的梗图吧。

Alex: 看看你们能不能搞懂我的 JSpace。

Peter Diamandis: 能看到里面的读数。在评论区也看到了很多对你的喜爱，有一些非常棒的人。难以置信的是，大多数 YouTube 视频 newspapers 都是喷子狂欢，而我们的完全相反，真的非常棒，向你致敬，Peter。不，我只是再次表达绝对的感激，感谢大家抽出时间听播客。我们团队和所有 Moonshot 伙伴花了大量时间评估发生了什么并呈现出来。如果您还没有订阅并开启通知，请开启。

Salim Ismail: 我只想说明，如果我们做足够多的这种紧急播客，在某些时刻它就会变成 Moonshots 每日播客。

Peter Diamandis: 或者是持续播客。我依然觉得大家一起搬进 Airbnb 然后打开摄像头，这早晚会发生。

Peter Diamandis: 好了，让我们切入第一个故事，这是个大新闻。我们刚刚经历了一个 AI 的斯普特尼克时刻，就像给美国的极前沿实验室注射了四倍浓缩咖啡一样。Kimi K3 于昨天发布，以有史以来最大的开放模型震惊了 AI 界，并直接登上第一名。这里有一些背景：Kimi 来自中国实验室 Moonshot AI（月之暗面）。在过去一年里，他们攀登排行榜，推出了 K2、K2.6、K2.7，每一个都在缩小与 Anthropic 和 OpenAI 的差距。这周他们不仅缩小了差距，而且一夜之间跨过了篱笆。他们发布了 Kimi K3，这是一个拥有 2.8 万亿参数的怪兽。他们完全绕过了计算墙，K3 比之前的 Kimi 模型跳升了 17 个名次，超越了 Claude Fable 5，在前端代码竞技场（Front-end Code Arena）斩获第一。K3 在其他 6 个领域也排名第一：品牌与营销、基于参考的设计、数据分析、消费品、模拟和内容创作。完整的模型权重定于 7 月 27 日左右发布，这意



意味着地球上的任何人都可以下载并在自己的本地（On-Prem）运行。各位，这有多重要？

Alex？

Alex: 我认为这对竞争非常有好处。首先作为一个初步事项，我想指出一些在报道和对 K3 的狂热中不太明显的事情。第一，正如 Moonshot 指出的，他们声称在过去 12 个月中的 9 个月中，Kimi 模型系列保持着开源权重模型中的 SOTA（最高水平）。如果这个说法属实，那么在过去一年里基本上一直都是 Kimi。第二，看看已发布的架构，因为我们还没有看到开源权重，但承诺在月底发布，里面并没有什么魔法，这非常引人注目。人们可以想象在 Anthropic 或 OpenAI 的幕后，Sam Altman 继续在暗示幕后有一些后 Transformer 架构实现了所有这些性能突破。但看看已发布的 K3 架构，没有魔法，它本质上仍然是 Transformer。他们显然做出了一些创新，但在他们如何做专家混合（MoE）、如何线性化注意力方面是大家熟知的创新，他们有自己的特殊的 Kimi 品牌的线性化注意力，但它本质上仍然是一个可识别的 Transformer。一个可识别的类 Transformer 架构可以在任务成本前沿上几乎匹配 GPT 5.5 Max，我认为这相当惊人。这就提出了一个问题：如果只需使用 Transformer 就能达到如此接近的水平，美国的前沿实验室把钱都花在哪了？如果它已经处于成本前沿，并且整体 AI 性能排在第三位，美国实验室到底把所有的钱都花在什么地方了？所以至少知道 Transformer 架构依然宝刀未老，我感到莫大的安慰。Emad，听听你的分析，因为你一直在追踪这个。

Emad Mostaque: Kimi 一直在各种基准测试中名列前茅，他们自一年多前发起以来就定期推出中国最大的开放权重模型。正如 Alex 所说，架构并没有什么特别新颖的地方，有一些改进，比如他们与 UCLA 等机构做的 Muon 缩放，他们一直在发布所有这些部件的线索。我认为这里的关键是底层数据。Kimi 的模型感觉一直有点不一样，这就是为什么它在写作基准测试中总是第一。他们在这里做的事情似乎非常非凡：GLM 出来时是个极好的模型，但仅限文本；而 K3 实际上是一个多模态模型，因此它可以有各种输入并做出理解，这也是它在前端如此出色的原因之一，尽管我们没料到它在前端代码上力压所有人登顶。这涉及我之前说过的话：构建优秀稳固的模型是前沿制造业。虽然会有算法改进等各种东西出现，但为什么中国电动车比福特更好？这感觉是同一回事。这是工程学，但也像上个月英国销量第一的车型 Jaiku J7，满配出来只要 5 万左右，只有三分之一的价格。这感觉非常相似，他们知道原材料成分，现在以一种对消费者极其友好方式呈现，并正在用他们现有的资源无情地执行制造过程。因为看架构内部，他们仍然在使用 H800，在 Nvidia 芯片上落后了几代，但他们通过静态形状等手段充分利用了华为和阿里的下一代芯片，在工程和易用性上不断推进，这就是为什么前端代码异军突起的原因。他们只是在想“如何做出最惊人的输出”，从个人网站到游戏；而美国实验室可能在看其他方向，专注于不同的事情。

Peter Diamandis: 有个问题，我们一直在讨论是否需要 LLM 之外的新突破才能实现 AGI，这是否让你确信我们不需要另一个突破就能继续前进？

Emad Mostaque: 这取决于对 AGI 的定义，对吧？六年前就讨论过。你有基础模型，然后所有这些优秀的套件，以及模型自我调用的方式。Kimi 博客文章中提到的一件事是，它实际上为自己的下一代设计了芯片，并设计了自己的运行内核。所以你从这个模型权重跨越到了模型本身构建的整个生态系统，这感觉就很 AGI，对吧？这感觉就像递归自我改进，感觉像通过动态改变自身来学习和适应新技能的能力。所以对于大多数 AGI 的定义，我们可能不需要新东西来优化和使其变得超级高效。甚至根据我们所知，它可能比现有的更高效，只是我们没有足够的算力，而新架构可以推动我们更进一步。你可以说“Attention Is Still All You Need”（注意力依然是你所需要的一切）。

Alex: 我们展示了性能图表，看到 Kimi K3 在多个地方登顶。如果能调出 AI 散点图，这是最有启发性的一张，来自 Artificial Analysis 智能指数。在所有图表中，这是我最喜欢的一张，因为它显示了 AI 定义的每任务成本与性能前沿。从左下到右上有一条锯齿状的前沿，右上角每任务最大成本和最大综合得分仍然是 Fable 5；沿着帕累托前沿往左下看，几天前前沿上的第二名仍

然是 GPT 5.6 Solve Max；而现在 Kimi K3 首次成为了第三名。无论是在原始能力方面，还是在最佳成本性能前沿的第三点上，它都处于前沿。这太震撼了。我们从几年前 OpenAI 和 Anthropic 双头垄断的世界，变成了现在美方的 Meta 与 SpaceX AI 加入帕累托前沿顶端自由竞争，而现在中国和 Moonshot 成为了帕累托最优前沿上的第三名。这对于任何愿意并能够使用中国开放（即将开源权重）模型来掌握自己命运的企业来说，都太令人兴奋了。我认为这是企业主权和竞争力的福音。我们正生活在 AI 版的《全人类》（For All Mankind）中，苏联人首先登上了月球，而现在太空竞赛永不结束。AI 竞赛不再以双头垄断结束，我认为这是未来光锥（Future Light Cone）的彻底福音。

Dave Blundin: Peter，你称之为斯普特尼克时刻，如果说有什么不同的话，那是低估了它的影响。上周 Alex Karp 在播客里发飙说：作为一个大企业或政府，你不能直接把所有的专有权重、专有 Alpha 和知识产权越过墙抛给 Anthropic 并作为未来的基础。但他没有给你路线图。仅仅一周后，正如 Alex 所说，这突然变成了一场自由竞争，任何读取这些权重的人都有能力极其接近前沿，然后针对任何垂直用例在超越前沿的领域进行微调。这给全世界的每个人、每家公司和每个政府提供了一种无需通过美国 AI 模型即可赶上前沿的方法。所以斯普特尼克时代乘以无限大。我不喜欢这张特定图表的地方在于左侧索引到了 100%，当绘制未来两年的图表时，它看起来像一条 S 曲线，我们现在处于非常陡峭的部分，但这暗示我们到了 100% 就达到了终点。但这实际上是一个指数级增长，智能趋于无穷大。基准测试饱和了，但智能本身趋于无穷大。典型的运作方式是嵌套的 S 曲线，对吧？一种特定技术触顶，但它构建了下一种开始指数上升的技术，以此类推。

Dave Blundin: Alex 和我花了大量时间研究 Keller Jordan speedrun，我们在 GitHub 上寻找它，它是一群黑客和 AI 研究人员不断试图采用五年前 Andre Karpathy 的 nanoGPT 形式的 GPT-2 类模型，尝试更快更便宜地再现它。如果你看看那个仓库里的创新，他们已经能够将创建 GPT-2 的原始成本降低 99%，现在只需原始成本的 1%。大家此前没太关注是因为它是 GPT-2，直到今天才明确这些想法是否适用于前沿规模。现在非常明确的是，当 Elon Musk 拿他的 160 亿美元 Colossus 2 数据中心花数十亿美元构建 10 万亿或 20 万亿参数模型时，存在一个 1% 成本的版本来创建实际上相同的东西。在 Kimi K3 之前没人知道这是否行得通，现在非常清楚它行之有效。我们在软件栈、内核优化、MoE 中看到了 100 倍级别的创新，这些来自中国的根本突破给他们带来了 1% 的成本。Ahmad 给汽车做了一个很好的类比，你可以以大约三分之一的价格获得几乎相同的汽车；而在这里，我们讨论的是不到 1% 的价格来创建同等产品。所以斯普特尼克时刻是本世纪最大的保守说法，这就是我们今天开紧急播客的原因。

Salim Ismail: 我有三点要说。我认为重点不在于 Kimi 击败了谁，而是前沿智能现在成了一项完全易过期的资产，对于任何达到最前沿的人来说，保鲜期现在只有几周。任何对最新的前沿模型感兴趣的企业或政府都没有时间去实际评估它、做 RFP、看其他模型、内部成立委员会思考是否部署，因为到时候你在模型上已经领先了三代。因此，所有的价值都来到了可以交换模型的架构上，我们 OpenExO 世界中称之为接口（Interfaces），这将是所有价值未来的归宿。

Dave Blundin: 我们需要一个新的词，比如“前沿解放阵线”（Frontier Liberation Front）。对于超级极客们，Ahmad 刚才提到了 Muon 优化器，任何爱好者都可以去查一下。我们构建这些原始的大规模模型时，从互联网上抓取了 20 到 30 万亿 Token，将人类写过的每个字都倾倒入训练集中，让 AI 变得聪明。但深入内部，大部分信息是泰勒·斯威夫特的演唱会和婚礼，这些并不能显著提升模型的智能，事实上恰恰相反。

Dave Blundin: 很多 Token 可能会拉慢训练而不是加速。因此仅通过清理垃圾并将训练集缩减为相关子集，就能在达到相同智能水平的同时减少 FLOPs 计算量。我们离解决这个问题还远着呢，所以你可以期待从 Muon 优化器过程和训练数据集精简过程中看到更多的 10 倍提升。



Peter Diamandis: 我放出了一个叫 Allaric 的人发出的令人深思推文：Anthropic 表示“Fable 是一种具身代码超级武器，能够以前所未有的速度和规模开发网络和生物武器，出于诚信我们不能在没有护栏的情况下发布它。”这是上个月的对话；而中国回答说：“笑死我了，这是 Fable 的开源版，祝你好运。”我很好奇，你们怎么看待我们因为护栏受到限制，而这里出现了 Fable 的开源等价物？

Salim Ismail: 前沿实验室面临三个巨大的根本约束：一是算力和芯片可用性及电力；二是与它们一样好甚至在许多情况下可无缝替代的前沿开源模型；三是政府审查。我拍脑门猜一下，当政府说必须审查所有模型时，OpenAI 原本价值万亿的估值缩水了大约 50%；我认为这又砸掉了 50%。如果不需要花 API 的钱，直接在本地运行 Kimi K3，我为什么要花这个钱？他们会受到收入大幅减少的打击吗？

Emad Mostaque: 有两点：一是收入减少，为什么人们依然为 IBM 付费、为非中国汽车付费？对于关键任务实体，确保不会出错的服务仍将维持一段时间，因此 OpenAI 等公司的收入仍会增长。但这里有替代效应，就像中国工业替代一样。在网络攻击安全方面，这意味着唯一能做的就是网络防御（Cyber Defense），这必然是风险投资中绝对最大的类别。如果是斯坦福或 MIT 的优秀毕业生，去建立一家切入前沿的网络防御初创公司，防御不可避免会到来的东西，因为这些能力的扩散会增加。GPT 5.6 网络版、Fable 等接受了大量 CVE 和网络数据训练，而中国模型实际上没有那么多，但有人可以将这些数据训练进去，因此我们可能会在特区看到具备网络攻击能力的开源出现。

Dave Blundin: 我们略过了递归自我改进（RSI）。美国政府的观点是：当我们得到一个能够构建自身、构建下一个模型的模型时，我们不会让它流向世界上的每个人，因为制造界从未有过像 AI 这样的产品。如果你有一辆最先进的汽车给外国政府，他们不能用它造出更好的车；但如果你把最先进的 AI 给外国政府，他们可以用它赶上你并创建最先进的 AI。一个月前政府意识到 Babel 5 跨过了那条线并阻止了它，只要有一个能够改进自己内核的 AI 就够了，人们以为 RSI 会在达到爱因斯坦级别智能时触发，但它只需要能够改进自己的内核并实现 10 倍的速度提升，这足以让它自我加速 10 倍。学术界很多人说参数数量的收益递减，但事实证明他们错了。所有证据表明，如果将原始速度提高 10 倍，就会看到天才级别的 AI。回过头看，Opus 4.8 左右就是微小的火花足以点燃火焰的点。限制下一个模型的政策不可能遏制前沿 AI 的全球和企业扩散。

Salim Ismail: 把两个想法融合一下：Ray Kurzweil 最初的观察是，一旦拥有基于信息的范式，就会在多种技术之间跳转。我们有真空管、继电器，然后是集成电路，这些都是嵌套的 S 曲线。随着这些架构的各部分在内部获得自我强化循环，每个循环都像是在加速整体的 S 曲线，它是不可阻挡的，没有极限，这就是为什么人们对它的上限感到如此震惊。

Emad Mostaque: 这对中国来说太棒了，从拥有十亿 IQ 即将通过这些工具提升的人口，到需要机器人解决人口结构问题，再到将受过中国教育的大脑嵌入世界各地的每个关键系统。过去中国实验室审核模型需要 60 天，现在大约需要一周。

Alex: 还要注意，杨植麟是 CMU 的毕业生，我们本可以给他发签证让他留下的。

Peter Diamandis: 这里有一张有趣的图表展示了估值：Moonshot AI 的估值为 200 亿美元，而 Anthropic 和 OpenAI 基本都在万亿级别。如果他们今天是上市公司，股价估计会下跌 30%。美国前沿实验室在用他们的资本做什么？

Dave Blundin: 如果你走进大楼与他们交谈，他们极度渴望更多聪明人来帮忙，因为他们正以从未有过的疯狂速度部署和改变世界。人类历史上从未有人以如此快的速度将这么多钱涌入他们的建筑，而之前没有任何商业经验，许多 CEO 从未运营过公司。如果你很聪明并且有好的想法，进入那些大楼并提出你的想法。前沿实验室也在问自己和美国监管机构这个问题。



Alex: 存在一种倾向去低估“存在性证明”的价值。仅仅知道运行在 Muon 优化器和简化数据上的高度扩展 Transformer 行之有效，就给了一份精炼的路线图。你不需要抄袭或窃取每个痕迹，只需知道该公式有效，这就能将研发成本削减 90% 到 95%。

Salim Ismail: 我有个绝妙的价值创造想法：9 天后当他们放弃开源权重时，我们以 Moonshots 播客的名义发布一个名为 Kimi 4 的开源模型并 IPO，瞬间我们就会成为亿万富翁。

Emad Mostaque: 我有个很好的类比：为什么美国人比其他人为药物支付更多费用？所有的研发都在美国发生，你支付溢价，然后其他地方有了通用仿制药（Generics）。这像极了 AI，是 99% 的成本削减。

Dave Blundin: 我们的朋友 Gavin Baker 在 X 上写了一篇杰出的文章，关于这对企业的深远影响。除了基础 AI 实验室之外，所有企业、所有股票都是巨大的受益者。基础实验室的未来和收入模式会受到追问。基于这一观察，下周应该会看到估值的剧烈重组。任何在技术上准备充分的企业（如具备卓越 IT 技能的银行）现在都有了一条明确的路线图，可以用自己的 AI（如 JP Morgan AI）来控制自己的命运。

Salim Ismail: 这就是为什么我们称之为“组织奇点”(Organizational Singularity)。每当使用 Fable 5 的人提到生物学或潜在边缘领域时都会被降级，为什么要忍受这些？9 天后每个人都会升级，我在 Mac Studio 上运行 Kimi 2.7，我会升级到 Kimi 3。

Emad Mostaque: 这就像 Stable Diffusion 发布时一样，原本受限的图像生成器面对开源后，激发了 1 亿、2 亿次下载和整个生态系统的爆发。为什么你要忍受受限的模型？当你可以以极低的成本获得完全开放的变体并进行定制时，整个生态系统都会围绕它建立。

Dave Blundin: Mira Murati 刚发布了 Inkling，这是来自 OpenAI 的人才打造的美国开源实验室，旨在让企业在私有墙内针对特定用例进行微调。这告诉你最佳前沿实验室内部的人也相信这条途径可以赶上前沿。结合 Kimi K3 的验证，下周将是一个不同的世界。半导体公司的需求会增加而不是减少，芯片将比以往任何时候都更加供不应求。

Emad Mostaque: Kimi K3 使用的总计算量与 Inkling 相同，通过数据混合优势实现了 2.5 倍的数据到智能转换率。他们不得不针对华为 910 Ascend 芯片和阿里芯片优化推理。K3 目前放在那里是因为他们只能使用中国芯片来运行，而美国公司（如 Modal、Fireworks）由于拥有 Nvidia 和 AMD 大芯片，能够以比中国竞争对手便宜 10 倍的价格提供该模型的服务。一旦针对下一代 Vera Rubin 优化，价格将暴跌 10 到 100 倍。

Salim Ismail: 智能渴望自由，这是不可阻挡的。任何试图约束它的实体、领域或政府总是失败。这是基本的自然规律，试图限制它是一种非常匮乏的心态。我们越快获得更好的智能，就能越快实现丰盈，越不需要争夺任何东西。

Peter Diamandis: 自 4 月中旬以来，我们看到了 13 个新的前沿模型发布，平均每 10 天一个。Elon 今天早上发推称：“我们的 2 万亿模型在各个方面都优于 1.5 万亿模型，下周将完成初始训练，速度和 Token 效率接近 Grok 4.5。”这证明了我们生活在奇点之中。

Alex: 如果将前沿模型发布进行指数曲线外推，按照目前的速率，到明年 1 月，我们将看到每天都有新的前沿模型发布！这基本上意味着持续的版本更新。

Peter Diamandis: 看看 Kimi K3 的用例：重现喜欢的游戏，或在浏览器中模拟 Apple 桌面。每个人都成为了创造者和制造者。



Salim Ismail: 单次生成游戏与构建包含客服和营销的整个生态系统大不相同，但根据个人兴趣启动游戏的摩擦力现在接近于零。

Dave Blundin: 许多人不擅长管理自己的幸福，只能忍受日常工作。在有选择的情况下你会做什么？AI 能够帮助我们探索这些可能性。

Peter Diamandis: 听到 Kimi K3 的崛起，你有两种选择：恐惧，或者意识到你释放了创造力，找到你的宏大变革目标（MTP），使用这些工具在宇宙中留下痕迹。

Peter Diamandis: 如果说 Kimi K3 是数据中心里数万亿参数的大模型，那么 Prism ML 的 Bonsai 27B 就是极小化的代表：第一个完全在智能手机上运行的 270 亿参数级模型。Emad，告诉我们为什么这很重要？

Emad Mostaque: Prism ML 和腾讯在量化方面取得了巨大提升，将 16-bit 或 8-bit 模型压到了 3-bit 的三元（Ternary，约 1.58 bits）甚至二进制（Binary）。Bonsai 成功将 27B 模型降到了 6 GB（精度仅下降 5%），降到 4 GB 时精度下降 15%。这意味着你在手机上拥有了一个离线可用的 110-120 IQ 的助手。从 16-bit 降到 3-bit 带来了 5 倍的速度提升。

Dave Blundin: 底层所有的计算一直都是矩阵乘法（MAC）。如果其中一个数字只是 1、0 或 -1，乘法运算将变得极其高效，这开启了新型计算的大门，未来我们将在晶体管、光子乃至液晶等新介质上进行计算。

Alex: 最量化的 Bonsai 模型约为 1.125 个有效 Bit/权重。三星最近发布了 Nano Quant 模型，打破了每权重 1 个有效 Bit 的屏障（Sub-one bit）。亚比特量化将在未来一年内成为主流，光子计算将成为未来的计算方式。

Emad Mostaque: 到明年年底，能够运行在 16 GB 内存上的模型将达到 Kimi K3 的水平。这意味着世界上每辆车、每个机器人和每台设备都有内置的持续智能，可以在边缘做出自主决策。智能成本在明年年底前将通过新型芯片速度降低 100 倍。

Dave Blundin: 基于量化和新计算方法，我们预计未来三年内原始算力将实现 100 到 10,000 倍的提升。结合算法改进，提升可达百万倍。

Peter Diamandis: 谈谈预测未来。根据 ForecastBench 数据，几个 AI 模型在统计上已经与顶尖的“超级预测员（Superforecasters）”无法区分。AI 能够在保险、投资、地缘政治和企业战略中提供疲倦永不消退的超人顾问。

Alex: 当超强预测与资本市场连接，AI 算法交易员对人类拥有比人类自身更好的内部自回归模型时，预测将超前塑造市场的行动，有效市场假说（EMH）将被加冕为王。

Salim Ismail: 高管大部分能力（预算、招聘、投资）本质上 salaried 都是预测。一旦 AI 具备这种预测能力，senior management（高级管理层）将大量蒸发，人们需要更加专注于目的和目标。

Dave Blundin: 人类的不快乐很大程度源于盲目的消费主义。AI 将成为极佳的教练，告别被动的的生活轨迹，给出最佳的替代路径。

Peter Diamandis: 欢迎来到 Fountain Life 赞助的健康环节。[健康广告插播]

Peter Diamandis: 关于数据中心耗水的辟谣：全美所有数据中心每年消耗 170 亿加仑水，而美国高尔夫球场消耗了 5310 亿加仑（31 倍），加州杏仁种植消耗 1 万亿加仑（60 倍）。

Salim Ismail: 亚马逊仓库占用的土地是数据中心的 10 倍。关于数据中心水耗和土地的恐慌完全是脱离数据的垃圾话。

Emad Mostaque: 麦当劳卖出的汉堡每年消耗的水量大约是高尔夫球场两倍。

Peter Diamandis: 聊聊人形机器人。中国已有 150 家人形机器人公司，最近机器人 MMA 格斗视频在网上疯传。

Alex: 虽然看到机器人格斗令人有些恐惧，但这代表了极其苛刻的工程压力测试（平衡、抗冲击、延迟等）。西方需要赶上，ProRL 在波士顿成功举办了人形机器人半程马拉松。

Emad Mostaque: Engine AI T800 机器人重 70 公斤，出拳力量是泰森的 4 倍。机器人在走进家庭前必须建立严格的安全监管标准。Unitree 目前仅生产了 11,000 台人形机器人，几年后将达到每年 1100 万台。

Peter Diamandis: 关于戴森群（Dyson Swarm）。Sam Altman 表示在太空部署数据中心目前是荒谬的，本十年内不会大规模生效。

Alex: OpenAI 自身退出了自建数据中心，存在明显的利益冲突。而 Elon 预测 2 到 3 年内将迎来成本交叉点。

Dave Blundin: 听听 Sam 的话，他其实和 Elon 的数据并不冲突，本十年只剩三年半，本世纪末相当一部分算力将在太空。近期 Starship 13 在 T-0 成功关断并导出燃料，展现了 SpaceX 惊人的控制与诊断工程能力。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

23 收藏

分享到:

写评论

请发表您的评论



