

AI云厂商展示的产品，正在从GPU算力进一步延伸至模型调用和智能体部署。

7月17日至20日举行的2026世界人工智能大会（WAIC）上，AI云服务商GMI Cloud集中展示了AI Cloud、Cluster Engine、Inference Engine和AgentBox等产品，覆盖GPU资源、算力调度、模型推理及AI Agent部署等环节。

这套产品组合背后是AI企业对云基础设施需求的变化。

过去，企业采购AI云服务，首先关注的是能否获得足够的GPU。随着大模型逐渐进入实际业务，企业还需要处理算力资源调度、多模型接入、高并发运行以及应用部署等问题。

GMI Cloud试图将这些环节连接起来。

底层的AI Cloud主要负责提供GPU资源。作为Reference Platform NVIDIA Cloud Partner之一，GMI Cloud提供英伟达H100、H200、B200、GB200和GB300等GPU资源，主要用于模型训练、微调和生产级推理。

在GPU资源之上，GMI Cloud此次还展示了Cluster Engine，这是一套面向AI工作负载的算力管理平台，主要解决的是GPU资源如何被有效使用的问题。

对AI企业而言，算力成本不仅取决于GPU单价，也与资源利用率、任务排队时间和集群稳定性有关。模型推理流量通常存在明显波动，固定配置大量GPU容易造成闲置，仅在业务高峰临时扩容又可能影响响应速度。

集群调度平台就此成为AI云厂商向上延伸的一层能力。

GMI Cloud在此次WAIC上重点展示的另一项产品是AgentBox，这是一套面向生产级AI Agent的部署、运行和分发平台，内置了内置 MaaS模型库，通过单一API 密钥即可无缝调用170+全球顶尖大模型。

此次展出的产品反映出AI云市场正在发生的变化。

随着单纯获取GPU不再是企业面临的唯一问题，AI云厂商也开始从资源供应商向模型和应用层延伸。

对GMI Cloud而言，GPU仍然是产品体系的基础，但业务边界已经扩展至推理和Agent运行。AI云厂商未来竞争的重点，可能不只是拥有多少算力，还包括能否帮助企业把模型和智能体稳定地部署到真实业务中。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 41  收藏

分享到:  

 写评论

请发表您的评论



表情



图片

发布评论

