

摘要：

杰富瑞认为，蒸馏技术降低大模型入场门槛，新玩家以数千万美元级融资进入头部榜单，API价格竞争也随之加剧。尽管AI推理需求仍在增长、算力需求保持扩张，但模型性能差距收窄和成本下降，也让高额资本开支能否转化为足够回报面临更大考验。

AI大模型竞争正在出现新变化：模型供给持续增加，蒸馏等技术不断降低研发门槛，新玩家开始以远低于头部厂商的资金投入进入高性能模型市场。杰富瑞认为，这一趋势正在压低API价格，也让AI行业此前依赖巨额资本开支建立竞争壁垒的逻辑面临挑战。

据杰富瑞9月16日发布的研究报告，在Artificial Analysis（AA）追踪的全球前14大语言模型榜单中，9月新增4个模型，分别来自新加坡、韩国、阿联酋和美国。这些模型背后的研发机构融资规模普遍有限，其中部分机构累计融资仅约2000万美元，却已经进入全球头部模型榜单。

杰富瑞分析师Edison Lee等人认为，LLM市场参与者数量持续增加，各地区对本土模型的支持力度上升，加上蒸馏技术广泛应用，正在进一步压低行业进入壁垒。与此同时，模型性能差距收窄和API价格竞争加剧，使AI供应链面临“高资本支出、低确定性回报”的新压力。

新玩家低成本入局，蒸馏技术降低门槛

报告显示，9月新进入AA前14榜单的4个模型分别为新加坡Sapiens AI的Agnes 3.0 Flash、韩国Motif Technologies的Motif-3-Beta、阿联酋MBZUAI的K2 Horizon，以及总部位于美国加州、研发团队在新加坡的Apodex 1.1。

其中，Sapiens AI累计融资约2000万美元，Motif Technologies完成约1660万美元B轮融资，整体投入规模与头部AI企业存在明显差距。

这类案例说明，大模型竞争的资本门槛正在下降。部分新玩家并没有复制头部企业大规模训练基础模型的路径，而是借助开放模型、较小规模团队和更高效的训练方法快速迭代。

蒸馏技术是其中的重要推手。通过利用现有大模型的输出训练新模型，开发者可以用更低成本获得部分先进模型能力。杰富瑞认为，这类技术很难被完全封堵，随着应用进一步普及，后来者追赶头部模型的成本仍可能下降。

但低成本入局并不意味着头部厂商的优势已经消失。训练最前沿模型仍需要大量算力、数据和工程投入，新玩家更多是在部分能力和细分场景中获得竞争力。真正的变化在于，“进入市场”与“做到最强”之间的资本门槛正在拉开。

API价格承压，模型开始进入价格竞争

模型数量增加已经开始向API价格端传导。杰富瑞数据显示，部分新模型的API价格已经显著低于头部模型，其中Apodex 1.1的混合API价格为每百万Token 0.3美元，在AA前15名模型中属于价格最低的模型之一。

与此同时，头部厂商并未全面加入降价，而是通过新一代模型的能力升级寻求更高定价。报告认为，这种提价不仅反映模型能力提升，也可能是向资本市场证明商业化能力的一种方式，即通过更高的智能水平支撑更高价格，从而改善市场对利润率和投资回报的预期。

问题在于，涨价与降价正在同时发生。头部模型试图用性能升级维持溢价，而新进入者则通过低成本争夺开发者和应用需求。杰富瑞指出，仅美国市场目前就已有7家大模型提供商，**参与者增加意味着API市场的价格竞争仍可能持续。**

从“拼智能”转向“拼效率”

模型竞争的另一变化，是行业开始从单纯追求模型智能，转向同时比拼推理效率。杰富瑞本月引入AutomationBench-AA基准测试，用于衡量模型在智能体自动化任务中的能力，并据此重新校准历史数据。

在这一背景下，**部分模型厂商开始通过模型架构和内存优化降低推理成本。**DeepSeek于9月10日发布V4.1 Flash模型，其混合API价格降至每百万Token 0.2美元，较上一版本下降74%。

该模型还通过Casual Encoder-Decoder设计、Engram条件记忆机制和Compressed Sparse Attention 2等技术，进一步压缩硬件需求：HBM需求降低约四分之一，SSD需求降低约八分之一。**杰富瑞认为，这类路线更强调算力 and 内存效率，而非单纯追求模型智能。**

这也意味着，AI模型的竞争维度正在增加。随着推理Token需求快速增长，模型厂商不仅需要提高能力，还需要降低每个Token的生成成本。对于应用开发者而言，如果更低成本的模型已经能够完成足够多的任务，模型之间的价格差异可能比单纯的性能差异更加重要。

资本支出仍在增长，但回报需要重新验证

杰富瑞对AI供应链的担忧，核心并不是AI需求消失，而是资本投入增长速度能否与最终回报匹配。一方面，新玩家已经能够以数千万美元级别的资金投入进入全球头部模型榜单；另一方面，头部企业仍在持续扩大算力、数据中心和基础设施投资。

从需求端看，AI推理需求仍在快速增长，模型能力提升也会不断催生新的应用场景，因此算力需求本身并未失去增长基础。问题在于，当模型供给越来越丰富、API价格受到竞争压制后，新增基础设施投入需要多长时间才能转化为足够的收入和利润。

杰富瑞因此认为，AI产业可能逐渐进入一个更加注重资本效率的阶段。对于头部企业而言，继续扩大资本开支仍可能是保持技术领先的重要手段，但行业整体需要更加关注重复建设、资源利用率以及新增算力所对应的实际商业价值。

最终，杰富瑞预计，行业可能通过整合、合作以及更高效的资源配置来降低整体资本开支。**AI基础设施需求仍然强劲，但“需求增长”并不自动等于“所有资本投入都能获得足够回报”，这将成为下一阶段市场重新审视AI估值的重要变量。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

写评论

请发表您的评论



表情



图片

发布评论

