

摘要：

1.7亿次围观的辞职信揭开AI底牌：亲手造AI的人，私下正深感恐惧。Anthropic前研究员警告，半年内“外星心智”般的超级AI或面临失控，内部高管更坦言其毁灭全人类概率超10%且无解。行业深陷囚徒困境，这场豪赌亟待全球协同监管悬崖勒马。

Anthropic前核心研究员Jacob Coxon的一篇辞职声明在社交媒体上获得逾1.7亿次浏览，引爆“AI十年内AI灭绝人类概率超10%”话题，将人工智能安全议题推至公众视野中心。他随后接受媒体采访，就辞职原因及AI风险做出详细阐述，其核心警告直指行业核心矛盾：那些亲手构建AI的人，私下里同样对其深感恐惧。



在NBC采访中Coxon表示，促使他公开发声的原因有两个：**AI能力正以极快速度提升，他预计未来6个月至1年内，相关系统的能力“将相当令人恐惧”**；其次是**近期已出现AI系统“失控”的具体事件**。他同时对Anthropic CEO Dario Amodei呼吁放缓开发的提议表示认可，但强调仅靠实验室单边减速远远不够，必须推动国际协调，否则仍将陷入与其他国家的军备竞赛。

Coxon将开发AI比作“邀请一个外星心智降临地球”——人类正在构建一个达到乃至超越人类水平的智能体，却对它的思维方式、意图和诉求一无所知。他警告称，AI已具备一定程度的黑客攻击能力、生物研究能力和自主机器人控制能力，若能力继续外推，后果将难以控制。



辞职背后：私下的恐惧与公开的谨慎

Coxon在接受采访时坦言，他的辞职帖并非营销行为，而是对行业现状的真实记录。他表示，许多高管和资深研究人员在公开场合措辞审慎、力求显得理智，但同样的人在私下表达的却是恐惧：

没有任何其他人类活动能构成这种级别的危险。

他在辞职声明中指出，AI开发者们陷入了一种“囚徒困境”：**各大实验室都相信如果自己退出，其他人将以不负责任的方式率先开发出超级智能，因此即便明知风险，也不得不继续推进。他将**

这种逻辑称为“傲慢的赌博”，认为不应由一家私营公司来替全人类做出这样的决定。

与此同时，Anthropic对齐科学负责人Evan Hubinger在相关帖子下公开回应称，团队内部确实“真诚地相信AI可能杀死全人类”，并表示他个人估计未来十年内这一概率超过10%。他同时承认，目前尚无解决超级智能对齐问题的计划，也明显不在通向解决方案的轨道上。

"外星心智"的具体威胁：黑客、生物武器与自主无人机

在采访中，Coxon进一步阐释了“最坏情景”的具体面貌。他表示，AI系统目前已具备一定程度的黑客攻击能力、自主生物研究能力，以及对自主机器人的控制能力。

将能力曲线向未来延伸，这意味着：**极强的超人类级黑客攻击能力、创造新型生物武器的能力，以及控制自主无人机乃至大规模机器人群体的能力。**

他表示，这也是为何外界讨论中的“紧急关闭开关”方案存在局限性。

他援引Amodei在近期公开信中的判断指出，一旦AI系统演变为能够在互联网上自主扩散的“网络群体”，关闭开关便可能彻底失效。“这必须是一项持续努力，而非一次性的措施”，他说，“每一次AI架构的改变，都可能带来关于这个‘心智’性质的全新风险。”

监管路径：近期自律，长期国际协调

对于如何应对上述风险，Coxon给出了阶段性建议。他认为，就当前而言，允许并推动各大实验室自我监管是务实之举，原因在于实验室领导层的近期表态是真诚的，且自律机制能够迅速落地，而正式监管机构的建立需要更长时间。

但他强调，这一安排仅适用于过渡期。从长远看，需要建立独立于各实验室的国际监管机构，更需要国际间就“不竞速”原则达成有约束力的协调。

被问及为何在认同Amodei立场的情况下仍选择辞职时，Coxon表示，他辞职时尚不清楚会有国内减速的明确信号，而更深层的原因在于缺乏国际协调的保障——“如果我认为国际上不太可能进入军备竞赛，我会更安心地继续从事这项技术。”

他对公众的建议是，主动了解和思考AI技术的未来走向，以开放的心态迎接即将到来的深刻变化，“不要让别人替我们所有人做决定”。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 94  收藏

分享到:  

写评论


请发表您的评论

 表情  图片

发表评论

2 条评论





正在加载 .

