

摘要：

Sam Altman公开承认，AI运行成本已从年初“无人提起”变成企业客户的“巨大问题”。OpenAI最大客户单月消耗1000亿tokens，Uber全年AI预算四个月耗尽。使用量百万倍级暴增正在击穿企业预算，控费、模型分层、智能路由成新常态，AI行业从增长叙事转向单位经济。

AI行业的核心矛盾正在从“能不能用”转向“用不用得起”。Sam Altman公开承认，运行AI的成本已从年初几乎无人讨论，变成企业客户面前的“巨大问题”，这让生成式AI的商业化焦点迅速转向单位经济、预算约束和投资回报。

据AI媒体Fello AI 6月3日报道，Altman在OpenAI于6月2日面向企业客户的线下活动上表示，2026年初，AI运行成本“从未被提起”，客户对支出水平“完全满意”。但到现在，AI成本已经成为企业采购和部署中的主要问题。

这番表态之所以引发关注，是因为Altman同时披露了使用量的极端变化。OpenAI最大客户之一每月消耗约1000亿个tokens，约相当于750亿个单词。而六年半前，OpenAI最高使用者的月消耗量约为10万个tokens。单一顶级用户的使用规模已放大约100万倍。

这表明AI支出进入审查阶段，企业开始设置tokens上限、切换更便宜模型、采用智能路由，模型供应商则面临收入增长与客户控费之间的张力。投资者需要关注的不再只是AI采用率，还包括推理成本、客户ROI和盈利路径。

成本问题突然浮出水面

Altman的最新表态显示，企业AI支出的讨论基调已经发生变化。

Altman称，半年前企业客户几乎不担心AI花费，相关问题“从未出现”。但现在，**成本已经成为“huge issue”**。这意味着企业对AI的态度正在从快速试用、扩大部署，转向预算管理和效率评估。



JUST IN: Sam Altman says AI budgeting has suddenly become a “huge issue” for companies.

10:18 AM · Jun 4, 2026

6.2K Reply Copy link

Read 401 replies

Altman还披露，OpenAI单一最大客户每月消耗约1000亿个tokens。tokens是AI模型读取和生成内容的基本计量单位，大致相当于四分之三个单词。换言之，这一客户每月处理的文本规模约为750亿个单词。而且Altman承认，**OpenAI发现公司外部还有人消耗更多tokens**。

Tokens爆炸正在击穿企业预算

AI账单已从技术部门的使用数据，变成企业预算问题。

Peter Steinberger，OpenClaw背后的开发者，曾发布截图显示，30天内消耗6030亿个tokens，单月费用约130万美元。报道称，在他加入OpenAI后，OpenAI承担了这笔账单。

据Fello AI援引《纽约时报》报道，一名OpenAI员工一周内消耗2100亿个tokens。McKinsey & Company作为客户也跨过每月1000亿个tokens的门槛。

企业侧的压力更直接。**Uber工程团队的2026年全年AI预算在四个月内耗尽，之后公司设置了硬性tokens上限。**Uber个别工程师每月AI支出在150美元至2000美元之间，Amazon也关闭了内部tokens排行榜。

Who	Token spend	What it cost
OpenAI's top customer	100 billion / month	The headline figure
Peter Steinberger (OpenClaw)	603 billion in 30 days	~\$1.3 million in one month
One OpenAI employee	210 billion in a week	Reported by the New York Times
McKinsey & Company	100 billion / month	Crossed the milestone as a client
Uber engineering	Entire 2026 budget	Gone in four months
Peter Steinberger, the creator behind OpenClaw, posted a screenshot of 603 billion tokens spent in 30 days, racking up around \$1.3 million in a single month. OpenAI ended up covering the bill after he joined the company.		

Altman在活动中还引用了客户间流传的说法：“**我的公司在一季度花完了整个2026年预算，你能让它更高效吗？**”这句话概括了企业当前的核心诉求，AI能力仍有吸引力，但无上限使用已经难以持续。

烧钱逻辑来自低价竞争和自动化使用

成本压力之所以在短时间内变得突出，关键在于AI行业早期的定价和使用模式。

在AI热潮的大部分时间里，大模型公司将服务价格压低到运行成本之下，以换取市场份额。OpenAI每获得1美元收入，约需支出1.35美元，亏损主要来自推理，也就是模型响应海量请求的成本，而不只是训练新模型的费用。

这种模式在使用量有限时可以维持。但随着智能体工具出现，AI开始循环调用、反复执行任务并自主运行，**tokens消耗不再是线性增长，而是成倍放大。**

Altman还提到，下一阶段可能出现“constant running proactive AI”，即持续运行、主动工作的AI智能体。如果当前企业已经难以承受按请求触发的AI成本，那么长期后台运行的AI将进一步考验预算和商业模式。

控费成为企业AI部署的新规则

企业并未停止使用AI，但使用方式正在变得更克制。

最直接的变化是设置上限。Uber在预算快速消耗后，对tokens使用设定硬性限制。Amazon关闭内部排行榜，也反映出企业不再鼓励单纯追求使用量。



第二个变化是模型分层。并非所有任务都需要最贵、最强的模型。日常写作、简单问答、常规代码辅助可以由更便宜、更快的模型处理，复杂推理任务才交给高端模型。Fello AI称，智能路由可帮助许多团队节省60%至80%的成本。

第三个变化是压缩重复订阅。企业和个人此前可能同时购买多个AI产品，但实际使用往往集中在少数场景。随着财务约束加强，AI采购会更重视模型匹配、费用透明和使用效率。

这意味着AI行业的竞争重点正在从“谁的模型最强”扩展到“谁能以更低成本完成足够好的任务”。

从增长叙事转向单位经济

Altman的表态不等于AI投资进入全面收缩，也不意味着行业需求崩塌。更准确地说，AI正在从早期试点和无约束扩张，进入预算纪律阶段。

对投资者来说，关键问题包括三点。

第一，收入增长是否建立在可持续的成本结构上。如果模型公司通过低于成本的价格扩大采用率，短期收入可能增长，但推理成本会压缩盈利路径。

第二，企业客户是否能看到明确回报。Altman承认，客户花了很多钱在AI上，但ROI和成本控制正在成为最公平的批评之一。预算帽、模型切换和智能路由，都会影响模型供应商的收入质量。

第三，下一代智能体是否会放大成本问题。持续运行的主动AI可能提升生产力，也可能让tokens消耗进一步失控。谁能在性能、成本和稳定性之间取得平衡，谁就更可能在企业市场获得长期优势。

AI行业的烧钱问题并非突然出现，只是现在被账单显性化了。Altman的公开承认，标志着生成式AI进入一个更现实的阶段：客户仍想要AI，但不再愿意为无限增长的tokens无条件买单。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

👍 221 ★ 收藏

分享到:  


写评论

请发表您的评论

 表情  图片

发表评论

1 条评论



正在加载 ..

