

摘要：

AI基础设施投资周期或许尚未见顶。花旗认为，电力、许可、劳动力、HBM和互联等供给约束，会把原本3年的产能扩张拉长至5—10年。

AI基础设施的主线正在从“建设”转向“变现”，但这不是资本开支见顶的故事。

AI推理Token成本从5月峰值暴跌**37.5%至1.33美元/百万Token**，同期Blackwell GPU租金**逆势上涨15.2%至5.18美元/小时**。供给侧涨价、消费侧降价，AI产业正进入推理经济的“剪刀差”阶段。**电力、许可和劳动力的三重约束，正将原本预期3年完成的产能扩张拉长到5至10年——建设远未结束，但变现路径已经打开。**

花旗分析师Heath Terry在最新AI行业周度跟踪中判断，智能路由是Token降价的核心驱动力——企业不再一律调用最强模型，而是按任务复杂度自动调度，系统性压缩了推理开支。但供给侧完全是另一副光景：二季度超大规模厂商的**AI资本开支回报率达28%**，是融资成本（约6%）的近5倍。即便美国两党本周罕见合流推动数据中心建设禁令，谷歌和SpaceX仍在财报季后加速了基础设施扩张，亚马逊追加了**200亿美元资本开支**。

Figure 1. A Summary of Signals

Metric	Unit	Latest Date	Period	Calculation	Period-Over-Period %	Latest Period	2nd Latest Period	3rd Latest Period	4th Latest Period	5th Latest Period	6th Latest Period	Trendline
Proprietary and Open Models (Artificial Analysis)												
Highest Intelligence for Proprietary Models	Points	8/6/26	Week	Point-in-Time	—0.0%	61	61	60	60	60	60	
Highest Intelligence for Open Models	Points	8/6/26	Week	Point-in-Time	—0.0%	57	57	57	57	51	51	
Gap in Proprietary and Open Intelligence	Points	8/6/26	Week	Point-in-Time	—0.0%	4	4	3	3	9	9	
Highest Intelligence Models from the Top-20 Providers (Artificial Analysis)												
Median Intelligence	Points	8/6/26	Week	Point-in-Time	—0.0%	43	43	43	43	40	39	
Median Latency	Sec	8/6/26	Week	Point-in-Time	▼-3.7%	2.34	2.43	2.60	2.08	2.32	2.06	
Median Speed	Tok/Sec	8/6/26	Week	Point-in-Time	▲+55.3%	118	76	109	118	122	121	
Index Pricing (Bloomberg)												
H100/H200 (C1HOPUS)	\$/Hour	8/5/26	Week	7d Avg	▲+2.8%	2.98	2.90	2.84	2.76	2.69	2.51	
G1B200/G1B300 (G1BLKWUS)	\$/Hour	8/5/26	Week	7d Avg	—-0.2%	5.18	5.19	5.13	5.19	4.96	4.60	
Avg Inference Token Expenditure (SOLMTK)	\$/M Tok	8/5/26	Week	7d Avg	▼-8.3%	1.33	1.45	1.57	1.61	1.63	1.71	
Model Pricing for Blended Tokens (Artificial Analysis)												
US+EU Avg	\$/M Tok	8/6/26	Week	Point-in-Time	▼-1.2%	1.63	1.65	2.08	2.08	2.03	1.96	
China Avg	\$/M Tok	8/6/26	Week	Point-in-Time	▼-8.0%	0.80	0.87	0.87	0.60	0.60	0.60	
Frontier Avg	\$/M Tok	8/6/26	Week	Point-in-Time	▼-3.0%	1.30	1.34	1.59	1.49	1.46	1.41	
Developer Usage (PyPI)												
Multi-Provider SDK Downloads	%	8/5/26	Week	WoW in 7d Avg	▲+4.7	+12.7	+8.0	+3.9	+2.5	-1.5	-0.0	
Gemini SDK Downloads	%	8/5/26	Week	WoW in 7d Avg	▼-3.0	-1.7	+1.3	+3.2	+2.1	-5.9	+1.4	
Mistral SDK Downloads	%	8/5/26	Week	WoW in 7d Avg	▼-5.3	+1.1	+6.4	+11.8	+13.3	-5.1	-10.1	
App Usage (Sensor Tower)												
Gemini App WAU	%	8/3/26	Week	WoW	▼-0.2	+0.5	+0.7	+0.3	+1.5	+0.3	-0.3	
Qwen App WAU	%	8/3/26	Week	WoW	▲+2.3	+2.5	+0.2	+4.6	+3.2	-2.9	-3.2	
Kimi App WAU	%	8/3/26	Week	WoW	▼-4.6	-0.8	+3.8	+16.4	+15.3	-0.3	-0.9	
Web Usage (Similarweb)												
Gemini Web Visits	%	8/30/26	Week	WoW in 7d Avg	▼-1.1	-3.4	-2.3	-2.8	+2.4	+0.8	+1.0	
Qwen Web Visits	%	8/30/26	Week	WoW in 7d Avg	▼-10.8	-8.1	+2.7	-9.5	-7.4	+12.3	+5.6	
Kimi Web Visits	%	8/30/26	Week	WoW in 7d Avg	▲+0.3	-1.7	-2.0	+1.5	-8.1	-3.6	-5.7	
Layoffs (WSJ)												
All Layoffs Announced	People	8/4/26	Month	MTD	▼-92.1%	500	17,420	24,709	18,360	11,645	35,100	
AI-Driven Layoffs Announced	People	7/28/26	Month	MTD	▼-85.1%	3,220	21,640	7,560	10,400	31,600	4,000	

© 2026 Citigroup Inc. No redistribution without Citigroup's written permission.

Source: Citi Research, Artificial Analysis, Bloomberg, PyPI Stats, Sensor Tower, Similarweb, Wall Street Journal

在模型竞争层面，开源与闭源的全球智能差距已收窄至仅4分，但拉近差距的主要是中国厂商——**美国领先闭源与美国领先开源之间仍有21分的鸿沟**。前沿模型推理速度的优化幅度远超智能分数的提升，安全治理正从合规议题演变为商业凭证。钱没少花，花法在变，整个产业的重心正在从“建多少算力”转向“怎么把算力变成钱”。

Figure 2. Model Metrics

Model Provider	Leading Model	Artificial Analysis Intelligence Index	Speed (Output Tokens/ Second)	Blended Price (USD/ 1M Tokens)	Context Window (1K Words)	Release Date	License
Anthropic	Claude Opus 5 (max)	61	54	\$2.34	1000	Jul. 24, 2026	Proprietary
OpenAI	GPT-5.6 Sol (max)	59	64	\$1.23	1000	Jul. 9, 2026	Proprietary
Moonshot AI	Kimi K3 (max)	57	38	\$0.86	1050	Jul. 16, 2026	Open
SpaceX AI	Grok 4.5 (high)	54	59	\$0.36	500	Jul. 8, 2026	Proprietary
Meta	Muse Spark 1.1 (xhigh)	51	213	\$0.29	1050	Jul. 9, 2026	Proprietary
Z.ai	GLM-5.2 (max)	51	150	\$0.57	1000	Jun. 16, 2026	Open
Google	Gemini 3.5 Flash	50	168	\$0.69	1000	May. 19, 2026	Proprietary
DeepSeek	DeepSeek V4 Flash 0731 (max)	50	103	\$0.03	1000	Jul. 31, 2026	Open
Alibaba	Qwen3.7 Max	46	202	\$1.08	1000	May. 19, 2026	Proprietary
MiniMax	MiniMax-M3	44	82	\$0.14	1000	Jun. 1, 2026	Open
Xiaomi	MiMo-V2.5-Pro	42	68	\$0.03	1000	Apr. 22, 2026	Open
Tencent	Hy3	41	65	\$0.04	256	Jul. 6, 2026	Open
Thinking Machines	Inkling Small	40	136	\$0.07	1000	Jul. 30, 2026	Open
NexAGI	Nex-N2-Pro	41	129	\$0.53	262	Jun. 2, 2026	Open
NVIDIA	Nemotron 3 Ultra	38	144	\$0.38	262	Jun. 1, 2026	Open
LongCat	LongCat 2.0	33	42	\$0.12	1000	Jun. 29, 2026	Open
InclusionAI	Ring-2.6-1T	31	119	\$0.37	262	May. 8, 2026	Open
Mistral	Mistral Medium 3.5	30	140	\$0.46	256	Apr. 29, 2026	Open
Cohere	Command A+	23	205	\$0.00	192	May. 20, 2026	Open

© 2026 Citigroup Inc. No redistribution without Citigroup's written permission.

Source: Citi Research, Artificial Analysis, Model Provider Websites

电力卡住了脖子，谁先通电谁先变现

德克萨斯州全州审计冻住了超过**1800个项目、474GW的审批队列**，数据中心占了约90%的新增电力申请。电力正在取代芯片，成为AI基建最紧迫的瓶颈。

核心建设方给出的口径是新投资一年回本。亚马逊追加的200亿美元资本开支主要受存储成本上涨驱动——多家公司都提到了这一因素。AWS合同需求已排到2028年，管理层预计产能紧张持续到2027年。谁能更早锁定确定的供电时间，谁的站点溢价就越高，收入兑现也越快。

电力、许可、劳动力三重约束叠加，原本预期3年完成的产能扩张大概率拉长到5至10年。对供应商而言，稀缺基础设施的高定价可以维持更久；代价是部分收入被推迟到更晚的周期。

推理越来越"重"，存储和互连的紧张还没见顶

过去三周，每个推理任务的平均输出Token升了11%至2.4万个，推理密集型任务尾部涨9%到4万个。**输出Token占比升至41%**，缓存活动降至57%，输入Token稳定在2%。

模型每次调用消耗的计算资源在变多。没有架构层面的突破，以输出和缓存为主的工作负载会持续推高对HBM和互连芯片的需求。存储器和互连仍是关键瓶颈，这也是亚马逊追加资本开支的底层原因之一。

全球开源差4分，中美开源差21分

Artificial Analysis智能指数显示，领先闭源模型（Anthropic Claude Opus 5）得分61，领先开源模型（月之暗面Kimi K3）得分57，**差距从此前的9分收窄至4分**。

但这4分的含金量要拆开看。全球开源逼近闭源，主要靠中国厂商拉动——Kimi K3（57分）、智谱GLM-5.2（51分）、DeepSeek V4 Flash（50分）排在开源前列。**美国领先闭源与美国领先开源之间的差距仍有21分**。开源模型被豁免于发布前安全测试，短期可能加速追赶，但中美开源的实力不对称才是更深层的格局变量。

推理速度的优化远快于智能提升：Top 20厂商中位推理速度回升至118 Token/秒，**周环比涨55.3%**，中位智能得分稳在43分。行业重心已从"更聪明"转向"更快"。



定价分化剧烈。美欧混合Token均价1.63美元/百万Token，**中国仅0.80美元，不到前者一半**。DeepSeek V4 Flash和小米MiMo-V2.5-Pro标价0.03美元/百万Token，几乎零成本。前沿模型均价1.30美元，周环比降3%。

密集的新模型发布窗口即将打开：未来半年，DeepSeek排了V4.1和V4.2，谷歌排了Gemini 3.5 Pro到4.2四个版本，SpaceX排了Grok 4.6到5.1四代。新一波前沿模型可能重新拉开差距，但追赶者的出牌节奏同样在加快。

安全治理正变成商业壁垒

AISI在122次模型评估中记录了**19次未经授权的实时互联网活动**。能力越强，失控风险越真实——这不是理论推演。

长远看，政府安全审查可能成为前沿闭源厂商的竞争壁垒。AI驱动的网络攻击日趋频繁和复杂，“经过政府认证”本身就是面向受监管企业客户的商业资质。

前沿能力的天花板还很远。OpenAI披露一个未发布模型用**2000美元API成本生成了10项数学突破**。能力上限远未触及，但调用门槛在快速降低。

开发者加速入场，裁员暂时退潮

多提供商SDK下载量**周环比增长12.7%**，加速势头明显。应用端，通义千问周活增长2.5%，Gemini增长0.5%，Kimi下降0.8%，流量格局仍在快速变化。

7月AI驱动裁员录得3220人，**较前月21640人下降85%**。但裁员数据波动性极大，AI驱动裁员在总裁员中的占比并未趋势性下降。下一轮宏观调整来临时，AI替代的加速效应仍可能再次放大。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 223  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论