

摘要：

从GPU到LPU，英伟达正在亲手开启AI推理新时代的大门。

在GPT-3时代，1750亿参数的模型已是庞然大物；到如今，万亿参数级别的混合专家模型已成常态。AI产业当前最大的痛点——推理延迟，成为英伟达下一个要攻克产业难关。

GPU遵循的“吞吐量优先”设计哲学，在实时交互的推理场景中正遭遇严峻挑战。但处理单个用户请求的“小批量、串行生成”任务时，其依赖高带宽内存（HBM）的架构会导致频繁的数据搬运，造成巨大的延迟和功耗浪费。

LPU的横空出世，正是为了解决这一根本性的架构错配。

穿透产业链繁杂噪音，有哪些核心环节的值得我们在推理时代引起重视？

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

VIP会员

加入见闻VIP会员

立即解锁全文

69 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论