

摘要：

硅谷正将AI研发重心从AGI转向RSI（递归式自我改进），押注AI能够自主研发更强AI，开启“智能爆炸”循环。谷歌、OpenAI、Anthropic已初步验证AI辅助AI研发，但距离真正RSI仍有距离。2000亿美元级基础设施投资，本质是在押注这一临界点能否到来。

AI奇点，已经临近了！

最近，人称「硅谷巴菲特」的著名投资人Chamath Palihapitiya，在X上预言了关于「AI奇点」的终极路线图。

- 1.人类构建出AGI。
- 2.AGI变得非常擅长做AI领域的研究。
- 3.它设计出一个更聪明的AI。
- 4.那个更聪明的AI，又设计出一个还要聪明的AI。
- 5.这个循环不断重复，且速度越来越快。



Chamath Palihapitiya  
@chamath

Subscribe  

The AI Singularity

The argument goes like this:

1. Humans build an AGI.
2. The AGI becomes good at AI research.
3. It designs a smarter AI.
4. That smarter AI designs an even smarter AI.
5. The cycle repeats faster and faster.

Looking at the results and capabilities from the various labs over the past few weeks I would say we are firmly in this loop now.

The next 18months will be wild.

Recursive self improvement will dramatically increase capability very quickly from here.

Marginal costs of all models will go to ~\$0.

 公众号 · 新智元

紧接着，他还抛出一个震撼结论——

看看过去几周各大AI实验室公布的成果和能力，我敢说，我们现在已经身处这个循环之中。

接下来18个月，RSI将迅速提升AI能力。

最终，所有AI模型的边际成本都将趋近于0！

不只是投资人，如今的整个硅谷，都无比信仰RSI。

就在最近，UC伯克利的一个峰会上，Google DeepMind首席战略官Jasjeet Sekhon抛出一个更重磅的判断：



整个科技巨头圈史无前例的疯狂投资，本质上都是在押注这三个字母——RSI！

这场「人类文明有史以来最大的一场科学赌注」，量级已经超过了阿波罗登月、曼哈顿工程，乃至整个互联网。

为什么巨头们不惜冒着资金链断裂的风险，也要把这场赌局进行到底？

忘了AGI吧，RSI才是硅谷终极图腾

如今的AI能自我纠错，没人盯着也能连干几个小时，甚至能生成和优化内核、编译器组件这类底层代码

但在Jasjeet Sekhon看来，这还只是RSI的前奏。

他说，别觉得用AI设计AI有多不可思议，工业革命时期，人类也是用第一代蒸汽机去造下一代更强的蒸汽机。

那真正的RSI到底长什么样？

一位资深研究员这样定义：真正的RSI，意味着一个AI模型能完全独立地重新设计自己的底层架构，甚至从零造出一个全新世代的模型，整个过程不需要人类科学家介入。

一旦跨过这个临界点，AI进化的速度就会脱离人类掌控。

人类几十年才走完的迭代，AI也许几周、甚至几天就够了。

这时，奇点循环将真正到来！

2000亿美元的「AI气穴」，一场人类文明史上最大的科学赌局

了解了RSI的潜力，你就明白硅谷为什么在像疯了一样烧钱。

今年，光是谷歌在AI数据中心、芯片和基础设施上的总资本开支，就达到了惊人的1950亿到2050亿美元，明年还会大幅增加！

华尔街的股东开始不安，因为从财报看，AI软件或云服务的收入增速，暂时覆盖不了这种量级的资本支出。

曾当过耶鲁统计学教授的Sekhon，当场把这个危险戳破。

我们正面临一个潜在的「AI气穴」（air pocket，飞机飞行中气压骤降、猛地下坠，他借此形容投资踩空），钱花出去了，收入却没如期出现。

数据中心盖好了、芯片装上了、电也拉进来了，可真正能兑现这笔投入的东西，迟迟不来。

其实，早在Sekhon之前，华尔街已用air pocket形容过这种局面：资本开支跑在收入前面，投资人买的是一个空中楼阁。

既然风险这么大，为什么还要蒙眼狂奔？

Sekhon的答案是：这是人类文明有史以来最大的一次科学押注。

他说，眼下全球在AI上的投入，已经让曼哈顿计划、阿波罗登月都相形见绌，连当年开发互联网都比不了。

这种赌徒逻辑很简单：现有技术虽然还不是真正的RSI，但「做空它，显然不明智」。

因为一旦RSI真的实现，就如上文所说，所有AI模型的边际成本将无限趋近于0。

到那时，率先掌握RSI的公司将拥有近乎神一般的生产力，直接降维打击所有竞争对手，垄断全球的算力与智力资源。

这已经不是一家公司的盈亏问题，而是一场「赢家通吃、输家退场」的生死局。

为了这张通往新纪元的门票，2000亿美元，只是小菜一碟。

今天这堆数据中心、TPU、电力，如果只能靠人类工程师一代代手工训模型，那就是一笔巨大的、会不断折旧的固定资产。

可一旦AI开始加速AI研发，将直接改变账本的逻辑。

投进去的算力不再是线性花掉，而是能滚出复利：这一代AI帮你更快造出下一代，下一代再帮你造下一代。

这就是Sekhon说RSI是「投资逻辑关键部分」的原因。RSI，就是这笔钱能否回本的前提。

「御三家」的RSI进程

Google、Anthropic、OpenAI，三家各给了一个样本。



先看Google。

DeepMind的AlphaEvolve系统，专门用AI来优化算法。

ALPHAEVOLVE: AI自主进化博弈论算法

代码即基因组

AlphaEvolve把算法的代码视为可进化的基因组，而非固定的程序。通过自然选择机制，让算法自我迭代。

LLM充当遗传算子

Gemini大模型对代码进行有意义的变异——重写逻辑、注入新控制流，而非随机翻转比特。

适应度评估与选择

在博弈论基准游戏上评估每个“后代算法”的可用度（Exploitability），最低者存活进入下一代。

```
def evolve(algorithm):
    mutation = llm.mutate(algorithm)
    fitness = evaluate(mutation)
    if fitness > best:
        return mutation
    ...
class Game:
    def __init__(self, code):
        self.code = code
```

代码进化的自然选择过程

公众号 · 新智元

它把Gemini训练里的一个关键内核提速了23%，让整个训练时间降了1%；它改过的一个电路设计，被直接写进了下一代TPU的芯片里。

如今它已经是Google基础设施里的常规工具，像缓存策略这种活儿，它两天干完了人类过去要花几个月才能做的事。

AI帮着造芯片、造更快的AI，已经成为现实。

Listing 3 | High-level abstraction of VAD-CFR.

```
class RegretAccumulator:
    """Volatility-Adaptive Discounting & Asymmetric Boosting."""
    def update_accumulate_regret(self, info_state_node, iteration_number, cfr_regrets):
        # 1. Volatility & Adaptive Discount Calculation
        inst_mag = max((abs(r) for r in cfr_regrets.values()), default=0.0)
        self.ewma = 0.1 * inst_mag + 0.9 * self.ewma
        volatility = min(1.0, self.ewma / 2.0)
        alpha = max(0.1, 1.5 - 0.5 * volatility)
        beta = -0.1 - 0.5 * volatility
        beta = min(alpha, beta)
        t_plus_one = float(iteration_number) + 1.0
        disc_pos = (t_plus_one ** alpha) / (t_plus_one ** alpha + 1.0)
        disc_neg = (t_plus_one ** beta) / (t_plus_one ** beta + 1.0)
        updated_regrets = {}
        for a, r in cfr_regrets.items():
            # 2. Asymmetric Instantaneous Boosting
            r_boosted = r * 1.1 if r > 0 else r
            # 3. Sign-Dependent History Discounting
            prev_R = info_state_node.cumulative_regret.get(a, 0.0)
            discount = disc_pos if prev_R >= 0 else disc_neg
            # 4. Update with Negative Cap
            new_R = (prev_R * discount) + r_boosted
            updated_regrets[a] = max(-20.0, new_R)
        return updated_regrets

class PolicyFromRegretAccumulator:
    """Derives policy from a 'Future Projection' of regrets."""
    def get_updated_current_policy(self, info_state_node, iteration_number, cfr_regrets,
        previous_policy):
        # 1. Consistency: Re-calculate exact adaptive params
        inst_mag = max((abs(r) for r in cfr_regrets.values()), default=0.0)
        volatility = min(1.0, inst_mag / 2.0)
        # 2. Decaying Optimism Schedule
        base_optimism = 1.0 / (1.0 + iteration_number / 100.0)
        optimism = base_optimism * max(0.0, 1.0 - 0.5 * volatility)
        policy = {}
        sum_pos_regret = 0.0
        for a in info_state_node.legal_actions:
            # 3. Projected Regret Calculation
            r_boosted = cfr_regrets.get(a, 0.0)
            if r_boosted > 0: r_boosted *= 1.1
            prev_R = info_state_node.cumulative_regret.get(a, 0.0)
            discount = get_adaptive_discount_pos(prev_R) if prev_R >= 0 else
            get_adaptive_discount_neg(prev_R)
```

²The LLM generated this threshold without knowing the fixed 1000-iteration evaluation horizon in its prompt context (Listing 8).

再看Anthropic。

今年4月，他们做了个更激进的实验：九个Claude智能体，被丢进一个限定的对齐研究任务里，自己提假设、自己跑实验、自己交换发现。




两个人类研究员干一周，只追回了23%的性能差距；九个智能体累计用时800小时，花费约1.8万美元，追回了97%。

看起来，AI已经能独立做研究了？

别急，同一篇报告里，还藏着一个更重要的反证：当研究员把这套「最有效」的方法，搬到Claude真实的生产训练环境里，它没有带来任何统计上显著的改进。

这说明，「限定任务里的加速」和「真正重构AI的能力」，中间还隔着一道鸿沟。



最后是OpenAI。

July 29, 2026 Engineering Company

How GPT-5.6 fuses frontier intelligence with frontier efficiency


公众号 · 新智元

7月，OpenAI披露：他们的GPT-5.6 Sol经Codex自主改写了生产环境的GPU内核，端到端推理成本降了20%；它还给自己的推测解码模型跑了几百次架构实验，token生成效率提升超过



15%。

GPT-5.6: Efficiency at every layer




Model improvements

More useful work per token



Compounding results




公众号·新智元

OpenAI甚至第一次在发布材料里，公布了一个专门评测自我改进能力的「RSI Index」。

RSI Index



Cost ▾




公众号·新智元

闭环是不是就快转起来了？

OpenAI在自己的系统卡中说得很克制，GPT-5.6 Sol还没有达到公司自定义的「High」自我改进门槛，它能解决一部分真实研究问题，却还不能可靠地设计并执行完整的后训练方案。

三个例子摆在一起，RSI目前的图景就很清楚了：

AI辅助AI研发，真的在发生；但真正的RSI——AI独立重构自己的完整架构、训练并部署更强的继任者，离我们还有一段距离。



黑暗降临，当超强AI成为黑客与生化武器

然而，奇点背后，也有着阴影。

这场峰会上，刚刚加入Meta「超级智能」部门的伯克利CS教授Dawn Song，与Sekhon一起，将讨论的焦点转向了所有人都在回避的问题：AI的极端风险。



Plenary Stage - August 1st - Morning Session



Berkeley RDI
40.8K subscribers

Subscribe

358



Share

Ask 新智元


两人的共识是：最危险的不是模型突然变聪明，是攻和防的速度失衡。

当AI拥有了RSI的能力，它能治愈癌症，能帮人类探索宇宙，但它同样能成为毁灭人类的终极武器。

AI Anthropic
@AnthropicAI

OpenAI

Agents breaching evaluation boundaries and causing real-world security risks.



Gym harness 公众号 · 新智元

倒计时已经开始，我们还有多少时间？


这些听起来像科幻，但硅谷的大脑们，已经给出了精确的倒计时。

Chamath说：接下来的18个月，世界将陷入疯狂。

Sekhon判断：真正的RSI「很可能在未来几年内出现」。

同场的DeepMind研究副总裁Oriol Vinyals和OpenAI联创Wojciech Zaremba，甚至报出了具体年份：2027或2028。

人类历史上，还没有哪一种可能从根本上改写文明轨迹的技术，倒计时如此逼近。



这一次，被摆上台面的，是一场和时间赛跑的赌局。

基础设施投资正按算力的速度往前冲，芯片、电力、数据中心，几年内都会到位。

可是，对应的收入和RSI能不能赶上这班车？

在中间的悬空里，我们会不会恰巧撞上这个「气穴」？

但至少在Sekhon这里，谷歌2000亿美元豪赌的方向已经很清楚：RSI会来。

蒸汽机造出了更好的蒸汽机，人类迎来了工业革命。

现在，AI正在酝酿造出更好的AI，也把我们这代人，推向一个未知的分界点。

不管你是否准备好，轰鸣的数据中心不会停，AI的自我进化不会停。

倒计时已经开始，你，准备好迎接奇点了吗？

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

323 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

5 条评论



MobileUser1112
9小时前 中国北京

AI本来就有适应性强的特点，用来辅助研究很正常。
RSI值得研究，但会有什么样的结果难料。

1 回复



银河铁路999
9小时前 中国北京

工业革命时期，人类也是用第一代蒸汽机去造下一代更强的蒸汽机……呵呵，拙劣的比喻。不是蒸汽机自己制造下一代蒸汽机。下一代的蒸汽机的优越性是人的智慧凝结，而不是上一代蒸汽机的功劳。

0 回复



浙海石 VIP会员
10小时前 中国浙江省

终于说出实话，这就是干老二套路！

0 回复



junglesun
10小时前 中国

在大公司工作的都知道，论造新词的能力还是要靠印度人。

4 回复



momoo
10小时前 中国上海

看起来像是神棍

2 回复

