

摘要：

内存短缺正成为AI扩张的最大“卡脖子”难题，但产业界并未坐等晶圆厂救场。降规、推理负载分离、CXL内存池化——三条绕道策略正在重塑AI算力格局，并催生新投资机会。摩根士丹利点名Astera Labs、Marvell、Cerebras为核心受益标的，同时维持Micron与SanDisk增持，判断本轮内存短缺周期远未终结。

内存短缺已成为本轮AI建设周期中最持久的结构性制约，而AI算力扩张的脚步不会等待新晶圆厂落地。面对这一矛盾，整个产业链正在探索三条绕道而行的路径——降低内存规格、拆解推理负载，以及通过CXL技术实现内存池化共享——并在此过程中催生出新的投资机会。

摩根士丹利在最新研究报告中指出，英伟达CEO黄仁勋近期已明确表态，行业需要以全新思维应对内存瓶颈。这并非悲观信号，而是产业界对未来数年持续短缺的主动预判。**内存紧缺的烈度或有起伏，但AI将在可预见的未来基本吸收全部可用供应。**

在投资层面，摩根士丹利将Astera Labs（ALAB）和Marvell（MRVL）列为CXL及规模扩展方向的潜在受益者，将Cerebras（CBRS）列为推理负载分离架构的核心受益标的，同时维持对Micron（MU）和SanDisk（SNDK）的增持评级，逻辑在于内存短缺周期远未终结。


降规：治标之策，压力转移而非消除

面对DRAM和NAND价格双双走高，生态链企业最直接的应对是压缩单设备或单服务器的内存配置。

摩根士丹利指出，英伟达正在为Rubin平台向客户提供多个规格版本：LPDDR5每机架容量从原定54TB压缩至28TB，对应模组从192GB SOCAMM2缩减至96GB；HBM方面，Rubin原计划每GPU搭载288GB HBM（8叠12hi HBM4），目前预计将推出192GB版本（8叠8hi HBM4）。对于Rubin Ultra，相关规格也从1TB HBM4e下调，实际可比基准或降至192GB至384GB区间。

Exhibit 3: De-speccing HBM/LPDDR should open up opportunities lower in the memory hierarchy

Diagram of the Memory Hierarchy Shift from Training to Inference




Source: TrendForce, Morgan Stanley

然而，降规并非真正意义上的解决方案。报告强调，当一层内存容量被削减，数据压力必然向下转移，HBM和LPDDR的缩水正在为NAND和网络互联带来增量需求，内存瓶颈发生了位移而非消失。

推动AI内存需求持续扩张的结构性因素包括三个维度：模型规模在LLM时代每6个月翻倍；上下文窗口长度以每年约5倍的速度扩张；推理并发量的增加使每个会话均需独立存储KV缓存。

Exhibit 1: Frontier AI model sizes are doubling every 6 months



Source: EPOC.ai, Morgan Stanley Research


摩根士丹利认为，这三个向量的持续演进决定了降规只能是临时性措施，一旦供应缓解，行业将迅速回补至更高规格，被压制的需求将更容易被吸收。

负载分离：为不同推理阶段配置专属硬件

推理过程由两个截然不同的阶段构成：预填充（prefill）以并行方式处理输入提示词，计算密集；解码（decode）逐token生成输出，对内存带宽和容量的依赖更为突出。将二者分离，分别交由最适合各自特性的硬件处理，是提升内存使用效率的第二条路径。

这一趋势在2025年底前后明显提速。英伟达收购Groq后，将其LPU（基于高带宽片上SRAM）整合进Vera Rubin平台，由Rubin GPU负责预填充及需要大容量KV缓存的解码环节，Groq处理前馈和专家混合部分，英伟达Dynamo负责协调与激活值传输。AWS随后宣布以Trainium负责预填充、Cerebras负责解码的异构架构，并计划于2027年第一季度在Amazon Bedrock上线；Cerebras与AMD的类似合作方案则预计于2026年第四季度投入生产。Matrix的Corsair也已进入量产阶段。

Exhibit 6: AI inference consists of two distinct stages: prefill and decode



Source: Adapted from Patel et al., "Splitwise: Efficient Generative LLM Inference Using Phase Splitting," ISCA 2024; Morgan Stanley Research.

摩根士丹利将Cerebras列为负载分离架构中最直接的纯正受益标的。Cerebras晶圆级处理器将大量SRAM与计算单元集成于同一硅片，显著降低数据在处理器与外部内存间的移动频率，在解码阶段优势突出。更重要的是，负载分离可实质性改善Cerebras Cloud的经济模型——据Cerebras与AMD披露，联合系统可在维持Cerebras推理速度的前提下将吞吐量提升最高5倍，每部署单元可产生更多收入，每token成本同步下降。

CXL：从内存扩展到AI推理的新战场

CXL（Compute Express Link）是一种基于PCIe物理层的高速互联协议，核心价值在于允许多个处理器访问同一内存资源池，从根本上打破了内存与特定CPU绑定的传统架构。

其三种主要应用形态为：内存扩展（为单处理器添加超出本地内存通道上限的容量）、内存共享（多处理器访问同一数据）以及内存池化（跨处理器或服务器动态分配内存，减少闲置浪费）。

摩根士丹利指出，过去CXL主要服务于通用CPU计算场景，在AI领域的渗透因延迟劣势而受限。但随着推理场景对长上下文、代理型工作负载和KV缓存的容量需求急剧扩张，大量数据并不需要始终驻留在HBM中，CXL挂载DRAM作为更低成本、更大容量的内存分层由此获得立足空间。

市场规模方面，摩根士丹利将CXL的可寻址市场预测从原先以CPU为基础测算的逾40亿美元上调至2030年约60亿美元，增量主要来自AI服务器侧的新部署场景。Astera Labs的Leo内存控制器系列（含针对KV缓存卸载的定制设计，预计2027年量产）以及Marvell覆盖内存扩展（Structera X）和机架级池化（Structera S）的全线产品组合，是摩根士丹利看好的两个核心标的。Marvell管理层此前已将CXL定位为2028年前后逾10亿美元的收入贡献来源，摩根士丹利预计在即将举行的投资者日上将获得更多细节披露。

对内存股的影响：周期逻辑以时长而非振幅为锚

摩根士丹利坦承，从短期盈利最大化角度看，上述绕道策略对DRAM厂商存在一定负面影响——若AI生态因内存短缺而完全停摆，近期定价可能更为有利。但这一情形从未现实，报告强调，分析本轮内存周期应以“持续时长”为主要驱动逻辑，而非价格振幅。

核心论据在于：降规源于供应约束而非需求消退，一旦供应改善，行业将迅速回补至更高规格，被压抑的需求将轻易消化新增产能。摩根士丹利同时提示了一个风险因素：若AI放缓并非由于需求下降，而是源于土地、电力或厂房等基础设施瓶颈，此类暂停可能对内存板块造成不同于算力板块的特有冲击。

基于上述判断，摩根士丹利维持对MU和SNDK的增持评级，认为内存短缺周期尚未终结，两者的配置价值仍然成立。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

60 收藏

分享到:

写评论

请发表您的评论



