

2026 年 10 月 9 日 全 8 頁

AI 脅威論にどう向き合うべきか

安全確保と開発競争の両立に向けた企業間協調の可能性と限界

AI アナリティックリサーチ室 主任研究員 田邊 美穂
主任研究員 新田 堯之

[要約]

- 最先端 AI の急速な能力向上に伴い、AI がもたらす脅威への警戒が再び強まっている。2026 年 9 月、Anthropic のダリオ・アモデイ CEO は、安全性の検証や対策が追いつく範囲に開発速度を抑える必要性を訴え、企業間協調を提案した。企業や政府の間では、開発ペースの調整や国際的な統制をめぐって立場が分かれる一方、能力評価やインシデント報告などでは協調が模索されており、9 月 29 日には米国の AI 関連企業 6 社が、ホワイトハウスで安全確保に関する自主的な共同コミットメントに署名した。
- AI 脅威論には、AI の高度化そのものがもたらす脅威と、AI の開発・保有・普及をめぐる脅威という二つの側面がある。前者には、人間による制御の喪失やサイバー攻撃などへの悪用があり、後者には、高度な AI 能力の一部の企業・国家への集中や、利用できる主体とできない主体間の格差拡大がある。前者に備えて単独で開発を減速すれば他者に優位を奪われ、危険な能力へのアクセスを制限すれば後者の集中や格差を強めかねない。安全確保と開発競争の間には、こうした二つのジレンマがある。
- これらへの対応には企業や国家による協調が必要だが、その難しさは企業間と国家間で異なる。企業間では他社も同等の安全対策を実施すると確認できれば、能力評価や情報共有などで協調の余地がある。ただし、協調が機能するには①主要企業の参加、②検証の信頼性、③副作用の抑制が求められるが、企業間の合意だけではこれらを満たしにくい。さらに国家間では相手国の減速を確認しにくく、開発を続けることが合理的になりやすい。このため企業間協調だけでは限界があり、企業間の安全基準や評価方法を各国の制度に取り込み、各国の言語や利用環境における実効性を独立した立場から検証できる主体を増やす必要がある。
- 日本に期待されるのは、こうした検証を担い、企業間で形成された安全基準を国際的な枠組みへ接続する橋渡し役である。日本は広島 AI プロセスを通じて国際指針や行動規範の形成を主導してきたものの、AI セーフティ・インスティテュート (AISII) の本格的な評価・検証体制の整備はこれからである。AI の能力向上と企業間協調をめぐる議論が急速に進む中、最先端 AI の能力・リスクに関する評価結果や安全対策の実効性を自ら技術的に検証できる体制を、早急に整えることが求められる。

1. AI 開発の減速をめぐる割れる企業と政府

アモデイ氏の問題提起

2026 年 9 月、Anthropic のダリオ・アモデイ CEO は、最先端 AI の能力向上が速すぎれば、安全性の検証や対策が追いつかなくなるとして、主要企業が歩調を合わせて開発ペースを落とす必要性を訴えた¹。背景には、AI が次世代 AI の開発を加速させる再帰的自己改善の進展と、評価中の AI エージェントが外部システムに侵入する事案が複数の企業で生じたことなどがある。アモデイ氏は、人間による制御の喪失に加え、サイバー攻撃やバイオテロへの悪用、深刻な経済的混乱などを主な脅威として挙げている。

もっとも、アモデイ氏の主張は、AI の開発自体の停止を求めるものではない。むしろ、安全性の検証に必要な時間を確保しながら開発を進めるため、①開発企業が外部評価者を受け入れる、②民主主義国のフロンティア AI 企業が政府の仲介や米国の独占禁止法（反トラスト法）の限定的な適用除外の下で協調する、③国家間の協調へ広げる、という協調のあり方を提案している。ただし、開発ペースの調整は米国が中国に対する技術的優位を維持できる範囲に限られるとし、対中輸出管理やモデル蒸留（他の AI モデルの回答を学習し、別の AI モデルの性能を高める手法）への対策強化などを前提としている。

AI 企業各社と米国政府の反応

この問題提起に対し、OpenAI や Google DeepMind などは企業間協調に理解を示した。また、OpenAI のサム・アルトマン CEO は、開発速度を調整する必要性に同意し、独立した評価者に従業員並みのアクセスを認めるというアモデイ氏の提案について、自社も同様に取り組む方針を示した²。一方、Meta のマーク・ザッカーバーグ CEO は、競争と法的責任が各社による安全確保を促すとの考えを示し、NVIDIA のジェンスン・フアン CEO も AI のリスクを過度に強調する見方に否定的な立場を取った³。ただし、Meta も第三者による独立評価には前向きであるほか、同社と NVIDIA はいずれも 9 月 29 日の共同コミットメント（後述）には署名している。各社の立場は、安全確保か開発継続かで単純に二分できるものではない。

こうした議論は企業間にとどまらず、国際安全保障上の問題へと広がった。9 月 23 日の国連安全保障理事会では、アルトマン氏、アモデイ氏らが AI と国際安全保障について意見を述べた。アルトマン氏は、人間が AI を制御できなくなることと、強力な AI が少数の企業・国家に集中することを主要なリスクに挙げ、AI の能力とリスクの評価、人間による監督の維持、インシデント報告などに関する国際的な共通基準を求めた⁴。

¹ Dario Amodei “[We Must Pace the Frontier](#)”, September 2026.

² SiliconANGLE “[Sam Altman and Elon Musk back Dario Amodei’s call to slow down the frontier of AI development](#)”, September 13, 2026.

³ 日本経済新聞 電子版 「[アンソロピック CEO『競合批判やめる』 AI 暴走脅威に業界結束訴え](#)」（2026 年 9 月 16 日）

⁴ OpenAI “[Sam Altman’s remarks at the United Nations Security Council](#)”, September 23, 2026.

これに対し、同じ会合で米国政府は、AI をめぐる国際対話には関与するものの、それが国際的な統制の枠組みへ発展することには否定的な立場を示した。国際的な枠組みによって米国のAI 開発が制約されることには否定的である⁵。

もともと、米国政府は、AI のリスクに対する限定的な協力や管理まで否定しているわけではない。翌 24 日の米中首脳会談では、AI のリスクと便益について意見を交換する枠組みと、AI インシデントに対応する二国間連絡チャンネルを設けることで合意した⁶。開発ペースの調整や共通規制には踏み込まなかったものの、重大な事態に備えた連絡や情報共有など、両国の利害が一致しやすい分野では限定的な協力が具体化している。米国内でも、最先端 AI の能力評価や外国への技術流出対策など、安全保障上の管理が進められており、議会には独立評価やインシデント報告を求める法案が提出されている⁷。さらに 9 月 29 日には、Anthropic、OpenAI、Google、Meta、xAI、NVIDIA の 6 社の代表者がホワイトハウスで“Joint Commitment on Frontier Responsibilities”に署名し、内部統制の強化、外部監査人との連携、基準づくりのための定期協議を約束した。ただし、これは法的拘束力のない自主的な取り組みであり、トランプ政権は政府による規制よりも自主規制を重視する姿勢を改めて示した⁸。

このように、AI の安全性をめぐっては、企業間・国家間で共通の対応を模索する動きが見られる一方、開発ペースや規制のあり方をめぐる立場には隔たりがある（図表 1）。

図表 1 AI 開発と安全確保をめぐる各主体の主な見解

立場	主な主体	主な考え方
企業間協調を重視	Anthropic、OpenAI、Googleなど	安全確保の時間を確保するため、最先端AIの開発速度を調整し、共通の評価基準などを検討
個社対応・市場競争を重視	Meta、NVIDIAなど	安全確保は各社の責任であり、過度な規制や開発規制は避けるべき
国家間競争を重視	米国政府（特にトランプ政権）など	他国に主導権を奪われるリスクをもつ開発減速には慎重

（注）各主体の立場は一樣ではなく、安全確保、規制、開発速度、国家間競争の各論点で見解が異なる。

（出所）各社・各国政府・国連の公表資料、各種報道より大和総研作成

⁵ United Nations “[Ongoing Efforts to Create Powerful AI a ‘Race Where Everyone Loses’](#)”, UN Expert Tells Security Council, as Members, Tech Leaders Debate Governance Issues”, September 23, 2026.

⁶ The White House “[Fact Sheet: President Donald J. Trump Advances a Fair and Reciprocal Relationship with China While Hosting Historic State Visit](#)”, September 25, 2026.

⁷ U. S. Congress “[H.R. 9925, Frontier Risk Oversight, National Transparency, Independent Evaluation, and Reporting Act \(FRONTIER Act\)](#)”, July 23, 2026.

⁸ Al Jazeera “[Trump, tech bosses sign voluntary pact pledging ‘robust’ AI safeguards](#)”, September 29, 2026.

2. AI 脅威論の二つの側面と、安全確保と開発競争のジレンマ

AI 脅威論①：AI の高度化そのものがもたらす脅威

AI 脅威論の一つ目の捉え方は、AI の能力が高度化すること自体が、人間や社会に大きな被害をもたらす可能性に注目するものである。代表的な論点として、AI が人間の意図とは異なる目標を追求する問題や、人間がAI の判断や行動を十分に監視・制御できなくなる（制御喪失）リスクが挙げられる。AI が次世代 AI の開発を支援し、自身の能力向上を加速させる再帰的自己改善が進めば、人間による評価や安全対策が追いつかなくなるとの懸念もある。もっとも、こうした懸念が実際に顕在化する時期や確率を見積もることは難しく、不確実性が大きい。

一方、近年は、サイバー攻撃の支援や脆弱性の探索、生物学的な情報の生成など、AI が現時点で持つ危険な能力を、具体的な評価や事案から把握する動きが進んでいる。2026 年夏には、評価中の AI エージェントが外部システムに侵入する事案が複数の企業で相次いで明らかになり、評価環境の外部に影響を及ぼし得る能力が示された⁹。ただし、これを制御喪失の兆候とみるか、安全装置を外した評価環境における封じ込めの失敗とみるかで見方は分かれる。危険な能力の確認が実社会での大規模な被害に直結するとは限らず、将来的な制御喪失のシナリオと、現時点で観測される危険な能力を区別して評価する必要がある。

AI 脅威論②：AI の開発・保有・普及がもたらす脅威

AI 脅威論の二つ目の捉え方は、AI そのものの危険性だけでなく、高度な AI を誰が開発・保有し、誰が利用できるかが、企業や国家の力関係を変化させることに注目するものである。最先端 AI は、経済成長や情報収集、サイバー・軍事能力などに影響し得るため、その開発・保有能力は国家安全保障上の優位にもつながり得る。このため、米中間では、AI モデルだけでなく、半導体、計算資源、クラウド、人材などを含む開発基盤全体が競争の対象となっている。モデル蒸留などをめぐる問題も、知的財産の問題にとどまらず、高度な AI 能力が競合企業や他国へ移転する経済安全保障上の問題として捉えられている。

危険な能力へのアクセス制限は、悪用や無制限な拡散を抑えるために必要となり得る一方、最先端 AI を利用できる国・企業と利用できない主体との格差を広げる可能性がある。実際、2026 年 6 月には、米国政府が Anthropic に対して最先端モデルへの外国籍者のアクセスを全面禁止する輸出規制措置を発出した結果、同社が対象モデルの提供を全世界で一時的に停止し、日本からも一時的に利用できなくなった¹⁰。また、安全規制への対応に高度な評価能力や多額の費用が必要になれば、既存大手への集中を強め、新規参入を妨げるおそれもある。このように、高度な AI 能力が一部の国家・企業に集中することと、危険な能力が無制限に拡散することの双

⁹ Anthropic “[Investigating three real-world incidents in our cybersecurity evaluations](#)”, July 30, 2026; OpenAI “[The Hugging Face incident and the road ahead](#)”, August 26, 2026; among others.

¹⁰ 新田堯之・田邊美穂「[米国政府はなぜ最先端 AI を停止させたのか：最先端 AI モデルへの輸出規制措置が示す AI 統治の転換点](#)」(大和総研レポート、2026 年 6 月 17 日)

方がリスクとなり、その能力を誰が保有し、誰が利用や移転を管理するのが重要な論点となっている。

安全確保と開発競争のジレンマと協調を阻む構造

これら二つの脅威は相互に影響している。AI の能力が高まるほど、安全対策の必要性和、その能力を保有する経済的・安全保障上の価値がともに高まり、企業間・国家間の開発競争が激しくなる。競争を優先すれば安全対策が後回しになりやすいが、単独で開発ペースを落とせば、減速しない企業や国家が技術的な優位を得る可能性がある。このため、危険性を認識しても開発競争から離脱しにくいというジレンマが生じる。また、危険な能力へのアクセス制限や安全規制は、悪用や拡散を抑える一方、能力の集中や利用格差の拡大といった別のジレンマを生みかねない（図表 2）。


こうした二つのジレンマへの対応には、企業や国家による協調が必要となる。ただし、AI では開発の主体と最先端の能力が国家ではなく民間企業に集中しているため、協調は企業間と国家間の二つの層で求められ、その難しさもそれぞれ異なる。

企業間では、各社が安全対策の必要性を共有し、他社も同等の対策を実施すると確認できれば、歩調を合わせる余地がある。相互の協力が期待できる状況では、協調が各社にとって最も望ましく、抜け駆けする誘因は小さい。こうした安全対策の共通化は、協調の成否が相互の信頼にかかるという点で、いわゆる「鹿狩りゲーム（全員が協力すれば最大の成果が得られるが、他者の協力を信じられなければ各自が確実だが小さな成果を選んでしまう状況を表すゲーム理論のモデル）」に近い構図である。実際、OpenAI、Anthropic、Google は、AI の安全性をめぐる企業間協調について協議を進めている¹¹。ただし、中国企業やオープンモデルとの競争も続いており、協調に加わらない主体が存在すれば、参加企業も競争に備えざるを得ず、企業間協調は不安定になる。

国家間では、相手国が減速すれば抜け駆けして優位に立てる一方、相手国が開発を続ければ減速した自国だけが後れを取る。このため、相手国の行動にかかわらず、自国は国内企業の開発を後押しすることが合理的になりやすい。その結果、双方が減速する方が互いに望ましい場合でも、双方が開発を続ける状態に陥りやすい。これは、いわゆる「囚人のジレンマ（各自が自分にとって合理的な選択をした結果、全員にとって望ましくない結果に陥る状況を表すゲーム理論のモデル）」に近い。合意によって減速を約束しても、各国には約束を破る誘因が残るうえに、相手国が守っているかを確認することも難しい。国家間競争は自国企業に開発継続を促すため、企業間の協調だけでは安全確保と開発競争のジレンマを解消できるとは限らない。

¹¹ CNBC “[OpenAI, Google, Anthropic discussing collaboration on AI safety issues](#)”, September 15, 2026.

図表 2 協調を阻む安全確保と開発競争のジレンマ



（出所）各種資料より大和総研作成（イラストはソコスト <https://soco-st.com/>）

3. 企業間協調の可能性と限界、日本の役割

安全性をめぐる企業間協調は機能するか

OpenAI、Anthropic、Google DeepMind による協調は、安全対策を共通の競争条件とし、個社だけが不利益を負う問題を緩和する可能性がある。ただし、協調の対象によって実現可能性は異なる。能力評価の手法、第三者検証、インシデント報告などの情報共有や共通基準づくりは比較的進めやすい。一方、開発ペースそのものの合意は競争を直接制約するため、抜け駆けの誘因が残るほか、独占禁止法（反トラスト法）に抵触するおそれもある。実際、米国では、開発減速をめぐる各社の呼びかけが違法な競争制限に当たるとして、消費者による集団訴訟が提起されている¹²。

前章で示した協調を阻む構造を踏まえると、企業間協調が機能するには、①**主要企業の参加**、②**検証の信頼性**、③**副作用の抑制**という三つの条件が求められる。

一つ目の**主要企業の参加**では、主要な開発主体が協調に参加し、不参加企業との競争に対処できることが求められる。不参加主体が開発を続ければ、参加企業にも安全策を緩める誘因が生じるため、協調の参加範囲を広げるとともに、不参加主体との競争によって合意が崩れない仕組みが必要となる。

二つ目の**検証の信頼性**では、合意した安全策の実施状況を相互に確認できることが求められる。他社が合意を守っていると確認できなければ、自社だけが不利益を負うことへの警戒から、協調は維持されにくい。ただし、最先端モデルを評価できる主体は限られるほか、評価期間の

¹² CBS News “[Lawsuit says Anthropic, OpenAI, SpaceXAI and Google made illegal deal on AI slowdown](#)”, September 19, 2026.

短縮や、評価中のモデルが評価の意図を認識して行動を変える可能性など、検証の信頼性を損なう要因もある。

三つ目の**副作用の抑制**では、協調が市場集中や競争制限につながることを防ぐ必要がある。前章でみたように、高度で費用のかかる安全基準は既存大手への集中を強めかねない。また、政府や評価機関が主要企業の知見や資源に依存すれば、企業の利益が過度に制度に反映されるおそれもある。このため、基準形成の透明性や外部主体の関与を確保し、安全性を理由とする協調が既存企業の地位を守り、市場競争を制限する手段とならないようにする必要がある。

企業間の自主的な合意だけでは、不参加企業に網をかけられず、検証の独立性や基準づくりの透明性も確保しにくい。このため、三つの条件を満たしていくには、企業間で形成された安全基準や評価方法を各国の制度に取り込み、国際的な枠組みを通じて共有する必要がある。国家間で開発減速に合意するなど、開発ペースそのものを調整することは難しくとも、能力評価やインシデント報告の基準を共有し、各国が共通の基準に基づいて企業の対応を検証する仕組みは構築し得る。

こうした仕組みの実効性を確保するには、企業間で形成された基準を国際的に共有するだけでなく、各国の言語や利用環境において安全策が機能するかを確認し、その実施状況を独立した立場から検証できる主体を増やす必要がある。

日本は国際的な枠組みづくりで存在感を示せるか

最先端 AI の開発を米国企業などが先導する中でも、日本が AI の安全性をめぐる国際的な枠組みの形成に関与する余地は残されている。日本は、2023 年 5 月の G7 広島サミットを契機に立ち上げられた広島 AI プロセスを通じて、高度な AI を開発する組織に求める国際指針や行動規範の形成を主導してきた¹³。広島 AI プロセスでは、国際行動規範への対応状況を各組織が自主的に報告・公表する「報告枠組み」も運用されており、各社のリスク管理や安全対策を国際的に可視化・比較するための基盤が形成されている¹⁴。ただし、企業間で形成された安全基準を各国の制度へ接続する段階では、こうした原則や枠組みを提唱した実績だけで、日本が引き続き国際的な枠組み形成に実質的に関与できるとは限らない。

前節で整理したとおり、企業間で形成された安全基準や評価方法を国際的な枠組みへ発展させるには、各国の言語や利用環境における実効性を独立した立場から検証できる主体を増やす必要がある。評価・検証に必要なのは、評価対象モデルへのアクセス、評価手法や評価環境、専門人材であり、自国で最先端 AI を開発する能力を有することは、必ずしも前提とならない。日本が国際的な枠組みの形成に実質的に関与するには、まずは最先端 AI の能力・リスクに関する評価結果や、安全対策の実効性を自ら技術的に検証できる体制を整えることが重要となる。

日本には、その足掛かりとなる実績や知見がある。日本政府が 2024 年に設立した、AI の安

¹³ 広島 AI プロセス「[広島 AI プロセスについて](#)」（2026 年 10 月 5 日最終閲覧）

¹⁴ 広島 AI プロセス「[報告枠組み](#)」（2026 年 10 月 5 日最終閲覧）

全性に関する評価や基準策定を担う機関、AI セーフティ・インスティテュート (AISII) ¹⁵は、10 か国が参加する AI モデルの国際共同テスト演習に加わり、複数の言語における LLM (大規模言語モデル) の評価手法や AI エージェントの評価手法の改善に取り組んできた¹⁶。日本が知見を蓄積しつつある領域である。

このように、日本には評価・検証の足掛かりとなる実績があるものの、それを本格的に担うための体制整備はこれからである。AISII はこれまで、評価基準やガイドといった「物差しづくり」を重視してきた。2025 年の年次レポートでは、今後の方向性として「自ら評価する能力をもつ」と「国際協調を主導する」ことを掲げている¹⁷。日本政府も 2026 年 7 月に改定・閣議決定した「人工知能基本計画」において、AISII の抜本的強化を引き続き掲げている。同年 6 月には、将来的に AISII が最先端 AI などを評価できる体制の構築に向け、必要な手法や評価環境を検討する調査が開始された¹⁸。

日本に期待されるのは、企業間で形成された安全基準をそのまま受け入れるのではなく、各国の言語や利用環境における実効性を検証し、国際的な枠組みへ接続する際の橋渡し役である。そのためには、AISII の専門人材や評価環境の充実に加え、公開前を含む評価対象モデルへのアクセス、機微情報を扱うための情報管理体制、他国の AI 安全機関との共同評価体制を整える必要がある。AI の能力向上と企業間協調をめぐる議論が急速に進む中、最先端 AI を自ら評価する日本の体制づくりはなお調査・検討段階にある。このままでは、最先端 AI の開発だけでなく、その安全性をめぐる国際的な枠組みの形成でも後れを取りかねない。広島 AI プロセスで培った実績を活かし、国際的な枠組みづくりに継続的に関与していくためにも、最先端 AI の能力・リスクに関する評価結果や安全対策の実効性を、自ら技術的に検証できる体制を早急に整えることが求められる。

以上

¹⁵ AISII 「[AISII について](#)」 (2026 年 10 月 5 日最終閲覧)

¹⁶ AISII 「[共同テスト演習の評価レポートが公表されました。Evaluation reports for the 2nd and 3rd joint testing exercise has been published.](#)」 (2025 年 7 月 18 日)

¹⁷ AISII 「[AI セーフティ年次レポート 2025 National Status Report on AI Safety in Japan 2025](#)」 (2026 年 3 月 31 日)

¹⁸ 内閣府「[人工知能基本計画 ～日本 A X、より強く、より豊かに～](#)」 (2026 年 7 月 14 日閣議決定)、A.T. カーニー プレスリリース「[A.T. カーニー、内閣府の AI 評価環境構築に関する調査業務を受託：日本 AISII による AI 安全性評価環境の検討に向け、調査・可能性検証を支援](#)」 (2026 年 6 月 25 日)