

摘要：

谷歌用两款芯片回答一个问题——效率。TPU 8t强化超大规模训练与吞吐效率，借SparseCore与FP4及新网络架构大幅提升算力扩展能力；TPU 8i则聚焦低延迟推理，通过超大SRAM与CAE提升并发与解码效率。两者共享软件栈并深度整合云AI基础设施，直指AI工作负载分化与算力成本优化趋势。

谷歌将AI芯片战略推向新阶段。

在周三拉斯维加斯举行的Google Cloud Next 2026大会上，谷歌云发布第八代张量处理器（TPU）的两款新品——专为训练设计的TPU 8t与专为推理优化的TPU 8i，这是谷歌首次将训练与推理任务拆分至独立芯片，标志着其AI硬件路线的重大转向。

两款芯片均计划于2026年晚些时候正式对外供应。与去年11月发布的第七代Ironwood TPU相比，TPU 8t在同等价格下性能提升2.8倍，TPU 8i性能提升80%；两款芯片每瓦性能均较上一代提升逾一倍，TPU 8t达124%，TPU 8i达117%。

TPU 8t and TPU 8i at a glance

Feature	TPU 8t	TPU 8i
Primary Workload	Large-scale pre-training	Sampling, serving, and reasoning
Network Topology	3D torus	Boardfly
Specialized Chip Features	SparseCore (Embeddings) & LLM Decoder Engine	CAE (Collectives Acceleration Engine)
HBM Capacity	216 GB	288 GB
On-Chip SRAM (Vmem)	128 MB	384 MB
Peak FP4 PFLOPs	12.6	10.1
HBM Bandwidth	6,528 GB/s	8,601 GB/s (~1.3x of TPU 8t)
CPU Header	Arm Axion	Arm Axion

谷歌高级副总裁兼AI与基础设施首席技术官Amin Vahdat表示，随着AI智能体的兴起，“业界将受益于针对训练和推理各自需求专门优化的芯片”。Alphabet首席执行官桑达尔·皮查伊亦在博客中指出，这一架构旨在“以具有成本效益的方式，提供同时运行数百万个智能体所需的大规模吞吐量和低延迟”。

为何拆分为两款芯片

此次将第八代TPU一分为二，是谷歌对AI工作负载日益分化趋势的直接回应。预训练、后训练与实时推理在计算特性上已显著分化：训练任务追求极致吞吐量与规模扩展，推理任务则对延迟和并发更为敏感。单一芯片难以同时兼顾两类场景的效率最优。

谷歌在技术博客中指出，第八代TPU的设计哲学围绕可扩展性、可靠性与效率三大支柱，两款芯片共享谷歌AI软件栈的核心基因，但各自针对不同瓶颈进行了专项优化。

TPU 8t: 面向超大规模训练的算力引擎

在规模上，TPU 8t最多可将9600块芯片组合为单一超级计算节点（superpod），并通过JAX与Pathways框架将分布式训练扩展至单一集群超过100万块TPU芯片。

其一是SparseCore加速器，专门处理嵌入查找中不规则的内存访问模式，将数据依赖的全局聚合操作从矩阵乘法单元（MXU）中卸载，避免通用芯片常见的零操作瓶颈。

其三是更均衡的向量处理单元（VPU）扩展设计，使量化、softmax等向量操作与矩阵乘法实现更好的流水线重叠，提升芯片整体利用率。

图 1: TPU 8t ASIC 框图




图2：TPU 8t 机架级与 Virgo 光纤通道的连接

存储方面，TPU 8t引入TPUDirect RDMA与TPUDirect Storage技术，绕过主机CPU直接在TPU高带宽内存（HBM）与网卡、高速存储之间传输数据，存储访问速度较第七代Ironwood TPU提升10倍，可确保MXU在处理大规模多模态数据集时保持满载。




图3：上图显示了不使用 TPUDirect Storage 的数据传输路径。下图显示了使用 TPUDirect Storage 的 TPU 8t 数据传输路径，包括两个 TPU 8t 芯片之间的数据传输以及使用 TPUDirect Storage 连接到托管的 10T Lustre 存储的数据传输。

TPU 8i：面向高并发推理的低延迟专家

TPU 8i针对后训练阶段与高并发推理场景设计，其架构重心在于降低延迟、提升每芯片的并发处理能力。

片上存储是TPU 8i最显著的硬件特征。每块芯片集成384MB静态随机存取存储器（SRAM），是上一代Ironwood的三倍，可将更大的KV Cache完整保留在芯片上，大幅减少长上下文解码过程中核心的空闲等待时间，对需要多步骤推理的AI任务尤为关键。



图 4：TPU 8i ASIC 框图

TPU 8i还引入了集合加速引擎（CAE），专门加速自回归解码与“思维链”处理中的归约与同步步骤。每块TPU 8i芯片包含两个张量核心（TC）与一个CAE芯粒，取代了上一代Ironwood中的四个SparseCore，片上集合操作延迟降低5倍，直接提升了同时运行数百万智能体所需的吞吐量。

网络拓扑方面，TPU 8i放弃了TPU 8t沿用的3D环面（torus）结构，转而采用全新的Boardfly互联拓扑。3D环面在1024芯片配置下，任意两芯片间最多需要16跳；Boardfly通过高基数设计将最大跳数压缩至7跳，网络直径缩减56%，全对全通信延迟改善最高50%，对混合专家模型（MoE）和推理模型中频繁的跨芯片令牌路由尤为有利。Boardfly采用分层结构，从四芯片构建块逐级扩展至最多1152块芯片的完整Pod，并通过光学电路交换机（OCS）实现组间互联。




图 5：TPU 8i 分层式 Boardfly 拓扑结构，从四个完全连接的芯片组成的基本单元构建而成，再构建成为八个完全连接的板组成的组，36 个这样的组完全连接成一个 TPU 8i pod。

软件生态与市场意义

谷歌强调，硬件性能的释放有赖于配套软件栈的协同。

第八代TPU延续第七代Ironwood建立的软件体系，支持JAX、PyTorch、Keras及vLLM等主流框架，并提供Pallas自定义内核语言以充分挖掘SparseCore与CAE的硬件潜力。

谷歌同时宣布，原生PyTorch对TPU的支持现已进入预览阶段，用户可直接将现有PyTorch模型迁移至TPU运行，无需修改代码。

从市场角度看，谷歌此次双芯片策略直接回应了AI基础设施成本压力。训

练与推理对硬件的需求差异显著，统一芯片意味着在某一场景下必然存在资源浪费。通过专项优化，谷歌得以在价格性能比上实现更大幅度的提升，为云客户提供更具竞争力的单位算力成本。

两款芯片均已纳入谷歌云AI Hypercomputer超算架构，与硬件、软件及网络深度集成，覆盖AI全生命周期工作负载。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

394 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论