

摘要：

摩根大通最新报告揭示AI基础设施市场深层裂变：9月Token用量环比暴增71%、同比飙至30倍，但价格却同比腰斩55%，廉价开源模型DeepSeek、GLM正以“以量换价”重塑行业格局。与此同时，H100租赁价格转跌、DRAM五连涨后首现回落，供给扩张压力隐现，算力市场繁荣表象之下暗流涌动。

AI基础设施需求整体保持强劲，但各细分市场的价格信号正在出现明显分化。据摩根大通最新数据中心观察报告，9月Token用量与支出双双加速增长，但GPU租赁价格走势分化，内存现货价格在连续上涨后出现首次回落。

据追风交易台，摩根大通分析师Joseph Cardoso在9月29日发布的报告中指出，9月OpenRouter平台Token用量环比激增71%，同比达30倍，**整体支出环比增长28%、同比扩大14倍**。

与此同时，英伟达GPU租赁市场出现明显分化：A100与H100租赁价格双双环比下滑，而B200在8月首次下跌后小幅反弹。内存市场方面，**DRAM现货价格在连续五个月上涨后于9月出现首次环比小幅回落，NAND价格则基本持平**。

上述信号对AI基础设施投资者而言意义复杂。Token用量的持续加速印证了AI应用层需求的真实性，但GPU租赁价格的下行压力以及内存价格涨势的暂歇，提示供给端扩张与需求结构变化正在对硬件定价形成制约。

Token用量加速，廉价开源模型主导增长

9月Token用量增长明显提速。据摩根大通追踪OpenRouter平台的数据，9月Token用量环比增长71%，高于8月的47%和7月的18%，同比增速达30倍。

增长的核心驱动力来自开源模型。开源模型（包括DeepSeek、Moonshot AI等）用量环比激增83%，同比增幅高达101倍，增速显著快于闭源模型（OpenAI、Anthropic等）的环比39%、同比10倍。闭源模型在总用量中的占比已从8月的33%降至27%。

按用量排名前五的模型依次为：DeepSeek V4.1 Flash、GLM 5.3 Flash、腾讯Hy4 preview、GPT-5.6 Luna及DeepSeek V4 Flash，合计占总Token用量逾53%。其中，DeepSeek V4.1 Flash与GLM 5.3 Flash两款模型单月合计贡献约41万亿Token，占总量约30%，且定价远低于此前开源模型均值。


量价背离：支出增长依赖用量扩张而非提价

Token用量的爆发式增长并未带动单价上行，量价背离特征显著。9月成交量加权平均价格（VWAP）环比下降25%、同比下降55%，主要由两方面因素驱动：一是用量向更廉价的高流量模型集中，DeepSeek V4.1 Flash与GLM 5.3 Flash的大规模采用拉低了整体均价；二是Kimi K3、GLM 5.3及GPT-5.6 Sol等模型出现同款降价。

尽管如此，整体Token支出仍实现加速增长，9月环比增长28%，高于7月和8月各7%的增速，同比扩大14倍。支出增长的主要贡献来自开源模型，其支出环比增长64%、同比增长132倍，在总支出中的占比从8月的22%升至28%。

Figure 1: Token Volumes


Weekly Tokens in Trillion



Source: OpenRouter, J.P. Morgan Estimates

Figure 2: Average Token Pricing

\$ per Million Tokens



Source: OpenRouter, J.P. Morgan Estimates

* Includes models without observable volumes on OpenRouter

值得注意的是，按支出排名的前五大模型与按用量排名的前五大模型仅有一款重叠。支出前五依次为GPT-6 Astra、腾讯Hy4 preview、Claude Fable 5.1、Claude Opus 5及GPT-5.6 Sol，合计占总支出50%，显示高单价闭源旗舰模型仍主导收入端。

GPU租赁：H100承压，B200企稳反弹

9月非超大规模云服务商的GPU租赁市场呈现明显分化。据彭博指数数据，A100租赁均价为每GPU小时1.59美元，环比下降2.8%，降幅较8月的0.7%有所扩大；H100租赁均价为每GPU小时2.64美元，环比下降2.6%，而8月为环比上涨0.4%。

B200走势则与前两者相反。9月B200租赁均价回升至每GPU小时5.70美元，环比上涨1.3%，扭转了8月环比下跌1.5%的局面。B200与H100的价格比率升至2.16倍（8月为2.08倍），H100与A100的价格比率也小幅升至1.66倍（8月为1.65倍）。


摩根大通指出，B200定价约为H100的2.2倍，H100定价约为A100的1.7倍，两项比率均环比走高，反映出市场对新一代算力的相对溢价仍在维持，但旧型号GPU的供给压力正在加剧。

内存价格：DRAM五连涨后首现回落，NAND趋于稳定

内存现货市场的涨势在9月出现阶段性停顿。据彭博数据，DDR5 16Gb现货价格9月报49.70美元，环比下跌约1%，为连续五个月上涨后的首次回落，但同比仍大幅上涨614%（去年同期为6.96美元）。


NAND方面，1Tb现货价格9月报30.54美元，环比微涨0.1%，基本持平，同比涨幅约470%（去年同期为5.36美元）。摩根大通指出，NAND价格在此前连续四个月小幅下跌后于上月首次转正，9月则维持稳定。

Figure 9: Memory Prices (M/M % Change)



Source: Bloomberg Finance L.P.

Figure 10: Memory Prices (Y/Y % Change)



Source: Bloomberg Finance L.P.

DRAM价格的环比回落是否预示涨势终结，目前尚无定论，但同比涨幅仍超6倍的绝对水平，表明AI驱动的内存需求扩张在过去一年间已对价格形成实质性支撑。

~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入【[追风交易台·年度会员](#)】

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

96 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论