

摘要：

AI迭代正击穿预测极限，受Claude Opus 4.6惊人表现冲击，权威研究员Ajeya Cotra坦言其对2026年的AI进展预测已提前失效，今年底“AI研发自动化”的概率达10%，她表示“已找不到任何稳固趋势能断言这不会很快发生”！

人工智能能力的跃升速度，正在让最严谨的预测者也措手不及。

知名AI预测研究者Ajeya Cotra近日公开承认，她仅在两个月前发布的2026年AI进展预测已显著偏于保守。触发这一自我修正的，是Anthropic最新模型Claude Opus 4.6在权威评测机构METR基准测试中的表现，该模型的软件工程“时间跨度”已达约12小时，远超Cotra此前预测的2026年底约24小时水平。这意味着AI在软件工程领域的实际进展，比她的预测提前了近十个月。

更具冲击力的是，Cotra随之上调了对“AI研发全面自动化”的概率判断。她将今年年底AI完全接管研究构想与实施、无需人类介入的概率维持在10%，并明确表示：“这是我第一次找不到任何可以外推的稳固趋势，来断言这件事不会很快发生。”这一表态在AI预测圈引发广泛关注。

Cotra曾在全球最大AI安全资助机构之一Coefficient Giving担任AI安全研究资助负责人，目前供职于METR——一家专注于AI能力评估的机构。

预测落空：两个月前的判断已经过时

今年1月14日，Cotra基于2019年至2025年间时间跨度约每年翻倍不到两次的历史趋势，预测2026年底最先进模型的50%成功率时间跨度约为24小时，80百分位预测为40小时。

然而，仅在她发布预测约两个月后，Opus 4.6便被评估为具备约12小时的时间跨度。在METR测试集中，19项被估计需要人类耗时超过8小时的软件工程任务里，Opus 4.6能够至少部分完成其中14项，并稳定攻克其中4项。Cotra坦言，在此后还有整整十个月进展的情况下，AI代理仍在24小时任务上有一半时间失败，“已经不再可信”。

值得注意的是，Cotra同时提示，当前时间跨度估算的不确定性显著上升——Opus 4.6的95%置信区间为5.3小时至66小时，部分原因在于长任务数量稀少、人工完成时间多为估算，且基准测试本身已接近饱和。

能力边界：传统评估框架正在失效

随着AI代理能力逼近乃至超越数十小时的任务量级，Cotra认为“时间跨度”这一概念本身的适用性正受到挑战。

她指出，任务的可分解性随规模增长而显著提升：一小时的调试任务几乎无法拆分并行，一天的开发任务勉强可以分工但边界模糊，而一个月乃至数月的项目则天然适合拆解为多个并行子任务。一旦AI代理能够稳定完成80小时量级的任务，理论上便可通过“管理层AI”分配任务、“执行层AI”并行推进的方式，持续推进任意规模的项目。

Cotra的同事Tom因此提出，以大型团队完成任务所需的日历时间，而非单人工时，作为衡量“内在难度”的更优指标。Cotra认为，随着AI进入这一新量级，“单人时间”指标可能开始呈现超指数增长，使得年底前软件工程能力的上限极难估算。



她同时承认，这种大规模任务分解在实践中不会完美运作——项目参与者对全局背景的直觉性把握，难以被Jira工单或Asana任务完全替代。但她认为，对于相当大一类软件项目而言，这种模式“可能出乎意料地有效”。

关键节点：AI研发自动化今年或成现实

在所有预测中，最受关注的是Cotra对“AI研发全面自动化”的概率判断。

她将这一概率定义为：**AI系统完全承担研究构想与实施工作，无需人类参与**。在1月的预测中，她给出了10%的概率，并在发布后收到多位AI预测领域同行的反馈，认为这一数字偏高。但在Opus 4.6的表现出炉后，她表示10%“再次感觉处于合理区间”。

Cotra同时保持审慎。她指出，全面自动化AI研发不仅需要软件工程能力，还需要在“研究判断力”和“创造力”等方面取得突破，而这些恰恰是当前AI系统相对人类研究者仍明显欠缺的领域。她认为，这一目标在未来三至五年内实现的可能性，远高于今年之内。

但她的措辞已发生根本性转变：“这是我第一次，找不到任何可以外推的稳固趋势，来断言它不会很快发生。”

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

👍 99

★ 收藏

分享到:  

写评论

请发表您的评论

😊 表情

🖼️ 图片

发表评论

1 条评论



MobileUser7913

2小时前 中国上海

别扯那些没用的，首先你就告诉我，ai 怎么判断一件事是对还是错？？？要回答这个问题，模型要先学会自己训练自己，而不是 4.5， 4.6， 4.7..... 的靠人去发布新的版本，如果你的模型版本更新还是靠人在发布，你就不要扯什么能够自主研发，自主学习。第一性原理，你可以通过任何渠道，任何办法获得到模型究竟是什么，模型就是个概率统计机器，概率是没有对和错的，没有善与恶，没有好与坏，没有方向，没有预期，没有白闭环迭代。搞懂他是什么。 [展开全部](#) ✓

👍 0 ↩️ 回复