

摘要：

OpenAI CEO Sam Altman警告，AI发展需避免失控或被少数主体掌控两种极端，并呼吁行业在模型能力提升的同时同步强化安全与治理。OpenAI正将安全评估前移至模型开发阶段，同时推动与Anthropic、谷歌等建立行业标准。他认为，即使监管尚未落地，AI企业也应先行推进安全标准。

上周末，全球AI三大巨头罕见释放“放缓研发”信号，OpenAI首席执行官Sam Altman也再次呼吁AI行业共同建立安全标准。

9月14日，Altman在X平台发帖称，人工智能发展存在两种最坏结果：一是AI最终失控，人类失去对未来的控制；二是极度强大的AI被少数个人、公司或国家掌控，并将自身意志强加于所有人。他认为，这两条红线都不能触碰。

Altman表示，OpenAI已开始在重大能力提升的强化学习训练启动前，主动制定明确的安全论证（safety cases），并希望其他前沿AI公司采取类似做法，围绕模型失准、监控和安全等问题形成统一标准。

据The Information援引知情人士，Anthropic、OpenAI和谷歌已就合作成立AI行业标准机构展开磋商，相关工作组会议仍在进行。这意味着，头部AI实验室的安全治理思路正从各自制定内部规则，逐步转向推动行业协调框架。

← 邮政



山姆·奥特曼 @sama



人工智能的发展有两种可能走向极端且极其糟糕的方向，我们必须避免。首先，我们可能会失去对未来的控制权，任由人工智能掌控。这是不可接受的；我们坚定地站在人类一边，人工智能必须始终服务于人类。为了确保这一点，我们需要采取措施，保证人工智能的适配性和安全性始终领先于模型能力的提升。其次，我们可能会陷入权力过度集中的世界。如果某个人或公司利用极其强大的人工智能将他们的世界观强加于所有人，其后果可能是极其反乌托邦式的。避免这两种威胁需要我们采取折衷方案；例如，避免某个国家权力过大，或者避免某个实验室权力过大。



山姆·奥特曼 @sama · 5小时

世界理应相信，美国公司在开发日益强大的人工智能时会秉持负责任的态度，尤其是在人工智能发展速度日趋加快的当下。每个前沿实验室都必须做到这一点，如果我们做不到这一点，我们就没有理由来上班。

下午12:18 · 2026年9月14日 · 140万 浏览量

2.3K

1.7K

11K

2.5K



安全治理前移，AI“调速”并非放缓发展

Altman强调，随着模型能力不断提升，对齐（alignment）和安全技术也必须同步甚至更快发展，避免AI能力跑在安全保障之前。AI行业需要走一条“狭窄的中间道路”：既不能因竞争压力牺牲安全，也不能让AI能力提升明显领先于对齐、监控和治理能力。



他认为，AI安全治理的重点正从模型部署后的风险控制前移至开发过程本身。OpenAI目前的做法是，在启动预计将显著提升模型能力的前沿强化学习训练前，就提前制定安全论证（safety cases），而不是等模型完成后再进行安全评估。

他同时强调，“调速”（pacing）并非停止AI进步，而是避免以技术上能够达到的最快速度推进。尽管安全论证和监控措施会增加研发成本，但这些投入仍有必要，以确保安全和治理能力跟上模型能力的提升。

监管尚待落地，AI行业应先行推动安全标准

在监管层面，Altman支持美国政府为前沿AI设立统一安全要求，但认为行业没有必要等到相关立法落地后再行动。即使缺乏政府参与，主要AI实验室也应率先推动行业标准机构成立，并探索独立审计等机制。

据报道，Anthropic首席执行官Dario Amodei上周六已公开呼吁AI公司加强技术测试和审核方面的协调。此前，Anthropic、OpenAI和谷歌已就合作成立行业标准机构展开磋商。

Altman在一次员工大会上表示，即便美国政府暂时没有参与，主要AI实验室也应自行推进标准建设；至于全球层面的协调，则需要政府介入，但“首先我们应当尽力自为”。

在他看来，随着AI能力持续提升，社会对前沿AI公司的安全要求也将越来越高，而行业自律最终需要落实到每一家AI实验室的具体行动中。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

79 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

4 条评论

7小时前 中国广东省

一边担心被赶超，一边担心不受控

0

回复





见闻用户
18小时前 中国浙江省

以美国的三巨头私人公司为主导建立的所谓安全标准，真的安全么？还是原本就是以安全为由建立垄断，排他性的标准呢？！

👍 0 ↩ 回复



TONY焦
19小时前 中国广东省

美国如果真的敢停或者暂缓，中国马上能追上来。如果美国失去了AI的领导地位，未来美国将失去所有。他们搞这个所谓的行业安全标准，绝对会打压开源。

👍 0 ↩ 回复



略知一二
19小时前 中国上海

呵呵，其实这产业最忌讳的是私有化。其实ai服务和电信服务，高速服务，航空服务，或者供电供暖服务，教育服务，医疗服务一样。都属于公共产业，最忌讳的就是私有化，导致价格和品质的失控。应该让国家来统一管理才令人安心。

👍 0 ↩ 回复