

摘要：

英伟达5月底就宣布，Vera已进入全面生产，并称该芯片的特定任务完成速度可达到传统x86 CPU的1.8倍。本周二英伟达强调，相比单纯堆叠更多核心，Vera更重视单线程性能、核心之间的通信带宽以及内存访问延迟，并表示Vera Rubin NVL72正在全球范围内进入量产爬坡，CoreWeave、谷歌、微软等合作伙伴已开始部署相关机架；CoreWeave运行基准测试结果显示，Vera Rubin NVL72的每兆瓦Token产出量较Blackwell架构提升10倍。

英伟达正在把战火从GPU市场烧向CPU。

在AMD举行AI相关活动前夕，英伟达于美东时间21日周二集中披露下一代Vera Rubin平台的最新进展：Vera Rubin NVL72已经进入量产爬坡阶段，英伟达称该平台的供应链覆盖全球350多个工厂和30个国家，已有超过300家合作伙伴参与其中。

同时，英伟达进一步公布了Vera CPU及Vera Rubin平台在AI智能体（agent）工作负载中的性能数据，试图证明，随着AI从“回答问题”转向自主规划、调用工具和执行任务，CPU正在成为AI基础设施的新战场。

英伟达披露的数据中心CPU产品Vera的完整规格、基准测试结果及架构信息是潜在客户全面评估该芯片所必需的关键数据。该公司表示，Vera芯片已于6月向OpenAI、Anthropic和SpaceX等客户完成交付。

Vera推出，是英伟达垂直整合战略的最新一步。该公司意图向客户销售包含自研芯片的完整计算机架系统，而非单纯出售单颗芯片。Wolfe Research估算中，Vera芯片单颗均价约为5000美元，预计今年出货量约达130万颗。对于AMD和英特尔而言，英伟达此举直接威胁到两家公司在服务器CPU市场的核心利益。

这并不是英伟达首次宣布Vera CPU进入量产。英伟达今年5月底就宣布，Vera已经进入全面生产阶段，并称该芯片在特定任务完成速度上可达到传统x86 CPU的1.8倍。5月中旬，英伟达还曾向Anthropic、OpenAI和SpaceX等客户交付首批Vera CPU系统。此次公告的重点，则进一步转向Vera Rubin整个平台的量产爬坡、客户部署以及真实生产环境中的性能表现。

AI智能体崛起，CPU重新成为“关键瓶颈”

英伟达押注CPU的核心逻辑，是AI应用正在发生变化。

传统生成式AI的主要任务是根据用户输入生成答案，GPU承担大规模模型计算，而CPU更多负责相对外围的调度工作。但随着AI智能体快速发展，AI系统开始自主拆解任务、调用外部工具、运行代码、访问数据并反复评估结果。

在这一过程中，CPU需要频繁处理大量低延迟、实时性的任务。英伟达认为，AI代理并不是单纯依赖GPU的工作负载：每一个智能体的运行环境、工具调用、任务编排以及长上下文数据检索，都需要CPU参与。

英伟达在此前发布Vera时就指出，代理式AI正在创造一个新的“CPU时刻”。其判断是，随着AI系统从“回答问题”转向“采取行动”，CPU在整个AI工厂中的作用将明显上升。

英伟达甚至预计，服务器CPU市场的长期规模可能达到2000亿美元。与传统服务器CPU市场相比，这一数字显得极为激进，但英伟达的逻辑在于，未来CPU的市场边界可能不再局限于传统企业服务器，而是扩展到AI推理、AI智能体、强化学习、数据处理以及AI基础设施的各种控制和编排任务。

这也是英伟达试图重新定义CPU竞争规则的原因。

不拼核心数量，英伟达押注“单核速度”

Vera的设计路线与传统服务器CPU存在明显差异。

英伟达称，Vera是其首款专门为代理式AI设计的CPU，采用英伟达自主设计的88颗Olympus核心，配备1.2TB/s内存带宽。英伟达此前表示，Vera相比传统CPU可实现50%的单核性能提升；在5月底公布的测试中，Vera在特定任务完成速度上达到x86 CPU的1.8倍。

而在最新披露中，英伟达进一步强调了Vera的核心设计取向：相比单纯堆叠更多核心，Vera更重视单线程性能、核心之间的通信带宽以及内存访问延迟。

英伟达称，Vera的定制Olympus核心可实现2倍单线程性能、3倍核心间带宽，以及相比竞争性芯粒设计降低40%的内存延迟。其目标是让AI代理能够更快完成任务，并尽快将计算资源交还给GPU，从而提高整个AI工厂的利用率。

这背后的商业逻辑非常直接：GPU是AI数据中心中最昂贵、最稀缺的计算资源之一。如果CPU处理任务速度过慢，GPU就可能处于等待状态。英伟达希望通过专门优化CPU，减少这一“空转”时间。

在DeepInfra对Vera CPU进行的生产环境测试中，英伟达称，Vera可支持最多1.6倍的并发AI代理数量，并实现最高2.2倍的任务编排速度。需要注意的是，这些数据来自客户的特定测试环境，并不意味着Vera在所有通用CPU工作负载中都全面领先。

竞争焦点从一颗芯片，升级为整座“AI工厂”

Vera CPU只是英伟达更大系统战略中的一部分。

在Vera Rubin平台中，英伟达不仅整合了自研的Vera CPU、Rubin GPU及网络和数据处理芯片，还纳入了基于Groq技术打造的Groq 3 LPX推理加速机架，形成一套覆盖训练、后训练、测试时扩展和实时推理的完整AI基础设施。

英伟达称，Vera Rubin NVL72正在全球范围内进入量产爬坡，CoreWeave、谷歌云、微软Azure和甲骨文Oracle Cloud Infrastructure等合作伙伴已经开始部署相关机架。英伟达还表示，其供应链覆盖350多个工厂和30个国家，参与合作伙伴超过300家。

在客户测试方面，CoreWeave使用Vera Rubin NVL72运行DeepSeek-R1测试后称，相比上一代Grace Blackwell NVL72，其每兆瓦每秒生成的Token数量提升了10倍。Google Cloud则已推出基于Vera Rubin NVL72的A5X实例，英伟达称其在特定场景下可实现更低的推理成本和更高的每兆瓦Token吞吐量。





这意味着英伟达的竞争对象已经不再只是AMD的Instinct GPU或英特尔的Gaudi等单颗加速芯片。

英伟达试图控制的是整套基础设施：CPU负责调度，GPU负责计算，网络芯片负责高速互联，软件负责调度和优化，最终以机架甚至数据中心级别的系统向客户交付。

对于AMD和英特尔而言，这种竞争方式的威胁在于，英伟达可能不需要在传统CPU市场中与它们进行完全对称的竞争。英伟达的目标是从AI服务器中最具增长潜力的部分切入，先争夺代理式AI、强化学习和高性能AI推理等工作负载，再逐步扩大CPU的应用范围。

AMD、英特尔的传统优势，迎来新的挑战

长期以来，英特尔和AMD掌握着服务器CPU市场的主导权。

但英伟达如今的判断是，AI基础设施正在改变CPU的价值排序。过去，服务器CPU的竞争更多围绕核心数量、通用计算能力和整体吞吐量展开；而在代理式AI时代，低延迟、单线程性能、内存带宽和任务编排效率的重要性正在上升。

这正是英伟达认为自己能够切入的市场空白。

从产品形态看，Vera既可以作为独立CPU使用，也可以与英伟达GPU组成Vera Rubin系统。英伟达还将其定位为连接AI代理与GPU计算资源的关键组件。

英伟达在此前公布的客户名单中已经包括Anthropic、OpenAI和SpaceX等AI公司，以及ByteDance、CoreWeave和Oracle Cloud Infrastructure等云服务商；戴尔、惠普企业、联想和超微等服务器厂商也在推进基于Vera的系统。

这使得英伟达拥有一个不同于传统CPU厂商的优势：它可以通过GPU、CPU、网络 and 软件的组合，向客户提供完整解决方案。

但这并不意味着英伟达能够轻易撼动AMD和英特尔。

CPU市场的竞争不仅是芯片性能的竞争，也包括软件生态、客户认证、服务器兼容性以及长期供应关系。尤其是大型云服务商和企业客户，通常需要多年时间完成硬件平台切换。

因此，Vera能否真正从AI专用场景扩展到更广泛的服务器市场，仍取决于客户能否获得足够明显的性能和成本优势。



英伟达正在打开GPU之外的新收入曲线

英伟达此次在AMD AI活动前夕集中释放Vera Rubin的量产和性能信息，也具有明显的市场竞争意味。

过去几年，英伟达几乎凭借GPU独占了AI基础设施最核心的利润池。但随着AMD持续扩大AI加速器布局，英特尔也试图在AI芯片市场寻找突破口，市场开始越来越关注英伟达能否继续维持高速增长。

与此同时，AMD和英特尔的CPU业务也因代理式AI带来的新需求预期而重新获得市场关注。

英伟达的回应是：如果AI数据中心的价值正在从单一GPU计算扩展到完整的AI工厂，那么英伟达不必把CPU市场拱手让给竞争对手。

从这个角度看，Vera并不是英伟达简单推出的一款服务器CPU，而是其垂直整合战略的进一步延伸。

英伟达希望客户购买的不再是单颗GPU、CPU或网络芯片，而是一整套能够直接运行AI模型和AI代理的基础设施。

如果代理式AI真的成为下一轮计算需求增长的核心驱动力，那么英伟达将争夺的，可能不仅是GPU市场的份额，而是整个AI服务器计算价值链。

而这也意味着，AMD和英特尔未来面对的竞争对手，可能不再只是彼此，而是一个已经拥有GPU、CPU、网络、软件和整机系统能力的英伟达。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取



限免

297

收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

