摘要：

AMD发布Helion智能体AI机架设计，基于开放计算项目（OCP）规范，CPU-only配置最高支持32768个CPU核心，同时提供CPU+GPU一体化企业配置。平台内置token路由器，支持多模型调度，思科、戴尔、HPE等八家主流硬件厂商已宣布支持，相关产品预计2026年11月上市。

AMD于10月12日正式发布Helion智能体AI机架，这是一套基于开放计算项目（OCP）规范的开放蓝图，搭载AMD自家计算芯片，专为智能体AI工作负载设计。

该平台提供两种主要配置，分别针对超大规模数据中心和企业级客户。AMD表示，合作伙伴的相关配置产品目前正在开发中，计划于2026年11月上市。

思科、戴尔、富士康母公司鸿海科技集团、惠普企业（HPE）、联想、QCT、超微（Supermicro）和Wiwynn八家公司已宣布支持该平台，覆盖从系统集成到液冷方案的完整生态链。

两种配置，分别对应超大规模与企业场景

Helion平台的第一种配置为纯CPU机架，**搭载第六代AMD EPYC处理器，最高可扩展至32,768个CPU核心。**AMD表示，该配置面向超大规模客户，提供专用的智能体执行容量，与模型推理基础设施相互独立。

第二种为一体化机架，将AMD EPYC CPU节点、AMD Instinct MI350P GPU节点与通用计算整合于单一平台，定位企业级智能体AI部署。

两种配置均支持液冷和风冷版本。此外，Helion还内置集成式令牌路由器（token router），可将AI智能体的模型调用分发至前沿模型和开源模型。

AMD高管：智能体AI不是单一工作负载

AMD计算与企业AI高级副总裁兼总经理Dan McNamara在声明中表示："智能体AI不是单一工作负载，它涵盖个人智能体、企业应用、代码执行和复杂工作流，每类场景的计算需求各不相同。"

他进一步说："AMD Helion将EPYC性能、开放软件和灵活机架设计整合在一起，让合作伙伴能够围绕客户需求构建系统，并高效利用可用电力。"

AMD还表示，Helion建立在现有AMD Helios机架级解决方案的设计思路之上，旨在让合作伙伴和客户能够将CPU与GPU配置与具体工作负载需求相匹配，包括性能、功耗和成本目标。

八大厂商背书，生态覆盖完整

八家合作伙伴均发表声明，表态支持Helion平台。

戴尔科技计算与网络高级副总裁Arun Narayanan表示，AMD Helion与戴尔PowerRack基础设施的结合，为客户提供了"一条完整、经过验证的大规模部署智能体计算路径"。

HPE高性能计算与AI基础设施解决方案高级副总裁Trish Damkroger表示，两家公司正在"以开放的大规模系统开启AI的下一个时代"，并指出该方案同时支持风冷和直接液冷网络选项。

思科计算业务高级副总裁Jeremy Foster表示："智能体AI正在改变客户对基础设施的需求，不仅仅是计算性能，还涉及整个系统的连接、管理和安全。AMD Helion这样的架构，结合思科的全栈基础设施能力，能给客户更大的灵活性。"

超微首席商务官Vik Malyala表示，超微将通过其数据中心积木式解决方案（DCBBS）将Helion推向市场，"帮助客户更快部署、高效扩展，加速智能体AI的上线速度"。

AMD表示，计划将Helion规范提交至开放计算项目（OCP），供更广泛的行业社区在此基础上进一步开发和采用。

这一举措延续了AMD在Helios平台上的开放平台策略，意在通过开放标准扩大生态影响力，吸引更多合作伙伴围绕该规范构建产品。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

45 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论