


摘要：

Dario Amodei发文呼吁，政府须对头部AI企业实施强制监管。他提出，计算量超 10^{25} FLOPs、AI营收超5亿美元或AI研发投入超10亿美元的企业，模型必须通过第三方安全测试，存在灾难性风险时政府有权阻挡或撤销其部署。同时，Anthropic承诺投入2亿美元用于政策研究、1.5亿美元用于奖学金。

就在刚刚，Anthropic 的创始人兼 CEO Dario Amodei发表了一篇万字檄文——《指数级AI政策》！

这是一篇足以载入AI发展史册的重磅文章。

在文中，Amodei做出了罕见的举动：作为全球顶尖AI实验室的掌门人，他主动要求政府对自己和同行实施严厉监管。



他主张，计算量超过 10^{25} FLOPs或者AI相关营收超过5亿美元/AI研发投入超过10亿美元的头部AI企业，必须接受政府强制监管。

一旦发现模型存在生物、网络安全或自主失控等灾难性风险，政府可以直接「封杀」！

同步发布的，还有Anthropic的两份正式政策提案：一份针对前沿AI模型的强制监管框架，一份针对AI引发的就业冲击的经济补偿方案。

Policy on the AI Exponential 人工智能指数政策

AI is advancing at exponential speed, and the policymaking process was built for a slower world.

人工智能正以指数级速度发展，而政策制定过程却是为发展速度较慢的世界而设计的。

We are sharing two policy proposals to prepare for AI progress. The first, our Advanced AI Framework, offers a roadmap for governing increasingly capable systems, from transparency and independent evaluation to government authority to block or deter dangerous deployments. The second, our Economic Policy Framework, turns to the question of how to prepare workers and the economy for AI's impact and ensure the financial benefits of AI are broadly shared. Together they cover two sides of the same challenge: steering the technology responsibly as it advances, and preparing society for what it brings.

我们在此分享两项政策建议，以应对人工智能的快速发展。第一项是我们的“高级人工智能框架”，它为管理日益强大的系统提供了路线图，涵盖了从透明度和独立评估到政府阻止或遏制危险部署的权力等各个方面。第二项是我们的“经济政策框架”，它着眼于如何让劳动者和经济做好应对人工智能影响的准备，并确保人工智能带来的经济效益惠及大众。这两项建议共同涵盖了同一挑战的两个方面：一是负责任地引导技术发展，二是让社会做好应对人工智能带来的挑战的准备。

微信公众号·新智元

为了表示来真的，Anthropic承诺为这两份提案提供了真金白银——2亿美元用于研究，1.5亿美元用于奖学金。

今天，Anthropic的这一举动，彻底打破了硅谷巨头长期以来抗拒监管的默契。

它向全球释放了这样一个信号：温和的自律时代已经宣告终结，AI指数级爆炸的速度，逼迫我们必须灾难发生前，给大模型套上真正的「紧箍咒」！



主动呼吁严厉监管，为AI装上“紧箍咒”



震撼发布
《策》
“诅咒”

Dario Amodei
Anthropic 创始人兼 CEO

Dario Amodei
Anthropic 创始人兼 CEO

核心主张：头部AI企业必须接受强制监管

监管门槛（满足任一条件）



计算量超过
 10^{25} FLOPs



AI相关营收超过
5亿美元



AI研发投入超过
10亿美元

政府强制权力

一旦发现模型存在生物、网络安全或自主失控等灾难性风险，政府可以直接“封杀”！



同步发布两份正式政策提案

1. 前沿AI模型强制监管框架

- 建立分级监管体系
- 要求安全评估与红队测试
- 强制信息披露与审计
- 赋予政府紧急干预与封禁权力

2. AI引发就业冲击的经济补偿方案

- 设立AI转型支持基金
- 提供再培训与教育支持
- 向受影响劳动者提供经济补偿
- 推动社会公平转型

真金白银的承诺：3.5亿美元投入



2亿美元
用于政策研究与安全评估



1.5亿美元
用于奖学金与人才培养

“温和的自律时代已经宣告终结，AI指数级爆炸的速度，逼迫我们必须要在灾难发生前，给大模型套上真正的“紧箍咒”！”



打破硅谷抗拒监管的默契！

Anthropic 向全球释放明确信号：安全高于竞争，责任重于速度。

为人类未来，负责任地发展AI



制图: Aeneas

树人觉醒了！

托尔金在《指环王》里写过，树人是森林的守护者，古老、睿智、强大。但他有一个致命的弱点：太慢了。跟另一棵树打个招呼，要花整整一天。

当半兽人的军队已经在砍伐他的家园，他还在慢悠悠地思考要不要行动。

现在，AI正在以闪电速度疯狂进化，而各国政府，正是那棵慢吞吞的树人。

Amodei为什么突然这么急？直接原因，就是Mythos。



Claude Mythos Preview能自主发现了所有主流操作系统和浏览器中的数千个高危漏洞。

用Amodei的话说：

Mythos Preview 彻底改变了全球网络安全的版图。它不容置疑地证明了，前沿AI模型如今已成为具有全球和国家战略后果的强力工具。而且，这绝不会是我们面临的最后一次危机。

Scaling Laws已经有超过十年的实证支持。如果它再持续两年，我们就会得到Amodei所说的「数据中心里的一个天才国度」——相当于一亿个顶尖科学家同时在线工作。

然而，国会通过一部重要法律，平均需要数年。

树人般的速度，根本无法阻挡化身为「天才国家」的指数级AI！

Policy on the AI Exponential 人工智能指数政策

June 2026 2026年6月

In one of the side plots to *The Lord of the Rings*, two of the Hobbits attempt to rouse Treebeard—a wise but ponderous sentient tree—to defend his forest from an army that is cutting it down. The problem is that Treebeard operates at a very different speed than the Hobbits. It takes him a full day simply to say hello to another tree, so getting him and his peers to act fast enough is nearly impossible.

在《指环王》的一个支线剧情中，两位霍比特人试图唤醒树胡——一棵睿智却行动迟缓的有感知能力的树——来保卫他的森林，使其免遭军队的砍伐。问题是，树胡的行动速度与霍比特人截然不同。他光是跟另一棵树打个招呼就要花上一整天，所以要让他和他的同伴们迅速行动几乎是不可能的。

公众号 · 新智元

过去几年，Anthropic一直在推动所谓的「透明度立法」，这就是当时能做到的全部。

因为在2023到2024年，AI的风险还不够具体。你无法精确描述一个尚未出现的风险，也就无法针对它立法。

但现在，Mythos让一切都不同了！

网络安全风险不再是假设，它已经是现实，生物武器风险和AI失控风险也在快速逼近。



FAA模式：AI系统上天之前，先做适航认证

Amodei给出的监管模板，是美国联邦航空管理局（FAA）。

飞机要上天，必须通过严格的第三方测试，拿到适航证书。无论是波音还是空客，只要审查通不过，就要停飞。

Amodei认为，前沿AI模型应该接受同等对待。



他提出的具体门槛是：

- 计算量超过 10^{25} FLOPs（这大约是当前最顶尖模型的训练规模）
- 或者：AI相关营收超过5亿美元，或AI研发投入超过10亿美元

达到这个量级的公司和模型，必须接受强制性的第三方测试，覆盖四个核心风险领域：

- 一、网络安全风险。AI是否可能被用于发现漏洞、攻击基础设施、瘫痪金融系统？
- 二、生物武器风险。AI是否会帮助降低开发危险病原体的门槛？
- 三、失控风险。AI系统是否可能在开发者无法控制的情况下自主行动？
- 四、自动化研发加速风险。AI是否在加速自身能力的提升，从而放大上述三类风险？

测试必须由合格的独立第三方完成，可以是类似FAA的政府机构，也可以是经政府授权和监管的私人评估机构。

These rules should apply only to models trained using more than 10^{25} floating-point operations (FLOPs), developed by companies earning more than \$500M in AI-related revenue or spending more than \$1 billion on AI R&D. They would address four kinds of catastrophic risk:

这些规则仅适用于使用超过 10^{25} 次浮点运算 (FLOP) 训练的模型，且这些模型必须由人工智能相关收入超过 5 亿美元或在人工智能研发方面投入超过 10 亿美元的公司开发。这些规则旨在应对四种灾难性风险：

- **Biological risk.** If AI systems are released without safeguards, it could become substantially easier to develop biological weapons. The same capabilities that accelerate drug discovery can be used to make it cheaper and easier for attackers to develop dangerous viruses.

生物风险。如果人工智能系统在缺乏安全保障的情况下被发布，生物武器的研发可能会变得容易得多。加速药物研发的能力同样可以被用来降低攻击者开发危险病毒的成本和难度。

- **Cyber risk.** Frontier AI models can now find critical software vulnerabilities at large scale. Used defensively, these capabilities can secure critical systems, but they also raise the stakes for protecting essential infrastructure like hospitals and the energy grid.

网络风险。前沿人工智能模型如今能够大规模发现关键软件漏洞。这些功能在防御层面可以保护关键系统，但也提高了保护医院和电网等重要基础设施的风险。

- **Loss of control risk.** As AI systems improve, it could become much harder to control systems that act outside of their developers' control.

失控风险。随着人工智能系统的不断改进，控制那些超出开发者控制范围的系统将变得越来越困难。

- **Automated R&D.** AI systems are automating the research and development of AI itself, which could further amplify the three above risks.

自动化研发。人工智能系统正在实现人工智能自身研发的自动化，这可能会进一步加剧上述三种风险。

公众号 · 新智元

如果你的模型测出来有不可接受的风险，政府拥有一票否决权，让模型不准上线！

如果第三方评估结果表明该模型存在不可接受的灾难性安全隐患，政府必须拥有合法的、强有力的阻挡、延迟或撤销该模型部署的权力。

这是Amodeli提案中，最具突破性、也最引发争议的一点。

同时，Amodeli还提出，前沿AI模型的「模型权重」是极具战略价值的资产，极易成为黑客的窃取目标。

一旦权重泄露，所有的安全对齐限制都可能在几小时内被完全剥离。

因此，开发商必须建立极高安全标准，保护其开发环境和模型权重，定期接受红队测试，并建立向政府通报模型蒸馏攻击的通道。

一旦发生安全事故，开发商必须向监管机构主动报告，不得瞒报。

防AI就业冲击：Anthropic要给失业者发钱

这篇长文的第二个重点，就是就业政策。

Amodeli讨论了一个全球痛点：宏观经济与持久性失业。

他的判断是：AI驱动的失业，可能比历史上任何一次技术革命都更深远、更持久。

工业革命、互联网革命，都造成了阶段性失业，但最终创造了更多新工作。这背后有两个缓冲机制：杰文斯悖论和比较优势原理。

但Amodei认为，AI可能会同时击穿这两个缓冲机制！因为AI不只是替代某个具体的任务，它在替代人类的通用认知能力。

一旦AI能在几乎所有认知领域超越人类，比较优势就会消失。因此，必须未雨绸缪，设计专门应对AI失业的政策工具。



Anthropic制定了三个层次的经济框架。

第一层：数据测量与追踪。政府应该大幅扩展对AI就业影响的数据收集和追踪。Anthropic已经有一个经济指数。

第二层：促进就业激励。包括工资保险、雇主留工税收激励、职业培训补贴。

第三层：长期宏观经济支持。如果仍不够，可能需要某种形式的全民基本收入，通过对AI公司征税或提高资本利得税来筹资。

为了支持这个框架，Anthropic宣布：2亿美元用于政策研究，1.5亿美元用于技能培训奖学金。



科学与权利：被AI重构的行业版图

此外，Amodei还呼吁：别让旧体制成为「科学加速」的绊脚石。

Amodei指出，在AI本身的监管上，我们应该极其审慎、甚至从严管控；但对于AI所加速的下游应用科学（如生物医药、能源、材料学），我们的监管思路应该松绑。

以生物医药为例，传统的药物研发流程面临着 FDA或 EMA极其漫长的审查。从靶点发现到最终获批上市，通常需要经历7到8年的漫长周期。

然而，AI的介入将颠覆这一常态。

AI不仅能以几何倍数增加候选药物数量，还能大幅提高新药的效果和安全性。

如果不进行制度改革，庞大的AI产出将彻底瘫痪现有的药监审批系统。

为此，阿莫代呼吁监管机构顺应潮流，开发全新的AI辅助评估标准，包括：

- 接受AI生成的药效学与药代动力学模拟模型。
- 推广AI预测毒理学，减少繁琐、缓慢的多物种动物毒性试验。 推广人工智能
- 在临床试验中引入合成控制组，大幅减少人类受试者的招募时间。
- 允许针对癌症、阿尔茨海默病等病症开发创新的快速通道。

这样，人类会最快地享受到AI带来的健康福祉。

在「树人」醒来之后

在文章结尾，Amodei乐观地说：「树人们和他们的森林，正在慢慢睁开眼睛。」

现在全球公众和政策制定者面前，有一个珍贵却又稍纵即逝的窗口期。

在硅谷圈子里，很多人觉得，公众害怕AI只是个「公关问题」，AI行业需要的是「更好的营销」。

Amodei直接怼了回去：

人们担心AI，不是因为我们的CEO不够乐观、不会画大饼，而是因为他们真真切切地看到了AI的风险。

作为AI行业的负责人，我的责任就是把风险摊在桌面上说清楚。公众的担心和抗议，恰恰说明民主监督在正常工作。

这一次，Anthropic砸了几个亿的真金白银，表明了态度。

我们究竟是要继续在黑暗中蒙眼狂奔，撞向悬崖；还是应该停下傲慢的脚步，与人类的社会治理机制，达成一次史诗级的和解？



树人已经醒了。

而霍比特人的生死竞速，才刚刚开始。

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 92  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论