

摘要：

Anthropic首席执行官Dario Amodei指出，AI模型应强制接受第三方测试，涵盖网络安全威胁及生物武器等多个风险维度。若某一模型被认定“存在不可接受的风险”，“政府应有权阻止或限制其部署”。特朗普本月初签署行政令，仅要求AI开发商向美政府提供自愿性的访问权限，并未要求模型部署需要审批。

Anthropic首席执行官Dario Amodei公开呼吁对人工智能实施更严格的强制性监管，主张政府应有权阻止存在安全风险的AI模型上线部署，此举与特朗普政府当前推行的自愿合规路线形成明显分歧。

Amodei周三在一篇长文中提出，AI模型应强制接受第三方测试，涵盖网络安全威胁及生物武器等多个风险维度。

他写道，若某一模型被认定“存在不可接受的风险”，“政府应有权阻止或限制其部署”。这是他迄今就AI监管发出的最强烈表态之一。

上述立场与白宫现行政策存在明显落差。特朗普本月初签署行政令，要求政府对AI模型仅获取自愿提交的访问权限，并未要求开发商在部署前寻求明确审批。

监管主张：从透明度走向强制约束

Amodei在文中援引汽车、飞机及药品作为类比，认为AI与上述技术同属现代经济不可或缺的强大工具，但若设计或运营不当，同样有能力造成大规模伤亡。

“现在是时候从透明度迈向更严肃、更具约束力的AI监管了，”他写道。他同时警告，全球政策机制反应迟缓，而AI带来的风险与机遇将“出乎意料地迅速复合叠加”。

就在上周，Anthropic还呼吁建立一套机制，由各国政府与AI开发商共同决定何时放慢研发节奏，以应对潜在危险。两度公开表态显示，该公司正将推动监管框架建立作为其战略优先事项之一。

Mythos模型：能力边界引发的内部抉择

Amodei在文中以Anthropic旗下新模型Mythos为例，称其“完美展示了AI的惊人能力与潜在风险”。

Anthropic此前披露，Mythos具备识别并利用关键软件漏洞的能力，公司因此决定将该模型的访问权限仅开放给少数合作伙伴。周二，Anthropic另行发布了一个剥离网络安全功能的版本，向更广泛用户开放。

这一系列决策折射出AI前沿开发商在产品能力与安全边界之间的内在矛盾——在对外呼吁监管机构介入的同时，企业自身已在进行类似“监管”性质的自主筛选与限制。

政策分歧：行业呼声与政府路线的错位

Amodei的表态将Anthropic置于与当前联邦政策方向相左的位置。特朗普行政令倾向于以自愿机制替代强制审批，体现了本届政府在AI领域总体上减少监管干预的施政取向。



Anthropic长期以"负责任的AI开发者"自我定位，此番公开主张政府获得强制介入权，意味着其有意在监管议题上扮演更积极的推动角色。

然而，在华盛顿政策环境偏向宽松的背景下，此类呼声能否转化为实质性立法或监管行动，仍存在较大不确定性。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

66 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论