


摘要：

Claude Sonnet 5.5是比Opus 5.5更快、更低成本的补充，是迄今速度最快的Sonnet模型，在低或中等努力水平下，以约Sonnet 5十分之一的成本就超过Sonnet 5的最佳得分；首次拥有与Anthropic最强模型类似的网络安全防护机制和fallback机制。据独立平台Artificial Analysis测试，Sonnet 5.5能力逼近Opus 5.5，但在最高推理强度下，单任务平均耗用输出Token为各模型之最。

继上周发布旗舰模型Claude Opus 5.5后，Anthropic再次扩充Claude 5.5家族，推出Opus 5.5的低成本替代互补方案Sonnet 5.5。

美东时间28日周一，Anthropic推出Claude Sonnet 5.5，称这是Claude 5.5家族的第二款模型。与上一代Sonnet 5相比，新模型输出速度提升超过30%，在保持API价格不变的情况下，由于完成相同任务通常所需的Token更少，单项任务成本最高可下降30%。

在多项基准测试中，Sonnet 5.5 在低或中等努力水平下，以大约Sonnet 5十分之一的成本就超过了Sonnet 5的最佳得分。



Anthropic表示，Sonnet 5.5尤其适合日常知识工作、修复代码、制作文档、幻灯片和电子表格等“边界清晰”的任务，是更强大的Opus 5.5之外、更快且成本更低的工作伙伴。公司同时称，新模型是迄今速度最快的Sonnet模型。

Claude Sonnet 5.5

	Sonnet 5.5	Sonnet 5	Opus 5.5	GPT-6 Sol
Agentic coding Terminal-Bench 4.0	70.6%	10.3%	66.4% ¹	—
Agentic coding FrontierCode 1.1 (Main)	46.2% Max ² 52.1% Xhigh	42.4%	54.4%	49.3%
Agentic coding CursorBench 4.0	55.5%	34.1%	57.8%	—
Knowledge work GDPval-AA v2.1 ³	1844	1449	1846	1487 ⁴
Knowledge work AA-Briefcase v1.1 ³	1811	1359	1822	1483 ⁴
Multidisciplinary reasoning Humanity's Last Exam (with tools)	64.5%	54.9%	67.7%	—
Computer use OSWorld 2.1 (partial)	80.1%	57.0%	81.8%	—
Visual chart recognition Chartography (no tools)	61.6%	15.6%	64.4%	53.6% ⁴

For details on how we run our evaluations, see the Sonnet 5.5 System Card.

¹ Terminal-Bench 4.0 results are reported for Claude Opus 5.5 at Xhigh effort which represents the model's highest score.

² Sonnet 5.5 scores lower at Max effort than at Xhigh. FrontierCode evaluates whether a code change could be merged without human edits. It penalizes out-of-scope changes, even if they are high-quality or helpful. At Max effort, Sonnet 5.5 more often ran Claude Code's code-review skill, which splits the review across many subagents, and in two cases Cognition examined, this led to a timeout or to extra edits beyond the task's scope, and therefore to a lower score.

³ Artificial Analysis ran GDPval-AA and AA-Briefcase on a pre-release deployment of Sonnet 5.5 on the Claude Platform, which we found to have a bug that could degrade responses to requests that use structured outputs. We expect the effect on Sonnet 5.5's scores, if any, to be small and to understate its performance. That bug has since been fixed.

⁴ OpenAI recently fixed a bug that degraded image understanding in GPT-6 Sol. Official AA-Briefcase v1.1 and GDPval-AA v2.1 scores from Artificial Analysis, and Chartography scores from Surge AI, may not have been updated yet to reflect the latest version of the model. Artificial Analysis does not expect major impacts to AA-Briefcase v1.1 and GDPval-AA v2.1. Internal testing of Chartography suggests its score was not impacted.

值得注意的是，第三方AI基准测试平台Artificial Analysis的数据显示，在最高推理强度下，Sonnet 5.5的综合智能指数达到56分，仅比Opus 5.5低2分，并在部分智能体和知识工作测试中与Opus 5.5基本持平。不过，要达到接近Opus 5.5的表现，Sonnet 5.5也付出了较高的Token消耗代价。

不涨价，却能把单任务成本压低三成

Sonnet 5.5此次最直接的卖点并不是降低API标价，而是用更少的Token和更快的生成速度完成相同任务。

Anthropic表示，Sonnet 5.5的API价格与Sonnet 5保持一致，为每百万Token输入2美元、输出10美元；但在内部测试中，新模型完成相同工作通常需要明显更少的Token，因此单任务成本最高可以下降30%。

与此同时，Sonnet 5.5的输出速度比Sonnet 5快30%以上。Anthropic称，这意味着用户不仅能够以相同的Token单价获得更快响应，还能够更多任务中减少模型调用和工具调用次数，从而进一步压低实际使用成本。

媒体指出，Anthropic此次强调的“30%成本下降”实际上更多来自效率提升，而非价格下调：模型通过更少的工具调用、更少的Token以及更快的输出速度完成工作，因此实际每项任务的成本下降。

Anthropic还表示，在部分基准测试中，Sonnet 5.5在Low或Medium推理强度下，就可以超过Sonnet 5此前的最佳成绩，而成本约为后者的十分之一；在另一项编程测试中，Sonnet 5.5在High模式下的成绩比Sonnet 5高约10个百分点，但单任务成本约为后者的十五分之一。



这意味着，Anthropic此次升级的重点并不是简单地把模型推向“更强”，而是试图扩大**性能—成本曲线上的可用区间**：对于不需要旗舰模型的日常任务，用户可以用较低的推理强度换取更快、更便宜的结果；而在复杂任务上，则可以提高推理强度，进一步逼近Opus级别的能力。


第三方测试：能力逼近Opus，但Token消耗创纪录

Artificial Analysis的测试则提供了另一幅更复杂的图景。

该平台表示，Sonnet 5.5在其Intelligence Index中获得56分，在最高推理强度下较Sonnet 5提升18分，排名仅次于Opus 5.5。其在Terminal-Bench 4.0中的得分达到64%，高于Opus 5.5和GPT-6 Astra的60%；在AA-Briefcase、GDPval-AA和AutomationBench-AA等测试中，也与Opus 5.5达到近似水平。

但Artificial Analysis同时指出，Sonnet 5.5为获得这样的成绩消耗了非常多的输出Token。

在最高推理强度下，Sonnet 5.5每个Intelligence Index任务平均使用约19.3万个输出Token，这是该平台测试过的模型中最高的水平，比Opus 5.5或Sonnet 5高出约60%，更是GPT-6 Astra的约7倍。



这也形成了此次发布一个颇值得关注的反差：**Sonnet 5.5的API标价没有上涨，但如果用户选择最高推理强度，模型为了追求更高性能所消耗的Token可能大幅增加。**

Artificial Analysis据此认为，在“智能水平—单任务成本”的比较中，Sonnet 5.5并非所有推理强度都处于最具成本优势的位置；高强度模式下，其性能已经非常接近Opus 5.5，但Token消耗也随之明显上升。

不过，这些测试是在Sonnet 5.5正式发布前的版本上进行的。Artificial Analysis表示，Anthropic后来发现该预发布版本存在一个可能影响结构化输出请求的Bug，并已在正式版本中修复，因此相关评测还将重新进行。由此来看，目前第三方数据更适合作为参考，而非最终性能定论。

从“写代码”扩展到办公生产力



相比Opus 5.5主要面向复杂编程、智能体和知识工作，Anthropic对Sonnet 5.5的定位明显更加偏向日常生产力。

Anthropic称，新模型擅长修复Bug、制作经过润色的文档、幻灯片和电子表格，同时具备更强的设计能力，可以进一步完善用户界面，并根据模板制作只需少量人工修改的演示文稿。

公司还特别强调了模型的文字表达能力。Anthropic表示，和上一代模型相比，Sonnet 5.5能够写出更加清晰的内容，而更快的速度也使其适合快速迭代和多人协作。

从产品策略来看，这意味着Anthropic并没有试图让Sonnet 5.5完全替代Opus 5.5，而是进一步拉开两者的产品定位：**Opus承担最复杂、最需要能力的任务，Sonnet则争夺规模更大的日常工作和高频任务。**

TechCrunch也将Sonnet 5.5描述为Anthropic更偏向日常工作的“更快、更便宜的工作伙伴”，并指出其重点应用场景包括编程和办公文档处理。

安全护栏首次向Sonnet级别下沉

除了速度和成本，安全能力也是此次升级的重要变化。

Anthropic表示，Sonnet 5.5在自动化行为审计中，大多数alignment和诚实性指标都优于或持平Sonnet 5。同时，新模型首次拥有与Anthropic最强模型类似的网络安全防护机制和fallback机制。

当模型面对特定高风险网络安全任务时，可以启用更严格的安全护栏并将部分请求转交给其他模型；而对于普通软件开发任务，Anthropic称这一机制不会产生影响。

这一变化尤其值得关注，因为此前Sonnet系列与Opus系列在网络安全能力和安全防护上的定位存在明显区别。Anthropic此次让Sonnet 5.5获得更接近旗舰模型的安全机制，也意味着随着中端模型能力越来越接近前沿水平，**安全控制正在从旗舰模型向更广泛的模型层级下沉。**

而这也延续了Anthropic此前发布Opus 5.5时的产品思路：模型能力提升与安全护栏同步推进。上周发布的Opus 5.5同样强调了网络安全等高风险场景的安全机制。

Claude 5.5家族还缺最后一块拼图

Sonnet 5.5是Claude 5.5家族继Opus 5.5之后的第二款模型。

Anthropic表示，Sonnet 5.5现已全面上线，未来几周还将推出Claude Haiku 5.5。届时，Claude 5.5家族将进一步覆盖从高端复杂任务到日常高频任务、再到更强调速度和成本的不同应用场景。

这也是Anthropic近期连续更新模型家族的延续。9月22日发布的Opus 5.5定位于更高端的智能体编程和知识工作，运行成本较Opus 5下降40%；如今Sonnet 5.5则在保持原有价格的基础上，通过降低Token消耗和提升速度来降低单任务成本。

从商业化角度看，Anthropic正在将模型竞争的重点从单纯的“谁的基准测试分数更高”，进一步推向**单位任务成本、响应速度、Token效率和安全性。**

而Artificial Analysis此次测试暴露出的另一个趋势同样值得关注：当中端模型通过提高推理强度不断逼近旗舰模型时，“模型本身的API价格”可能已经不足以衡量真实使用成本，**完成一项任务**



究竟需要多少Token、多少次工具调用以及多长时间，正在成为AI模型商业竞争的新变量。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免

210 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



江州司马
7小时前 中国上海

差距越拉越大了

0 回复