

摘要：

Anthropic在Mythos限制性发布一周后，推出其主力模型的升级版本Opus 4.7。该模型软件工程能力更强，图像识别能力也有所提升，不过却主动"削弱"了其网络攻防能力。这一审慎取舍背后是AI安全与商业化之间的博弈。

Anthropic在限制旗下最先进模型Mythos发布仅一周后，推出其主力模型的升级版本Opus 4.7，同时正寻求新一轮融资，估值或较此前翻倍至8000亿美元或更高。

公司周四表示，Opus 4.7在软件工程方面表现更为出色，指令遵从能力及图像识别能力均有提升。

然而，Anthropic明确指出，该模型在网络安全等方面的综合能力弱于Mythos，公司甚至在训练过程中专门实验性地对其网络攻防能力进行了"差异化削减"。

这一部署策略折射出Anthropic在模型能力与安全边界之间的审慎取舍，也为其最终实现Mythos级模型的广泛商业化探路。

Opus 4.7：编程能力提升，网络攻防能力削弱

Anthropic表示，Opus 4.7的核心改进集中于软件工程领域，包括处理此前需要更多人工监督的高难度编程任务。此外，该模型在图像识别方面的能力也有所提升，能够识别复杂图表或图片中的细节信息。

在安全机制方面，Anthropic在Opus 4.7中内置了自动检测与拦截系统，可识别并阻断涉及违禁或高风险网络安全用途的请求。

公司在博客文章中表示，"我们将从这些防护措施的实际部署中积累经验，以推进Mythos级模型最终实现广泛发布的目标。"

值得注意的是，Anthropic在训练阶段对Opus 4.7进行了主动干预，专门针对其网络攻防能力实施"差异化削减"，这一做法在大模型研发中较为罕见。

Mythos能力存忧，限制发布成既定选择

上周，Anthropic披露其Mythos系统具备高度危险的网络攻击能力——在用户指示下，该模型能够识别并利用"每个主流操作系统和每个主流浏览器"中的安全漏洞。

出于安全考量，Anthropic决定仅向部分精选企业客户开放Mythos，专门用于帮助这些客户加固自身软件系统，而非面向大众发布。

这一决策背景下，Opus 4.7的推出既填补了Mythos无法广泛商用的市场空缺，也为Anthropic提供了在真实部署环境中验证安全机制的机会。

竞争格局与融资前景

Anthropic目前正与OpenAI展开激烈竞争，双方均致力于部署更先进的AI模型，并争取更多企业客户付费采用。

近几个月来，Anthropic的AI编程产品势头强劲，消费者端也在持续获得更多关注，尽管公司与五角大楼之间在AI安全标准问题上存在分歧。

在融资层面，Anthropic最近一轮估值为3800亿美元。据悉，**公司目前正就新一轮融资向投资者征集报价，估值或达约8000亿美元乃至更高，较上轮估值翻倍有余。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 380

 收藏

分享到:  

写评论

请发表您的评论

 表情

 图片

发表评论