

摘要：

Anthropic将为Claude生成文本嵌入隐形水印，图片附加溯源元数据。文本水印直接织入内容本身，复制粘贴或部分编辑后仍可追踪。此举旨在响应欧盟AI法案，将全球适用并覆盖全产品线。Anthropic提醒，水印仅为参考信号，并非确认内容来源的绝对铁证。

Anthropic正在为其旗下Claude系列AI模型引入机器可读标记技术，所有由Claude生成的文本将被嵌入隐形水印，图片等文件则附加经数字签名的溯源元数据。这一举措标志着AI内容透明度监管进入实质落地阶段。



根据Anthropic在8月11日发布的官方说明，该水印直接编织于文本内容本身，而非附加在元数据层面，这意味着文本被复制粘贴至其他平台后水印依然随之传播，并可能在经过部分编辑后仍然留存。这一特性使得AI生成内容的追踪能力大幅提升，超越了此前依赖元数据标注的同类方案。

上述计划的直接触发因素是Anthropic签署了欧盟《人工智能法案》第50条第2款《AI生成内容透明度行为准则》。依据该准则，2026年8月2日起在欧盟推出的新Claude模型须在发布之日起即支持内容标记。Anthropic同时表示，标记机制将在全球范围内适用，覆盖Claude所有产品线及合作云平台，并非仅限于欧盟地区。

水印如何运作：嵌入文本，随文流转

Anthropic采用两种互补技术对Claude生成内容进行标记。

How Claude marks AI-generated content

Updated today

Copy for LLM

Anthropic has signed the EU AI Act's Article 50(2) Code of Practice on Transparency of AI-Generated Content, as a provider of both generative AI models and generative AI systems. This article describes how we're planning to put those commitments into practice, how marking works, and what its limitations are. We'll update this article and publish more detailed technical guidance as it becomes available.

Anthropic's commitments under the EU AI Act's Code of Practice on Transparency of AI-Generated Content

What our marking commitments mean for Claude:

- **New models will mark AI-generated content from day one.** Claude models launched in the EU on or after August 2, 2026 will support machine-readable marking at launch. Generated text will carry embedded watermarks, and generated files will include digitally signed provenance metadata where supported.
- **Marking works everywhere you use Claude.** Marks will apply to output from supported Claude models across Claude Platform (API), Claude, Claude Code, Claude Cowork, and Claude Tag, and wherever Claude is offered, worldwide. Some platforms or features may not support certain marking types.
- **We'll help you detect Claude's marks.** We'll support users and other third parties to detect Claude's marks, as the Code requires, and we'll share details in forthcoming documentation.
- **Existing models are in progress.** The law includes a transition period for Anthropic models launched before August 2, 2026, and we're working to add marking support for those models as well.

More details about our marking plans are below.

其一为嵌入式文本水印。当受支持的Claude模型生成文本时，模型会将一个不可见的水印直接织入文本本身。该水印不会改变内容的含义、质量或可读性，用户无法通过肉眼察觉。由于水印属于文本的组成部分，而非附加的元数据，其将随文本的复制粘贴一同转移，并可能在经历部分编辑后依然保留。水印在模型层面施加，意味着无论通过哪个Claude产品或界面生成的文本，均会携带该标记。

其二为签名溯源元数据。当Claude生成受支持的文件类型（如.svg、.png、.jpg等）时，将附加经数字签名的溯源元数据。该元数据遵循内容溯源与真实性联盟（C2PA）开放标准——这一标准已在业界广泛采用，用于记录内容来源信息。若签名元数据标签存在，则表明该文件经由Claude处理，并可用于检测文件是否遭到篡改。

Anthropic明确，标记机制将覆盖Claude旗下所有主要产品与接入渠道，**包括Claude Platform（API）、Claude、Claude Code、Claude Cowork及Claude Tag，并适用于通过AWS、谷歌云及Microsoft Foundry接入的云合作伙伴。**

在地域范围上，标记将适用于Claude提供服务的所有地区，并不局限于欧盟。

时间节点方面，2026年8月2日后在欧盟推出的新模型须从发布之日起即支持标记。对于此前已发布的现有模型，欧盟法规设有过渡期，Anthropic表示正在推进为这些模型补充标记支持，并将适时更新相关说明。

技术局限：信号而非铁证

Anthropic在官方说明中对水印技术的局限性作出了明确披露，这对依赖该机制进行内容核查的用户和开发者而言尤为重要。

检测到Claude标记，仅表明内容“可能”经由Claude处理，并不能完全确认内容的完整来源。

例如，Claude可能并非原始作者——用户常借助Claude进行校对、翻译、摘要或文件转换，输出内容即便携带Claude标记，其底层思想、文字或数据也可能源自其他来源；此外，内容在经



反之，未检测到标记，也不能证明内容并非AI生成。以下情形均可能导致标记缺失：内容由标记功能上线前发布的模型生成；文本经过大量编辑、改写、翻译或与其他内容混合；文本段落过短，不足以承载可靠信号；文件元数据在格式转换、重新保存或截图等操作中被剥离；或内容来自尚不支持特定标记类型的平台、功能或文件格式。

另外，Anthropic在说明中特别提示，在自有产品中部署Claude的开发者，应独立评估《人工智能法案》第50条对其产品和服务的具体要求。Anthropic表示，其目标是支持开发者履行各自的透明度义务，并将在技术文档就绪后发布关于标记与检测方案的详细指引。

这意味着，对于将Claude能力集成至下游产品的企业而言，AI内容标记合规责任并不因Anthropic的技术实现而自动转移，开发者仍需主动厘清自身在相关法规框架下的义务边界。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

限免

204

收藏

分享到:

写评论

请发表您的评论

表情

图片

发布评论