

摘要：

Anthropic发布"玻璃翼计划"，联合亚马逊、谷歌、微软等12家机构，围绕新模型Claude Mythos Preview开展网络安全防御行动。该模型代码与推理能力超越Claude Opus，已扫描主流系统并发现数千个零日漏洞，含多个存在十余年的高危漏洞，均已修复。

Anthropic今天宣布了一个计划：Project Glasswing（玻璃翼计划），之所以推出这个计划是因为Anthropic训练出了一个全新的超强模型Claude Mythos Preview，这其实就是前两天cc源码泄露中提到的模型。



项目参与方包括亚马逊AWS、苹果、博通、思科、CrowdStrike、谷歌、摩根大通、Linux基金会、微软、英伟达、Palo Alto Networks，以及Anthropic自己，共12家机构联合发起。

说人话就是由于这个模型太强了要采取安全测试模式，只给认可的机构内部使用，不对外开放，有多强呢，大家直接看数据，代码和推理能力吊打opus 4.6：

代码：

Agentic coding

Reasoning

Agentic search and computer use

SWE-bench Pro

Mythos Preview

77.8%

Opus 4.6

53.4%

Terminal-Bench 2.0

Mythos Preview

82.0%

Opus 4.6

65.4%

SWE-bench Multimodal (internal implementation)

Mythos Preview

59.0%

Opus 4.6

27.1%

SWE-bench Multilingual

Mythos Preview

87.3%

Opus 4.6

77.8%

SWE-bench Verified


Mythos Preview

93.9%


Opus 4.6

80.8%

推理:



搜索与计算机使用



opus字面意思是杰作，Mythos字面意思是神话，Anthropic CEO以及合作方一众大佬都出来为这个计划站台了。

Anthropic明确表示，不打算将Claude Mythos Preview向公众开放。但长期目标是让用户能够安全使用同等能力级别的模型。为此，他们计划先在即将推出的Claude Opus模型上开发和验证相关安全防护机制，在风险可控的条件下完成迭代，再逐步推进，可能很快会推出一个opus 新版本提供相应的能力。

我们来详细看看Project Glasswing究竟是什么东西

这个模型发现了什么？

过去几周，Anthropic用Claude Mythos Preview扫描了世界上主流的操作系统、浏览器和其他重要软件。

结果：发现了数千个此前从未被发现的零日漏洞，其中大量被评定为高危级别。

几个具体案例：

OpenBSD中一个存在了27年的漏洞。OpenBSD以安全性著称，被用于运行防火墙等关键基础设施。这个漏洞允许攻击者仅通过连接目标机器，就能让其远程崩溃。

FFmpeg中一个存在了16年的漏洞。FFmpeg被无数软件用于视频编解码。模型找到漏洞的那行代码，此前已被自动化测试工具扫描了500万次，从未被发现。

Linux内核中，模型自主发现并串联了多个漏洞，使攻击者能从普通用户权限提升至完全控制整台机器。

以上漏洞均已向相关软件维护方报告，目前已全部修复。其余漏洞，Anthropic已先行发布加密哈希值，待修复完成后再公开具体细节。

为什么要做这件事？

Anthropic给出的判断是：AI模型在发现和利用软件漏洞方面的能力，已经超过了除少数顶级人类专家之外的所有人。

这种能力的扩散，是时间问题，而不是是否会发生的问题。

全球网络犯罪造成的经济损失每年估计约为5000亿美元。针对医疗系统、能源基础设施、政府机构的攻击已经造成实质伤害，也已对民用和军事基础设施构成持续威胁。

AI让发动这类攻击所需的成本、门槛和专业程度都大幅下降。

Anthropic的逻辑是：与其等别人先把这种能力用于进攻，不如主动把它用于防御。

计划具体怎么做？

Project Glasswing目前包含两个层面。

第一层面是12家创始合作伙伴，他们将获得Claude Mythos Preview的访问权限，用于扫描和修复自身核心系统的漏洞，重点方向包括本地漏洞检测、二进制黑盒测试、端点安全、渗透测试等。

第二层面是另外40余家构建或维护关键软件基础设施的组织，同样将获得模型访问权限，用于扫描自有及开源系统。

Anthropic为此承诺提供最高1亿美元的模型使用额度。研究预览期结束后，Claude Mythos Preview将向参与方提供商业访问，定价为每百万输入/输出token 25/125美元，支持通过Claude API、Amazon Bedrock、Google Cloud Vertex AI和Microsoft Foundry接入。

此外，Anthropic通过Linux基金会向Alpha-Omega和OpenSSF捐赠250万美元，向Apache软件基金会捐赠150万美元，合计捐赠400万美元，用于支持开源软件维护方应对这一新形势。开源软件维护方可通过Claude for Open Source项目申请访问权限。



接下来的计划

在信息共享方面，合作伙伴将尽可能互通信息和最佳实践。Anthropic承诺在90天内公开发布研究进展报告，内容包括发现的漏洞数量、已修复的问题，以及可披露的改进成果。

在政策建议方面，Anthropic将与主要安全机构合作，就以下方向形成实践建议：漏洞披露流程、软件更新流程、开源与供应链安全、安全软件开发生命周期、受监管行业标准、漏洞分类的规模化与自动化、补丁自动化。

本文来源：[AI寒武纪](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 252  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论

1 条评论

 **momo**
2小时前 中国湖北省

牛逼

 0  回复