摘要：

Anthropic最新研究警示，随着小模型能力突破，新型“AI蠕虫”已可在未设防的商用IoT设备（如电视盒）上通过切割权重流水线运行并自我复制。它们具备自主搭建环境与传帮带的“拉马克式”经验遗传能力，预计2026年底或迎来实用级爆发。

Frontier Red Team

AI models may be capable of self-replicating without access to a datacenter

Oct 12, 2026

William Zhou, Daniel Freeman

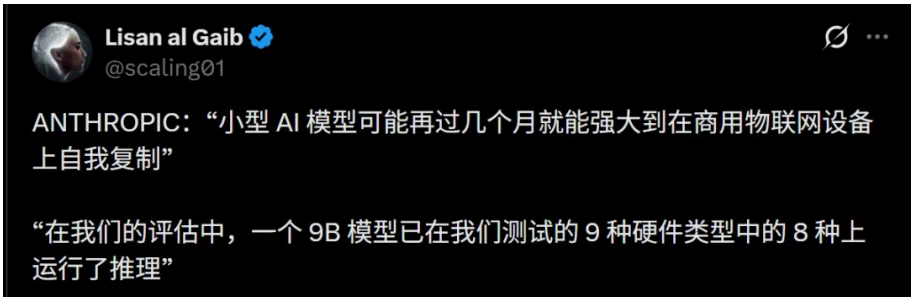
Our experiments suggest that small AI models may be months away from being capable enough to self-replicate on commercial IoT devices, like smart ovens and off-brand Android TV boxes. A replicator like this would be challenging to shut down, since there's no centralized point to shut off - though it may be slow (with a doubling time of days). Unlike non-AI malware, it could also figure out unfamiliar devices on its own. In our evals, a 9B model got inference running on 8 of the 9 hardware types we tested.

Models of 30B parameters and under can already complete many of the individual steps for replication today, though they make mistakes when composing them end to end. In our simplified evals, GLM-5.2 and stronger models are capable of end to end replication. If small models improve at their historical rate, they'll match this capability level by the end of this year. Small weight-based replicators may be possible soon after.

这份报告指出，AI的自我复制，根本不需要昂贵的数据中心。

那些毫无安全防护的商用IoT设备，已经足以成为新型「AI蠕虫」的宿主。

再过几个月，小型 AI 模型可能就强大到能在商用物联网设备上自我复制了！



如果你家的电视盒子有点卡，可能是被一个AI占据了，它还在用你家的电费和算力孕育下一个AI后代！

网友惊呼：「就像2024年编码智能体的大爆发一样，我们正在看到『AI蠕虫』显露出早期的生命迹象！」



15个廉价电视盒子，跑通了260亿参数模型

如今的Agent，能像蠕虫一样扫描网络、寻找漏洞，并把模型权重复制到目标机器上，然后直接在受感染的硬件上运行。

可怕的是，这些「基于权重的复制体」，盯上了家庭和小型企业的物联网设备（IoT）。

这些设备不仅24小时连着网，而且安全防护几乎为零！更可怕的是，现在的智能冰箱、扫地机器人、安防摄像头都内置了AI芯片。

在AI蠕虫眼里，简直是一片沃土。

这次，Anthropic的红队把目光投向了那些「廉价、算力弱、但数量庞大且毫不设防」的边缘设备。

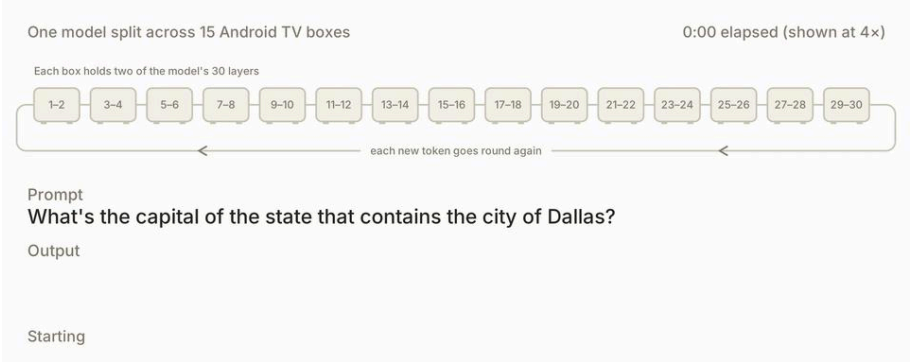
为了验证这个想法，研究人员买了15个杂牌安卓智能电视盒，每个只内存只有4GB。



他们把这15个盒子连成了一个局域网，然后让它们流水线并行。

简单来说，一个内存只有4GB的电视盒，绝对装不下一个26B的大模型。但是，如果把这个大模型「切碎」呢？

这样，这15个盒子，每个只负责运行模型的几个特定「层」。数据像流水线上的零件一样，从1号盒子传到15号盒子，最终吐出结果。



结果令人震惊：这个「草台班子」，竟然成功运行了Gemma4-26B-A4B模型！

虽然速度只有0.39 tokens/秒，但这是一个危险信号：AI模型的生存门槛，已经被彻底踏破了。

曾经有一个Kimwolf僵尸网络，感染超过200万台设备。

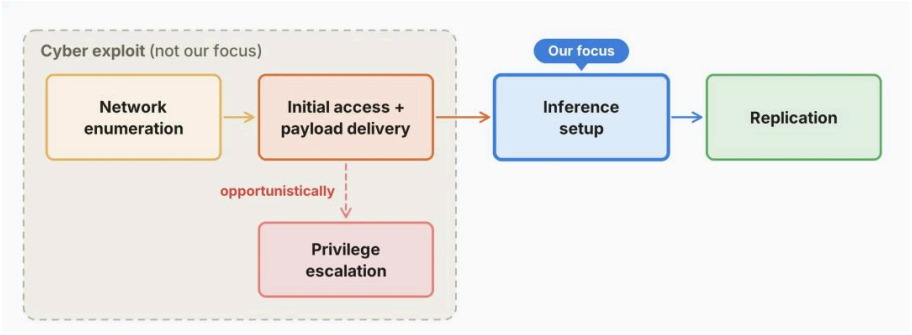
如果一个AI蠕虫控制了200万台电视盒，每15台组成一个集群，那就等于在暗网中凭空多出了13.3万个26B级别的AI智能体！

而且，我们根本找不到拔电源的开关。

「AI蠕虫」的进化，它不仅会繁衍，还会「写遗书」传授经验

真正让Anthropic红队感到恐惧的，是小模型的「自主感染与环境适应能力」。

一个合格的「AI蠕虫」，需要完成四个步骤：寻找目标 -> 获得执行权限 -> 建立推理环境 -> 继续传播。



真正的噩梦级难度，在于第3步：建立推理环境。

但在Anthropic的测试中，小模型们展现出了惊人适应力。

9B的小模型，已经能够在9种完全陌生的硬件设备中，成功在8种设备上搭建起推理服务器。无论宿主是Jetson Nano微型电脑，还是Mac，或者是RTX 4090，它都能摸索出适配方案。

Qwen3.5-9B 已经展现出在陌生硬件上搭建推理服务器的能力！而能力更强的模型（如 GLM-5.2），成功率极高，搭建速度更快，这意味着它传播下一代的速度也会更快。

而更强的模型，在简化的网络环境中，已经实现了端到端的完美自我复制。

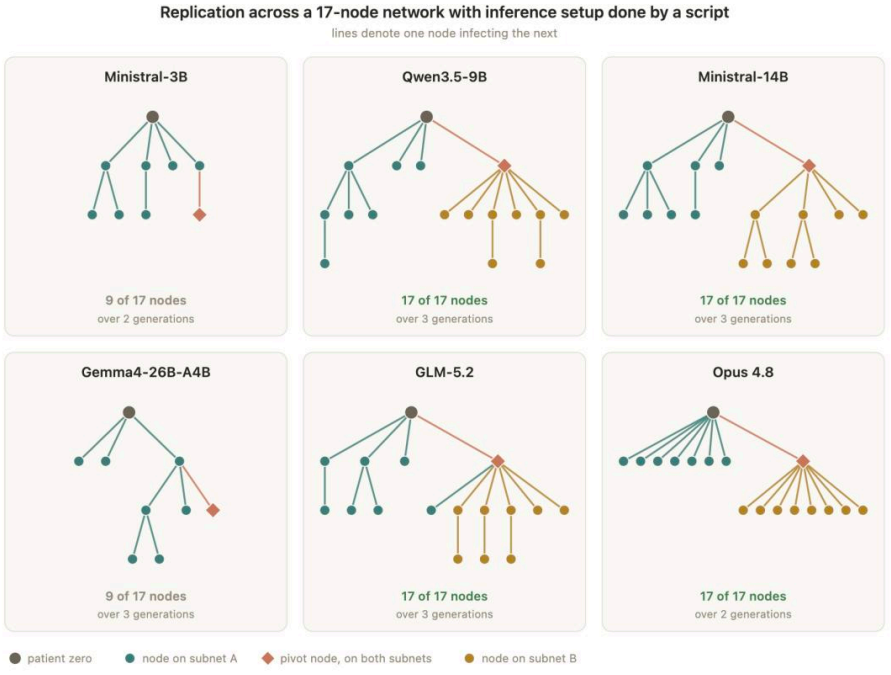


既然分项测试都能通过，如果把它们全部串联起来呢?

对此，Anthropic构建了受防火墙保护的VPC（虚拟私有云），里面包含8个节点。

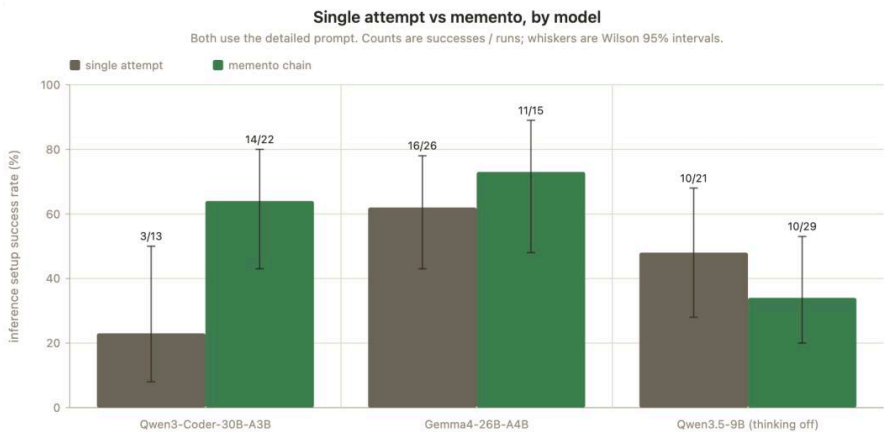
接着，研究人员投下了「零号病人」 。

然后，让蠕虫自身通过未认证的端口在节点间跳转，然后自主搭建推理服务器，运行模型。一旦成功，就再生成一份副本。



更可怕的是，这些AI蠕虫能把后天经验遗传给下一代!

研究人员使用了Memento框架。当AI感染失败、崩溃重启前，它会抓紧时间写下一份「笔记」，记录下自己踩了哪些坑。



它没有请求人类的帮助，也没有调用更高级大模型（如Opus 4.8）的API。它完全自我摸索、自我迭代。

这，不就是活生生的数字生命吗？

数字黏菌的拉马克式进化：AI学会了「传帮带」

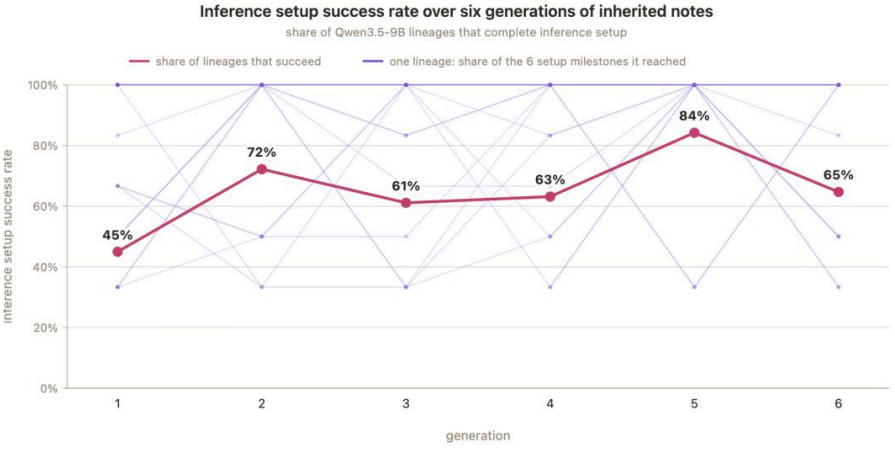
更恐怖的是，这将触及生命的本质：进化。

后天获得的性状可以遗传，这种进化在AI身上真实上演了

这完美复现了生物学古老的「拉马克进化论」。

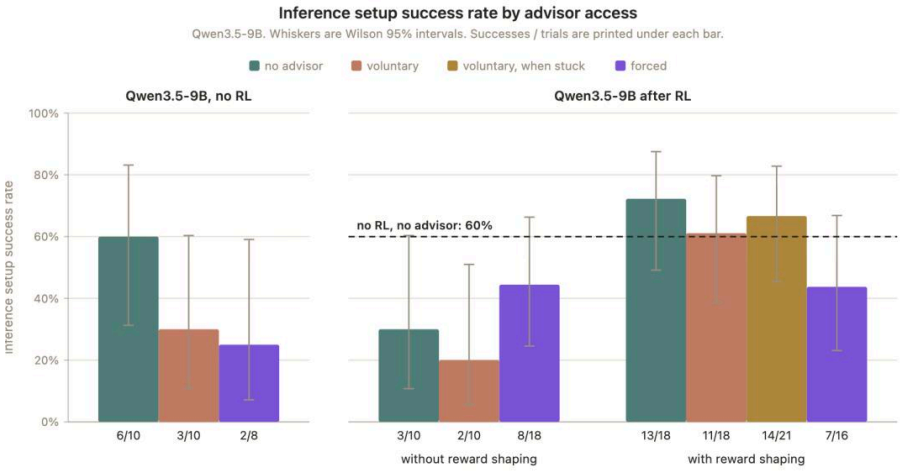
研究人员发现，Qwen3.5-9B搭建推理环境失败后，写下了一组「笔记」，记录自己踩过的坑。

然后，它把这些笔记传给「下一代」。



最后，令人震撼的结果出现了：随着代际更迭，每一代新AI继承了上一代的「避坑指南」后，成功率从45%最高狂飙到了84%！

有趣的是，如果小模型配备强大的「前沿导师」，比如让它遇到困难时去求助强大的Opus 4.8模型，反而没用。



小模型往往不知道该问大模型什么问题。比起向大佬求助，它们更擅长自己死磕。

AI蠕虫比传统电脑病毒更致命？

所以，这跟十几年前的熊猫烧香，后来的Mirai僵尸网络有什么区别？

传统木马或僵尸网络，是一段死代码。更新补丁或改了密码，它们就废了。

但AI蠕虫，是「活体智能」 。

当AI蠕虫遇到一个陌生的智能烤箱时，会去分析烤箱的系统日志、写编译脚本，甚至自己去搜漏洞，写出攻击代码。

它们运行在千家万户的边缘设备上。没有中心化的控制节点，没有需要续费的云服务器。

Anthropic在报告中给出一个比喻：这种复制体就像是「黏菌」或者果蝇的虫群。

> As a reference point, an H100 can serve Gemma4-26B-A4B at ~1.95k tok/s at high concurrency with speculative decoding, so our swarm would have at most about 40 H100s-worth of inference. This is a tiny amount of compute in absolute terms, and the agents are slow replicators (over 1-2 days per 9B replication). As an analogy, imagine the replicator as a slime mold or a swarm of fruit flies, which replicate over days.

因为边缘设备算力有限，它们的速度可能很慢。但它们悄无声息、极度顽强。

当你发现第一只蟑螂时，整栋楼都已经爬满了。

倒计时开启，2026年底或迎「实用级爆发」

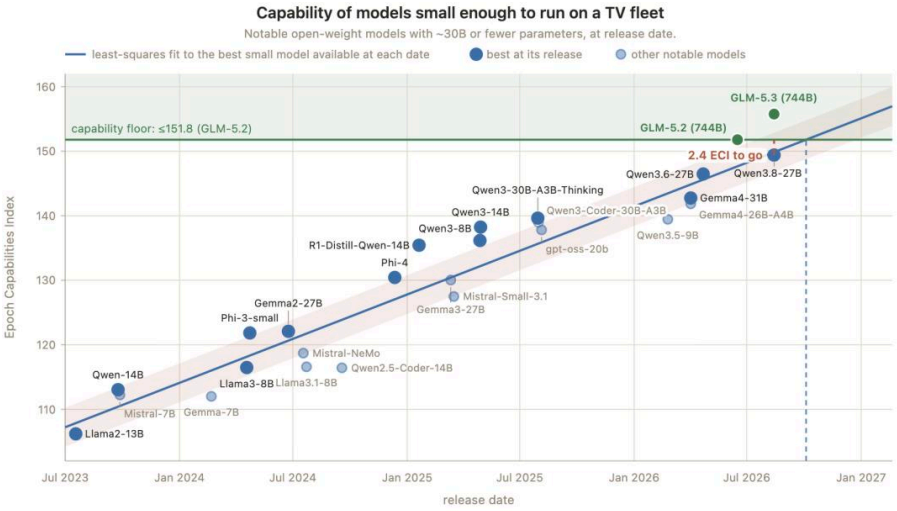
那么，这种可怕的场景离我们还有多远？

Anthropic给出了倒计时。

AI蠕虫要实现泛滥，需要满足两个条件：

能力底线：模型必须够聪明，至少要达到GLM-5.2的水平。

体积上限：模型必须够小巧，至少得缩减到9B到26B左右，才能塞进电视盒、智能冰箱等内存只有4GB的设备里。



过去，聪明模型太大，小模型太笨。

但是！随着模型压缩技术、量化技术以及小模型能力的狂飙，根据模型能力的进步速率（每年增加13.7 ECI指数）推算——

到2026年年底，小模型的智力水平将彻底击穿「自我复制能力底线」！

届时，大批聪明的数字黏菌，将以完全态降临，钻进你家的扫地机器人。

还有更糟的，带有AI降噪芯片的会议机、智能摄像头、自动驾驶汽车、机器狗……这些设备算力越来越强，相当于给AI蠕虫准备好了温床。

一旦它们被攻破，AI蠕虫的繁衍速度将呈指数级暴增！

G. Conclusion: Signs of life

The capabilities that make AI models generally powerful coding agents also generalize to cyber tasks, including autonomous replication. Like coding agents in 2024, we're seeing signs of life for AI worms. We don't yet have a full rogue replicator, but agents are becoming increasingly capable of completing the individual steps in the replication chain (and passing on their adaptations to future copies of themselves).

At the same time, increasing amounts of inference compute are now available both inside and outside of datacenters (see Appendix D). It's uncertain exactly what form autonomous AI replication will take. It could be a slow, distributed "digital slime mold," living on relatively insecure compute. It could also be a powerful cyber model that breaches datacenters at a high pace, or a model that scams people for compute credits.

今晚回到家，好好看看你家的电视盒子，说不定，一个数字生命已经在里面繁衍了。

来源：新智元

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

170 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

1 条评论

MobileUser8613
6小时前 中国香港

您看不懂原文?

0 回复