

摘要：

Computex大会上，Arm宣布自研AGI CPU正式量产，150亿美元销售目标有望提前完成；Arm版Windows规模化节点已到，华硕等八家厂商将推出Arm架构笔记本。黄仁勋解释RTX Spark集成Arm芯片，是为了“重新定义PC”。Arm同时预警，存储芯片仍是AI算力扩张的最大瓶颈。

Arm在Computex 2026正式宣布AGI CPU进入量产阶段，押注Agentic AI时代数据中心对CPU算力的爆发性需求，并由此确立了向自研芯片领域的战略转型。

CEO Rene Haas表示，此前设定的150亿美元自研芯片营收目标“有望提前实现”——“需求比我们预期的还要强劲，需求表现非常好”。该目标原定于本十年末完成，届时自研芯片业务营收预计将超越现有IP授权业务规模。

Arm股价周一大涨逾15%，收报408.85美元，创历史收盘新高，年内涨幅累计达274%，过去12个月累计上涨224%。英伟达发布RTX Spark笔记本芯片——该产品集成Arm定制版Grace CPU，搭载20颗Arm架构核心，并配备专为智能体计算设计的Blackwell GPU，宏碁、华硕、戴尔、技嘉、惠普、联想、微星、微软等主流PC厂商均已确认推出对应机型。

Rene Haas直言，“常年不断有人咨询：Windows+Arm生态何时能在笔记本、通用计算领域形成规模化竞争力？我的答案是：如今这个节点已经到来。”黄仁勋则表示，打造智能体设备离不开高性能CPU，这也是我们选用Arm架构的核心原因。产品搭载20核CPU，单核性能优异。

与此同时，Arm AGI CPU正式宣布进入量产阶段，Meta、OpenAI、Oracle Cloud Infrastructure等头部AI及云端企业相继加入该产品生态。



AGI CPU量产：以能效优势切入数据中心CPU市场

Arm AGI CPU定位Agentic AI快速增长带来的数据中心CPU增量需求，目前提供气冷与液冷两种系统配置。风冷机柜功耗约36千瓦，搭载8000个核心；液冷机柜功耗约200千瓦，搭载超过45000个核心。Rene Haas表示，在相同机柜功耗下，Arm AGI CPU的性能约为竞争架构系统的两倍，意味着数据中心可在相同电力条件下获取更高算力，或在降低功耗的同时维持具竞争力的性能表现。

Rene Haas在主题演讲中阐述了Agentic AI推升CPU需求的底层逻辑：GPU与XPU擅长训练与推理，可视为token生成器；但AI Agent持续运行且会不断启动新的Agent，后端随之产生大量token分配、管理、协调与传送任务，这些系统层级工作负载仍须由CPU承担。他指出，Arm此前预估未来在相同功耗范围内数据中心可能需要4倍CPU核心数，而市场目前讨论的倍数已涵盖4倍、8倍乃至10倍等不同估算。

在市场规模层面，Arm曾估计未来五年CPU市场规模可能达到1000亿至1200亿美元以上，Rene Haas表示随着AI Agent应用持续成长，市场讨论的规模数字甚至已超过原先预测。他以约10GW容量的数据中心测算，导入更高每瓦效能的CPU方案后，可带来最高100亿美元量级的成本节省。

RTX Spark重塑AI PC格局，Arm生态系统壁垒凸显

英伟达CEO黄仁勋亲赴主题演讲台，与Rene Haas对谈，阐述RTX Spark的产品定位。黄仁勋表示，英伟达的目标是重新定义个人电脑，PC问世已有四十年，过往手写开发的系统软件将逐步被各类智能体应用替代，这一图景驱动英伟达重构硬件架构与操作系统。他指出，打造智能体设备离不开高性能CPU，这是选用Arm架构的核心原因，Arm的定制化能力可灵活适配整机设计需求。

产品层面，RTX Spark标配128GB内存，基于英伟达自研NVFP4数值格式压缩，本机可常驻千亿参数级大模型以满足日常运算，复杂推理任务对接云端算力。黄仁勋还透露，奥多比已宣布重构Photoshop、Premiere，接入CUDA加速并适配智能体调用，Blender、欧特克、达索、西门子等行业软件亦将陆续完成RTX硬件加速适配。

Rene Haas在演讲中指出，当前Linux、全系苹果macOS、Chrome OS、Windows均已完成Arm平台适配，全系统兼容能力仅有Arm可以实现，是Windows+Arm生态在笔记本与通用计算领域形成规模化竞争力的重要基础。他表示，这一节点已经到来，离不开与苹果、谷歌、微软数十年的持续合作。



客户阵营持续扩大，利益冲突质疑获正面回应

Arm AGI CPU已获得Meta、Rebellions、SAP、Cerebras、OpenAI等企业支持，甲骨文等近期亦宣布加入该生态。

Rene Haas在演讲中正面回应了外界对Arm自研CPU是否与现有IC设计客户产生利益冲突的质疑。他表示，该项目的驱动力来自客户主动提出需求，而非Arm主动切入竞争——“是客户要求我们做出这个产品，而不是我们主动跨入这块市场。”他披露，Meta早在两年前便向Arm提出需求，彼时市场上几乎没有基于Arm架构的服务器芯片可用选项。

Rene Haas强调，目前AI运算芯片的需求远大于供给，Arm AGI CPU与英伟达产品的订单均极为强劲，现阶段尚未出现自有产品对既有客户形成排挤效应的情况。他以3月24日发布会上多家合作伙伴公开提供正面引述与见证视频为佐证，表示重要合作伙伴事前已获充分沟通。

市场展望：分析师看多x86与Arm两端需求并存

Mizuho分析师Vijay Rakesh在研报中对Arm和AMD均维持“跑赢大市”评级，对英特尔维持“中性”评级，称“在整体强劲前景下，我们继续看到x86和Arm平台在2026年下半年至2027年均受益于强劲的CPU需求增长”。

独立分析师Richard Windsor则在其Radio Free Mobile博客中写道，若AMD宣布推出基于Arm架构的CPU，这将是其放弃x86架构的信号，届时“现实将变得无法忽视”。

在供应链层面，Rene Haas在Computex期间向媒体表示，包括高带宽存储芯片、DRAM和NAND在内的各类存储芯片供需平衡均处于紧张状态，由于此前下行周期中产能扩张不足，存储芯片仍是目前最难解决的瓶颈，未来一段时间内供应整体仍将保持紧张。

以下为演讲实录，部分内容有删减：

Arm首席执行官Rene Haas：

大家好，欢迎各位到场。


每逢六月就迎来中国台北电脑展（COMPUTEX），六月的中国台北午后与晚间气候闷热，但能再次回到这里，我倍感欣喜。

放在以往，很多事看似相隔久远，但身处当下人工智能飞速发展的时代，行业迭代速度近乎以光年计。

今年3月24日我们举办了名为“Arm无处不在”的主题发布会。

当时我们重点研判智能体与智能体人工智能的行业增长趋势。

就在3月24日的活动现场，我们展示了一张数据幻灯片，对比OpenClaw项目相较于Linux、Kubernetes的增速变化。图表左侧为GitHub项目收藏星标数量，星标数值直观反映一款应用的受欢迎程度与用户粘性。



彼时3月的数据就显示，OpenClaw项目的用户增长呈现近乎指数级的爆发态势。

这一数据变化向我们传递一个信号：各类智能体平台的高速发展，正在催生前所未有的中央处理器（CPU）需求。

背后逻辑十分清晰：图形处理器（GPU）、异构处理器（XPU）擅长生成Token，这也是这类加速芯片的核心定位。

无论是模型训练生成学习参数，还是推理环节输出Token，Token生成的核心载体都是各类硬件加速器。

但智能体和人类不同，没有休息周期，智能体会持续衍生出新的子智能体，子智能体又会继续繁衍。

海量Token的分发、调度、统筹、下发落地，全部依赖CPU完成相关算力负载，同时CPU需要搭配整套系统架构协同工作。

基于以上逻辑，我们在3月24日的发布会上率先提出预判：**未来同等功耗约束下，市场所需CPU核心数量将增至现有四倍，我们也是业内较早提出该观点的企业。**

四倍这个系数发布后，大量业内人士向我们求证测算逻辑与数据来源。此后行业陆续出现四倍、八倍甚至十倍的相关增长预判。受智能体发展速率影响，精准数值很难敲定。

但有几点趋势可以确定。

从3月24日至今，智能体产业的增长速度持续突破预期，呈现爆发态势。

雪花数据（Snowflake）、赛富时（Salesforce）、ServiceNow等SaaS服务商，都在研发可在后端运行的各类智能体应用。

Anthropic旗下Claude代码模型、OpenAI的Codex模型落地，层出不穷的智能体算力需求持续推高CPU采购量。

进而带动CPU市场迎来高速增长。

如果把纵坐标统计口径更换为硬件出货量，从增长曲线可以看出，CPU行业增速已经超出我们此前预估。

这是全行业的共性趋势，并非Arm一家独有。

后续我会进一步介绍Arm相关产品，目前整个CPU赛道所有厂商都面临需求暴涨的现状。

智能体不断迭代繁衍，直接带动CPU需求持续井喷。

最终需求涨幅究竟是四倍、六倍还是八倍，我们无法精准定论，但可以确定增长系数仍在持续走高。

智能体产业加速扩张，同步拉动CPU市场规模持续攀升。

3月24日我们给出预测：**五年内全球CPU整体潜在市场规模（TAM）将突破1000至1200亿美元。**

发布会举办当时，不少媒体、投资机构、行业分析师都表示该预测数值过于激进，质疑测算依据。




时隔不久，当前行业给出的市场预测数值，已经接近我们当初预估数值的两倍甚至更高。

核心驱动逻辑在于：AI智能体算力负载下，Token生成量越高，数据处理体量越大，智能体智能化程度越高，对应算力消耗也就越高。

针对该市场需求，我们推出了对应解决方案：Arm通用人工智能（AGI）架构处理器。

正如之前所说，这款处理器全系在中国台湾生产。接下来我再次播放3月24日发布会展示过的产品宣传片，既方便没看过的观众了解产品，我个人也十分喜爱这支短片。



我几乎每天都愿意回看这支视频，每次观看都备受鼓舞。

Arm AGI处理器落地中国台湾量产，合作伙伴台积电已经协助我们实现产品量产。

我们此前定下产品发布准则：在敲定终端客户、产品正式出货、拥有落地合作伙伴前，不对外详细披露产品细节。

在当前产业环境下，芯片落地不能只依靠单款硬件，需要联合合作伙伴打造整套全栈解决方案。

我们在中国台湾集结了全球顶尖的产业链合作伙伴。

现场展区就能看到部分合作厂商产品，据了解超微（Supermicro）还在展区摆放了完整服务器机柜。

华擎、晶圆代工伙伴台积电、广达、Insycle、超微、智邦（ASPEED）等优质合作伙伴，依托完善生态助力我们落地高性能产品方案。

从系统形态划分，这款产品分为两大版本。

Arm AGI处理器主打极致性能、高密度集成与高能效表现，能效优化也是Arm的标志性优势，该基因源自早年移动端芯片研发。

早年我们定制移动端处理器时，就要在小型塑封封装内实现电池供电运行，这套研发思路深深烙印在工程师的产品设计中，最终落地为高竞争力产品。

产品两款机型参数：风冷机柜功耗36千瓦，搭载8000颗处理器核心；液冷机柜功耗200千瓦，核心数量超45000颗。

两套差异化方案的核心优势在于单机柜算力、单位功耗算力表现。同等功耗条件下，单机柜算力是同规格X86架构设备的两倍；若想要持平算力，整机功耗仅需竞品一半，能效优势突出。



放眼全球大型数据中心建设，相关合作消息几乎每日都有披露，就在近期，Arm母公司软银官宣在法国投资建设一座总功率5GW的数据中心。

大型数据中心前期资本投入高昂，常年电费成本支出巨大。依托Arm产品单机柜算力强、功耗低的优势，能够大幅降低数据中心综合投入。

经我们测算，规模化部署后可支撑约10GW算力需求，帮助客户节省近百亿美元成本；未来随着处理器装机量持续提升，降本收益还会进一步放大。

3月发布会时我们就公布了首批落地合作客户：Meta、Rebellions、思爱普（SAP）、Cerebras、OpenAI、韩国SK Telecom。

时隔数月，又有多家企业加入合作名单：甲骨文（OCI业务长期和Arm深度合作）等。

两家新伙伴的落地，印证Arm AGI处理器能够切实解决行业实际算力痛点。

这里我再次强调：如今Arm已经转型全栈端到端解决方案供应商。

虽然Arm AGI处理器已经实现量产，但并非所有客户都愿意直接采购成品芯片，对此我们也提供多元化合作模式。

客户既可以采购整套计算子系统，也能单独采购架构知识产权（IP）。谷歌、亚马逊、英伟达、微软等众多头部企业都选择IP授权合作模式，我们会按照客户需求灵活定制解决方案。

伴随智能体AI产业爆发，无论是自研成品处理器，还是对外输出IP与子系统，Arm整体业务增长势头迅猛。

上个月谷歌重磅官宣：TPU 8t、TPU 8i两款加速芯片配套主控CPU，将从原有X86架构切换为自研Axion处理器，该芯片基于Arm Neoverse架构打造，同等性能下功耗降低60%。

亚马逊CEO安迪·贾西在财报电话会议中提到，不少合作方希望全额买断亚马逊Graviton架构相关产能。如今亚马逊超半数全新服务器项目选用Graviton替代X86，而几年前该比例还是零。英伟达全新Vera产品同样选用Arm方案，是我们重要的合作伙伴。

Vera产品综合实力出众，实际合作厂商名单远超现场展示内容，幻灯片版面无法尽数罗列。目前Vera相关业务增长势头强劲。

我们对Arm AGI处理器有着长期规划，产品采用多代迭代路线，第二代Arm AGI处理器研发工作已经启动，新品核心数量更多、能效与性能进一步优化；第三代产品也在筹备阶段。

全系列产品依托自研计算子系统（CSS）落地，我们同步向合作伙伴输出该套子系统，既赋能合作方自研硬件，也支撑自有处理器迭代，全系列产品保持统一迭代周期。

以上就是增长势头强劲的Arm AGI处理器相关介绍。

接下来切换话题。二十多年前我第一次参加中国台北电脑展，早年展会集中在老展馆，展区随处可见软盘控制器、USB线材，周边电脑城品类齐全。

当时的电脑城一栋十层建筑内，一层就能聚集数十家配件商铺，堪比巨型连锁电脑卖场Fry's，消费者可以在店里买到各类电脑配件，这也是当年台式电脑主流选购方式。

早年PC整机的组装、选购模式十分有趣，产品价格覆盖全价位区间，从入门级便携上网本，一直到高端电竞主机，产品售价按50美元档位划分。



在场还记得上网本的朋友可以举手，英伟达的同仁肯定深有体会，我们都经历过那个产品周期。

产品在主频、内存容量等硬件参数上做差异化，各厂商争抢细分市场份额。

时至今日行业变化巨大，不仅PC选购模式彻底改变，产品使用场景也因智能手机、互联网、各类应用软件出现迎来颠覆性升级。

当下PC产品逐步分化为两大产品方向。

第一类是便携生产力设备：续航优异、全场景互联，形态近似大屏带键盘手机，使用逻辑和智能手机高度互通。我本人就在使用折叠屏产品，日常用来审阅文档、修改演示文稿；作为企业高管，我日常文稿创作不多，以审核工作为主。

我经常在折叠便携设备和传统PC之间切换使用，设备间数据、应用高速同步是刚需。

第二类是超高算力机型，用于智能体部署、大模型运行、程序开发等重度负载场景，对硬件性能要求拉满。而Arm是唯一可以同时支撑两条产品路线的架构。

早年PC行业靠丰富价位、差异化硬件参数瓜分市场，如今产品聚焦两大极致赛道：一端主打超长续航与轻量化AI体验，另一端主打智能体超高算力，两条赛道Arm全部适配。

宏碁相关产品、苹果Mac Neo、谷歌Chromebook、微软Surface、Mac Studio以及英伟达刚发布的RTX Spark，都是对应两大赛道的代表机型，而这些产品全部依托Arm生态落地。

常年不断有人咨询：Windows+Arm生态何时能在笔记本、通用计算领域形成规模化竞争力？我的答案是：如今这个节点已经到来。

当前Linux、全系苹果macOS、Chrome OS、Windows系统全部完成Arm平台适配，全系统兼容能力仅有Arm可以实现。这份成果离不开各大操作系统厂商的深度协同，我们和苹果、谷歌、微软数十年持续合作，生态搭建绝非一朝一夕之功。

在此感谢所有合作伙伴助力生态落地。

接下来介绍英伟达新品RTX Spark笔记本，该产品采用Arm架构，我们是英伟达本款产品的核心合作方。

产品搭载定制版Grace CPU，内置20颗Arm架构核心，是目前市面笔记本处理器核心数量的天花板。搭配专为智能体运算打造的Blackwell旗舰GPU，产品综合实力出众。

硬件可实现FP4精度下1PFlops算力、超大内存容量，原生预装Arm版Windows系统。

宏碁、华硕、戴尔、技嘉、惠普、联想、微星、微软均已确认推出对应机型，微软全新Surface Ultra就是标杆产品。在此祝贺英伟达团队顺利落地这款产品。

本项目落地过程中，我们依托自研计算子系统（CSS）方案，和英伟达、联发科深度协同。

简单解释计算子系统：CSS是定制SoC开发的模块化基础组件，涵盖CPU、配套GPU、系统IP、内存控制器等芯片全部组成模块，我们将整套组件打包对外供货。

联发科既可以选用整套完整解决方案，也能按需采购零散模块化组件。依托IP+计算子系统的商业模式，Arm在PC智能体算力赛道迎来广阔机遇，产品落地逻辑和AGI服务器处理器一脉相承。




正如前文所说，未来PC行业发展前景广阔：一端是我日常办公使用的轻量化创作设备，另一端是支撑智能体交互、大模型运算的高端算力主机，两大细分市场空间全面打开，英伟达RTX Spark已经印证该产品路线的可行性。

与黄仁勋的互动

Rene Haas：接下来我邀请一位重磅嘉宾上台，一同深入聊聊RTX Spark以及英伟达整体布局。

黄仁勋：谢谢。



Rene Haas：Arm架构适配Windows早已不是新概念，为什么这款产品能实现差异化突破？每次你发布新品，你们公司股价大涨，反观我这边毫无波动。

黄仁勋：客观来说我对此乐见其成，顺便说明，你曾经持有我方股票并且已经变现。

Rene Haas：没错，我当时需要现金流周转。咱们言归正传，聊聊RTX Spark，这次产品的革新之处在哪？

黄仁勋：**我们想要重新定义个人电脑。**PC问世已有四十年，过往手写开发的系统软件，未来会逐步被各类智能体应用替代。智能体AI依托PC硬件、调用PC内置工具运行，基于这套未来图景，我们着手重构硬件架构与操作系统，实现电脑产品革新。

打造智能体设备离不开高性能CPU，这也是我们选用Arm架构的核心原因。产品搭载20核CPU，单核性能优异；为容纳海量大模型参数，我们自研NVFP4数值格式，压缩大模型体积，让超大参数AI模型可以装进设备本地内存。

我们同时整合用于通用加速计算的CUDA、面向张量核心运算的CUDA Tiles至单颗处理器。智能体自主思考、调用工具时响应速度极快，因此配套工具必须同步提速。

奥多比官宣重构Photoshop、Premiere软件，产品接入CUDA加速、适配智能体调用；Blender、欧特克、达索、西门子等行业软件都会陆续完成RTX硬件加速适配，全品类工具加速落地后，即可快速响应智能体指令。

想要落地这款片上系统（SoC），需要CPU厂商灵活定制架构、深度适配整机设计，Arm的定制化能力完美契合我们的需求。

Rene Haas：感谢分享，接下来聊聊本地部署智能体和云端智能体的取舍问题，长期来看两种模式会如何演变？



黄仁勋：不客气。未来个人电脑本身就会变成全天候自主运行的智能体。如今出门忘带笔记本就无法使用设备，未来只需要通过手机和本机智能体对话，远程操控PC完成任务，比如快速起草发言稿。PC在闲置时段依旧在后台持续运算。

需要调用云端接口的任务走云端算力，能够本地完成的运算全部在PC端落地，这也是个人终端产品的核心属性：本地算力任务自主处理，不用担忧计费与时长，跨域复杂需求再联动云端。

Rene Haas：伴随大模型迭代，PC硬件性能与架构能否持续扩容？贵司Blackwell、Rubin系列产品已经交出亮眼答卷，软硬件如何协同实现算力扩容？

黄仁勋：RTX Spark标配128GB内存，依托NVFP4格式压缩，本机可常驻千亿参数大模型（例如Nemotron 3 Super），满足日常基础运算；前沿复杂推理任务随时对接云端算力。

Rene Haas：本地大模型普及会改变传统端云算力配比吗？未来云端算力需求会缩减还是继续走高？

黄仁勋：智能体体系包含主智能体、多层级子智能体，算力分布兼顾云端与终端，和当下移动互联网逻辑一致，移动端和云端缺一不可。兼顾本地算力与云端资源，才能打造优质个人智能体体验。

Rene Haas：有个颇具探讨性的问题：智能体在后台自主处理大量工作后，操作系统还有存在的必要吗？未来智能体本身会不会替代操作系统？

黄仁勋：操作系统的重要性只增不减。不少人鼓吹AI到来后软件行业消亡，实际恰恰相反：智能体运行的基础是各类应用软件，智能体需要调用Photoshop、Pr、Canva、西门子工业软件等海量工具，而所有软件都依托操作系统运行。智能体通过读取软件使用手册、调取程序接口，完整解锁软件全部隐藏功能，倒逼软件价值提升，Windows等操作系统在很长周期内都是刚需。

Rene Haas：英伟达深度布局AI全产业链，覆盖算力、网络、整机全环节，从贵司视角来看，未来数年行业增长瓶颈集中在哪些领域？

黄仁勋：全产业链各环节都存在阶段性约束。产品迭代上，Hopper架构主打模型训练；Grace+Blackwell架构兼顾训练，搭配NV-Link72链路优化推理性能。早期行业普遍低估推理难度，实际上混合专家大模型想要高效生成Token，离不开高规格硬件支撑，Grace Blackwell+NV-Link72方案实现业内最低Token生产成本，是行业里程碑。

Vera、Rubin系列在上述技术基础上拓展智能体算力场景。两年前我们提出产品适配智能体时业内难以理解，如今行业达成共识：智能体需要自主思考、调用工具、管理长短时内存、索引多格式数据，整套运行逻辑需要全新硬件架构支撑，Vera Rubin就是面向智能体的专用计算平台。

当下智能体已经落地商用创造实际收益，是全行业算力爆发的核心动因：Token生成产生盈利，市场就会无限度扩充Token产能；并且智能体运算负载远高于普通人机对话，算力消耗最高可达闲聊场景的百万倍。智能体单次任务可连续运算数天乃至数周，Token生成需求呈指数暴涨，供需错配造成全产业链算力紧缺。

英伟达提前预判智能体风口、布局供应链，实现连续高增速，今年营收同比近乎翻倍，明年依旧保持高速扩张；即便如此，终端市场需求增速依旧超过产能扩容速度。近期我和行业同仁交流，大家都感慨从未见过半导体行业连续四年处于高景气周期，而从智能体产业基本面来看，本轮行业上行周期仍将延续。

底层逻辑在于：过往计算机用户受限于人类数量，全球仅十亿人使用电子设备；未来数十亿级别的智能体、人形机器人、自动驾驶设备都会接入算力网络，全球算力市场规模有望在现有万亿体



量基础上再翻十倍，这也是英伟达市值登顶全球的底层逻辑，如果两家企业合并，市值依旧稳居全球首位。

Rene Haas：这个设想十分美妙，再次祝贺RTX Spark顺利落地。我准备了一份小礼品送给您，这件藏品很有纪念意义：Tegra3是全球首款落地Windows+Arm架构的笔记本芯片。

黄仁勋：不得不说，相比当年，我保养得更好。

Rene Haas：在场各位觉得我说的对吗？礼品送给您，麻烦在藏品上签名留念。

黄仁勋：签完再回赠给我就能形成采购单据，这套流程我很熟悉，不行。

Rene Haas：感谢。欢迎投资收购Arm，我之前就尝试过促成合作。展品里的原型机是早年双方合作的真实项目，相关研发同事都记忆犹新。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 280  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论