

摘要：

押注“快Token”的晶圆芯片公司Cerebras正站在IPO窗口前：凭借21PB/s片上带宽实现2000 tok/sec/user的极致推理速度，拿下OpenAI 750MW算力大单，撬开246亿美元订单背书。但硬币的另一面同样刺眼——44GB SRAM容量天花板、仅150GB/s的片外I/O、高度依赖单一客户，以及“快Token溢价能否长期覆盖复杂系统成本”的终极悬念，决定着这场豪赌的胜负。

Cerebras的故事突然变顺了。几年前，它还是一家用“整片晶圆做芯片”的激进AI硬件公司，技术足够大胆，但商业化一直不够确定；现在，快推理成为大模型厂商愿意付溢价的方向，OpenAI又签下750MW推理算力合作，Cerebras站到了IPO窗口前。

SemiAnalysis分析师Myron Xie在14日发布的一份研究报告把核心变化概括得很直接：“过了某个智能阈值之后，开发者更偏好更快的Token，而不是更聪明的Token。”这句话解释了Cerebras估值逻辑的转向：它不一定要在所有AI算力场景里击败GPU，但只要“高交互速度”成为可收费产品，它的晶圆级架构就有了用武之地。

这也是Cerebras最迷人的地方。WSE-3把44GB SRAM、计算核心和片上互联塞进整片晶圆，带来21PB/s级别的内存带宽，推理速度可以达到传统HBM加速器难以触及的区间。但同一套架构也带来限制：SRAM容量不够大，片外I/O只有150GB/s，冷却、供电、封装都高度定制，服务超大模型和长上下文时会越来越吃力。

OpenAI是Cerebras的最大机会，也把风险集中到了一个客户身上。双方协议对应750MW推理算力，OpenAI还有额外1.25GW选项；Cerebras披露的剩余履约义务达到246亿美元。但这笔交易同时绑定了10亿美元工作资本贷款、接近免费行权的认股权证，以及高强度数据中心交付压力。IPO投资人真正要问的，不是“晶圆芯片酷不酷”，而是：快Token的溢价，能不能覆盖Cerebras的结构性成本和单一客户风险。

Cerebras押中的不是“总吞吐”，而是“交互速度”


过去AI推理硬件的主线，是每张GPU、每个机柜能吐出多少Token。对云厂商和模型厂商来说，总吞吐意味着单位成本，意味着能服务更多用户。

但用户行为正在把另一条曲线推到前台：tokens/sec/user，也就是单个用户拿到输出的速度。

OpenAI、Anthropic都在把同一模型拆成不同服务档位：fast、priority、standard、batch。用户愿不愿意为更快响应付钱，已经不只是产品经理的猜测。Opus 4.6 fast曾以约6倍价格换取2.5倍交互速度，后来速度优势降到约1.75倍；即便如此，高速模式仍是开发者愿意付费的SKU。SemiAnalysis自身4月AI支出一度年化达到1000万美元，其中80%花在Opus 4.6 fast上。

这说明一个市场变化：当模型能力足够可用，等待时间就会变成生产力瓶颈。对写代码、调用工具、连续迭代的agentic workflow来说，慢几秒不是体验问题，而是工作流被打断。

Cerebras的优势正好在这里。它不是靠更多HBM堆容量，而是靠片上SRAM极高带宽，把低batch、小并发、高交互速度的decode场景做得非常快。换句话说，GPU像一辆能拉很多人的大巴，Cerebras更像为了少数乘客高速直达而设计的跑车。



WSE-3不是“大号GPU”，它是一整片晶圆


Cerebras的核心产品WSE，是把整片晶圆当成一颗芯片，而不是切割成几十、上百颗独立die。

WSE-3采用台积电N5工艺，由12×7、共84个相同步进区域组成。每片晶圆上有约97万个核心，其中90万个启用。晶圆面积的一半给SRAM，另一半给计算核心。这个设计的关键，是计算和存储都留在同一片硅上，尽量避免数据离开芯片、离开封装。

参数很夸张：

- SRAM容量：44GB
- SRAM带宽：21PB/s
- 对外I/O：150GB/s
- 公开营销口径FP16算力：125PFLOPs
- 按8:1非结构化稀疏折算后的dense FP16算力：约15.6PFLOPs

From Small Core to Massive Wafer



这组数字要分开看。21PB/s内存带宽是Cerebras最强的地方；15.6PFLOPs dense FP16算力也不低，但如果按单位硅面积衡量，并不像宣传口径那么惊人。125PFLOPs来自稀疏假设，材料里把这种算法调侃为“Feldman’s Formula”，对应的是把dense算力乘以8。

真正的分界线在内存类型。GPU、TPU、Trainium这类主流AI加速器把模型权重和KV Cache放在HBM里；Cerebras把它们尽量放进SRAM。SRAM快、延迟低，但单位bit成本高，容量密度低。

44GB SRAM放在单芯片世界里很大。可和HBM比，它又不大。单个HBM3E 12-Hi堆栈就有36GB；当前一颗高端GPU或TPU封装常见8堆栈，对应288GB，是WSE-3 SRAM容量的6.5倍。

这就是Cerebras的基本交换：用容量换速度。

晶圆赢在低算术强度decode，输在大模型和长上下文

Cerebras最适合的任务，是低算术强度、内存带宽受限的decode阶段。

大模型推理里，很多kernel并不是缺算力，而是缺内存带宽。GPU的Tensor Core可能很强，但如果权重和KV Cache喂不上来，算力就会饿着。Cerebras把大量SRAM铺在晶圆上，数据离计算单元更近，带宽足够高，batch=1这类低并发decode场景能跑出传统HBM系统很难达到的交互速度。

材料中的理论对比很清楚：如果看一个batch=1、算术强度约为2的decode kernel，NVIDIA GPU和Groq LPU理论上只能实现几十到数百TFLOPs量级；Cerebras WSE-3在理想条件下可以接近完整15.625PFLOPs dense FP16算力。

这就是“快Token”的硬件基础。

但只要模型变大、上下文变长，44GB SRAM就开始紧张。推理系统的内存要装三类东西：

- 。模型权重；
- 。并发请求所需KV Cache；
- 。长上下文带来的更大KV Cache。

agentic coding这类工作负载尤其麻烦。样本测算中，约43.2万条请求、约800亿Token显示，典型P50输入序列长度约为96.3k Token，而不是Cerebras产品假设中的64k；接近50%的请求超过128k，这已经达到Cerebras公开端点目前支持的最大上下文窗口。

这意味着，如果未来模型服务走向256k、1M上下文，Cerebras要么压缩KV Cache，要么上更多晶圆，要么牺牲交互速度和经济性。

冷却和BOM说明：这不是便宜算力

CS-3系统不是把一颗芯片插进服务器那么简单。

每台CS-3包括一个WSE-3 engine block、外围计算和I/O模块、两个机械泵、12个3.3kW电源模块，以及液冷系统。单片WSE-3本身功耗约25kW，放在46,225平方毫米晶圆上，平均热流密度约50W/cm²，还没算热点。

风冷却不现实。普通3D均热板如果放大到21.5厘米见方，会遇到毛细极限，工质回流跟不上。Cerebras只能做定制液冷结构：冷板、晶圆、柔性连接器、PCB组成四层“三明治”，散热歧管接在冷板背后。硅和PCB热膨胀系数不同，传统封装会裂，所以连接、预压、装配工具都要定制。

数据中心侧也被改变。GB200 NVL72参考设计的设施侧流量约1.5 LPM/kW，而WSE-3在25kW下约100 LPM，相当于4 LPM/kW，接近3倍。这要求更大的泵、更粗的管、更大的CDU和更高流量的快接头。CS-4若能把机架级流量拉回1.5—1.7 LPM/kW，才更接近标准化基础设施。

成本同样不轻。CS-3加KVSS CPU节点的BOM估算，在去年四季度内存涨价前约35万美元/机架；计入最新内存价格后约45万美元/机架。KVSS是双路AMD CPU节点，配6TB DDR5 RDIMM，用于KV Cache offload。

有意思的是，最贵的不只是台积电N5晶圆。单片N5晶圆名义成本约2万美元，但Cerebras还要为每批晶圆做额外上层金属mask，用来绕过缺陷tile；Vicor定制供电模块也很贵，材料中估计其价值量接近台积电内容；冷却、封装、组装大量自研，外围还有12个100GbE Xilinx FPGA承担类似NIC的角色，把Cerebras自有I/O转换成以太网。

所以Cerebras并不是“便宜芯片替代GPU”。它是在一个特定推理速度区间，用复杂系统换极致交互速度。

SRAM扩展停滞，是Cerebras绕不过去的节点问题

Cerebras最依赖SRAM，但SRAM scaling正在失速。

三代WSE的SRAM容量变化很能说明问题：

- WSE-1，台积电16nm，18GB SRAM；
- WSE-2，7nm，40GB SRAM，代际提升2.2倍；
- WSE-3，5nm，44GB SRAM，只提升约10%。

同样从7nm走到5nm，逻辑晶体管数量增长约50%，但SRAM容量几乎没怎么动。往后更难。N3E相对N5在SRAM上基本没有缩小，N2及以后也继续受限。

对Cerebras来说，这比对GPU厂商更致命。GPU可以继续叠HBM、扩封装、靠互联池化内存；Groq这类SRAM机器也可以用hybrid bonding在Z方向堆更多SRAM tile。Cerebras是整片晶圆，平面面积已经用满。如果增加SRAM面积，就要牺牲计算面积。

CS-4的路线也暴露了这一点：仍使用N5基础的WSE-3，但提高功耗、提升时钟和计算持续能力，SRAM容量不变。

可选方向是晶圆对晶圆混合键合，把DRAM晶圆或更多存储叠到WSE上。Cerebras确实在探索这种路径。但晶圆级整体芯片的热机械问题、bond wave问题，都比常规hybrid bonding更难。

它过去解决过很多不寻常问题，但下一步仍然是硬仗。

最大硬伤是I/O：晶圆很大，出口却很窄

WSE-3片外带宽只有150GB/s，也就是1.2Tb/s。相对它的计算规模和片上带宽，这个出口太小。

这个问题不是工程师没意识到I/O重要，而是晶圆级架构自身的几何约束。

WSE由84个相同步进区域组成，每个reticle曝光图案必须一致，逻辑、SRAM、布线位置都一样，才能让跨划片道互联在晶圆上连续延伸。也就是说，不能只在边缘reticle放SerDes PHY，而中间reticle全做计算。每个reticle都必须长一样。

如果要增加边缘I/O，就要在每个reticle里都放PHY。问题是，中间那些PHY没有办法连接外部世界，只会变成浪费的硅面积。更糟的是，高速SerDes PHY面积大、模拟电路不喜欢贴近数字逻辑，还要guard region；放进晶圆内部，会在2D mesh里打洞，增加绕线和延迟，削弱晶圆级互联本来要解决的问题。

材料里给了一个直观数字：WSE当前片外带宽约0.17GB/s/mm边缘密度，NVIDIA片外I/O密度约为其130倍。

Cerebras的解法是光互联晶圆：通过混合键合把光子互联晶圆叠到WSE上，让数据沿Z轴进出，而不是从晶圆边缘挤出去。合作方是Ranovus。

这条路很漂亮，也很难。光学器件对温度敏感，不能太热也不能太冷；它还要贴着一片高功耗晶圆。光纤耦合在普通CPO里都还没完全工程化到轻松量产，更不用说放大到整片晶圆。

大模型会迫使Cerebras用流水线，而这违背了“快”的初衷

如果模型装不进一片WSE，就只能跨多片晶圆切分。

但低I/O带宽排除了很多常见并行方式。高带宽collective通信不现实，大张量频繁进出晶圆也不现实。剩下最可行的是pipeline parallelism：按层把模型切到多片WSE上，每片晶圆保留对应层权重，只在阶段之间传激活值。

Cerebras服务Llama 3 70B时，就是把模型切到4片WSE-3上，只在晶圆之间传激活，通信量能压在1.2Tb/s I/O能力范围内。

但流水线会带来三个问题。

第一，pipeline bubble。4个阶段至少需要约4个in-flight microbatch保持忙碌；16个阶段就需要约16个。阶段越多，调度越难。

第二，每个in-flight microbatch都有自己的KV Cache，而KV Cache也要和权重一起挤在44GB SRAM里。哪怕新模型用更强KV压缩，KV在片上片下搬运仍会以毫秒级增加TTFT和TPOT压力。

第三，晶圆数量增加，激活在晶圆间传输的固定延迟也线性增加。模型越大，越偏离Cerebras最理想的形态：小batch、低延迟、单片或少数晶圆高速decode。

公开产品线也透露了边界。Cerebras Inference Cloud目前最大生产模型是GPT-OSS，120B总参数；更大的preview模型GLM 4.7也到355B为止。Llama 70B和405B曾经受欢迎，后来被下线，可能与服务经济性有关。DeepSeek V3和Kimi K2这两个2025年热门开源前沿模型，也没有出现在Cerebras公共云上。

不过这不是绝对死局。DeepSeek V4 Pro这类模型如果采用更强KV Cache压缩，在足够并发下，1T+模型也可能重新变得可服务。问题在于，能不能同时保住Cerebras最值钱的东西：速度。

OpenAI把Cerebras拉进主牌桌，也把风险集中到自己身上

OpenAI在Cerebras未来里不是普通客户。

2025年12月，双方签署Master Relationship Agreement。OpenAI承诺购买750MW AI推理算力，2026—2028年分批部署，每批期限3—4年，可延长到5年。OpenAI还有选择权，可额外购买1.25GW，把总量提高到2GW。


S-1披露，截至2025年12月31日，Cerebras剩余履约义务为246亿美元。更重要的是，数据中心租金、电力、租赁改良、安全等pass-through成本由OpenAI报销，并按总额确认为收入。

OpenAI还提供10亿美元工作资本贷款，年利率6%。如果Cerebras通过交付算力或硬件偿还，对应利息可豁免。偿还从初始250MW最后一批交付后开始，三年等额摊还。如果MRA因OpenAI重大未补救违约以外原因终止，Cerebras可能要立即偿还全部未偿本金和应计利息。OpenAI还可以指示托管银行停止按Cerebras指令使用资金，转为直接控制资金处置。

股权绑定也很深。Cerebras向OpenAI发行33,445,026股Class N无投票权普通股认股权证，行权价0.00001美元，几乎等同免费。其中一部分因10亿美元贷款已立即归属，另一部分和400亿美元市值或付款门槛挂钩，剩余部分和算力交付、额外2GW扩张选项相关。完全稀释后，OpenAI最多可持有Cerebras约12%股份，不包括后续新发行。

按ASC 505-50，给客户的权益激励会在商业协议期内作为contra-revenue确认。以S-1中82.02美元/股估值粗算，全部认股权证理论上对应约27.4亿美元contra-revenue，约为OpenAI预期收入的10%。

这是一笔能改变命运的订单，也是一个把公司命运押到单一对手方上的结构。



GPT-5.3-Codex-Spark证明了速度价值，但也暴露模型尺寸问题

OpenAI发布GPT-5.3-Codex-Spark后，Cerebras的叙事更完整了。这个模型使用gpt-oss-120B架构，由真正的GPT-5.3-Codex蒸馏而来，在Cerebras上最高可跑到2000 tok/sec/user。

关键在“120B”。它不是完整GPT-5.3-Codex，而是小得多的蒸馏模型。材料中明确写到，它比完整模型小10倍以上。

这对Cerebras既是好消息，也是限制。

好消息是，120B级别模型如果能力足够强，再叠加极快输出速度，确实可能成为高价值产品。开发者已经证明过，愿意为了更快Token放弃部分前沿智能。

限制在于，OpenAI如果要在Cerebras上跑1T参数以上、1M上下文窗口、面向真实agentic workload的大模型，就要接受明显成本取舍，并且实际交互速度可能低于1000 tok/sec。能不能卖出足够高的Token溢价，是商业模型成立的关键。

材料给出的路径假设很激进：小模型能力继续提升，约一年内120B形态可能接近GPT-5.5级别智能。如果这成立，Cerebras就不需要承载最前沿、最大参数模型，也能卖出高价快Token。OpenAI锁定的750MW只是第一步，真正的上行空间来自是否行使额外1.25GW选项，甚至继续扩大采购。

但这个上行条件很窄：Cerebras必须证明，能在自己硬件适合的模型尺寸里，持续装下足够聪明、足够赚钱的模型。

IPO的核心问题：快Token溢价能不能长期覆盖硬件取舍

Cerebras不是另一个GPU故事。它不是在训练、大模型通用推理、长上下文吞吐上全面替代NVIDIA，而是在一个更窄但可能很赚钱的区间里押重注：高交互速度、低batch、用户愿意付溢价的推理。

晶圆级架构给了它极强的带宽和极快decode，也让它背上了SRAM容量、片外I/O、冷却、BOM、数据中心适配这些硬约束。OpenAI订单解决了需求问题，却没有消除交付风险和客户集中度。

所以Cerebras的IPO定价，不该只看246亿美元backlog，也不该只看2000 tok/sec/user这种漂亮速度。更重要的是三个问题：

- OpenAI需要的快Token，长期是不是120B—355B这类模型就够；
- 用户愿意为速度付出的溢价，能不能覆盖Cerebras更复杂的系统成本；
- 750MW到2028年能否按节奏落地，且不被冷却、电力、供应链和数据中心能力拖住。

如果答案偏向“是”，Cerebras会成为快推理时代最有辨识度的AI硬件公司之一。如果答案偏向“否”，整片晶圆带来的速度优势，可能会被大模型和长上下文的内存需求一点点吃掉。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

18 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论