

摘要：

CEO Andrew Feldman表示，我们看到对快速推理的需求是无限的，速度改变了用户参与度，改变了智能体性能，也改变了AI生产力。公司“解耦推理”方案可以在保持速度的同时，吞吐量提高5倍，预计今年第四季度部署。Cerebras预计其快速推理服务将在2027年第一季度在AWS Bedrock上线。

Cerebras 2026 Q2财报：云业务翻倍增长与解耦推理技术突破


Cerebras 2026年第二季度核心营收同比增长103%，主要由云服务（增长287%）驱动。公司通过“解耦推理”技术实现吞吐量5倍提升，并计划在2026年将产能扩大10倍，力争在2027年实现营收增长3倍以上的激进目标。

业绩摘要与核心财务

核心总营收：2.099亿美元 (+103% YoY)

核心业务表现远超此前指引，展现出极强的增长动能。

核心营收构成（亿美元）与同比（YoY）



云业务翻倍领跑，硬件稳步增长

云服务收入达1.277亿美元(+287%)，硬件收入达8210万美元(+17%)。

核心云及服务能力提升十倍

通过与Flex、Sanmina合作建厂，全面支撑大规模交付需求。

技术革新与基建扩张

“解耦推理”技术：吞吐量提升5倍

解耦推理流程（AMD合作）



与AMD合作，GPU负责预填充，Cerebras负责解码，大幅提升推理效率。



600MW+ 数据中心容量储备

已获取或将在2027年底前交付的容量，管道规模已达吉瓦级。




2026年制造能力提升10倍

通过与Flex、Sanmina合作建厂，全面支撑大规模交付需求。

增长指引与产品路线


2026全向上调营收目标：8.8亿-8.9亿美元



2027年激进目标：营收增长3倍以上

押注快速推理需求、产能扩张及超大规模客户拓展。

下周发布CS4，2027下半年发布CS5



Cerebras第二季度呈现明显分化：云业务高速增长、硬件收入承压，但管理层仍上调全年指引，并把2027年“增长3倍以上”的目标押在快速推理、产能扩张和超大规模客户拓展上。

美国当地时间8月12日，AI芯片公司Cerebras公布[2026年第二季度财报](#)并举行电话会。公司GAAP营收为1.801亿美元，同比增长74%；硬件收入5410万美元，同比下降23%，成为市场关注的主要压力点。财报公布后，公司股价盘后一度跌约17%。

不过，按公司“核心”口径，第二季度收入达到2.099亿美元，同比增长103%，超过此前指引。其中核心云及其他服务收入1.277亿美元，同比增长287%；核心硬件收入8210万美元，同比增长17%。

云业务成为增长核心，“快速推理需求是无限的”

CFO Bob Komin表示，第二季度大部分核心收入增长来自云业务，主要受OpenAI部署扩大和其他云客户使用量增长推动。

“核心云及其他服务收入为1.277亿美元，同比增长287%。这一近四倍的增长反映了对Cerebras快速推理服务的巨大需求。”

相比之下，硬件收入表现疲弱。管理层强调，**大型云容量部署和硬件发货时间会导致季度间业务结构出现较大波动，因此公司更关注核心总收入而非硬件与云业务的单季占比。**

CEO Andrew Feldman将Cerebras未来增长的核心逻辑归结为“速度”。

“展望未来，我们看到对快速推理的需求是无限的。市场正在意识到速度不是一项基准指标。速度改变了用户参与度，改变了智能体性能，也改变了AI生产力。”

公司认为，AI编码、智能体和安全等新应用都对低延迟推理有更高要求。

第二季度Cerebras签署了六笔超过3000万美元的交易，并与Figma、Cognition、lovable、Block、AlphaSense和GSK等公司达成新协议。

AMD解耦推理：不牺牲速度，吞吐量提高5倍

本次电话会另一个重要关键词是“解耦推理”。

Cerebras正在与AMD和AWS合作，将推理拆分为预填充和解码两个阶段：GPU负责更适合并行处理的预填充，Cerebras负责对内存带宽要求更高的解码。

Cerebras称，与AMD Helios机架结合后，在保持速度的同时，吞吐量可以提高5倍。Feldman表示：

“如果你能在不放弃速度的情况下做到这一点，那么每个系统你就有更多的收入。”

公司预计GPU解耦推理方案将在今年第四季度部署。



这一模式也意味着Cerebras可以利用现有GPU基础设施，而不必要求客户完全替换已有设备。管理层认为，这有望把市场从Cerebras硬件客户进一步扩展至庞大的GPU存量市场。

AWS明年一季度上线，OpenAI营收占比将逐渐下降

AWS合作同样是投资者关注重点。

Cerebras预计其方案将在2027年第一季度通过AWS Bedrock上线。管理层同时强调，目前254亿美元的剩余履约义务（RPO）并未包含来自AWS或其他超大规模企业的积压订单。

客户集中度方面，Feldman承认OpenAI明年仍将是重要客户，但预计随着AWS、编码、安全等业务增长，OpenAI收入占比将逐步下降。

“AWS和其他客户……所占的比例将会更大，而OpenAI占我们收入的比例将随时间推移而缩小。”

600MW数据中心，制造能力今年提高10倍以上

为了支撑未来增长，Cerebras正在大举扩充基础设施。

公司过去七个月已经获得超过600MW的数据中心容量，这些容量已经上线或将在2027年底前交付；同时，新增数据中心机会的渠道已经开始以吉瓦计算。

制造方面，公司与Flex、Sanmina建设新工厂，预计2026年制造能力较2025年上半年提高10倍以上，并在2027年继续扩张。

供应链方面，公司强调自身不使用HBM、不依赖3纳米晶圆产能，并主要采用台积电5纳米节点，因此希望避开AI产业链部分最紧张的供应瓶颈。

上调全年指引，2027年目标更激进

Cerebras将2026年全年核心收入指引上调至8.8亿至8.9亿美元，核心毛利率上调至41%至43%，核心营业利润率目标为-19%至-17%。

公司预计第三季度核心收入为2.14亿至2.16亿美元。

但真正吸引市场注意的是2027年的增长目标。Feldman表示：

“我们预计2027年核心收入将增长两倍以上，并在接下来的几年里继续保持倍数增长。”

CFO则进一步表示，公司有望在2027年实现“收入增长3倍以上”。

与此同时，公司预计未来几年每年推出速度翻倍的新系统，并计划在未来18个月将吞吐量提高20倍以上；第四代CS4将于下周发布，CS5计划于2027年下半年推出。

Cerebras2026年第二季度财报电话会议全文翻译如下：



Andrew Feldman

第二季度是强劲的一个季度。我们完成了公开上市，但这并没有分散我们对执行的注意力。我们实现了创纪录的核心收入，并在所有指标上都超出了预期：核心收入、核心毛利率和核心营业利润率。展望未来，我们看到对快速推理的需求是无限的。市场正在意识到速度不是一项基准指标。速度改变了用户参与度，改变了智能体性能，也改变了AI生产力。快速推理解锁了新应用和新市场。

正如我们之前与大家分享的，2026年是Cerebras奠定基础的一年。自上次财报电话会议以来的七周里，我们在多个方面取得了卓越进展，为我们实现大规模增长的2027年、2028年和2029年做好了准备，届时我们将交付目前账面上250亿美元的剩余履约义务。凭借这些进展，我们预计2027年核心收入将增长两倍以上，并在接下来的几年里继续保持倍数增长。我们认为进展体现在产能、能力和客户三个方面。

我们正在通过在全球范围内为数据中心签订新合同、扩大制造能力以及与供应商合作来确保供应和支持我们非凡的增长，从而扩大产能。我们正在通过发明新技术来提升我们的能力，这些技术扩展了我们的性能、吞吐量和能效。我们正在通过加速现有市场（如编码和智能体流程）中的AI生产力，并开拓安全等新领域来扩大我们的客户基础——在这些新领域，速度带来了全新的机会。

在产能方面，数据中心空间仍然是整个行业的瓶颈，我们也不例外。我们和客户建设新数据中心的越快，我们的增长就越快。因此，在过去七个月里，我们全力以赴地争取和建设数据中心。我们有两个优势。首先，由于我们服务于推理，我们不需要像训练集群所需的那种千兆瓦级占地面积的位置。这使我们在全球多个地点的产能扩展上具有更大的灵活性。其次，我们已经建立了一个可重复的场地选择、集群部署和客户激活流程，这是将千兆瓦级电力转化为全球规模生产性令牌所需的运营能力。

我很高兴地报告，我们的推进非常成功。我们现在在阿拉巴马州、达拉斯、丹佛、明尼阿波利斯、圣克拉拉、斯托克顿以及美国以外的法国、芬兰、马尼托巴省、蒙特利尔、挪威、萨斯喀彻温省和多伦多都拥有已建成或已签约的数据中心。总的来说，在过去七个月里，我们已经获得了超过600兆瓦的数据中心容量，这些容量要么已经上线，要么将在2027年底前交付。

虽然这还远远不能满足我们的需求，但我们的数据中心新增扩张机会的渠道仍在增长，现在已以吉瓦为单位衡量。换句话说，随着我们继续建设我们的第一方云，它将成为最大的非超大规模AI云之一。而在2025年底，我们还处于陡峭的学习曲线上。今天，我很高兴地报告，我们在数据中心建设方面已经相当擅长，并且有明确的路径变得卓越。

产能的其他关键维度包括制造和供应链。在这方面，我们成功提高了制造能力，并正在与Flex和Sanmina建设新工厂，预计在2026年将制造能力提高10倍以上，并在2027年继续扩展，再次为我们预期未来几年的卓越增长做好准备。我们与供应链供应商的合作也已转化为显著优势。台积电再次给予了支持，我们拥有推动增长所需的晶圆。

我们获得晶圆供应的能力也得益于我们能够在台积电的5纳米节点上提供行业领先的性能，而该节点的晶圆成本较低且供应不那么受限。我们与供应伙伴数十年的合作关系增强了我们对于未来能够实现增长计划的信心。这些关系稀有而宝贵，尤其是在供应短缺时期。最后，请记住，行业目前面临的大多数关键供应链限制对我们并不适用。例如，我们不使用HBM内存、封装，也不获取3纳米晶圆厂产能。

在能力方面，在第二季度，我们为OpenAI的GPT-5.6 Sol提供了支持，这是最大、能力最强的前沿模型。事实上，Cerebras服务GPT-5.6 Sol的速度比使用GPT-5.6 Sol时快10倍，这消除了关于我们支持大型前沿模型能力的任何剩余担忧。作为GPT-5.6 Sol交付的合作伙伴并在我们的云中提供服务，这体现了我们软件栈的成熟度。



达到能够提供超大规模质量和可靠性的水平，需要数百万小时的系统生产环境加固。我们为我们的推理云能够满足最苛刻客户的要求而感到自豪。我们在服务前沿模型方面的合作开辟了以前只有NVIDIA才能获得的新的、重要的战略优势。闭源前沿模型包含了源源不断的新见解和新AI技术。服务这些模型使我们能够洞察未来并为之做好准备。我们的硬件到软件栈的路线图现在反映了我们所看到的情况，并将在未来几年给我们带来复合优势。

继续围绕能力的主题，让我们转向解耦。我们现在与两家领先的芯片公司——AMD（与其Helios）和AWS（与其Trainium）——拥有解耦推理解决方案。这种聚合扩大了GPU提供商和Cerebras的市场机会。这种聚合使GPU能够参与目前对它们关闭的市场，即快速推理。这种聚合使Cerebras能够将我们的机会扩展到那些对价格更敏感的客户，并提高我们数据中心的盈利能力。让我们看看这是如何运作的。

与任何计算市场一样，随着推理的增长和成熟，专业化的机会就会出现。解耦是一种专业化形式，特别适用于具有已知流量模式的工作负载。在这些情况下，解耦通过将推理分为两个阶段：预填充和解码，并为每个阶段使用不同的处理器来实现优势。预填充处理来自用户或智能体的输入。这是一个可并行化的工作负载。因此，预填充非常适合GPU及其基于HBM的内存架构。解码生成输出令牌。这是更难的技术问题，也是解耦解决方案中的主要计算工作。它是顺序执行的，并且对内存带宽要求很高，特别适合我们的引擎。预填充和解码处理器需要连接以创建端到端解决方案。而这正是基于标准的I/O和开放参与策略使Cerebras的集成变得简单直接的地方。

几周前，我们宣布与AMD建立合作伙伴关系，以构建解耦推理解决方案。这些解决方案将他们的Helios机架与RCS系统相结合。组合解决方案在保持速度的同时，将吞吐量提高了5倍。要理解这有多强大，重要的是要理解速度和吞吐量之间的区别。速度是每个用户的度量标准。它以每个用户每秒的令牌数来衡量。它是您的查询得到回答的速度，或者智能体完成任务所需的时间。这体现在x轴上。

另一方面，吞吐量是解决方案每秒可以产生的令牌总数。它通过将所有并发用户的所有令牌加起来来衡量。这通常显示在y轴上。速度对用户体验至关重要。吞吐量对推理经济性至关重要。GPU解决方案可以支持高吞吐量，但只能在低速度下。当配置为支持甚至中等速度时，GPU吞吐量会急剧下降。这不仅适用于GPU，也适用于ASIC和所有使用HBM的解决方案。HBM内存架构迫使在吞吐量和速度之间进行权衡。像Cerebras这样的基于SRAM的架构则完全相反。我们支持极快的令牌，但吞吐量适中。因此，GPU希望在不放弃吞吐量的情况下变得更快。

Cerebras希望在不放弃速度的情况下获得更多吞吐量。这就是我们解耦解决方案的优势所在。它以5倍更高的吞吐量提供速度。在保持我们行业领先速度的同时将吞吐量提高5倍，对令牌生成的经济性产生了深远影响。这意味着每个系统可以产生多达5倍的高速、高价值令牌。每个系统以更低成本产生更多令牌意味着更多的收入和更高的毛利率。每个CS系统产生更多令牌也意味着每瓦特更多令牌，使每个数据中心更有利可图。也许在数据中心受限的环境中，最重要的是，解耦解决方案使我们能够服务RPO中更多的需求。

最后，我们相信这种解耦方法对任何GPU都具有性能和经济效益。对于已经部署了大量GPU的运营商来说，与Cerebras的解耦为他们提供了通过将其部分GPU与Cerebras解决方案配对来利用其现有投资创造有意义杠杆的机会，从而显著提高其数据中心足迹的价值和实用性。

继续围绕能力的主题，让我们转向我们的路线图。我们的工程执行正在持续推进。我们预计在未来几年内每年都会交付速度翻倍的新系统。请记住，我们是在比业内其他所有人都快15倍的性能优势基础上再翻倍性能的。此外，在保持性能桂冠的同时，我们计划在未来18个月内交付将吞吐量提高20倍以上的解决方案。下周在我们的年度Supernova大会上，我们将发布我们的第四代系统CS4。

这这将是一个充满产品公告的重要活动，所以我建议您参加。最后，我们目前按计划在2027年下半年推出我们的CS5。展望更远的未来，我们的发明引擎正在蓬勃运转。我们与美国政府就交付堆叠内存解决方案以及集成晶圆级光学解决方案建立了重要合作伙伴关系。在未来几年，您可以



期待我们在芯片和芯片架构以及系统设计的所有要素（包括封装、I/O和电力传输）方面的发明。

总结能力部分，我们期望继续在产品和技术上提供开创性的进步，以提高速度和吞吐量，降低每令牌的功耗，并削减我们解决方案的每令牌成本。

现在让我们转向客户方面。快速令牌需求旺盛，在市场上享有溢价，而具有前沿智能的快速令牌仅可通过与OpenAI的合作获得。我们与AWS的合作仍在继续，我们预计解决方案将在2027年第一季度通过AWS的Bedrock平台全面上市。这个AWS合作伙伴关系扩大了我们的市场机会，并通过一个受到全球几乎每家企业信任的行业领导者为我们提供了全球覆盖。我们与其他超大规模企业的讨论也进展顺利。我们预计从2027年年中开始产生首批收入，并在2028年及以后逐步提升。

鉴于所有这些进展，我认为重要的是要记住，我们250亿美元的RPO目前并未反映来自AWS或任何其他超大规模企业的任何积压业务。我们在OpenAI和超大规模企业之外的业务继续良好增长。例如，在第二季度，我们签署了六笔超过3000万美元的交易。AI编码继续保持高速增长。根据我们的经验，在编码时没有人会说他们对慢速令牌感到满意。因此，毫不奇怪，在编码类别中，我们的足迹持续增长。我们与Figma等上市公司以及Cognition等初创企业领军者签署了新协议，并在欧洲扩大了我们的影响力，在lovable取得了重大胜利。

随着智能体操作迅速向多步骤、多智能体解决方案演变，流程增长迅速，速度的价值成倍增加。Block、AlphaSense和GSK等多元化公司在第二季度与Cerebras签署了新协议，利用快速推理为其客户提供智能体服务。

快速AI也开辟了新市场，扩展了Cerebras的TAM（总可寻址市场）。安全就是一个例子。我们最近与CrowdStrike的合作是一个只有在AI足够快的情况下才存在的应用。快速AI使基于AI的安全设备能够嵌入企业流量，并使用LLM来保护流量，速度快到无人察觉。快速AI使LLM能够提供对用户不可见的安全保障。AI提供安全，速度创造了这种隐身性，使安全能够避免延迟和中断。我们预计，鉴于快速演变的威胁格局，这种安全类型将成为常态。企业很快将期望其大部分流量以这种方式被检查，这创造了仅通过快速AI才能实现的大量新机会。

前沿实验室、超大规模企业、领先的芯片制造商、增长最快的初创公司以及大型企业现在都已成为Cerebras的客户和合作伙伴，并从我们的快速推理中受益。

总而言之，总体而言，这是一个强劲的季节。我们成功完成了IPO上市。我们在所有指标上均超出预期：核心收入、核心毛利率和核心营业利润率。我们在每个关键领域——产能、能力和客户——都取得了进展。这些是我们实现2027年和2028年大规模增长目标，并在2029年及以后继续保持这一非凡增长率的基础。说到这里，我将把电话交给Bob。Bob？

Bob Komin

谢谢，Andrew，大家下午好。我们在2026年上半年取得了巨大的进展。正如我们所描述的，2026年是为未来几年倍数增长奠定基础的一年。进入今年时，我们赢得了有史以来最大的技术交易之一，创造了超过250亿美元的RPO。这要求我们立即着手大幅提升产能的三个关键组成部分。首先，我们需要增加晶圆供应。

正如Andrew所描述的，由于我们与台积电的牢固关系和支持，我们做到了这一点，并且现在不仅为今年余下时间，也为明年做好了充分准备。其次，我们需要扩大我们的制造能力。我们已经是2025年上半年水平的四倍，并且我们将在2026年将制造能力提高10倍以上。所以我们在这方面取得了很大进展。

第三，我们需要大幅增加我们的数据中心容量。我们取得了显著进展，目前已拥有或已签约超过600兆瓦的容量，预计在2027年底前交付，此外还有以吉瓦计量的渠道。因此，支持2027年核心收入增长两倍或更多以及未来年份更多倍数增长的基础已经到位。



这种增长也为我们在2027年及以后的显著利润率扩张奠定了基础。转向第二季度的财务业绩。我们又迎来了一个业绩强劲的季节，在指导的每个方面都超出了预期。我们实现了创纪录的核心收入，超出了核心毛利率和核心营业利润率的预期。我将使用与上季度介绍的核心业务相同框架来描述我们的进展。核心业务指标的定义以及它们与GAAP的调节表均包含在今天的财报和我们的网站上。

核心收入为2.099亿美元，同比增长103%。我们的私有云业务正以惊人的速度增长。核心云及其他服务收入为1.277亿美元，同比增长287%。这一近四倍的增长反映了对Cerebras快速推理服务的巨大需求。本季度核心硬件收入为8210万美元，同比增长17%。我们关注的是核心总收入，而非两者之间的组合，因为组合可能因大型新云容量增加和硬件发货的时间安排而在季度间出现显著差异。在第二季度，大部分核心总收入归因于我们核心云产品的增长，反映了我们OpenAI部署的增加、其他云客户使用量的增加，以及那些也在努力解决新数据中心容量时间安排的硬件客户。

对快速推理的需求依然强劲，来自新客户为数亿美元后期硬件交易以及2027年重要的新云交易都在管道中。现有的快速推理市场正在增长，新的市场也在启动。我们认为解耦是推动新用例的重要解锁方式，因为它显著改善了推理和数据中心所有权的经济性。如今，这意味着每个CS系统可产生多达5倍的令牌，因此每令牌的功耗和成本显著降低。通过持续在研发和产品路线图上进行大量投资，Cerebras将在2027年底前将我们目前的行业领先速度提高四倍，并将吞吐量提高20倍以上，从而大幅改善我们的性能和推理经济性。

现在转向毛利率。核心毛利率同比大幅提升。第二季度核心毛利率为40.6%，比2025年第二季度高出约940个基点。这反映了市场对快速推理价值的认可、我们持续的产品改进以及额外的规模经济效应。将核心总毛利率分解为其组成部分，核心云及其他服务毛利率为41.8%，比2025年第二季度高出1600个基点。核心硬件毛利率为38.8%，比去年同期高出510个基点。

正如我们上季度所述，我们通过暂时从云客户那里租回我们自己的部分系统，并通过Cerebras云提供，来满足对我们快速推理服务的一些巨大需求。更早地服务这种推理需求增强了我们满足云客户需求并随时间推移与他们共同成长的能力。我们相信这将为Cerebras及其股东创造额外的长期价值。短期内，这会降低毛利率，因为我们为这种租用容量支付了更高的成本。因此，环比来看，核心毛利率为40.6%，而2026年第一季度为46.5%。如果我们没有因为通过租回更多系统来增加私有云容量而产生更高成本，核心毛利率将高出约500个基点，更接近上季度的水平。

展望未来，我们预计第三季度将是核心毛利率的低点，然后在2026年第四季度显著改善，届时我们将上线更多由成本更低的Cerebras自有系统填充的数据中心，这将使核心云毛利率回升。核心毛利率也将在2027年继续改善，并向我们60%以上的目标迈进，原因如下：市场已经认识到快速令牌是更有价值的令牌，这支持了更高的定价，这将在未来几个季度确认的硬件和云交易中得到体现；

在未来几个季度，我们将逐步淘汰成本更高的租用系统，并在我们的私有云中用成本更低的自有系统替换；我们的产品路线图要求在未来18个月内将吞吐量提高20倍，这降低了每个系统和每单位功率产生令牌的成本；随着我们规模的扩大，我们在供应链中的物料成本将进一步改善；由于我们采用5纳米节点，我们的晶圆成本低于那些需要采用3纳米或2纳米节点的其他公司，我们也在以更高的数量购买晶圆；最后，我们不依赖HBM，这给那些使用HBM的公司带来压力，迫使他们要么提高价格，要么损失利润率。我们没有暴露于这种风险，我们相信这将提升我们的价值主张和定价灵活性。

转向营业利润率。核心营业亏损为3360万美元。核心营业利润率为负16%，而去年同期为负42%，同比提高了约2600个基点。我们在收入翻倍多并加大各方面投资的同时，能够实现核心营业利润率的显著提升，这展示了我们商业模式中固有的强大运营杠杆。如今，我们正在投资于世界级人才、制造和数据中心容量以及公司基础设施，以支持我们预计在未来几年实现的规模显著增长。



截至2026年6月30日的剩余履约义务为254亿美元。这一积压订单为我们提供了可见性，使我们能够对未来收入增长抱有高度信心，并需要提前进行投资。我们现有的大型战略客户提供了验证、合同可见性以及按规模建设新产能所需的经济支持。与此同时，我们在扩大可寻址市场和客户群方面也取得了成功。OpenAI提供了（除其他外）规模和前沿洞察。AWS提供了全球企业覆盖。最近与AMD的合作将市场机会扩展到包括解耦推理，而快速推理则开拓了像安全这样的新市场。

我们在第二季度结束时拥有超过86亿美元的现金、现金等价物、受限现金和有色证券。我们还拥有一笔高达8.5亿美元的循环信贷额度，迄今为止尚未使用。我们的流动性和资产负债表状况强劲，并在第二季度的IPO中得到增强。这是一个显著的优势，为我们提供了灵活性，可以在这些非常动态和高增长的市场条件下进行投资和调整机遇。此外，在绝大多数AI云提供商中，我们每兆瓦的净资本支出要低得多，这有两个关键原因。首先，我们主要为部署自己的硬件和数据中心承担资本支出，其物料成本要低得多，不包含许多其他公司必须支付的高额利润。其次，我们最大客户以数据中心转嫁成本补偿的形式，为我们报销了剩余数据中心装修资本支出的相当一部分。

现在转向我们的展望。对于2026年第三季度，我们预计核心收入在2.14亿美元至2.16亿美元之间。核心毛利率在38%至40%之间，核心营业利润率在负25%至负23%之间。对于整个2026财年，我们将核心收入预期上调至8.8亿美元至8.9亿美元，将核心毛利率预期上调至41%至43%，并将核心营业利润率预期上调至负19%至负17%。

最后，第二季度对Cerebras来说是持续执行和增长非常强劲的一个季度。我们实现了创纪录的核心收入，云和服务收入几乎翻了两番，毛利率和营业利润率也显著优于我们的指引。我们提高了这些项目全年的指引。我们在建设能力、产能和客户方面取得了巨大进展，并以超过86亿美元的现金、现金等价物和投资结束了本季度，以继续执行我们的增长计划。我们处于有利地位，能够在2027年实现收入增长3倍以上，并在接下来的几年实现巨大的额外增长，同时显著扩大毛利率和营业利润率，朝着我们的目标迈进。我现在将把电话转交给Andrew做最后总结。

Andrew Feldman

谢谢，Bob。十多年前，我们创立Cerebras时相信，我们可以为AI构建更好的处理器，并相信要交付该处理器，我们需要构建一个完整的加速器系统和机架。如今，Cerebras是仅有的四家公司之一——谷歌、亚马逊、NVIDIA和Cerebras——能够构建处理器、系统、数据中心，并向客户提供基于AI的云服务。

感谢您收听我们的既定发言。说到这里，我请接线员打开提问线路。

问答环节

接线员

（接线员说明）请稍等，我们正在整理问答名单。我们的第一个问题来自瑞银的Timothy Arcuri。您的线路已开通。

Q - Timothy Arcuri

非常感谢。Andrew，我想问关于客户集中度的问题。您确实说过明年收入将增长两倍以上。显然，我们知道OpenAI目前正在提升规模。所以这可能是你们当前增量收入的一大块。我想AWS明年可能贡献10亿美元，类似这样，也许更多。那么您如何看待明年的客户集中度？比如说，这两个客户是否会占你们收入的三分之二？另外，您能否谈谈与其他公司（如谷歌和微软等）的谈判情况？非常感谢。

A - Andrew Feldman

当然。我认为这是一个好问题。我认为一些历史视角可能是有价值的，对吧？在2021年，人们抱怨我们只有政府客户。然后当我们赢得一个10亿美元的主权云项目时，人们担心我们只有一



个主权云客户；然后我们赢得了最大的实验室，最大的前沿实验室；然后人们担心我们没有超大规模客户；然后我们赢得了AWS。

所以我认为在每一种情况下，我们都能够利用前一步带来的势头来扩展我们的业务。我认为OpenAI是一个巨大的客户，他们不仅是我们业务的重要组成部分，也是该领域所有企业业务的重要组成部分。我认为他们明年仍将是我们业务的重要部分。但您说得完全正确，AWS和其他客户，无论是快速增长的编码公司还是一些安全用例，它们所占的比例将会更大，而OpenAI占我们收入的比例将随时间推移而缩小。但我认为，对于明年，您可以预期他们仍将是我们收入的重要组成部分。

Q - Timothy Arcuri

很好。然后紧接着一个快速跟进问题。我知道，Bob，您说过产能，我想您说今年同比将增长10倍。有没有关于明年将增长多少的预期？我知道Andrew说收入将增长3倍，但您能否谈谈制造产能明年同比增长幅度？

A - Andrew Feldman

是的，我们将在今年年底实现制造产能超过10倍的增长，而且我们已经为2027年的增长承包了3倍或4倍以上的设施，我们还有一些时间来承包更多。因此，我们正在关注未来数年内的巨大增长。

接线员

谢谢。我们的下一个问题来自TD Cowen的Joshua Buchalter。您的线路已开通。

Q - Joshua Buchalter

嘿，各位。感谢接受我的提问。也许可以接着Tim之前的问题。您能否简单介绍一下亚马逊交易的经济性将如何运作？计划是明年在其AWS云中提供，然后我们基本上会看到需求有多大，因此目前很难预测？谢谢。

A - Andrew Feldman

当然，它将可用。它部署在亚马逊数据中心。它将通过亚马逊的API服务Bedrock提供。我们现在正在组织部署的过程中。所以，我认为这就是思考这个问题的方式。我们预计该服务将在第一季度上线。

Q - Joshua Buchalter

明白了。谢谢您，Andrew。然后关于与AMD的合作，您能否就销售策略提供更多细节，因为它是与Helios机架连接，以及您预计何时产生收入？另外，关于AMD的合作，他们最近收购了一家推理硬件公司。您能否谈谈这与你们提供的产品如何契合，因为我们在考虑他们更广泛的产品组合？谢谢。

A - Andrew Feldman

当然。我认为有几点。我认为我们将随着时间的推移宣布与AMD安排的其他部分。但我认为，在Cerebras系统前端配置Helios机架的联合解决方案——Helios机架负责预填充，Cerebras负责解码——是一个非常强大的产品，对吧，这个产品提供了比Helios单独能提供的快得多的速度，以及比Cerebras单独能提供的多得多的吞吐量。

这个解决方案极具吸引力，我们已经有了买家。第二个问题是关于AMD最近的收购。看，我认为他们收购的那家公司很有趣且具有创新性，没有人比我们更对创新硬件感到兴奋。我认为收购硬件初创公司，从收购到交付之间需要很长时间，我们确实对那些正在做的工作印象深刻，并认为在AMD的产品组合中，它们有很多应用。我认为数据中心推理不会是它们的首要应用。

接线员

谢谢。我们的下一个问题来自巴克莱银行的Tom O'Malley。您的线路已开通。



Q - Kyle Bleustein

嘿，各位，我是代表Tom O'Malley的Kyle Bleustein。感谢接受我们的提问。我想回到Josh关于AMD交易经济性的问题。运作方式是你们购买AMD Helios机架并安装到你们的云中，然后客户租用解耦推理解决方案产生的所有收入都归你们吗？还是这里存在某种收入分成协议？

A - Andrew Feldman

对问题的第一部分回答是“是”。

Q - Kyle Bleustein

好的。谢谢。然后是我的跟进问题。AWS交易是安装在他们自己的云中。您是否看到一种最终路径，可以让你们在自己的云或其他超大规模云中共同托管Trainium和CS-3？只是想思考一下Cerebras推理在未来部署中可能如何演变？

A - Andrew Feldman

我认为我们对这种方法非常感兴趣。我认为，正如您在谷歌身上看到的，拥有自己部件的超大规模企业有机会在其数据中心边界之外部署这些部件。这是我们不仅对AWS，而且对其他公司都感兴趣的事情。所以我认为这在未来与AWS的合作中是很有可能性的。

接线员

谢谢。我们的下一个问题来自Needham & Co的Quinn Bolton。您的线路已开通。

Q - Quinn Bolton

我想就AMD交易做一点澄清。Andrew，如果你们购买并安装Helios机架到你们的Cerebras云中，但该服务是根据你们的合同交付给OpenAI的。这代表了一个额外的收入机会吗？或者我们应该如何看待在这种情况下收入的潜力？然后我有一个跟进问题。

A - Andrew Feldman

我认为，当你在保持性能不变的同时提高吞吐量时，你就增加了收入机会。吞吐量是你同时支持的客户数量。如果你能在不放弃速度的情况下做到这一点，那么每个系统你就有更多的收入。现在我不想深入讨论我们与OpenAI关系的具体细节，但我们对这种合作感到如此兴奋的事情之一是，你保持了我们的速度并增加了吞吐量，这使得每个系统更有利可图。每个系统产生更多令牌。这意味着每个令牌成本更低，每个令牌使用的电力更少。所以我们不仅在收入上赚得更多，而且我们的利润率也提高了。不仅我们的利润率和收入提高了，而且这使得每项数据中心投资更有价值，因为数据中心是一个电力容器。如果你能从那个电力容器中榨取更多令牌，那就能转化为更多美元。所以这是一个非常强大的事情，随着AWS与我们进行解耦，AMD也与我们进行解耦，我们已经联合了大约一半的领先芯片制造商，所以这是一个非常、非常强大的故事。

Q - Quinn Bolton

那很有趣。然后我的跟进问题是，您在发言中几次提到，到2027年底，您将把晶圆级引擎的吞吐量提高20倍。这是否消除了您所谈论的这些解耦计算或异构推理的需求？还是说这只会使异构解决方案的整体吞吐量变得更快……

A - Andrew Feldman

对。我认为……

Q - Quinn Bolton

还是只是更高的吞吐量？

A - Andrew Feldman

我认为我们正在探索各种提高吞吐量的方法，对吧？如果你的吞吐量提高20倍，而成本保持不变，你的状况就非常非常好，对吧？所以我们——我们的系统正在提高吞吐量。我们正在寻找方法来提高解耦解决方案的吞吐量。我们正在研究各种不同的发明、技术、合作伙伴关系，以延续我们行业领先性能的模式并大幅提高吞吐量。



接线员

谢谢。

A - Andrew Feldman

这是一个非常好的问题。我的意思是，这正是我们在路线图中思考的问题，正是这一点。

接线员

谢谢。我们的下一个问题来自摩根士丹利的Joe Moore。您的线路已开通。

Q - Joe Moore

是的。谢谢。关于您刚才谈到的内容，当您谈到解耦解码时，你们在这个方面的商业化进展如何？比如，你们是否——我们知道你们可以进行大规模的快速推理，你们已经做到了，但解耦方面，它现在是否已经准备好部署了？以及——嗯，在接下来的大约一年里，需要做哪些工作才能达到你们所谈论的那种改进？

A - Andrew Feldman

当然。我认为我们现在已经在实验室里运行着GPU的解耦推理。我认为它将在第四季度部署并可用。

Q - Joe Moore

好的。谢谢。然后您在发言中谈到了与已安装的GPU基础配合工作的能力。当你们与亚马逊更紧密地合作，与AMD更紧密地合作时，这些合作会比你们能够与现有的NVIDIA已安装基础GPU合作效果更好吗？

A - Andrew Feldman

嗯，我认为公平地说，虽然我们还没有做到，但当然可以说，Helios机架将给我们带来比使用355s更大、更好的解决方案，对吧？而Trainium-3将给我们带来比使用Trainium-2更好的解决方案。如果我们使用其他GPU，当前世代，即前三代，会给我们比前一代（即前三代减一代）更好的性能。但我认为同样公平地说，前一代在解耦解决方案中的表现将远远优于不在解耦解决方案中的表现。在一个每个人都试图延长其硬件寿命并继续使其交付有价值的令牌的环境中，这是一个重要的选择。

这样说有道理吗？

接线员

谢谢。我们的下一个问题来自瑞穗证券的Vijay Rakesh。您的线路已开通。

A - Andrew Feldman

嘿，Vijay。

Q - Vijay Rakesh

是的，嗨。嘿，Andrew。只是几个快速问题。关于您提到的已签约的600兆瓦容量和年底前10倍的产能增长。您认为这应该有助于加速2027年的部分增长吗？

A - Andrew Feldman

是的，当然。我认为我们每天都在全球范围内寻找数据中心容量。我们这样做是因为我们对快速推理有巨大的需求。我们部署得越快，收入增长就越快。这不仅适用于我们的云业务，也适用于我们客户的本地部署业务，对吧，他们获得数据中心的越快，我们就能越快地向他们发货硬件。所以这是头等大事。这是我花费大量时间的事情。我们现在有一个完整的团队。我们在全球范围内追逐数据中心方面已经相当擅长。一旦你签约了，你的工作并没有结束。正如您所熟知的。我们每天都有人在现场。我们在每个阶段都与开发商和建筑公司接触，尽力让他们按计划进行。因此，我们做得越快，我想我们就能越快提升收入。



Q - Vijay Rakesh

明白了。然后，关于合作伙伴关系，我知道您提到了超大规模企业，但还有一群新兴的Neocloud（新型云服务商）正在涌现，他们正在获得融资。华尔街正在开发许多融资结构。您认为这个渠道对您来说发展如何？谢谢。

A - Andrew Feldman

当然，对吧。我认为早期，Neocloud非常专注于NVIDIA。我认为随着业务对投资者变得更加清晰，一些Neocloud正在多元化，并发现自己对单一硬件供应商的依赖程度降低。所以我们在这一类别中的机会很大。有采用多供应商的Neocloud，有只采用AMD的Neocloud，还有由拥有电力资产的人创办的Neocloud，我认为在2027年，这将是我们业务的重要组成部分。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

69 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

