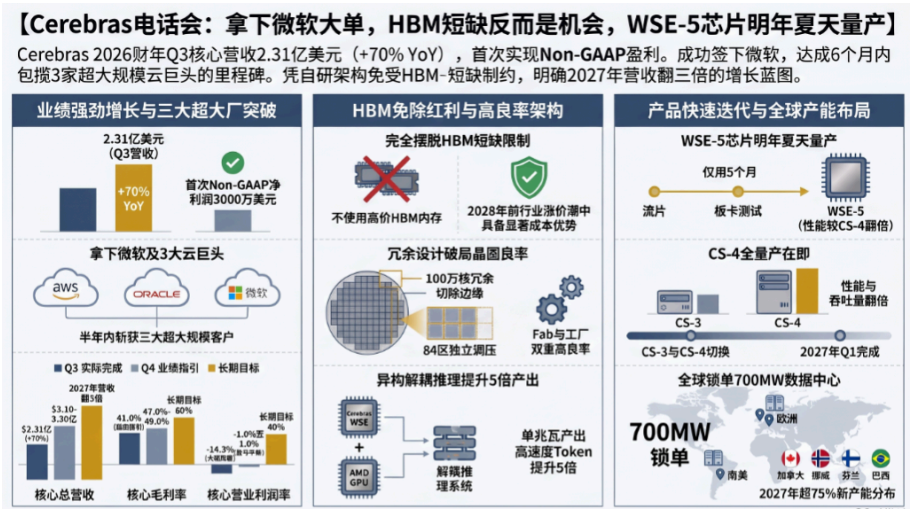
摘要：

AI芯片公司Cerebras宣布签署微软云合作协议，六个月内完成亚马逊、甲骨文、微软三家超大规模云服务商合作布局，管理层重申2027年营收三倍增长目标。制造端产能年底将提升逾10倍，且因不使用HBM可有效规避持续至2028年的内存短缺及涨价压力，形成供应链层面的结构性优势。



AI芯片初创公司Cerebras在2026年第三季度交出首次实现净利润转正的答卷，并宣布微软成为其六个月内拿下的第三家超大规模云服务商客户，公司重申2027年营收将实现三倍增长的强劲指引。

华尔街见闻提及，当地时间11月12日，备受市场瞩目的Cerebras公布2026年第三季度财报。公司当季核心营收达到2.309亿美元，同比增长70%，高于分析师平均预期的2.147亿美元。

公司首次作为上市公司实现了非公认会计准则（Non-GAAP）下的净利润转正，达到3000万美元。

随后电话会上，Cerebras联合创始人兼CEO Andrew Feldman表示，**公司同步上调第四季度及全年指引，预计核心营收环比增速接近40%。公司还维持2027年营收"三倍增长"的目标，并预期核心毛利率持续向60%的长期目标靠拢。**

Andrew Feldman宣布，**公司正式签署与微软的云合作协议**，加上此前已公布的AWS和甲骨文合作，Cerebras在过去六个月内完成三家超大规模云服务商的客件。他表示，**微软协议的更多细节将于明年上半年披露，相关收入亦预计于同期开始确认**。

与此同时，首席财务官Bob Komin在电话会上披露，公司与OpenAI数据中心容量交付存在阶段性滞后，已据此在剩余履约义务（RPO）中扣除相应延迟补偿额度。他同时强调，潜在取消量占OpenAI合同总承诺容量不足5%，公司预计于2027年下半年恢复正常交付进度。

制造端，Andrew Feldman表示，公司正与Flex和Sanmina协同扩大产能，**预计2026年底制造产能将较年初提升逾10倍，2027年将进一步新增工厂**。

他还强调，**由于公司不使用高带宽存储器（HBM），可有效规避持续至2028年的内存短缺及涨价压力，形成供应链层面的结构性优势**。

拿下微软大单，六个月内集齐三家Hyperscaler

除了强劲的财务数据，市场最关注的增量信息是Cerebras在客户拓展上的重大突破。Feldman在会上正式宣布：

> 今天，我们与微软签署了一项重要的云协议。

至此，加上此前宣布的AWS和甲骨文，Cerebras在短短六个月内已经赢得了三家超大规模云服务商的青睐。这些协议将极大拓宽其市场渠道。

Feldman透露，搭载Cerebras的甲骨文云推理服务预计将于2027年夏天推出，而与微软合作的更多细节将在明年初公布。

CFO Bob Komin补充道，过去几个月里，公司的销售渠道增长了“远超10倍”，需求不仅来自超大规模云服务商，还涵盖了主权云、企业客户和AI原生公司。

直面OpenAI合同争议：“延期是因为缺电和壳，不是缺芯片”

作为Cerebras目前最大的客户，OpenAI的合同履行情况是投资者审视的焦点。**截至9月30日，Cerebras的剩余履约义务（RPO）高达261亿美元，其中绝大部分来自OpenAI。**

针对市场关于OpenAI订单交付延期的担忧，管理层给出了透明的回应。受制于全球数据中心建设的普遍瓶颈，Cerebras未能按原定激进的时间表交付基础设施。CFO Bob Komin坦言：

> **如果延期达到90天或以上，双方都有权取消该部分容量。但我们估计，今年可能面临取消的容量将不到总承诺兆瓦数的5%。**

管理层已将潜在的延期违约金从RPO中扣除。Bob Komin强调，**该违约金对营收和毛利率的影响相对有限**，原因在于违约金额占RPO比例较小，且将在未来数年内摊销确认。**公司预计在2027年下半年能赶上进度。**

Feldman更是直言不讳地指出，瓶颈完全不在于硅片或系统制造：

> 我们有产能，我们有所有材料。**我们等待的是土地、电力和外壳（Land, Power, Shell）的完工。**

他强调，不仅是Cerebras，包括OpenAI在内的所有行业巨头的数据中心建设“都在全面延期”。

同时，Feldman坚决辟谣了关于Cerebras技术无法支持OpenAI大模型的传言：

> **有谣言称Cerebras因技术原因无法支持Astra。这些都是假的。我们的系统完全能够支持Astra规模甚至更大的模型。**

打破“低良率”偏见，不依赖HBM成战略优势

面对华尔街对晶圆级计算（Wafer-Scale Computing）架构良率的质疑，Feldman用了一个比喻来进行反击：

> Cerebras发明了一种全新的计算架构。用为其他架构设计的指标和思维模型来套用我们，就像检查一辆特斯拉，然后问：排气管在哪里？电动汽车需要不同的参照系，晶圆级计算也是如此。

他明确表示，无论是台积电的代工厂良率还是参数良率，“我们的良率都非常高。”

同时，Feldman指出了竞争对手面临的致命软肋——内存短缺。由于Cerebras的架构不需要高带宽内存（HBM），这使其在全球供应链中占据了独特优势。Feldman补充称：

> 我们认为，内存短缺及其相关的价格上涨将持续到2028年，这将推高竞争对手的成本并限制其供应。**全行业的内存挑战，对Cerebras来说正是机会。**

Andrew Feldman在电话会上介绍，公司目前已签约约700兆瓦总数据中心容量，计划于2027年底前完成交付。超过75%的新增容量将落地美国境外，近期将有加拿大、法国和挪威的新设施陆续投入运营，同期还在挪威和芬兰追加签约，并处于在圣保罗签约南美首个数据中心的最终阶段。

Bob Komin在电话会上表示，**较大规模的数据中心容量增量将于2027年中期开始释放**，这也是导致第四季度云收入环比持平的直接原因，并非定价或需求问题。他补充称，公司正积极推进吉瓦级容量谈判。

WSE-5芯片已回片，明年夏天量产

在技术迭代上，Cerebras继续保持激进的步伐。

公司宣布，其下一代处理器Wafer-Scale Engine 5（WSE-5）已经从代工厂回片，进度超前。Feldman自豪地表示：

> WSE-5于6月15日流片。芯片现已返回，已点亮，并已经在运行模型，正在进行机箱内测试。在不到五个月的时间内从流片进入系统测试，这是非凡的执行力。

基于台积电5纳米工艺的CS-5系统将在2027年初夏投入生产，性能将比CS-4翻倍。

此外，公司还率先推出了异构解耦推理（DISAG）方案，将AMD的GPU用于预填充（Pre-fill），将Cerebras的CS-3系统用于解码，大幅提高了每兆瓦的算力产出和利润率。

针对市场上关于低批次GPU可挑战Cerebras推理速度的讨论，Andrew Feldman在问答环节表示，GPU通过降低批次规模可换取一定速度提升，但代价是单位Token成本大幅上升。

他指出，在每秒约250至300个Token的速度区间以上，Cerebras的经济性已明显占优；在每秒800至2000个Token区间，GPU在技术上已无法达到同等性能。

Cerebras Q3财报电话会全文（AI辅助翻译）：

接线员：各位好，欢迎参加Cerebras Systems 2026年第三季度财报电话会议。会议期间，所有参与者处于仅收听模式。演讲结束后，将进行问答环节。请注意，本次会议正在录音。

现在，我将会议移交给投资者关系负责人Sean Dorsey。请开始，Sean。

Sean Dorsey（投资者关系负责人）：谢谢接线员。大家下午好，欢迎参加Cerebras Systems 2026年第三季度财报电话会议。今天早些时候，我们已发布新闻稿，并将补充财报演示文稿发布至公司网站的投资者关系专区。本次网络直播的重播也将在会后发布于投资者关系网站。

今天与我一同参加会议的有：联合创始人兼首席执行官、总裁Andrew Feldman，以及首席财务官Bob Komin。

在开始之前，我想提醒大家，今天的讨论将包含1995年《私人证券诉讼改革法案》安全港条款下的前瞻性陈述。这些陈述涉及但不限于公司未来财务表现、商业战略、市场机遇、客户需求、产品路线图、技术领先地位、供应链、运营模式，以及2026年第四季度和全年展望等方面。

前瞻性陈述基于我们当前的预期和假设，受风险和不确定因素影响，实际结果可能与陈述或暗示的内容存在重大差异。相关风险已在我们向SEC提交的文件中予以说明，包括与IPO相关的最终招股说明书及未来定期报告。除法律要求外，我们不承担更新这些前瞻性陈述的义务。

今天的电话会议中，我们还将讨论若干非GAAP财务指标。GAAP与非GAAP业绩的调节表已包含在今日新闻稿及投资者关系网站上的补充材料中。

下面，我将会议移交给Andrew。

Andrew Feldman（首席执行官兼联合创始人）：谢谢Sean，也感谢大家今天的参与。

展望未来数月，我们看到两个确定性趋势：快速变化与算力短缺。过去90天里，AI生态系统见证了前沿模型领导者数度易主，数十款有价值的开源模型相继发布，重大安全事件相继发生，强大的新型消费者智能体不断涌现，还有许多其他发展动态。

任何人都无法预测90天后AI的能力走向，更遑论一年之后。然而，在所有这些变化中，智能与速度始终是每一个应用场景的两大核心要素——无论是编程、安全，还是个人智能体。

在这个快速变化的世界中，Cerebras的使命是确保无论AI如何发展，Cerebras都能持续增长。基础模型增长，我们增长；开源模型增长，我们增长；个人智能体增长，我们增长；无论是企业还是初创公司增长，我们增长；无论客户需要硬件还是云计算资源，我们都能增长。我们的目标是，无论什么因素驱动行业发展，Cerebras都能赢得先机。

第三季度，我们在这一目标上取得了显著进展。

首先，我们超越了所有业绩指引目标。在对这些成绩感到满意的同时，我认为更重要的是——自上次财报电话会议以来，我们与多家AI行业领军企业达成了重要合作，最新进展是今天宣布与微软签署了一项重要云服务协议。加上此前宣布的AWS和甲骨文合作，迄今已有三家超大规模云服务商选择将Cerebras平台纳入其基础架构战略。

这些新合作，叠加现有客户的持续增长，使我们得以全面上调第四季度核心业绩指引，并继续预期2027年营收实现三倍增长，同时毛利率持续扩张。Bob将在其发言部分详细介绍第三季度表现及前瞻性指引。

关于业务结构

作为一家AI加速器公司，我们的核心创新在于芯片、系统和软件，使AI计算更快速。我们是一家AI硬件公司，拥有两条市场渠道。

第一条渠道是系统销售：将Cerebras硬件机架安装在客户的数据中心。这是一项优质业务，收入确认快、回款快，但也具有一定的不规律性，取决于客户数据中心是否具备接收硬件的能力。

第二条渠道是我们的云服务。AI原生企业这一快速增长的客群，更倾向于消费算力（token），而非自行部署硬件。鉴于数据中心和算力资源极为稀缺，我们同时拥有系统和数据中心，构成了重要的战略优势。

对于自主生产硬件的公司而言，AI云业务尤为出色。我们每兆瓦的成本远低于新兴云服务商，因此能够实现更高的资本效率。两条渠道的业务比例会因季度而异，但我们相信两者都将随时间大幅增长。

关于与OpenAI合作的市场猜测

OpenAI是我们的重要大客户，也是紧密合作伙伴，我相信未来双方将继续保持这一关系。OpenAI在第三季度相较第二季度实现了增长，我们预计未来还将进一步增长。

OpenAI基于Cerebras推出的UltraFast SOL5-6预览版取得了压倒性的成功，有力证明了市场对快速token的需求极为巨大。

与此同时，Cerebras确实没有足够的算力支持UltraFast在包括Apsara在内的更大范围内推出。正如业界所述，我们认为算力是行业商业决策的关键驱动因素。事实上，即使OpenAI拥有海量GPU供应，仍需实施基于使用量的限制措施。

协议签署后，我们花费的时间比预期更长，才找到合同并上线满足协议要求所需的大量数据中心增量产能。因此，我们目前在初始阶段的执行上有所滞后。

鉴于这一合作对我们业务的重要性，我们理解投资者对其给予高度关注。关于协议细节或相关新闻，信息来源不太可能来自Cerebras或OpenAI以外的渠道。

例如，此前有传言称Cerebras出于技术原因无法支持Astra，这是错误的。CS3、CS4和CS5完全有能力支持Astra级别的模型，乃至更大规模的模型。

同时，我预期并建议投资者预期，OpenAI将利用多种合作关系和多样化硬件方案构建算力。OpenAI将淘汰旧模型，在这些计算资源上部署新模型，用于内部和外部用途。他们的算力需求极为庞大，不同解决方案在其规模化进程中均有机会发挥作用。

关于推理速度的竞争地位

在此我想补充一点：尽管市场上存在各种实验性方案——低批次GPU、初创公司发布、超大型计算核心、超大规模云服务商的内部定制芯片——我们依然是毫无争议的最快推理解决方案。我们相信，我们的产品路线图将使我们在未来数年内保持这一优势。

业务评估框架：客户、算力、能力

我们对业务进展的评估框架保持不变，围绕三个维度进行：客户、算力和能力。

客户

我们正在快速拓展客户群，以扩大覆盖范围、多元化收入来源。第三季度是成果丰硕的一个季度。我们赢得了两家新超大规模云服务商的合作。

我们与甲骨文签署协议，将Cerebras硬件引入甲骨文云，Cerebras将部署在甲骨文数据中心，服务于AI实验室、企业客户以及构建交互式智能应用的开发者。我们预计由Cerebras驱动的甲骨文云推理服务将于2027年夏季正式上线。

我们还与微软签署了令人振奋的合作协议，相关详情将于明年进一步披露。

至此，我们在过去六个月内已赢得三家超大规模云服务商的合作，这是重要的里程碑成就，为我们2027年和2028年的发展奠定了良好基础。

我们还与多家高质量新兴云服务商扩大了合作，包括Firework等，进一步多元化我们的市场渠道，为客户提供更多访问Cerebras高速推理服务的途径。

开源权重模型同样为我们带来了助力，这些模型持续催生新应用，拓展AI在日常生活和各行业中的应用边界。例如，就在本周，我们宣布Cerebras快速推理服务正在为Built公司的OS平台及个人助手提供支持，为数百万用户带来极速推理体验。

通过Built这样的消费者应用，我们将Cerebras的强大算力直接送到用户手中。这正是快速token能够获得溢价的原因——我们的云客户告诉我们，快速token能产生出色的毛利率，而Cerebras的快速token是他们销售的利润最高的token。

算力

算力包含两个组成部分：数据中心算力和制造产能，两者对于业务增长都至关重要。

数据中心可用性是整个行业面临的持续性制约，我们也不例外。此外，我们认为美国政策环境的演变可能会为美国境内的数据中心建设带来更大挑战。

2027年，我们超过75%的数据中心产能将在美国境外上线。实际上，未来几个月内，加拿大、法国和挪威的新设施将陆续投入运营。本季度，我们还签署了挪威和芬兰新增产能的合同，进一步扩大了欧洲业务布局。同时，我们正处于在圣保罗签约数据中心的最后阶段，这将是我们在南美洲的首个数据中心。

迄今为止，我们已为2027年底前交付签署了约700兆瓦的数据中心产能合同。我们的自有云已跻身非超大规模云服务商中规模较大之列，目前正深入推进吉瓦级产能的谈判。

提升数据中心产能的最佳途径，是提升数据中心硬件的token生成能力，即每兆瓦产生更多token。为此，分解式推理（disaggregated inference）通过将数据中心的token交付能力提升最多5倍，有效扩大了我们的产能。每兆瓦产生更多超快token，意味着每个数据中心创造的收入将显著增加。

在制造和供应链方面，我们正与Flex和Sanmina协力扩大制造规模，预计2026年底的制造产能将超过年初的10倍。2027年，我们计划增设工厂、进一步提升产能，以支撑预期的大幅增长。我们的供应链也已做好支持这一增长的充分准备。

最重要的是，我们已获得台积电充足的晶圆产能承诺，台积电持续彰显其世界级合作伙伴的实力。

同样值得关注的是我们供应链所不需要的东西——这对我们同样至关重要。与其他竞争对手不同，我们不使用HBM内存。我们认为，内存短缺及由此引发的价格上涨将持续至2028年，这将推高竞争对手的成本并限制其供应。行业性内存挑战为Cerebras创造了机遇。

工厂和供应是扩大产能的必要条件，但并不充分，我们还必须保持高良率。

关于良率问题

Cerebras发明了一种全新的计算架构。用针对其他架构设计的指标和思维模型来衡量我们，就如同检查一辆特斯拉时追问排气管在哪里。晶圆级计算需要不同的参照框架，正如电动汽车需要不同的评估维度一样。

我们欢迎就设计的各个方面提出问题，并将努力更清晰地分享架构细节。

然而，金融界存在一些持续流传的不实之词：一是声称我们的系统无法支持大型模型——这显然是错误的，因为我们目前已在运行大型模型；二是声称我们的制造良率低。两者均不属实。

关于模型规模问题，我已在前面的发言及此前的讨论中做出了回应。由于制造良率较难从外部观察，我将在此直接加以说明。

良率分为两类：晶圆厂良率和参数良率。我们来自台积电的晶圆厂良率很高，参数良率同样如此。我们的技术博客对此有详细介绍，以下做简要说明。

所有晶圆都含有缺陷。几十年来，这些缺陷是业界认为晶圆级处理器不可能实现的核心原因。我们通过冗余设计解决了这一问题。

我们的设计包含约一百万个完全相同的计算单元（tile），其中一小部分作为备用。当缺陷导致某个单元失效时，硬件会自动绕过它并激活备用单元。这一机制在晶圆厂生产阶段和现场使用阶段均有效，实现了高晶圆良率和强大的现场可靠性。

第二个挑战是参数变异（parametric variation）。即使硅功能正常，其电气特性也会在晶圆各处存在差异——在相同电压下，某些区域运行速度更快或更慢。这是芯片设计的基本现实，也是实现晶圆级计算必须克服的障碍之一。

我们通过三种方式解决参数变异问题：

第一， 去除晶圆外缘。外缘是晶圆最薄弱的部分，也是参数变异的主要来源。我们使用适合300毫米晶圆的最大正方形区域，剔除大量边缘硅片。

第二， 针对宽泛的工况进行设计和测试。我们的核心能够容忍更大范围的变异。在时序收敛（即验证电路满足时序要求的过程）阶段，我们在远比行业常规更宽泛的工作条件下对设计进行验证，从而确保在晶圆各处变异的情况下仍能实现预期性能。

第三， 在晶圆各区域独立调节电压。我们发明了一种技术，可在晶圆的84个分区内独立调节核心电压——对较慢区域提高电压，对较快区域降低电压，从而对性能进行精确控制。据我们所知，目前没有其他芯片具备这一能力。

最终结果是在晶圆厂和工厂两个环节均实现了极高的良率。我们通过工程化手段解决了其他人认为使晶圆级计算不可能实现的问题，从而达成了这一成就。

最后补充一点：有人将我们硬件出货的相对较低毛利率视为良率问题的证据，而实际上这仅仅反映了我们制造能力的持续提升过程，以及在早期客户特殊定价协议下的最终批次出货情况。我们预计，未来几个季度硬件毛利率将大幅改善，最终超越50%的长期目标。

能力

我们在各个方面持续提升能力：新系统与处理器、改进的软件、先进的制造技术，以及提供行业最佳解决方案的合作伙伴关系。

尽管AI行业变化节奏极快，推理速度的重要性仍在持续提升，Cerebras依然是无可争议的领导者。我们相信这一性能优势将长期持续，为此我们的产品路线图持续快速推进。

CS4即将进入全面量产，性能和吞吐量均将翻倍。

我们的下一代处理器——晶圆级引擎5（WSE-5），已部署于第五代CS5系统，已从晶圆厂如期归来，甚至早于计划。WSE-5于6月15日完成流片，芯片已回厂启动，正在运行模型，并已进入整机测试阶段。从流片到系统测试不足五个月，是出色的执行力体现。CS5的速度将比CS4提升一倍以上，预计于2027年初夏进入量产。CS5基于台积电5纳米工艺节点，该节点的晶圆竞争相对不那么激烈，晶圆成本也大幅降低。

我们的创新还延伸至完整解决方案领域。据我们所知，Cerebras是首家实现生产级异构分解式推理的公司。目前，我们的云服务正在使用AMD GPU处理预填充（pre-fill），使用Cerebras CS3系统处理解码（decode）。为支持生产级上线，我们构建了一套分解式推理软件平台，兼容AMD及其他GPU产品，并将在Cerebras推理云及部分数据中心客户中部署同款方案。

分解式推理在相同功耗下能够提供更多高速token，这意味着云服务商每兆瓦获得更高利润，AI用户获得更低的每token成本。我们相信分解式推理将成为主流云部署的默认配置之一。

我们的软件栈持续成熟，云服务实现了令人印象深刻的高可用性，系统运行速度不断提升，新模型的启动时间也已缩短至仅需几天。

Cerebras是Kimi K3.1的零日上线合作伙伴——Kimi K3.1是月之暗面旗下的2.8万亿参数前沿级开源权重模型，或许是目前市场上最顶尖的开源权重模型。Cerebras上运行的Kimi K3.1不仅是业界最快，运行速度高达每秒2000个token。

走过近11年的历程，我们继续以惊人的速度创新。我们的团队在顺境与逆境中始终凝聚在一起，公司内部的活力与激情从未如此高涨。

我们为解决行业中最艰难的问题而感到自豪。

总结： 我们超越所有指标，全面上调第四季度指引，并预期2027年营收三倍增长。我们在各核心领域取得重要进展，包括新增两家超大规模云服务商客户，在过去六个月内已累计赢得三家超大规模云服务商。CS4已开始出货，第五代处理器WSE-5已回厂，并以创纪录的速度完成CS5整机测试。AMD生产级分解式推理已上线，对另一款2.8万亿参数模型的零日支持也以行业最佳性能成功实现。

下面，我将发言权移交给Bob。

Bob Komin（高级副总裁兼首席财务官）：谢谢Andrew，大家下午好。在介绍第三季度业绩和第四季度展望的具体内容之前，我想先回顾一下我们的业务规模化历程。

业务战略背景

我们选择在2025年初启动云服务，原因在于在这个快速演进的AI格局中，AI原生企业希望快速扩展算力，而不愿自建数据中心。由于超大规模云服务商会提前数年规划其数据中心算力分配，往往无法为新硬件提供近期的自有设施空间。为了赢得基础模型实验室和超大规模云服务商所需的大型部署合同，Cerebras需要证明我们的系统能够在规模化场景下提供行业领先的推理性能。在私有云中充分评估我们的解决方案之后，这些客户可以选择购买硬件，或采购我们的云服务。

为了尽快提供足够的云算力以满足这些需求，我们选择尽快租用数据中心产能，将私有云规模向吉瓦级推进。这一总体战略被证明是正确的——数据中心产能目前已极为稀缺，而我们已有大量

产能在合同中锁定。

更重要的是，拥有私有云之后，我们得以向整个市场展示快速推理的价值，并进一步激发市场需求。由于新型大型数据中心从立项到投入使用需要15至18个月，为了加快满足我们已有的大量需求，我们选择从一家客户处回租了部分自有设备。如前所述，这在短期内对毛利率造成了下行压力，但也使我们能够在客户有需求时及时服务，从而拓展现有客户、赢得重要新客户。

如今，我们已赢得OpenAI等前沿实验室，以及AWS等超大规模云服务商，近期又新增了两家超大规模云服务商客户。Cognition、Figma、Block、Built等领先客户也已加入我们的云平台。我们以客户需求为导向，因地制宜——有时销售硬件，有时提供云服务。

此前，我们也已说明，2026年将是一个建设之年——扩大算力、提升能力、积累客户，为2027年营收实现三倍以上增长奠定基础。凭借今年迄今取得的强劲进展，我们有充分信心实现这一目标。

第三季度业绩

现在转入第三季度业绩，我很高兴地宣布，第四季度将是我们增长和核心财务趋势的重要拐点。

我们已连续第三个季度超越核心财务指引。我们还提前实现了首次非GAAP净利润转正，早于预期。

提示一下，核心指标的定义及其与GAAP的调节表已包含在今日财报发布中，并可在我们的网站上查阅。

核心营收： 创历史新高，达2.31亿美元，环比增长10%，同比增长70%，超出我们2.15亿美元指引中点1600万美元，超出幅度为7%。

核心云服务及其他服务营收： 同样创下历史新高，同比增长272%，达1.45亿美元。第三季度云服务营收环比增长13%。我们目前预计第四季度云服务营收将基本持平。这一趋势并非由定价或需求问题驱动——定价环境依然健康，我们解决方案的需求持续远超供给。

云服务营收的增长瓶颈完全在于数据中心产能。我们将于12月开始提升数据中心产能，为明年积蓄动能，但遗憾的是时间太晚，无法对第四季度产生实质影响。我们预计2027年数据中心产能将出现更为可观的增加，主要增量将从明年年中开始释放，届时我们将交付目前已在合同中锁定的700兆瓦数据中心产能的较大部分。

核心硬件营收： 本季度为8600万美元，环比增长5%。我们看到客户对快速推理服务的需求不断增长，不仅来自我们的私有云，还来自与多家新客户签署的硬件采购合同。随着这些硬件发货计划于第四季度启动，核心总营收将出现大幅跃升。

第三季度至第四季度的核心营收环比增长将接近40%，同比增长约为85%。这些硬件订单（包括甲骨文订单）将至少持续发货至2027年上半年。

正如Andrew前面提到的，我们今天还宣布微软成为新客户。过去几个月，我们的销售管线规模增长超过10倍，驱动因素涵盖多元化机遇，包括超大规模云服务商、新兴云服务商、主权云、企业客户和AI原生公司等各类新老客户的需求。

毛利率

第三季度核心毛利率为41%，较第二季度环比改善40个基点，并比我们的季度指引高出200个基点。

除了回租系统对毛利率的影响外，本季度我们还面临一些逆风因素——来自多年前签署的硬件采购协议（采用较低定价）的最后一批发货正在消化。我们之前已指引，所有这些因素将造成暂时性毛利率下滑，低点将出现在第三季度。实际上，我们的表现优于预期——低点已于上季度（第二季度）出现。

现将第三季度核心毛利率分拆如下：

核心硬件毛利率 环比下降至31%，主要由年前客户协议项下最后批次发货所致。我们目前正以大幅提升后的现行价格执行硬件订单，这也意味着从第四季度起毛利率将显著改善。

核心云服务及其他服务毛利率 大幅提升至46.9%，较第二季度提升510个基点。主要驱动因素是以更高定价和利润率承接的新业务。部分被从客户处回租数据中心产能和硬件的较高成本所抵消。我们预计这一情况将至少持续至2027年年中，直至我们拥有足够的自有数据中心产能来满足较高水平的云需求。

综合以上情况，第四季度核心毛利率预计将实现阶梯式改善，提升700个基点，至中点值48%。我们预计核心总毛利率将在近期超过50%，并持续向60%的长期目标推进。

盈利能力进展

第三季度及年初至今，我们在盈利能力方面取得了强劲进展。核心经营利润率环比改善170个基点，亏损率降至14.3%，超出指引中点近10个百分点。核心经营亏损与第二季度持平，约为3300万美元。核心净利润转正，达3000万美元。年初至今调整后核心EBITDA也实现正值，为200万美元。

随着第四季度营收和毛利率大幅增长，我们预计所有核心关键盈利指标（包括经营利润率）将于下季度转为正值。

剩余履约义务（RPO）与OpenAI合同

截至9月30日，剩余履约义务增至261亿美元。我们按季度更新RPO，纳入新签业务，并根据剩余承诺期内预计待确认金额的变化对现有合同价值进行调整。第三季度RPO不含9月30日之后签署的新合同影响，包括甲骨文这一大额合同。

关于OpenAI合同的状态，投资者提问颇多，因为其占我们迄今已报告RPO的大部分。提示一下，该合同已在IPO前随S1文件提交，是一份750兆瓦算力的照付不议（take-or-pay）合同。

合同包含众多对双方均适用的条款，其中有一条规定：若我们在交付算力方面出现延误，OpenAI有权在此期间获得抵扣额度，用于未来的承诺采购。我们已计算潜在延误抵扣额度，并已在9月30日的RPO中予以扣除。

这些抵扣对营收和毛利率的影响较小，原因有二：一是占RPO的比例相对较小；二是绝大部分营收将在未来数年内按比例确认，抵扣金额将随之分摊。未来每个季度将根据最新估算进行更新，并在必要时反映在指引中。

若算力交付延误持续达90天或以上，OpenAI和Cerebras双方均有权取消该部分算力承诺（仅限该部分）。我们估计今年可能面临取消风险的算力量，将低于总承诺兆瓦数的5%。

鉴于全球数据中心产能需求旺盛，我们在寻找并上线初始数据中心产能以满足交付计划方面，相较极为紧张的时间表花费了额外时间。根据我们团队对各站点的频繁实地检查，我们目前预计将于2027年下半年追回进度，届时未来延误抵扣风险应会相应降低。

我们采取了保守态度，未假设任何延误将因超出我们控制范围的外部依赖因素而被豁免。若豁免情况发生，将减少我们所预估的延误抵扣金额。

此外，即便OpenAI或Cerebras选择取消某批次延误算力，我们认为凭借充足的市场需求，完全可以找到其他客户承接。

OpenAI还保留了在初始750兆瓦承诺之外，另行采购最多1.25吉瓦算力的选择权，最早可于2029年起上线。鉴于这还有三年时间，且AI领域变化之快，我们尚未就此展开讨论。

资产负债表与资本效率

我们继续保持强劲的流动性。第三季度末，现金、现金等价物、受限现金及有价证券合计约78亿美元。我们还拥有最高8.5亿美元的循环信贷额度，目前尚未动用。

今年1月获得的10亿美元预付流动资金贷款，以及作为OpenAI合同部分内容用于新数据中心产能装修的非经常性直通费用的持续收款，已为今年迄今大部分净营运资本需求和资本支出提供了资金。

我们不是一家新兴云服务商，而是业界最快推理解决方案的垂直整合发明者。我们的业务具备技术差异化所赋予的韧性，我们相信这将在长期内驱动更高的利润潜力和现金创造能力。

我们的模式在已部署算力设备的资本投入方面也较低。对于我们在数据中心自主制造的大量设备——与其他选择自研并部署AI芯片的公司类似——我们无需向第三方支付70%毛利率，也无需使用高价HBM，只需支付我们的物料清单（BOM）成本。这既降低了每兆瓦的相对资本支出，又使我们能够生产最快速、最有价值的token。

这反映在我们的资本结构中——尽管我们私有云建设规模快速扩张，资产负债表上唯一的债务仅为OpenAI流动资金贷款。我们还持续从客户处获得预付款，这是提升资本效率的另一杠杆。

我们当前的资本结构包含充裕的现金和投资，负债极少，为我们以多种方式持续融资、支撑快速增长提供了充分灵活性——这在当前资本市场环境下尤为有利。

展望

2026年第四季度展望：

- 核心营收：3.10亿至3.30亿美元
- 核心毛利率：47%至49%
- 核心经营利润率：-1%至1%

2026年全年展望（上调）：

- 核心营收：9.40亿至9.60亿美元
- 核心毛利率：42%至44%
- 核心经营利润率：-10%至-8%

总结

第三季度是Cerebras又一创纪录的季度，第四季度亦将如此。我们灵活的硬件与云服务兼售模式正在推动营收强劲增长，毛利率改善也比预期提前了整整一个季度。

我们在制造和数据中心产能规模化方面取得了显著进展，这将使我们能够在2027年实现营收三倍增长，同时核心毛利率向60%的长期目标持续推进。我们已展现出强劲的运营杠杆效应，并预计第四季度核心经营利润将基本实现盈亏平衡，此后预计在2027年大幅向40%的长期经营利润率目标迈进。

这种规模、增长与盈利能力的综合优势，使我们成为独具特色的领先AI系统提供商。

最后补充一点：提醒大家，我们上市已逾180天，IPO股票锁定期已于11月9日全部届满解锁。

感谢大家聆听我们的准备发言，下面请接线员开放提问通道。

问答环节

接线员：感谢各位。我们将开始问答环节，请稍候片刻。第一个问题来自Park Place的Tom O'Malley。请提问。

分析师（Tom O'Malley，Park Place）：

嗨，Andrew，嗨，Bob，感谢接受提问，也恭喜取得优异业绩。**第一个问题关于新合同——甲骨文和微软。能否介绍一下两笔合同的相对规模？另外，Bob，您提到甲骨文部分已纳入RPO，能否告知已纳入的具体金额？**

Andrew Feldman：

Tom，很高兴和你交流。关于微软合作的更多细节以及我们达成的协议，我们将在明年上半年进一步披露，届时也预计将开始产生收入。Bob？

Bob Komin：

Tom，关于RPO中纳入的甲骨文部分，请稍作纠正——我们纳入的是OpenAI的估算金额，即照付不议合同下的承诺收入总额，不含任何延期选项或附加选项，并已扣除我们认为可能需要支付的延误抵扣额度。其中还包括：针对已为OpenAI签约的数据中心，客户为设施建设支付的非经常性费用，以及合同期内的每月经常性费用，这些均作为直通收入和直通支出在利润表中确认。

Tom O'Malley：

明白，Bob。我刚才说的是甲骨文，不是OpenAI，不过我们可以稍后再谈。那么，关于甲骨文部分——

Bob Komin：

我们为赢得超大规模客户付出了巨大努力。而甲骨文的情况更加直接——目前我们在RPO中尚未纳入甲骨文，因为协议是在9月30日之后签署的。

Tom O'Malley：

明白，谢谢。后续问题是：我们看到前沿AI实验室不仅能快速研发硬件（比如Jalapeno项目），还能加速模型在不同计算硬件上的部署，提升硬件通用性。请问贵公司如何从这一趋势中受益，以及您对未来异构基础设施的发展预期是什么？这对Cerebras有何利好？

Andrew Feldman：

这是个非常好的问题。Profit公司在其S1或某条推文中提到，他们只用了约三天时间完成了AMD GPU的迁移上线。

这是一个非常有意义且重要的进展，尤其对于长期视角的观察者而言。我认为，业界尚未充分认识到这对我们生态系统意味着什么。

编译器和底层软件历来是新架构面临的根本障碍，它们天然有利于在位者，也是人们常说的"软件护城河"的核心来源。如果Profit公司真能实现他们所说的，那就意味着底层软件的价值将收缩，并随时间趋近于消失。软件护城河也将随之收窄并消弭。

若底层软件的价值趋于零，真正能够提供价值的，就只剩下创新硬件。这意味着竞争分化将更多取决于硬件的差异化程度。

我认为，这对Cerebras这样的创新硬件公司——以及其他采用全新架构的硬件先行者——是巨大的优势，同时将削弱在位者长期以来享有的优势地位。

这个问题问得很好，值得整个行业密切关注。谢谢。

接线员：感谢提问。下一个问题来自摩根士丹利的Joe Moore。请提问。

Joe Moore（摩根士丹利）：

谢谢。祝贺硬件业绩表现强劲。请问关于云业务排期方面的RPO问题，有没有什么具体情况可以重点关注？另外，您对在延误演变为额外罚款之前解决问题的信心如何？

Andrew Feldman：

我认为我们在RPO中纳入的数字是绝对最坏情况下的极为保守估计，因此我们有信心实际结果将优于这一预估。这类条款在大型数据中心合同中很常见——我们与数据中心建设方也有类似协议，延误同样会触发相应条款。通常情况下，双方会在届时综合商业考量后决定是否执行这些条款。我认为这是这类协议的惯常运作方式，未来也会如此。

Joe Moore：

好的。关于延误的原因，我想大家都能理解土地、电力、建筑等方面的挑战。请问这是类似的原因，还是其他原因？

Andrew Feldman：

我们目前的延误完全是土地、电力和建筑方面的原因。

Joe Moore：

明白了。我们有算力，有所有物料，只是在等待土地、电力和建筑方面的工程完工。

Andrew Feldman：

正是。谢谢，Joe。

接线员：谢谢。下一个问题来自花旗的Atif Malik。请提问。

Atif Malik（花旗）：

谢谢接受提问。**Andrew，我有个关于产品路线图的问题：CS4与CS3的交叉点预计何时出现？是2027年吗？另外，CS4在吞吐量上有了显著提升，如果沿着这一路径推进到CS5及后续产品，在某个节点上，贵公司的芯片是否能单独提供足够快的速度和吞吐量，无需搭配GPU使用？**

Andrew Feldman：

Atif，你好，很高兴和你交流。首先，就在几周前，我们所有的部署都是单独使用CS3的，只是最近才开始部署分解式推理方案，由此带来了吞吐量的显著提升，非常令人振奋。这是第一个观察。

可见，CS3单独使用效果已经很好，但分解式推理（我们目前正在部署，已进入正式可用阶段）在高速token受限的情况下，能够产生更多高速token。

关于CS3与CS4的交叉点，我预计将在2027年第一季度出现。产品路线图目前看起来非常好，CS5进度超前。虽然我在准备发言中已提及，但从流片到芯片完成整机测试仅用五个月，确实是非凡的执行成果。CS5预计将于2027年初夏开始量产，性能比CS4翻倍，而CS4性能比CS3翻倍。

Atif Malik：

很好。Bob，**关于第四季度云营收指引持平的情况：在2027年营收三倍增长的目标中，能否帮助我们理解云与硬件的业务结构？**

Bob Komin：

我认为理解硬件业务结构的关键在于，这类订单的规模可以非常大。我们希望在未来一两个季度内提供一些关于发货情况的指引。这在很大程度上取决于客户数据中心是否准备就绪。可以说的是，第四季度和进入第一季度，硬件占比将比过去几个季度更接近50%。

至于2027年其余时间的情况，在第四季度财报电话会议时我们会有更多信息，届时将对2027年整体情况提供更完整的展望。

Atif Malik：谢谢。

接线员：谢谢。下一个问题来自Needham的Quinn Bolton。请提问。

Quinn Bolton（Needham）：

大家好，祝贺取得进展。Andrew，**我想确认一下我理解是否正确：在RPO和您的假设中，您已经就潜在延误抵扣做了预提，但目前尚未收到任何关于延误算力的取消通知，是这样吗？**

Andrew Feldman：正确。

Quinn Bolton：

好的，很好。**第二个问题：市场上有一种担忧，认为低批次GPU能够实现快速推理。听起来那是一种成本很高的token交付方式。能否比较一下Cerebras与低批次GPU配置的每token成本？**

Andrew Feldman：

当然。GPU可以通过降低批次规模来换取更高的速度，但代价是牺牲吞吐量——低批次下吞吐量很低，而当你试图提高速度时，GPU会进入低批次区间，总吞吐量变得非常小。

这是由架构特性决定的。可以这样理解：GPU通过降批次确实能获得一定程度的性能提升，但这样做时，每token成本会急剧上升——同时服务的用户数大幅减少，总token生产量极为有限。

随着速度要求进一步提高，我们的优势会越来越强。当速度达到GPU无论如何都无法提供的水平时，Cerebras是唯一的选项——在批次为1的情况下，GPU仍然无法与我们媲美。

关于成本交叉点：大约在每秒250至300个token时，我们在经济性上更有优势；到每秒500、800、1000个token时，我们的优势会远超对手；在800至2000个token的区间，GPU根本无法参与竞争。这就是当前竞争格局的基本面貌。这个问题涉及复杂话题，提得很好。

Quinn Bolton：谢谢，Andrew。

接线员：感谢提问。下一个问题来自TD Cowen的Joshua Bruckheimer。请提问。

Joshua Bruckheimer（TD Cowen）：

大家好，感谢接受提问，并祝贺微软合作顺利落地。首先，请谈谈在土地、电力和建筑问题的背景下，您是如何分配算力的？看起来硅片和机架供应不是问题，那么在增量硬件销售方面还有多大空间？另外，鉴于云客户面临土地、电力和建筑方面的挑战，是否与OpenAI讨论过由OpenAI或其合作伙伴购买硬件并部署在他们自己的数据中心？谢谢。

Andrew Feldman：这个问题确实有两层。Josh，第一层是：土地、电力和建筑及其施工是否真的是限制因素？答案是肯定的。台积电已向我们做出了2027年充足晶圆产能的承诺，我们对此非常有把握。不使用HBM显然也是极大的优势，因为HBM目前供应极为紧张。

你第二层问题问得很好：这是否为我们在数据中心建设期间销售硬件创造了机会？唯一需要注意的是，据我们所知，几乎所有人的数据中心建设都在延期——包括OpenAI，包括我们知道的所有超大规模云服务商数据中心。数据中心延期是全球性的普遍现象，并非我们独有，我们的客户同样面临这一制约。所以，答案是：是的，我们有产品供应；是的，我们正在向拥有数据中心的客户发货；但同样，当前数据中心普遍延期，确实影响了实际进展。是否清楚了？

Joshua Bruckheimer：

明白，但**三问中的最后一个，也是我提的问题里比较难听的一部分——OpenAI合同是否有可能转为硬件采购？**

Andrew Feldman：

抱歉，合同中确实赋予了他们这一权利，但据我们了解，他们自己的数据中心建设同样落后于计划。

Joshua Bruckheimer：好的，明白了。谢谢。那么跟进问题——

Andrew Feldman：Josh，这已经是第七问了。

Joshua Bruckheimer：确实我的问题，我承认。**能否谈谈甲骨文和微软是如何向他们的客户定位Cerebras的产品和服务？这是否主要体现为硬件销售，然后根据超快推理需求来驱动客户使用量？谢谢。**

Andrew Feldman：当然。甲骨文合作的更多详情已有所公布，微软合作的细节将留到2027年披露。就甲骨文而言，他们采购的是硬件，部署在其位于美国的数据中心，我们正在合作，他们也在为此构建商业管线。目前兴趣非常浓厚，我们绝不认为这只是一次性合作，这是一段大型合作伙伴关系的开端，我们的设备将作为OCI云的组成部分部署在甲骨文数据中心。

Quinn Bolton：谢谢Andrew，我下个季度让一次提问机会。

Andrew Feldman：用一个汉堡包换一个下季度的提问机会?

Quinn Bolton：成交。

接线员：非常感谢。今天的问答环节到此结束，现在移交给Sean做结束语。

Sean Dorsey（投资者关系负责人）：最后，提醒大家，我们将于下周11月17日出席在奥斯汀举办的TomorrowX峰会，以及12月9日出席在旧金山举办的巴克莱全球科技大会。感谢大家今天的参与。接线员，请关闭会议。

接线员：感谢各位，本次会议到此结束，请大家断开连接。会议已结束。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

94 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论