

摘要：

面对DRAM价格暴涨，AI存储向低成本闪存转移。AMD收购内存优化公司MEXT将AI驱动闪存技术引入数据中心，苹果推进端侧闪存方案。巨头看重闪存成本仅为DRAM的1/55，正重构AI存储架构。

AI推理对昂贵DRAM的依赖正在松动。AMD宣布收购内存优化公司MEXT，将AI驱动的闪存优化技术引入数据中心。这标志着AI存储架构正在经历一场结构性迁移，而核心驱动力只有一个数字：**闪存成本仅为DRAM的1/55**。

周一，AMD宣布以未披露金额完成对MEXT的收购。MEXT开发的AI驱动预测内存技术，旨在让闪存的行为更接近DRAM，在维持性能与效率的同时扩展可用内存容量。AMD表示，此次收购将扩充其AI产品组合，帮助数据中心客户提升性能、降低总拥有成本并加速工作负载部署。“对内存的需求正在企业计算的每个品类中增长，”AMD在声明中称。

AMD Acquires MEXT to Advance Memory Optimization for Compute Infrastructure

📅 Jun 15, 2026



收购消息刺激AMD股价周一上涨7.7%至550.75美元，市值逼近9000亿美元关口，当日S&P 500指数整体上涨1.8%。AMD今年以来累计涨幅已达323%。花旗上周五将AMD评级从中性上调至买入，目标价从460美元上调至575美元。



AMD

NASDAQ: AMD

547.26 USD

↑ 144.89% +323.79 年初至今

收盘时间: 6月15日 GMT-4下午7:59 • 免责声明

盘后价 546.57 -0.69 (0.13%)

+ 关注

1 天 | 5 天 | 1 个月 | 6 个月 | YTD | 1 年 | 5 年 | 最大



值得注意的是，苹果早在2024年就开始推进“LLM in a Flash”端侧方案。这一布局背后，是愈演愈烈的DRAM供给危机。据TrendForce数据，高带宽内存（HBM）已占全部DRAM晶圆产能的约四分之一，DRAM合约价格在2026年第一季度单季环比暴涨约90%。Citirini Research指出，AI存储需求已大到需要多层架构共同承接，闪存并非取代HBM，而是在容量维度承接溢出需求——这场架构重构正在重新定价整条AI存储产业链。



AMD and AAPL both, in different ways, have announced a focus on flash as a way to reduce the AI memory tax. We wrote about this in our State of the Themes last week.



内存税危机：瓶颈从AI蔓延至全经济


据摩根士丹利分析师Shawn Kim团队本月早些时候的判断，**内存价格飙升和供应稀缺正演变为数字经济的全面风险**，“从AI基础设施的瓶颈，蔓延至硬件利润率、设备可负担性、云成本、通胀乃至政策层面。”这一压力已有具体案例佐证：Xbox首席执行官Asha Sharma上周表示，内存成本在过去两年间上涨了约五倍，导致公司无法生产消费者所需数量的游戏主机。

HBM对DRAM产能的持续蚕食是这场危机的核心驱动。据TrendForce及三星、SK海力士、美光等厂商的披露数据，HBM在DRAM晶圆产能中的占比已从2020年的2%攀升至2026年预估的25%。超大规模云厂商以多年期合同预购未来晶圆产出，进一步压缩了面向手机和PC的标准芯片可用产能。

新增DRAM产能的建设同样面临结构性制约。扩产依赖EUV光刻机印制更精细线宽，每台EUV设备售价高达约2亿美元，一座新晶圆厂的投资动辄数百亿美元，建设周期在顺利情况下也需数年。这一供给刚性，正是本轮短缺具备持续性的根本原因。

55倍成本差：闪存替代的经济逻辑

据Citrini Research测算，闪存的每比特成本约为DRAM的1/55——**QLC NAND约为每GB 0.05美元，DDR5 DRAM约为2.75美元，HBM3E则高达15美元**。这一价差的可利用空间，在于AI推理中最大的单一内存消耗——KV缓存（记录模型每次生成步骤中所有先前标记的上下文，长对话中可增长至数百GB）——对读取速度的要求远低于模型权重的解码路径。对于此类顺序读取数据，DRAM的速度优势大幅收窄，而闪存的容量优势则充分体现。



闪存的扩容路径也与DRAM存在本质区别。闪存通过垂直堆叠更多单元层来增加容量，依赖现有工厂已有的沉积和刻蚀工艺，无需新的光刻节点，不占用EUV资源。闪存控制器基于成熟的6/7纳米制程生产，远离正在制约先进制程的瓶颈节点。

苹果研究人员此前发表的论文“LLM in a Flash”提供了方法论支撑：通过将大语言模型参数存储于设备闪存、按需调取至DRAM的方式，可在DRAM容量受限的设备上运行超出其容量上限的模型，并在CPU和GPU上分别实现比朴素加载方式快4至5倍和20至25倍的推理速度。




Figure 1: LLM in a flash.

两条路径：数据中心与端侧同步演进

AMD的收购聚焦数据中心场景。通过将MEXT技术整合至AMD数据中心产品组合，AMD寻求帮助企业客户在AI工作负载部署中提升资源利用效率并压缩成本。摩根士丹利Shawn Kim团队认为，尽管内存短缺持续，AMD在云端市场竞争格局上仍具结构性优势——“代理式AI驱动的CPU需求在结构上有利于AMD在云端市场份额的扩张。”花旗对AMD的乐观预判则更多基于其GPU销售与英伟达的正面竞争态势。

苹果的路径则落子端侧。“LLM in a Flash”方案将模型推理对昂贵云端内存的依赖部分转移至设备本地闪存，在降低云端运算成本的同时，为端侧AI应用提供可行的内存架构支撑。

据Citrini Research，两大路径共同指向同一结论：**AI推理的内存层级正在重构，低频KV缓存、模型权重及端侧数据，将逐步从高价HBM/DRAM下沉至NAND Flash/SSD层，形成多层次存储架构。**

这一架构转变正沿产业链形成多层次的传导效应。据Citrini Research梳理，最直接的受益层是NAND原厂，大容量NAND、企业级SSD及QLC NAND为最纯粹的方向，包括SanDisk、西部数据、美光及铠侠。

SSD控制器层被认为持续性最强——让闪存真正接近内存体验的核心在于控制器、固件与NVMe架构优化，涉及Silicon Motion、Marvell等。CXL/PCIe高速互联层亦受益。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
VIP会员·7天畅读卡 | 大师课·入门串讲

扫码
免费领取

* 体验资格每人限申领一次



限免

👍 282 ⭐ 收藏

分享到:

写评论



请发表您的评论



表情



图片

发布评论

