

摘要：

据Anthropic披露数据，Claude已经主导26%的内部AI研发工作，协作超过90%的相关任务；主导是指人类提供高级指令，AI完成大部分工作，人类则负责监督。同时Claude尚未在任何被测AI研发工作中达到完全自主运行的水平。

AI正在越来越多地参与开发下一代AI。

当地时间周四，Anthropic公布了一组用于追踪前沿AI实验室研发进展的新指标。数据显示，截至今年8月，Claude已经“主导”Anthropic约26%的AI研发工作；与此同时，约3万个AI Agent在该公司同时开展研究和工程工作。

不过，Anthropic的数据也显示，AI距离完全自主开展AI研发仍有明显距离。截至8月，Claude尚未在任何被测AI研发工作中达到完全自主运行的水平。

Anthropic表示，希望通过持续披露这些指标，缩小前沿AI实验室内部实际进展与公众所能了解的信息之间的差距。

Claude已主导26%的AI研发工作

根据Anthropic披露的数据，截至8月，Claude参与的AI研发工作中，约26%已经达到“AI主导”（AI leads）的自动化水平。

这一指标参考了Epoch AI的AI研发自动化分级体系。其中，“AI主导”意味着，人类可以提供较高级的指令，而AI完成大部分具体工作，人类则负责监督。按此标准，Claude主导的研发占比在今年2月尚不足1%。

目前超过90%的相关任务已经达到“AI协作”（AI collaborates）或更高的自动化水平。

不过，Anthropic同时强调，Claude目前尚未在任何被测的AI研发工作中达到完全自主的水平。这意味着，尽管AI已经深入参与模型研发和工程流程，但人类仍然处于研发流程的重要环节。

3万个Agent同时开展研究和工程工作

Anthropic披露的另一项指标显示，今年8月约有3万个AI Agent同时在公司内部执行研究和工程工作。

这一规模反映出，AI Agent正在从单纯的辅助工具逐渐成为企业研发流程中的实际生产力。

Anthropic还对8月超过10亿次AI Agent决策进行了分析。数据显示，在线监控系统拦截了约0.002%的Agent决策，即大约每4.7万次决策中有1次被拦截。

这一数据衡量的是被监控系统阻止的决策比例，并不等同于AI的错误率或危险行为发生率。

AI研发越自动化，安全问题越受关注

Anthropic同时公布了AI研发计算资源的分配情况。



在7月13日至7月20日的一周内，公司约6%的AI研发计算资源用于安全工作；如果只计算由AI驱动的AI研发工作，约12%的计算资源被用于安全相关工作。

随着AI越来越多地参与AI模型本身的研发，AI安全也成为越来越重要的问题。

Anthropic表示，公司计划让独立第三方评估机构获得对内部流程和数据的访问权限，以便对安全实践进行验证，并帮助外部人士了解前沿AI实验室内部AI研发的实际进展。

这一安排意味着，AI实验室正在尝试通过第三方评估，减少企业内部信息与外部公众认知之间的差距。

从“AI辅助研发”走向“AI驱动研发”

Anthropic此次披露的数据提供了一个观察AI产业发展的新角度：市场过去主要通过模型参数、基准测试成绩和用户数量衡量AI进步，而Anthropic开始尝试衡量AI究竟在多大程度上参与了开发下一代AI。

从目前的数据来看，AI已经深度进入前沿AI实验室的研发流程，大量Agent正在承担研究和工程任务，但完全由AI独立完成整个研发过程仍未实现。

这也意味着，当前AI产业正在经历的变化，与其说是“AI已经能够自主研发AI”，不如说是AI正在快速提高自身参与AI研发的程度。

随着这一比例继续提升，如何衡量研发自动化程度、如何监督AI Agent行为，以及如何确保安全投入跟上研发自动化速度，可能成为前沿AI实验室未来需要持续回答的问题。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 100  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论

