

摘要：

中金认为，Agentic AI的复杂任务编排与高并发需求使CPU成为推理核心瓶颈，地位重塑。预计CPU与GPU配比将趋向1:1，2030年市场超1300亿美元，短期涨价持续。技术向高带宽与专业化演进；Arm因高能效契合推理需求，份额将加速追赶x86。

摘要

CPU需求为什么会增长？在大模型训练阶段，以GPU为核心的矩阵计算能力是决定模型能力的核心，产业内关注焦点也聚焦在FLOPs等GPU的计算性能优化上。但从2H25起，出现了两方面变化：1) 在训练侧，强化学习的重要性提升，使得CPU/GPU配比成为了系统的关键指标之一；2) 在推理侧主要有三个领域：a) 推理Host CPU，配合GPU进行任务调度和利用率优化等，甚至执行简单推理任务，形成对GPU的替代作用；b) 编排节点CPU，在复杂agentic任务中，作为独立节点承担逻辑运算并进行任务编排；c) 沙盒执行层随并发任务数增加带来CPU需求。

AI驱动下，CPU市场规模有多大？我们从两个维度尝试进行测算：1) 中性基于GPU:CPU=1:1配比估计下，我们测算至2030年全球CPU市场规模将超1300亿美元；2) 我们测算Agentic AI当前情景下（5亿DAU或300亿日均token）对CPU的新增需求大约为840万颗。从技术发展趋势看，作为新操作系统的“调度器”CPU的升级趋势包括更强的单核性能、更大的内存带宽、更强的I/O能力、更多核心数。长期来看，我们预计数据中心CPU迭代将围绕三条主线展开：数据带宽能力提升、任务分工专业化，以及与加速器的深度融合。此外，在需求快速增长情况下，我们认为2026年服务器CPU涨价趋势有望持续。

竞争格局：x86 vs Arm，谁将胜出？目前全球服务器CPU市场中Arm市占率不到20%，仍以x86架构为主。考虑Agent类产品拥有高并发、持续运行、大量轻量级推理请求的特点，Arm精简指令集的功耗效率占优，可以支持更多核心处理并发请求，适用于高吞吐的推理服务，我们预计未来其份额或将提升。

正文

随着推理需求的持续提升，对服务器系统从原本以GPU（矩阵计算）为核心转向CPU（任务编排等）重要性提升的讨论逐渐升温，我们认为长期来看，服务器内部的异构系统会成为趋势。本文重点讨论四个问题：1) 从需求角度来看，本轮CPU需求提升的原因是什么？2) 类比存储的变化，当前CPU市场在供给和需求端呈现什么状态？3) 长期视角看，未来CPU的发展趋势有哪些？4) CPU市场的竞争格局如何？

CPU需求为什么会增长？

在大模型的训练阶段，以GPU为核心的矩阵计算能力是决定模型能力的核心，产业内关注焦点也聚焦在FLOPs等GPU的计算性能优化上。但从2H25起，出现了两方面变化：1) 在训练侧，强化学习的重要性提升，使得CPU/GPU配比成为了系统的关键指标之一；2) 在推理侧主要有三个领域：a) 推理Host CPU，配合GPU进行任务调度和利用率优化等，甚至执行简单推理任务，形成对GPU的替代作用；b) 编排节点CPU，在复杂agentic任务中，作为独立节点承担逻辑运算并进行任务编排；c) 沙盒执行层随并发任务数增加带来的CPU需求。

训练视角：强化学习带来对CPU需求的提升

强化学习对CPU/GPU配比提出新要求。与传统意义上认为在训练阶段GPU是唯一重要的衡量指标不同，随着强化学习的重要性提升，考虑CPU资源的约束也成为了一个值得关注的方向。目前强化学习的实践中，环境交互以及如何分配硬件资源，已经成为了系统的主要瓶颈，由于需要大量CPU资源去运行模拟环境，CPU不足也会造成GPU 空转。因此合理设计CPU/GPU的配比，让CPU的线程数等于或者大于GPU SM 的数量，也成为了一个重要方向。但从绝对量的角度看，我们判断强化学习带来的对CPU的需求相对推理较为有限。

推理视角：Agentic AI时代，CPU成为瓶颈环节

◦ 简单推理：成本视角下，CPU对GPU的替代作用

成本视角考量，CPU对GPU存在一定替代可能。当前GPU仍处于紧缺状态，同时高性能的GPU不管是租赁价格还是缺货情况都未见明显缓解。在训练场景中很难采用其他计算芯片对GPU进行替代，但来到推理场景后，一方面对矩阵计算的性能要求有所下降，另一方面在一些简单的推理任务中，如chatbot等，业内已经开始采用浮点计算性能较低的RTX系列等算力芯片进行推理。

考虑CPU价格对比GPU的优势明显，我们判断在一些简单的推理任务中，CPU一定程度上也可能替代GPU，带来一定拉动。从海内外头部CSP对ASIC芯片的推动，以及对定制化CPU芯片的探索思路看，也具有一定的共同之处。但这部分无法进行具体的测算，同时潜在空间有限。

图表1：CPU在推理中的重要性提升

维度	训练	推理
主要瓶颈	GPU/加速器负责前向和反向传播（CPU 为次要瓶颈）	CPU 端负责请求处理及预处理/后处理，适用于较轻量的 GPU/CPU 推理内核
典型 CPU:GPU 比例趋势	较低的 CPU:GPU 比例 集群针对 GPU 密度和互连进行优化	较高的 CPU:GPU 比例 每个加速器对应多个服务和线程，并包含仅 CPU 的推理路径
关键 CPU 任务	数据加载、数据增强、编排、日志记录以及分布式训练控制	API 逻辑、路由、批处理、分词、特征转换、排序以及响应格式化
延迟与吞吐量优先级	最大化吞吐量和缩短训练时间 延迟相对次要	严格的单请求延迟服务协议（SLA） 和高每秒查询率（QPS） CPU 须承受流量峰值

资料来源：The Rising CPU:GPU Ratio in AI Infrastructure: Drivers, Trends, and Implications
(Intel，2026年)，中金公司研究部


◦ Agentic AI：Token消耗占比持续提升，复杂任务编排使CPU成为新的瓶颈

我们认为Agentic AI时代CPU的变化具有三个特点：1）总体来看：任务链条和流程复杂带来的CPU重要性上升；2）工作负载复杂化：不同的工作负载对CPU要求不同，RAG、ChemCrow等工作负载中，CPU 已经成为了核心瓶颈；3）并发数量增加：并发数量增加会进一步加大CPU作为瓶颈的约束情况，进而在执行层带来对沙箱的需求增长。

Agentic AI具有更泛化的应用能力，正逐渐成为AI应用的主流。Agentic AI以生成模型为基础，增加了编排、记忆和目标导向行为，可以规划多步骤任务、调用工具、迭代结果，并在更长时间的工作流程中运行。根据OpenRouter数据，到2025年底，推理产生的token已超过总token的50%，有15%的推理过程以“外部工具调用”结束。

图表2：推理产生的token数占比





资料来源：OpenRouter，中金公司研究部


图表3：以“外部工具调用”结束的推理过程占比



资料来源：OpenRouter，中金公司研究部

多步骤、多工具调用的Agentic AI带来任务流程的复杂化。从工作流视角看，在传统的生成式AI（如单轮对话的大语言模型）中，整体的输入-输出流程相对简单，步骤也较少。但随着AI向Agentic（智能化）演进，在推理过程中步骤更加繁杂、不同工具、外部API调用等成为常态，因此CPU作为任务编排的核心重要性在上升。


图表4：Agentic AI在编译器，任务执行流程，执行复杂度方面的变化



资料来源：A CPU-CENTRIC PERSPECTIVE ON AGENTIC AI（Georgia Institute of Technology，Intel，2025年），中金公司研究部

Agentic AI 任务中工具处理需求的出现，在部分的工作负载场景下CPU已经成为新的瓶颈环节。在大语言模型的执行方式下，推理流程为：推理1——工具调用1——推理2——工具调用2——推理3……，由于系统必须等到LLM生成完整工具调用的所有token，才开始执行，因此会带来GPU空转（等待工具返回结果）和工具空转（等待模型生成指令），因此需要CPU进行工具处理。从而使系统从原来的GPU为核心之外，CPU作为工具处理的重要性大幅提升。《A CPU-CENTRIC PERSPECTIVE ON AGENTIC AI》的论文中列举了不同的工作负载延迟表现，可以看出由于CPU上的工具处理可能占据端到端延迟的很大一部分，因此行业内优化的重点来到了以CPU为核心的优化策略上。

图表5：在没有部分工具调用的情况下，会形成GPU空转带来延迟



资料来源：Conveyor: Efficient tool-aware llm serving with tool partial execution (Duke University, 2024年)，中金公司研究部


图表6：不同工作负载下端到端运行的延迟情况，CPU 已经成为了核心瓶颈



资料来源：A CPU-CENTRIC PERSPECTIVE ON AGENTIC AI (Georgia Institute of Technology, Intel, 2025年)，中金公司研究部


动态视角看，CPU 的超额订阅会随着并发任务的数量增加变得更加严重。随着批处理（Batch size）大小的增加，以及输入/输出 token 长度的增加，在不同的工作负载下，CPU 作为瓶颈环节的影响是在逐渐变大的。也就是说，用户数或者并发任务的增加，会使得CPU 核心数量的要求更高。例如当Batch-size达到 128 的时候，系统需要同时调度数百个工具执行进程，因此 CPU 的核心数成为了新的短板。而增加CPU资源在延迟改善和提高系统利用效率方面具有明显效果。

图表7：增加CPU资源的分配可以减轻延迟



资料来源：Characterizing CPU-Induced Slowdowns in Multi-GPU LLM Inference (Georgia Institute of Technology, 2026年)，中金公司研究部

图表8：分配更多的CPU核心可以缩短高利用率时间




资料来源：Characterizing CPU-Induced Slowdowns in Multi-GPU LLM Inference (Georgia Institute of Technology, 2026年)，中金公司研究部

- Sandbox执行层：驱动多核并发与硬件虚拟化需求的增长

复杂Agent任务带来沙箱（Sandbox）需求快速增长。在企业级应用场景中，为确保系统安全性与执行环境的纯净，系统会针对每一个外部工具调用请求，瞬时拉起（Spin-up）并随后销毁（Tear-down）一个独立的微型虚拟机或容器（MicroVM/Container），即沙箱。从当前的任务分类看，除了少数的只读型、纯API 调用、纯本地调试等任务之外，涉及到自主执行代码或调用外部工具的任务，沙箱在系统安全、效率控制、环境一致性等方面的优势表明它都是必须存在的。

图表9：多智能体架构中，执行智能体利用虚拟机（VM）作为沙箱来运行代码



资料来源：The Rising CPU:GPU Ratio in AI Infrastructure: Drivers, Trends, and Implications (Intel, 2026年)，中金公司研究部

沙箱消耗 CPU 的硬件虚拟化指令集（如 Intel VT-x/AMD-V）性能，更对 CPU 的物理核心数提出了线性增长的需求。当系统面临同时执行数十个网页抓取、代码编译或数据清洗等并发任务时，庞大的物理核心数是实现横向扩展、降低任务间上下文切换损耗的唯一解，因此对CPU调度能力产生更高要求。而CPU的核数决定了能开启多少个沙箱（即并行环境）。

图表10：Agentic AI对沙箱的需求

维度	需求逻辑	资源限制因素
基础需求	1 个任务会话 = 1 个沙箱	内存 (RAM) 基础占用
多智能体协作	1 个任务 = N 个 Agent = N 个沙箱	CPU 核心数/线程数
评测	需要并行运行数千个沙箱以获得统计结果	CPU 吞吐量与 I/O 速度

资料来源：微软，中金公司研究部

AI驱动下，CPU市场规模有多大？

从上文可以看出，训练和简单推理对CPU的需求处于次要地位，核心还是agentic AI。随着 agentic AI 的快速发展，及多步骤的复杂推理任务比重和难度增加，对任务编排调度的要求也持续提高，进而引发了对CPU需求的增加及未来GPU:CPU配比变化的探讨，本章节从两个维度尝试进行测算。

配比视角：Agentic AI推动服务器CPU市场规模快速增长

。我们预计2030年全球CPU市场规模将突破1300亿美元

CPU在单台AI服务器中的配比将迎来提升，提升系统边际效率。从第一章对CPU需求的视角出发可以看出，过去AI服务器中CPU在配比的数量、核数等多个方面都已经无法满足需求，为保持系统整体的高吞吐量，服务器架构需要显著提升CPU的核心数和缓存性能，导致CPU在整体算力采购成本中的占比提高。因此我们预计CPU的需求将迎来增长。

配比的具体数字是核心。聚焦几家CPU 厂商最新表述来看：1) 英特尔：CEO陈立武在1Q26业绩会上提到CPU:GPU配比有望从1:8/1:4进一步提升；2) AMD：1Q26业绩会上苏姿丰预计全球服务器CPU市场有望在2030年达1200亿美元规模；3) ARM：4Q26业绩会上CEO预计全球服务器CPU市场有望在2030年超1000亿美元规模。

需要指出的是，当前对GPU:CPU的配比并没有一致结论。由于现有的服务器架构较为固定，因此在推理服务器中我们预计仍将以2个GPU配1个CPU的方式进行配置；但考虑到agentic AI的需求，纯CPU的机柜也将开始陆续部署，因此从综合的视角看，CPU:GPU配比将从目前8卡服务器中1:4的比例逐渐提升，2030年或将达1:1甚至更多。

中性基于1:1的预计倒推，我们测算至2030年全球CPU市场规模将超1300亿美元。核心假设有：1) 全球算力卡预计2030年达4240万颗；2) AI服务器CPU:GPU配比2030年达1:1；3) AI服务器CPU单价随核心数的增加、性能的提升及代工的升级2026-2030年增幅在16%。

图表11：数据中心CPU市场规模测算

	2024	2025	2026E	2027E	2030E	2026-2030CAGR
Step1: 算力卡出货量（万颗）						
英伟达	450	650	890	800	1,500	14%
AMD	70	80	80	120	240	32%
谷歌	180	240	450	885	1,300	30%
亚马逊	100	150	230	350	600	27%
META	20	20	30	50	200	61%
微软	10	10	20	50	200	78%
其他	20	200	100	100	200	19%
合计算力卡出货量	850	1,350	1,800	2,355	4,240	24%
Step2: AI服务器CPU出货量（万颗）						
ARM CPU	223	389	603	797	1,385	23%
X86 CPU	86	115	114	138	252	22%
外挂CPU 增量				243	2603	假设 2027 年CPU:GPU=1:2; 2030 年=1:1
英伟达				30	806	
AMD				44	715	
谷歌				30	180	
亚马逊				88	450	
META				13	150	
微软				13	150	
其他				26	152	
合计AI服务器CPU出货量	309	504	717	1,178	4,240	56%
YoY		63%	42%	64%		
Head node	309	504	717	935	1,637	
Orchestrator				243	2,603	
Step3: 通用服务器CPU出货量（万颗）						
通用型服务器CPU出货量	2,501	2,626	2,757	2,895	3,351	5%
YoY		5%	5%	5%		
Step4: 平均价格（美元）						
通用服务器CPU ASP	800	840	882	926	1,041	4%
AI 服务器CPU ASP	1,200	1,380	1,656	1,987	2,385	10%
Step5: 服务器CPU市场规模（亿美元）						
通用型服务器CPU	200	221	243	268	349	9%
AI服务器CPU	37	69	119	234	1,011	71%
合计服务器CPU市场规模	237	290	362	502	1,360	39%
Step6: 单CPU核数（个）						
通用型服务器CPU	16	24	32	64	128	
AI服务器CPU	24	32	64	96	160	
Step7: CPU 核数（亿个）						
通用型服务器CPU 核数	4	6	9	19	43	48%
AI服务器CPU 核数	1	2	5	11	68	96%
总CPU 核数	5	8	13	30	111	70%

注：图中CPU价格为预估，并不代表实际售价

资料来源：BBG，各公司官网，中金公司研究部

需求视角：Agentic AI对CPU数量及核数提出新需求

◦ 总量：当前情境下Agentic AI对CPU新增需求超过800万颗

我们测算Agentic AI当前情景下对CPU的新增需求大约为840万颗。从需求端对CPU的测算较为复杂，我们简化后通过并发任务数量的形式，讨论Agentic AI对CPU的拉动作用。测算的核心思路为：1) 通过日活用户数或日均token消耗量对并发任务数量进行预估；2) 对任务按复杂度进行核心参数分配，包括任务占比，占用核数，调用agent数量等；3) 分四种情况计算对应CPU核数需求；4) 测算所需CPU数量。

图表12：Agentic AI对CPU额外需求测算

Step1: 计算并发任务数量				
方法一：按并发任务测算（主要思路）				
DAU（亿）	5			
并发率	10%			
任务并发量（万个）	5,000			
方法二：按日均 token 测算并发数（交叉验证）				
日均 token（万亿）	300			
平均每秒吞吐量（亿）	35			
单任务每秒消耗速度（秒）	150			
平均并发任务量（万个）	2,315			
峰值系数	2			
峰值业务并发任务数（万个）	4,630			
Step2: 按任务复杂度分配核心参数				
任务类型	单任务峰值占用核数（个）	并发占比	峰值持续时间（分钟）	涉及Agent 数量（个）
简单	1	45%	4	1
中等	2	30%	8	4
复杂	8	20%	60	10
超复杂	20	5%	180	20
Step3: 四种任务所需CPU 核心数				
简单任务		复杂任务		
总并发任务数（万个）	2,250	总并发任务数（万个）	1,000	
单任务调用 agent 数量（个）	1	单任务调用 agent 数量（个）	10	
单任务峰值核数（个）	1	单任务峰值核数（个）	8	
单任务峰值计算时间占总峰值持续时间比	10%	单任务峰值计算时间占总峰值持续时间比	20%	
实际冲峰时间（秒）	24	实际冲峰时间（秒）	720	
任务总时间（秒）	240	任务总时间（秒）	3,600	
总所需CPU 核数（万个）	225	总所需CPU 核数（万个）	16,000	
中等任务		超复杂任务		
总并发任务数（万个）	1,500	总并发任务数（万个）	250	
单任务调用 agent 数量（个）	4	单任务调用 agent 数量（个）	20	
单任务峰值核数（个）	2	单任务峰值核数（个）	20	
单任务峰值计算时间占总峰值持续时间比	15%	单任务峰值计算时间占总峰值持续时间比	25%	
实际冲峰时间（秒）	540	实际冲峰时间（秒）	2,700	
任务总时间（秒）	3,600	任务总时间（秒）	10,800	
总所需CPU 核数（万个）	1,800	总所需CPU 核数（万个）	25,000	
Step4: 总CPU 需求量				
以上合计所需CPU 核数（万个）	43,025			
系统余量	25%			
合计CPU 核数（万个）	53,781			
单个CPU 核数（个）	64			
CPU 需求量（万颗）	840			

资料来源：各公司官网，中金公司研究部

。结构：CPU应用场景需求进一步细化

从技术发展趋势看，作为新操作系统的“调度器”CPU的升级趋势主要有：1）更强的单核性能来降低单次推理的延迟，2）更大的内存带宽和更强的I/O能力来调度更长的上下文以及管理海量的数据，3）更多核心数来支持高并发查询及虚拟化。

图表13：Agentic AI下数据中心CPU三大应用场景

维度	推理伴生CPU	编排节点CPU	RL训练环境CPU
定位	与GPU物理紧耦合，负责推理前后的数据处理、token监控和GPU利用率优化	独立CPU节点，负责Agent的规划、决策、工具调用执行和多Agent协调	为强化学习(RLVR)提供大规模并行模拟环境，训练Agent的推理和工具使用能力
具体职能	GPU任务调度与利用率优化 KV/Cache调度与显存管理 Token监控与子Agent完成判断 推理结果的中间评估数据预处理与后处理	·Agent控制流管理：规划/分支/重试，多Agent协调与结果整合 ·工具调用执行：API/网页搜索/数据库 ·沙箱环境运行：代码编译/执行/验证 ·上下文/记忆管理 ·结果反思与任务完成判断	·代码编译与执行验证 ·模拟工具交互环境 ·测试用例运行与结果判定奖励信号计算 ·训练数据生成与清洗 ·沙箱隔离与安全管控
CPU核心需求	高单核性能·低延迟·GPU紧耦合	高核心数·大内存带宽·强I/O	超大规模并行实例·沙箱隔离低成本效率
代表性硬件	·Nvidia Grace ·Intel Xeon 6 (SambaNova 三层蓝图) ·AMD EPYC (与Instinct GPU同tray)	·Arm AGI CPU机架(液冷 200kW, 45000+核心) ·Nvidia Vera CPU独立机架 ·AMD EPYC Venice (256核/512线程)	·大规模x86/Arm CPU集群 ·云厂商自研芯片 (Graviton/Cobalt) ·高密度多节点服务器

资料来源：各公司官网，中金公司研究部

价格趋势：短期供需失衡，服务器CPU有望持续涨价

由于CPU产能分配存在一些模糊性，因此缺乏CPU供给侧的较好测算，但从定性视角看，Agentic AI等需求对CPU的拉动还在持续增长，因此CPU市场出现了一定程度缺货涨价。

受供需缺口影响，我们认为2026年服务器CPU涨价趋势可持续。截至2026年5月，我们观察到Intel服务器CPU在2月、3月已经历了两次涨价，涨幅在5-15%之间，同时部分型号CPU交期还在持续拉长，侧面体现了对CPU的需求增长。



► **需求侧来看**，如前所述，主要受益于AI推理需求增长，同时通用型服务器面临更新换代的需求，我们预计2026年全球服务器出货量有望同比增长近20%，未来Agentic AI有望拉动AI及配套服务器需求的加速增长。

► **供给侧来看**，AMD和Arm均采用台积电先进制程代工，结合GPU、ASIC等算力芯片需求持续上修，台积电2-5nm制程订单需求旺盛，产能扩张较为有限，我们预计供需缺口将持续至27年。目前来看，AMD CPU27年产能供给仍有一定弹性。根据陈立武5.19JPM大会发言，英特尔18A良率每月稳步提升，有望在26年底前实现成熟良率目标。结合来看，我们预计供需缺口将持续至27年，2026年服务器CPU有望迎来进一步涨价。

此外，受益于服务器CPU旺盛的需求，服务器CPU配套芯片，如PCIe retimer、PCIe switch以及内存接口芯片等细分赛道，亦值得关注。

图表14：Intel产能预计

成熟制程	工艺	时间	主力产品/客户	先进制程	工艺	未来月产能（片/月，300mm晶圆）	主力产品		
已投产站点				已投产站点					
亚利桑那州 Fab12+22+32	Intel7（10nm）	三家工厂分别于2006、2002、2007年投产	满产Intel7可达60,000月产能 和UMC合作在转产12nm FINFET，承接通信、网络等成本敏感订单	亚利桑那州	Fab42	原Intel7/Intel4，升级18A中	亚利桑那州未来共计：100,000		
				Fab 52	18A	1Q26: 40,000	panther lake和clearwater, 预计26年晚些时候将有diamond rapids		
				Fab 62	18AP-T? (for AI ASICs)/14A?	2028: 40,000			
爱尔兰	Fab24	FinFET Intel 16	4Q25开始量产	联发科（电视和WiFi）	爱尔兰	Fab 34	Intel 4（约7nm） Intel 3（约3nm）	100,000	酷睿Ultra第一代Meteor Lake（于23年9月发布） 服务器Granite Rapids（Xeon P核）和Sierra Forest（Xeon E核）
以色列	Fab28	Intel7（10nm）	20,000-30,000月产能，自身服务器和PC CPU	以色列	Fab 38	计划Intel 18A	建设停工中		
远期产能潜力			90,000	远期产能潜力			200,000		

注：绿色为目前主力产能，统计截至1Q26

资料来源：Intel官网，中金公司研究部

长期趋势：推理架构正从“GPU附属CPU”转向“CPU强绑定集群”


未来十年，数据中心CPU的演进路径不太可能回到单纯追求频率或核心数扩张的传统逻辑，而将围绕三条主线展开：数据带宽能力提升、任务分工专业化，以及与加速器的深度融合。

► **CPU 将进一步向高带宽数据设备演进**。随着 AI 负载从单次张量计算扩展至大规模上下文管理与状态维护，我们预计内存通道数量、内存带宽密度和缓存容量的重要性将持续上升。LPDDR 在数据中心的采用、SOCAMM 模组的发展，以及更高通道数 DDR 设计，均指向一个方向：隐藏内存延迟、提升带宽密度、支撑大容量上下文成为核心目标。我们认为未来竞争焦点将不再仅是每核心性能，而是数据 fabric 组织能力与片上网络带宽。

► **CPU 将持续分化以匹配不同工作负载，朝三类方向并行发展**：1) 高单核性能、高内存带宽、与 AI 加速器保持一致性互连的紧耦合型 CPU；2) 面向 KV-cache 管理、网络分层与数据路径处理的 DPU/数据平面型 CPU；3) 高核心密度、重吞吐的云型 CPU。这种分化说明 CPU 并未被 GPU 替代，而是在 AI 体系中承担更专业化的角色。

图表15：NVIDIA BlueField-4将Grace CPU与NIC协同封装






资料来源：英伟达官网，SemiAnalysis，中金公司研究部

图表16：英伟达发布Vera CPU机柜

Vera CPU Rack
(Liquid Cooled)



资料来源：英伟达官网，中金公司研究部

► CPU 与加速器的边界可能进一步模糊。APU架构（如集成 CPU + GPU 的设计）可能减少独立 head node 的需求；部分 RL 训练负载可能迁移至具备本地环境执行能力的专用加速器；同时，内存池化与 CXL 扩展可能降低传统每机架必配独立 CPU的绑定比例。从更长远角度看，CPU 甚至可能嵌入交换芯片或数据中心网络核心之中，成为数据流调度的基础控制单元。

我们认为，未来CPU的价值不在于替代GPU，而在于承载系统复杂性。在 AI 2.0 时代，模型能力的提升带来更多交互、更长上下文与更多外部调用，CPU 作为通用执行与控制单元，仍将是维持系统可扩展性的基础组件。其形态可能变化，但其在计算体系中的核心地位不会消失。

竞争格局：X86 VS Arm，谁将胜出？

X86 VS Arm：X86 份额领先，Arm有望加速追赶

目前，全球服务器CPU市场中Arm市占率不到20%，仍以x86架构为主。

X86 vs Arm：x86生态成熟度仍较为领先，Arm在云端推理份额预计将持续增长。Agent类产品拥有高并发、持续运行、大量轻量级推理请求（比如多轮对话、工具调用、规划推理等）的特点，ARM精简指令集的功耗效率占优，可以支持更多核心处理并发请求，适用于高吞吐的推理serving。

x86在生态成熟度上仍然保持领先的优势。大量推理框架在x86上优化更成熟，部分指令集对矩阵运算有专门的加速，因此我们认为对于较大模型的运行、混合精度计算或和传统软件栈深度集成的场景下，x86的兼容性和工具链优势明显。

总结来说，Arm架构的CPU因为高能效比在CSP中获得大规模部署，为CSP自有业务、有能力为Arm架构进行软件优化的客户提供更具性价比的选择；x86 CPU的服务器具有更完整的生态和极强的兼容性，对中小型企业意味着开箱即用的通用性与最低的迁移摩擦，具有广泛而稳定的需求。我们预计随着Agentic AI带动AI服务器CPU配比的提升，以及ARM在CSP厂商及企业级客户的持续突破，在2030年全球服务器CPU市场中占比有望接近一半。

图表17：x86 vs ARM市场规模预测及份额

	2024	2025	2026E	2027E	2030E	市占率	2026-2030CAGR
全球通用型服务器CPU出货量（万颗）	2,501	2,626	2,757	2,895	3,351		
其中：x86	2,501	2,626	2,757	2,750	2,346		
ARM				145	1,005		
全球AI服务器CPU出货量（万颗）	309	504	717	1,178	4,240		
其中：x86	86	115	114	259	1,554		
ARM	223	389	603	918	2,686		
全球服务器x86 CPU市场规模（百万美元）	22,000	25,774	31,053	39,055	74,314	55%	24%
YoY		17%	20%	26%			
全球服务器ARM CPU市场规模（百万美元）	1,714	3,231	5,140	11,154	61,695	45%	86%
YoY			59%	117%			

资料来源：IDC，中金公司研究部

本文来源：[中金点睛](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

127 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论