

摘要：

继续前进

作者 | 林克

4月24日，备受关注的DeepSeek的V4模型预览版终于发布并同步开源了权重。

这次发布的两个版本，一个是总参数1.6万亿，激活49B的旗舰版V4 PRO，一个是经济型V4-Flash，总参数284B，激活13B，均支持100万token上下文，MIT协议完全开源。

就在前一天，OpenAI刚刚上线GPT-5.5，每百万输出token定价30美元。今天DeepSeek V4-Flash的输出定价是2元人民币/百万token，折合不到0.3美元。

前后两天，闭源与开源的两种定价逻辑，面对面呈现在了市场面前。

DeepSeek V4落地释放的五个信号



两大模型发布

V4-Pro 1.6万亿参数
V4-Flash 2840亿参数支持100万
token上下文
行业标配新起点

超低定价

V4-Flash输出价
2元/百万token

完全开源

MIT协议
开放权重


聚焦Agent

深度适配主流
Agent工具链

1

时间：三次跳票后的落地

- 从去年底到今年4月，DeepSeek V4发布窗口三次推迟，行业竞争进入最密集时刻
 - V4给出全新混合注意力架构：DSA稀疏注意力+token压缩机制，区分轻重，降本增效
 - 预训练超过32万亿token，引入mHC超连接与Muon优化器，提升深层网络稳定性
 - 百万token上下文，V4-Pro每处理1个token的算力消耗仅为V3.2的27%，KV缓存占用10%
- “从现在开始，1M上下文将是DeepSeek所有官方服务的标配。”



2

图纸：两型号+三模式

- V4-Pro（旗舰版）**
1.6万亿总参数 | 激活49B
定位：高性能Agent Coding利器
- V4-Flash（经济版）**
284B总参数 | 激活13B
定位：高性价比，普惠开发者

三种推理模式

- 非思考模式**
快速响应，适合简单任务
- 思考模式-高**
显式推理链，提升准确性
- 思考模式-极限**
推到模型能力边界
官方建议复杂Agent场景使用

官方自评对标

- Pro版：
- ✓ Agentic Coding体验优于 Claude Sonnet 4.5
 - ✓ 交付质量=Opus 4.6（非思考）
 - ✓ 数学/STEM/竞赛代码超越所有开源模型，比肩顶级闭源
 - ✓ 世界知识大幅领先开源模型，稍逊于Gemini-Pro-3.1
- Flash版：
- ✓ 推理能力接近Pro版
 - ✓ 简单Agent旗鼓相当，高难度任务有差距

3

扳机点：Token价格差

DeepSeek V4 API定价（预览版）		
模型	输入价 (缓存命中价)	输出价 (百万token)
V4-Flash	1元 (0.2元)	2元
V4-Pro	12元 (1元)	24元

* Pro版下半年算力扩容后将大幅下调

* 缓存命中价：Flash为原价1/5，Pro为原价1/12

与行业主流模型输出价对比（每百万token）



💡 定价策略洞察：用Flash低价铺量，用Pro高阶能力覆盖顶端场景，通过缓存机制大幅降低Agent开发者边际成本

4

方向：Agent底座

- 深度适配主流Agent工具**
Claude Code, OpenClaw, OpenCode, CodeBuddy等，Agentic Coding达开源最佳
- 不做应用，做底座**
定位Agent时代基础设施，成为开发者的“供电站”
- 解决核心痛点**
百万上下文一次性容纳代码仓库、需求文档、历史对话，降低上下文管理成本

行业趋势

“Anthropic靠Claude Code年化收入从90亿\$增至300亿\$，Cursor估值达600亿\$，应用层价值巨大。DeepSeek选择成为底座供应商，支撑生态共同繁荣。”



5

生态：开源集体赛跑

近期国产开源模型密集突破

Qwen3.5	3970亿总参数 激活170亿 百万token API价0.8元，仅为Gemini-3-Pro的1/18
GLM-5	代码生成（HumanEval 92.8%）开源最强
Kimi K2.6	SWE-Bench Verified 80.2% 逼近Claude Opus 4.6
GLM-5.1	SWE-Bench Pro 58.4% 超越GPT-5.4和Claude Opus 4.6
Qwen 3.6 Plus	跨入百万token上下文行列

中国AI研发进入“持续在场”阶段

- ✓ 2025年1月，DeepSeek R1发布引发全球震动，被称为AI领域的“新哥特尼克时刻”
- ✓ 2026年4月，V4落地，中国AI研发从“偶尔令人震撼”走向“持续在场”
- ✓ Qwen、Kimi、GLM、MiniMax、MiMo等共同构建强大开源生态，系统性能不断增强

“不诱于誉，不恐于诽，率道而行，端然正己。”

—— DeepSeek V4发布公告



DeepSeek V4：用技术创新降低智能门槛，让每个开发者都能站在AI时代的最前沿。



一、时点：三次跳票之后

DeepSeek这一天来得不算突然，但比所有人预期的都晚。

从去年底到今年2月、3月、4月初，DeepSeek V4的发布窗口推了三次，行业里各大模型的频繁更新几乎进入了最密集的时刻。

必须承认在2026年4月末，百万上下文已称不上是绝对领先，Gemini、Qwen等都到了这个量级。这次DeepSeek V4落地，要回答的不是“能不能做到”，而是“做到了之后，成本撑不撑得住”。

V4给出的回答是一套全新的混合注意力架构。它在token维度引入压缩机制，结合自研的DSA稀疏注意力，其让模型在处理超长文本时不再对所有token做全量计算，而是区分轻重：强关联的token精读，弱关联的压缩或跳过。

这套机制从预训练阶段就改变了模型处理长序列的方式。根据技术报告，V4还引入了流形约束超连接（mHC），替代传统残差连接来增强深层网络信号传播的稳定性，并使用Muon优化器提升训练收敛速度。整个模型在超过32万亿token上完成了预训练。

实际效果用两个数字就能概括：在百万token上下文设置下，V4-Pro每处理一个token的算力消耗只有V3.2的27%，KV缓存占用只有10%。

官方在公告里说得更清楚：“从现在开始，1M上下文将是DeepSeek所有官方服务的标配。”这意味着长上下文正式从“加价功能”变成了“默认配置”，这对整个行业的成本预期是一次重新校准。

二、矩阵：两型号+三模式

在这次发布中，旗舰V4-Pro和经济型V4-Flash都支持三种推理模式：非思考模式（快速响应）、思考模式-高（显式推理链）、思考模式-极限（推到模型能力边界）。官方建议复杂Agent场景使用极限模式。

DeepSeek对V4-Pro的定位给了一个直白的对标：内部员工已经把它当作日常Agentic Coding工具使用，体验优于Claude Sonnet 4.5，交付质量接近Opus 4.6非思考模式，但与Opus 4.6思考模式仍有差距。

推理性能方面，在数学、STEM和竞赛型代码评测中超越当前所有已公开评测的开源模型，比肩世界顶级闭源模型；世界知识大幅领先其他开源模型，稍逊于Gemini-Pro-3.1。

V4-Flash的推理能力接近Pro版，但世界知识储备稍逊；简单Agent任务旗鼓相当，高难度任务有差距。

这组自评有一处值得注意，DeepSeek主动划出了与Opus 4.6思考模式的差距，在国产大模型发布话术的传统里，这种克制本身就是一种技术自信的表达。

三、扳机：Token价格差

随着预览版的公开，V4的API定价已随发布同步上线。

每百万token，V4-Flash的输入价是1元（缓存命中0.2元），输出价2元；V4-Pro的输入价12元（缓存命中1元），输出价24元。官方注明这是预览版定价，Pro版下半年算力扩容后将大幅下调。

这组数字需要放在坐标系里看才有意义。

Flash版每百万token输入1元——这个价格让几乎所有开发者都能无负担地调用一个万亿参数级MoE架构的开源旗舰模型。



对比之下，GPT-5.5前一天刚刚上线的输出定价是30美元/百万token，折合人民币超过200元，与V4-Flash的2元输出价差超过100倍。即便拿V4-Pro的24元输出价来比，差距仍在一个数量级以上。

Pro版当前价格较高，但官方已经给出了明确的降价预期。背后的约束并非定价策略，而是算力供给——Pro版的高性能推理对芯片资源要求更高，当前服务吞吐十分有限。这也从侧面印证了V4在自主算力适配上的深度投入。

缓存命中的折扣幅度同样值得关注。Flash的缓存命中价只有未命中价的五分之一，Pro是十二分之一。

这意味着DeepSeek在用定价杠杆鼓励一种使用方式：把系统提示词、工具定义、文档模板等固定内容放在请求头部，让缓存机制自动生效，对于Agent类应用，这恰好是最典型的调用模式。

用Flash的白菜价铺量，用Pro的高阶能力撑住顶端场景，用缓存机制降低Agent开发者的边际成本。每一刀都切在应用层最痛的地方。

四、方向：Agent底座

如果在V4的发布里只提炼一个关键标签，那么Agent比百万上下文或许更重要。

官方明确写道：V4针对Claude Code、OpenClaw、OpenCode、CodeBuddy等主流Agent产品进行了专项适配和优化，在Agentic Coding评测中达到开源模型最佳水平。这份适配名单同时包含Anthropic的产品和国产开发者工具。

这个信号很明确，DeepSeek不打算自建应用生态，而是要成为Agent时代的底座供应商。

这个选择放在当前的行业格局里是一个有意识的取舍。Anthropic的年化收入过去四个月从90亿美元翻到300亿美元，增量几乎全部来自Claude Code；Cursor一个代码编辑器估值已到600亿美元。应用层的钱在那里，但DeepSeek选择不去碰。

这说明它的定位不是下一个Anthropic，更有可能是Agent时代的基础设施。

长上下文+低价API+Agent适配的组合，本质上是把自己做成一个供电站，让所有电器都能更便宜地跑起来。

对于那些整天跟Token消耗作斗争的Agent开发者来说，V4打开的是一个具体的场景：把整个代码仓库、完整的需求文档、几百轮历史对话一次性塞进调用，不再需要切分、检索、摘要这套工程绕路。过去做Agent最头疼的就是上下文管理——每多一轮对话，token就指数级堆叠，成本和稳定性同时恶化。

V4如果能在真实负载下兑现承诺，这个痛点的成本结构将被改写一次。

五、生态：模型、算力赛跑

V4延期的这段时间里，国产开源大模型的战场从未安静过。

今年农历年前后出现了一次密集爆发：阿里Qwen3.5总参数3970亿、激活仅170亿，百万token的API价低至0.8元，是Gemini-3-Pro的十八分之一；智谱GLM-5的代码生成的HumanEval96.2%打到开源最强。

4月继续加速：Kimi K2.6在SWE-Bench Verified上拿到80.2%，几乎追平Claude Opus 4.6；智谱GLM-5.1在SWE-Bench Pro上以58.4%超过了GPT-5.4和Claude Opus 4.6；Qwen 3.6 Plus也跨入百万token上下文行列。

Qwen、Kimi、GLM、MiniMax、MiMo，这些国产模型在国际开发者社区的出现频率正在肉眼可见地上升。

生态：模型、算力赛跑

国产开源大模型密集爆发，算力适配同步落地，系统性创新生态加速成型

1 模型赛跑：国产开源大模型密集爆发

今年农历年前后

Qwen3.5 总参数3970亿 激活170亿 百万token API价 0.8元 是Gemini-3-Pro的 十八分之一	GLM-5 代码生成 (HumanEval) 96.2% 打到开源最强
--	---

4月持续加速

Kimi K2.6 SWE-Bench Verified 80.2% 几乎追平 Claude Opus 4.6	GLM-5.1 SWE-Bench Pro 58.4% 超越GPT-5.4和 Claude Opus 4.6	Qwen 3.6 Plus 跨入 百万token 上下文行列
--	--	--

Qwen、Kimi、GLM、MiniMax、MiMo
国产模型在国际开发者社区的出现频率肉眼可见地上升

2 算力适配：模型发布首日，全系列国产算力支持

华为昇腾：全面适配 V4-Flash 和 V4-Pro
双方芯模技术紧密协同，适配工作从模型
研发阶段就在同步推进

性能数据（基于昇腾）

场景/配置	V4-Pro	V4-Flash
昇腾 950超节点 8K输入时延	约20ms	约10ms
单卡吞吐 (TPS)	4700	1600
昇腾A3超节点 64卡大规模部署	—	单卡吞吐 >2000 TPS

昇腾950 三项代际升级

- 原生支持 FP8 / MXFP4 低精度格式 内存占用降低 50%以上 算力翻倍
- 针对MoE 稀疏访存特征 硬件级优化
- Vector与Cube 单元共享片上 内存新设计

寒武纪：Day 0 适配，开源交付
Cambricon 寒武纪

- 基于vLLM框架完成 V4-Flash和V4-Pro适配
- 发布当天代码开源到 GitHub

工程生态同步落地

- 华为同步开源PyPTO编程范式 让Attention压缩、mHC等复杂算子 开发周期从周级缩短到天级 开发者无需处理硬件同步和数据搬运

3 深度协同：从研发到部署的系统性匹配

DeepSeek为底层算力迁移付出巨大工程代价 重写大量核心代码，完成从CUDA生态 到昇腾CANH框架的艰难技术过渡， 是V4反复跳票的重要原因之一

模型与算力深度咬合，非临时适配 两家国产芯片厂商在模型发布首日就拿出 完整部署部署方案，适配代码开源，给出 具体的硬件协同特征数据

意义超越单一模型评测 万亿参数级开源旗舰模型，发布首日即可能在 国产算力全系列产品上，标志着系统性能力 的成型

良性竞争，共同构建繁荣生态

模型持续突破性能与成本边界
算力不断优化效率与开放生态
开发者获得更强更普惠的工具
中国AI生态走向全球舞台中央

不断连续性创新的中国AI生态

模型 竞争中协同 协同中进化 算力

4 从“斯普特尼克时刻”到“持续在场”

2025年1月
DeepSeek R1发布
引发美股单日市值暴增
超1万亿美元

人工智能领域的
“斯普特尼克时刻”

2026年4月
DeepSeek V4发布
没有戏剧性暴增，
但中国AI研发已进入
“持续在场”阶段

荀子·修身
“不诱于誉，不恐于诽，
率道而行，端然正己。”

这份倔强不只属于DeepSeek，
更属于中国所有开源模型
坚定前行的脚步。

除了模型，算力侧的匹配也在同步落地。

华为在V4发布同日确认昇腾全系列产品——A2、A3及最新的昇腾950已全面适配V4-Flash和V4-Pro。

措辞是“双方芯模技术紧密协同”，意味着DeepSeek和昇腾的适配工作从模型研发阶段就在同步推进。

华为给出了一组具体的性能数据：基于昇腾950超节点，V4-Pro在8K输入场景下实现了约20ms的单token解码时延，单卡吞吐4700 TPS；V4-Flash可以做到约10ms时延，单卡吞吐1600 TPS。

昇腾A3超节点上，V4-Flash在64卡大规模部署下单卡吞吐超过2000 TPS。

这些数字背后是昇腾950在底层架构上的三项代际升级：原生支持FP8/MXFP4等低精度格式（内存占用降低50%以上，算力翻倍）、针对MoE稀疏访存特征的硬件级优化，以及Vector与Cube单元共享片上内存的新设计。

更值得关注的是工程生态层面的动作。

华为同步开源了PyPTO编程范式，让V4新架构中涉及的Attention压缩、mHC等复杂算子的开发周期从周级缩短到天级，开发者不需要手动处理硬件层面的同步和数据搬运。

寒武纪同样在发布当天宣布，已基于vLLM框架完成V4-Flash和V4-Pro的Day 0适配，代码开源到GitHub。

两家国产芯片厂商在模型发布首日就拿出了完整的推理部署方案，这个响应速度本身就说明，适配工作不是临时赶出来的，而是跟模型研发深度咬合了很长时间。

DeepSeek为这次底层算力迁移付出的工程代价不小。据此前报道，团队重写了大量核心代码，完成了从CUDA生态到昇腾CANN框架的整套技术栈迁移，这也是V4反复跳票的原因之一。

但当一个万亿参数级的开源旗舰模型，在发布首日就能跑在国产算力的全系列产品上，适配代码直接开源，推理性能给出了具体的吞吐和时延数据而不是“即将支持”——这件事的意义，已超出了任何单一模型的评测范畴。

无论模型还是算力，它们之间存在竞争关系，但从更大的维度看，它们都在证明了同一件事：

中国AI研发的系统性能力不是一两个特例，而是可以不断连续性创新的生态。

2025年1月，DeepSeek R1发布，引发美股单日市值蒸发超1万亿美元，被业界称为人工智能领域的“斯普特尼克时刻”。

今天V4的发布没有那种戏剧性的震撼，但中国AI研发已经从“偶尔令人震撼”进入了“持续在场”阶段。

DeepSeek在公告末尾引了《荀子》中的一句话：

不诱于誉，不恐于诽，率道而行，端然正己。

放在一家三次跳票、核心人才流失、刚传出融资的公司身上，这句话读起来有几分倔强。

但在整个国产开源模型群体站出来的2026年，这句话不只属于DeepSeek，更属于中国所有AI创新坚定前行的脚步。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码 >

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

👍 88 ★ 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论



1 条评论



见闻用户
8小时前 中国广东省

“不诱于誉，不恐于诽，率道而行，端然正己。”👍👍

👍 0 ↩ 回复

