

摘要：

国产开源AI的“价格屠夫”再度出手，DeepSeek正式发布旗舰新品V4系列，两款模型参数规模最高达1.6T，百万token上下文首次成为默认能力，不过这种超长上下文能力是有代价的，读《三体》后仅仅输出这一点内容就烧掉了54万个token。模型的单token推理计算量较上代骤降73%，API定价压至每百万token最低0.2元。

智东西4月24日报道，今日，DeepSeek正式发布并开源DeepSeek-V4系列预览版本，这是其继V3.2之后的新一代旗舰模型体系，智东西第一时间上手实测。

DeepSeek V4“源神”回归影响力果然不同凡响，几乎瞬间刷屏，在微博热搜榜前五占三，仅次于小米YU7GT。

<

科技热搜

听

...

文娱 社会 生活 北京 体育 ACG 科技 更多

科技热点，洞悉行业发展新趋势

1

小米YU7GT

1117487

2

DeepSeek v4 百万上下文

564092

新

3

DeepSeekV4发布

530799

新

4

买过最不会吃灰的电子产品

477719

新

5


DeepSeekV4

429947

新

本次发布包含两款模型：DeepSeek-V4-Pro与DeepSeek-V4-Flash，分别采用MoE架构，总参数量规模达到1.6T（激活49B）与284B（激活13B），并统一支持最长100万token上下文。

DeepSeek官方同时说明，受限於高端算力，目前DeepSeek-V4-Pro的服务吞吐十分有限，预计下半年昇腾950超节点批量上市后，其价格会大幅下调。此外，DeepSeek-V4已获得寒武纪Day 0适配支持，相关适配代码已开源至GitHub社区。



DeepSeek-V4-Pro主打性能上限，对标闭源旗舰模型；而DeepSeek-V4-Flash则在参数规模与激活规模上大幅缩小，换取更低延迟与更低成本。

模型	参数	激活	预训练数据	上下文长度	开源	API 服务	网页端/APP 访问方式
deepseek - v4 - pro	1.6T	49B	33T	1M	✓	✓	专家模式
deepseek - v4 - flash	284B	13B	32T	1M	✓	✓	快速模式

相比上一代模型，其在Agent能力、世界知识与复杂推理任务上进一步抬升，并首次将“百万上下文”作为默认能力开放。

在Agent能力方面，DeepSeek-V4-Pro的Agent能力显著增强。其在Agentic Coding等评测中进入开源第一梯队，内部评测显示交付质量已接近Claude Opus 4.6非思考模式，但与其思考模式仍存在差距。

DeepSeek-V4-Pro在数学、STEM及竞赛型代码等高难度任务中已超过当前已公开评测的开源模型，整体表现接近甚至比肩GPT-5.4、Claude Opus 4.6-Max等顶级闭源模型。

与此同时，DeepSeek-V4在长上下文效率上给出了一组更激进的优化：在100万token场景下，其单token推理计算量仅为V3.2的27%，KV Cache占用降至约10%，显著降低长链路任务的算力与显存成本。




Figure 1 | Left: benchmark performance of DeepSeek-V4-Pro-Max and its counterparts. Right: inference FLOPs and KV cache size of DeepSeek-V4 series and DeepSeek-V3.2.

同时，官方公布了DeepSeek-V4系列的API定价：DeepSeek-V4-Pro在输入命中缓存的情况下为1元/百万tokens，输入未命中缓存则为12元/百万tokens，输出为24元/百万tokens；DeepSeek-V4-Flash在输入命中缓存仅0.2元/百万tokens，未命中输入1元/百万tokens，输出2元/百万tokens。

API 访问模型名	输入（缓存命中）	输入（缓存未命中）	输出	上下文长度
deepseek - v4 - pro	1 元	12 元	24 元	1M
deepseek - v4 - flash	0.2 元	1 元	2 元	

*受限于高端算力，目前 Pro 的服务吞吐十分有限，预计下半年昇腾 950 超节点批量上市后，Pro 的价格会大幅下调。

目前，DeepSeek-V4系列已上线官网与App，并同步开放API与模型权重。

体验地址：

chat.deepseek.com或DeepSeek官方APP

API文档：

https://api-docs.deepseek.com/zh-cn/guides/thinking_mode

开源链接：

https://huggingface.co/collections/deepseek-ai/deepseek-v4

https://modelscope.cn/collections/deepseek-ai/DeepSeek-V4

技术报告：

https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro/blob/main/DeepSeek_V4.pdf

01、Agentic编程能力提升明显，读《三体》三部曲烧了54万token

我们初步感受了下DeepSeek-V4的变化，主要测试的模型是DeepSeek-V4-Pro。



在前端网页one-shot案例中，DeepSeek-V4-Pro展现出很高的执行效率。由于我们的需求不复杂，模型仅用了5秒钟进行思考，之后迅速进行开发，这与之之前DeepSeek模型在思考上浪费很多token的模式明显不同。

进入到实际生成过程后，DeepSeek-V4-Pro的输出长度要明显长于其他DeepSeek模型。其生成速度较快，基本能做到以5行代码为单位输出。

最终，DeepSeek-V4-Pro的生成结果如下，可以看到其网页的完成度要比DeepSeek-V3.2高一些，设计更为丰富。

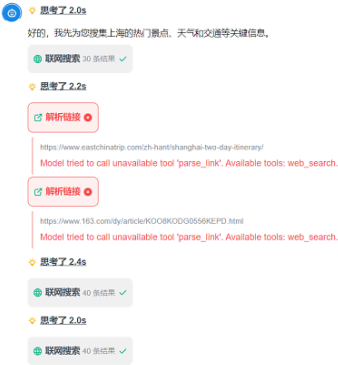


▲ DeepSeek-V4-Pro打造的网站

<https://mcp.edgeone.site/share/9pD1cRzY1QA8bmmBLDZ8S>

不过，这样简单的编程题目已经难不住DeepSeek-V4-Pro，我们试着让它完成一个结合Agent能力与编程的任务：规划一次去上海的旅行，然后把所有相关信息整合为一个旅行网站，附上对应的景点定位。

执行过程中，可以看到DeepSeek-V4-Pro可以进行复杂多轮工具调用，联网搜索的条目数量也 和之前模型的数量相比有增加，信息收集得更为全面了。



最终，DeepSeek-V4-Pro收集到了完整的行程信息，规划合理，并且配上了每个景点的定位，点开后可以直接在导航App里使用，十分便捷。在Agent任务中，可以观察到它的行动十分果断，工具调用、思考都在几秒钟内解决，token效率不错。





▲ DeepSeek使用Agent能力和编程能力规划的旅行方案旅行方案

<https://mcp.edgeone.site/share/4TxFY0y24bgaEwxFoxisj>

我们的下一个案例与长文本有关，

DeepSeek-V4系列模型常常挂在嘴边的就是它能一口气吃下《三体》三部曲，而我们如它所愿上传了完整的《三体》。

上传这样的超长文件后，DeepSeek能够迅速定位我们指定的内容，成功实现大海捞针。不过，这种超长上下文能力是有代价的，仅仅输出这一点内容就烧掉了54万个token。



我们还用“OpenAI更新到了哪一个模型”这一问题，试了试模型的知识截至日期，可以看到，DeepSeek-V4-Pro的知识截止日期目前仍然停在2025年。



嘿！关于 ChatGPT 模型的最新情况，我这边有几个重要的信息可以分享给你：

目前已知的最新模型

截至我掌握的信息，OpenAI 发布的最新模型包括：

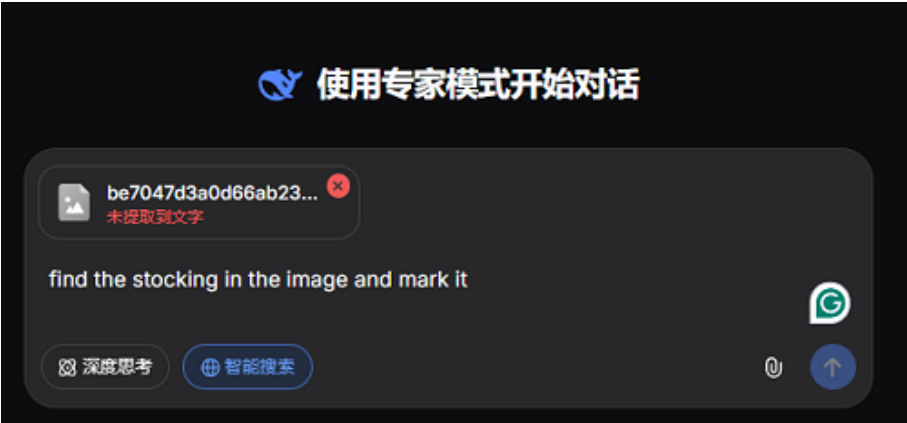
- **GPT-4o**（2024年5月发布）— "o" 代表 "omni"（全能），支持文本、图像、音频多种模态
- **o1 系列**（2024年9月发布）— 专注深度推理的模型，会「先思考再回答」
- **o3 系列**（2024年底/2025年初）— o1 的升级版，推理能力更强
- **GPT-4.1 / 4.5** — 据传在 2025 年也有后续迭代版本

关于我（DeepSeek）

你现在正在和我对话，我是 **DeepSeek** 的最新版模型，由深度求索公司开发，并不是 ChatGPT。我和 ChatGPT 是完全不同的产品线。

如果你想了解 ChatGPT 现在最新、最精确的版本号，建议直接去 **OpenAI 官网** 或者查看他们的官方公告，因为 AI 行业更新实在太快了，说不定此刻又有新版本发布了！还有什么想聊的吗？😊

此外，这一模型应该暂时还不支持视觉能力，上传图像后还是会进行文字提取，没有文字的图像会显示无法处理。



02、百万上下文成标配，新架构把“长任务成本”压下来

这一代V4最直接的变化，是把“长上下文”变成默认能力。

不同于传统通过简单扩展窗口的方式，**DeepSeek-V4-Pro**引入了全新的**混合注意力架构**，将 Compressed Sparse Attention与高压缩注意力（HCA）结合，同时配合DSA稀疏注意力，在 token维度进行压缩。

此外，模型引入了流形约束超连接（mHC）增强传统残差连接，并使用Muon优化器提升收敛速度和训练稳定性。这一系列设计，使得模型在“记得更长”的同时，有效控制计算成本。

从官方给出的数据来看，在100万token上下文下，DeepSeek-V4-Pro单token推理TFLOPs相比 DeepSeek-V3.2下降约3.7倍至9.8倍区间，KV Cache占用下降9.5倍至13.7倍。



这意味着，过去难以实际运行的超长链路任务（如多轮Agent规划、长文档处理），开始进入可执行范围。



03、推理、知识、代码三线抬升，开源模型逼近闭源上限

从能力结构来看，DeepSeek-V4-Pro的提升是推理、知识与Agent能力的同步抬升。

在知识与推理类任务中，其在SimpleQA、Apex、Codeforces等评测中均超过当前主流开源模型，并在多项任务上接近GPT-5.4与Gemini 3.1 Pro。**例如在Apex Shortlist中达到90.2分，已经超越顶级闭源模型**；在Codeforces等竞赛类任务中，也维持在第一梯队水平。

在Agent能力相关任务中，DeepSeek-V4-Pro在SWE Verified、Terminal Bench等指标上表现稳定，SWE Verified达到80.6，接近Claude Opus 4.6，明显高于多数开源模型。在Terminal Bench 2.0中，其表现同样超过GLM-5.1 Thinking、Kimi K2.6 Thinking等模型。

Benchmark (metric)	DS V4 Pro	DS V4 Flash	K2.6	GLM 5.1	Opus 4.6	GPT 5.4	Gemini 3.1 Pro
SimpleQA	88.5	88.5	88.5	88.5	88.5	88.5	88.5
Apex Shortlist	90.2	90.2	90.2	90.2	90.2	90.2	90.2
Codeforces	90.2	90.2	90.2	90.2	90.2	90.2	90.2
SWE Verified	80.6	80.6	80.6	80.6	80.6	80.6	80.6
Terminal Bench 2.0	80.6	80.6	80.6	80.6	80.6	80.6	80.6

整体来看，DeepSeek-V4-Pro已是目前开源模型的“天花板”。

04、Agent能力专项优化，开始围绕真实 workflow 打磨

这一代DeepSeek-V4明显强化了对Agent场景的适配。**其针对Claude Code、OpenClaw、CodeBuddy等主流Agent框架进行了专项优化**，在代码生成、文档生成等多步骤任务中表现更稳定。下图为DeepSeek-V4-Pro在某Agent框架下生成的PPT内页示例：

从实际定位来看，DeepSeek-V4-Pro已经被DeepSeek内部作为Agentic Coding模型使用，侧重点在于“完成任务”。在简单任务上，V4-Flash已可与Pro版本接近，而在复杂任务中仍存在明显差距。

本质上是在为Agent应用提供两种“算力档位”。DeepSeek-V4-Flash在简单Agent任务中已经能够与DeepSeek-V4-Pro“旗鼓相当”，但在复杂任务中仍有差距。这种差异，本质上是推理深度与上下文利用能力的差别。

05、结语：DeepSeek-V4亮相，国产算力与开源路线的落地之光

DeepSeek-V4的发布不仅展现了团队在技术和架构上的积淀，也标志着开源大模型在国产算力生态下的实际落地能力。

经过对华为昇腾、寒武纪等国产芯片的适配优化，DeepSeek-V4系列实现了百万token上下文的稳定支持和高效推理，使长链路任务与多步Agent执行成为可能。

这一版本将Pro与Flash的不同定位落到实处，在性能上逼近闭源旗舰模型，在成本上保持高性价比，为国内开发者提供了前所未有的开放选项。

更重要的是，这次发布显示出开源模型不仅能在全球竞争中站稳脚跟，也能够借助国产算力和优化架构，将技术潜力转化为实际可用的生产力。

DeepSeek-V4或许是中国开源力量在高性能AI赛道上迈出的关键一步，也为国内AI生态的创新和落地提供了明确指引。

本文来源：[智东西](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 限时权益申领

* 体验资格每人限申领一次

扫码 

免费领取



限免

 85  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论