

摘要：

DeepSeek V4正式版正式发布后将同步调整API定价策略，引入峰谷定价机制。API 高峰时段价格将是平时价格的2倍，高峰时间段为每天的上午9 点到12点、下午2点到6点。

DeepSeek在产品迭代与技术开源两条线上同步提速。正式版V4宣布7月中旬上线，届时API将启动峰谷定价机制，高峰时段价格翻倍；联合北京大学发布的推理加速框架DSpark已全量部署于线上服务，使单用户生成速度最高提升85%。两项进展叠加释出，显示这家公司正将商业化压力管理与技术能力兑现同步推进。

6月29日，DeepSeek团队宣布DeepSeek V4正式版计划于7月中旬上线，并同步引入峰谷定价策略。根据公布的价格表，**高峰时段API价格为平时价格的两倍，平时价格与现行V4 API定价持平**。高峰时段界定为每日上午9时至12时及下午2时至6时。官方表示，此举旨在更合理地配置资源、提升服务稳定性。

在技术层面，DeepSeek于6月27日联合北京大学发布推理加速框架DSpark，并同步开源全栈推测性解码工具链DeepSpec。论文由公司创始人梁文锋本人署名，已上传至公开代码库。实测显示，DSpark部署后V4-Flash单用户生成速度提升60%至85%，V4-Pro提升57%至78%，效果已在线上服务全量验证。这也是DeepSeek完成500亿元融资后首次对外发布的开源技术成果。

对API用户而言，峰谷定价将直接推高工作时段使用成本；对开发者而言，推理速度的显著提升或可在高并发场景下部分抵消成本压力，并进一步降低推理优化的落地门槛。

# DeepSeek V4 正式版

发布计划及计费调整说明



## deepseek-v4-pro

| 计费项                   | 平时价格        | 高峰时段价格    |
|-----------------------|-------------|-----------|
| 百万tokens输入<br>(缓存命中)  | 0.0<br>25 元 | 0.05<br>元 |
| 百万tokens输入<br>(缓存未命中) | 3 元         | 6 元       |
| 百万tokens输出            | 6 元         | 12 元      |

## deepseek-v4-flash

| 计费项                   | 平时价格       | 高峰时段价格    |
|-----------------------|------------|-----------|
| 百万tokens输入<br>(缓存命中)  | 0.0<br>2 元 | 0.04<br>元 |
| 百万tokens输入<br>(缓存未命中) | 1 元        | 2 元       |
| 百万tokens输出            | 2 元        | 4 元       |

⌚ \*\* 高峰时段定义: 每日 9:00~12:00 和 14:00~18:00 (北京时间)

### V4正式版上线与峰谷定价机制

DeepSeek V4模型预览版于4月24日上线并同步开源，具备百万字超长上下文，在Agent能力、世界知识及推理性能上均实现国内与开源领域领先。正式版预计于7月中旬推出，将带来进一步的功能优化与性能提升。

V4系列分为两个规格：旗舰版V4-Pro总参数量达1.6万亿，激活参数49B，预训练数据量33T，支持1M上下文，网页端以专家模式运行；轻量版V4-Flash总参数284B，激活参数13B，预训练数据32T，同样支持1M上下文，网页端以快速模式运行。两款模型均已开源并提供API服务。

| 模型                    | 参数   | 激活  | 预训练数据 | 上下文长度 | 开源 | API 服务 | 网页端/APP<br>访问方式 |
|-----------------------|------|-----|-------|-------|----|--------|-----------------|
| deepseek - v4 - pro   | 1.6T | 49B | 33T   | 1M    | ✓  | ✓      | 专家模式            |
| deepseek - v4 - flash | 284B | 13B | 32T   | 1M    | ✓  | ✓      | 快速模式            |

峰谷定价是此次正式版更新的另一核心变量。该机制将每日API使用成本切分为两个层级，平时价格维持现行水平不变，高峰时段收费翻倍。对于在工作时段密集调用API的企业用户而言，成



本影响将较为直接；而有条件将批量任务迁移至低峰时段运行的用户，则可在定价调整后维持原有成本水平。

## DSpark：推测性解码的工程化落地

DSpark并非全新架构的模型，而是在现有V4模型基础上引入了推测性解码模块，核心在于工程层面的优化落地。推测性解码的基本逻辑是：先由轻量级小模型快速生成候选token（草稿），再由大模型并行验证，接受符合目标分布的连续前缀，从而在不损失生成质量的前提下提升速度。



### DSpark: Confidence-Scheduled Speculative Decoding with Semi-Autoregressive Generation

Xin Cheng<sup>1,2,\*</sup>, Xingkai Yu<sup>2,†</sup>, Chenze Shao<sup>2,\*</sup>, Jiashi Li<sup>2,\*</sup>, Yunfan Xiong<sup>2,\*</sup>,  
Yi Qian<sup>2</sup>, Jiaqi Zhu<sup>2</sup>, Shirong Ma<sup>2</sup>, Xiaokang Zhang<sup>2</sup>, Jiasheng Ye<sup>2</sup>, Qinyu Chen<sup>2</sup>,  
Chengqi Deng<sup>2</sup>, Jiping Yu<sup>2</sup>, Damai Dai<sup>2</sup>, Zhengyan Zhang<sup>2</sup>, Yixuan Wei<sup>2</sup>, Yixuan Tan<sup>2</sup>,  
Wenkai Yang<sup>2</sup>, Runxin Xu<sup>2</sup>, Yu Wu<sup>2</sup>, Zhean Xu<sup>2</sup>, Xuanyu Wang<sup>2</sup>, Muyang Chen<sup>2</sup>,  
Rui Tian<sup>2</sup>, Xiao Bi<sup>2</sup>, Zhewen Hao<sup>2</sup>, Shaoyuan Chen<sup>2</sup>, Huanqi Cao<sup>2</sup>, Wentao Zhang<sup>2</sup>,  
Anyi Xu<sup>2</sup>, Huishuai Zhang<sup>1</sup>, Dongyan Zhao<sup>1</sup>, Wenfeng Liang<sup>2</sup>  
<sup>1</sup>Peking University <sup>2</sup>DeepSeek-AI  
{chengxin, xing kai, shaochenze, js.li, yunfanxiong}@deepseek.com

#### Abstract

Speculative decoding accelerates Large Language Model (LLM) inference by decoupling draft generation from target verification. While recent parallel drafters efficiently propose long token sequences in a single forward pass, they suffer from rapid acceptance decay due to a lack of inter-token dependencies. Furthermore, indiscriminately verifying these extended blocks wastes critical batch capacity on tokens with high rejection risks, severely degrading throughput in high-concurrency serving systems. We introduce DSpark, a speculative decoding framework that unifies high-throughput parallel generation with adaptive, load-aware verification. To maintain draft quality, DSpark utilizes a semi-autoregressive architecture—coupling a parallel backbone with a lightweight sequential module—to introduce intra-block dependency modeling and mitigate suffix decay. To optimize system efficiency, DSpark employs confidence-scheduled verification, dynamically tailoring the verification length for each request based on estimated prefix survival probabilities and engine-specific throughput profiles. On offline benchmarks across diverse domains, DSpark substantially improves the accepted length over state-of-the-art autoregressive and parallel drafters. When deployed within the DeepSeek-V4 serving system under live user traffic, DSpark successfully mitigates verification waste. Compared to the established production baseline (MTP-1), DSpark accelerates per-user generation speeds by 60%–85% at matched throughput levels. More importantly, by preventing severe throughput degradation under strict interactivity constraints, it enables performance tiers that were previously unattainable, shifting the Pareto frontier of our serving system. To facilitate community progress, we open-source the DSpark checkpoints alongside DeepSpec, an algorithm-driven training repository for speculative decoding.

DSpark针对这一技术路线在实际落地中的两个核心瓶颈提出了针对性方案。

其一是半自回归生成架构，主要解决并行草稿的“后缀衰减”问题——并行独立生成各位置token时，位置间缺乏依赖约束，越往后错误累积越严重，验证接受率随之断崖式下跌。DSpark采用“并行主干+轻量串行头”的两阶段设计：并行主干保留速度优势，串行模块则补充相邻token间的依赖关系，修正语义冲突，直接提升每轮验证的有效接受长度。测试显示，2层深度的DSpark有效接受长度甚至超过5层深度的纯并行方案DFlash。




Figure 1 | The DSpark architecture and decoding cycle. Given prompt tokens  $[ABC]$ , the target model executes one step to generate the next token  $[D]$ , which serves as the anchor for the drafting phase. Using  $[D]$  as the input, DSpark employs a heavy parallel backbone and a lightweight sequential head to generate draft tokens  $[EFGH]$  along with their corresponding confidence scores  $[c_1 \sim c_4]$ . The Hardware-Aware Prefix Scheduler then evaluates these scores to retain the prefix  $[EFG]$  and drop the low-confidence token  $[H]$ . Finally, the target model verifies the scheduled prefix in parallel. As illustrated,  $[E]$  and  $[F]$  are accepted while  $[G]$  is rejected, prompting the model to generate a corrected token  $[G^*]$  to complete the current round.

In combination, the two components let DSpark draft better and verify smarter. We detail each below.

其二是置信度调度验证机制，针对全量验证导致的算力浪费问题。DSpark在草稿模型上增加置信度评分模块，实时预测每个候选token的条件接受概率，并通过“顺序温度缩放”校准方法将评分误差从3%-8%压缩至约1%。在此基础上，调度器根据实时负载动态调整验证长度：低并发时拉满算力，高并发时主动裁剪低价值token，避免资源争抢与速度骤降。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

**限时权益申领**

\* 体验资格每人限申领一次

**扫码**

**免费领取**

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

469 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论

