

摘要：

DeepSeek正式发布并开源全新系列模型DeepSeek-V4预览版，分为Pro和Flash两个版本。V4-Pro在Agent能力、世界知识和推理性能上达到开源领先水平，可比肩顶级闭源模型；V4-Flash参数更小，速度更快、成本更低。两款模型均支持百万字（1M）超长上下文，采用创新注意力机制，大幅降低计算与显存需求。

全新系列模型 DeepSeek-V4 的预览版本正式上线并同步开源。

4月24日，中国人工智能公司DeepSeek再度向开源社区投下重磅，其全新系列模型DeepSeek-V4预览版正式发布并同步开源，**在Agent能力、世界知识与推理性能三大维度宣称达到国内及开源领域领先水平。**

DeepSeek-V4分为Pro与Flash两个版本，均支持百万（1M）token超长上下文，两个版本均大幅降低了对计算和显存的需求。

模型	参数	激活	预训练数据	上下文长度	开源	API 服务	网页端/APP 访问方式
deepseek - v4 - pro	1.6T	49B	33T	1M	✓	✓	专家模式
deepseek - v4 - flash	284B	13B	32T	1M	✓	✓	快速模式

API服务同步上线，开发者将model参数修改为deepseek-v4-pro或deepseek-v4-flash即可调用，接口兼容OpenAI ChatCompletions与Anthropic两套标准。

DeepSeek同时披露，受限于高端算力供给，Pro版本当前服务吞吐十分有限，预计下半年随华为昇腾950超节点批量上市后，Pro版本价格将大幅下调。

值得注意的是，昇腾CANN将在16点直播DeepSeek V4在昇腾平台的首发。



2.2万

粉丝

15

关注

1.6万

获赞

+ 关注

昇腾CANN

LV4

带你掌握AI开发技术

详情

主页

动态

投稿

收藏

 **昇腾CANN**
5分钟前

点击预约按钮，不错过直播

直播预约：DeepSeekV4昇腾首发

今天 16:00直播 181人预约

🔔 预约

🔗 2

💬 15

👍 17

此次发布与OpenAI前一天推出GPT-5.5几乎同步落地，两款产品定价策略截然对立。有网友指出：

GPT-5.5昨日以每百万输出token 30美元的定价上线，DeepSeek V4今日以MIT许可证开源发布，AI智能的成本底线刚刚崩塌，每一家AI产品公司都不得不重新审视自己的利润结构。

 **Trey Smith** ✓
@trey_smith

🔄 翻译自 英语 显示原文

在 24 小时内发布了两个前沿模型，但商业模式完全相反。昨天 GPT-5.5 以 30 美元/百万输出令牌的价格推出，今天 deepseek v4 则采用 MIT 许可发布。智能的成本底线刚刚崩塌，每家 AI 产品公司都必须重新思考它们的利润结构。

评价此翻译：👍 🗨

上午11:47 · 2026年4月24日 · 35 查看

网友Enrico亦评价称DeepSeek V4“真的令人印象深刻，快速、智能”，不过他认为输出价格为每百万token 3.48美元，“并不便宜”，但表示LocalAI将推动该模型面向更广泛用户群体普及。

📱

🔄

✍

⚠

⬆

 翻译自 英语 显示原文 

Deepseek V4 真的令人印象深刻。快速、智能、额外 resourceful (已经扫描了我全部 2700 条聊天记录, 对我了如指掌!)

它不便宜, 输出价格 3.48 美元, 但 @LocalAI_API 将把这个模型推向大众



GG @deepseek_ai

评价此翻译:  


上午11:48 · 2026年4月24日

DeepSeek-V4-Pro: 性能比肩顶级闭源模型

DeepSeek-V4-Pro是本次发布的旗舰版本, 官方将其定位为性能比肩顶级闭源模型。

Benchmark (metric)		DS-V4-Pro	DS-V4-Flash	K2.6	GLM-5.1	Opus-4.6	GPT-5.4	Gemini-3.1-Pro
Reasoning Effort		Max	Max	Thinking	Thinking	Max	xHigh	High
Knowledge & Reasoning	MMLU-Pro (EM)	87.5	86.2	87.1	86.0	89.1	87.5	91.0
	SimpleQA-Verified (Pass@1)	57.9	34.1	36.9	38.1	46.2	45.3	75.6
	Chinese-SimpleQA (Pass@1)	84.4	78.9	75.9	75.0	76.2	76.8	85.9
	GPQA Diamond (Pass@1)	90.1	88.1	90.5	86.2	91.3	93.0	94.3
	HLE (Pass@1)	37.7	34.8	36.4	34.7	40.0	39.8	44.4
	LiveCodeBench (Pass@1)	93.5	91.6	89.6	-	88.8	-	91.7
	Codeforces (Rating)	3206	3052	-	-	-	3168	3052
	HMMT 2026 Feb (Pass@1)	95.2	94.8	92.7	89.4	96.2	97.7	94.7
	IMOAnswerBench (Pass@1)	89.8	88.4	86.0	83.8	75.3	91.4	81.0
	ApexK (Pass@1)	38.3	33.0	24.0	11.5	34.5	54.1	60.9
	Apex Shortlist (Pass@1)	90.2	85.7	75.5	72.4	85.9	78.1	89.1
Long	MRCR 1M (MMR)	83.5	78.7	-	-	92.9	-	76.3
Context	CorpusQA 1M (ACC)	62.0	60.5	-	-	71.7	-	53.8
Agentic	Terminal Bench 2.0 (Acc)	67.9	56.9	66.7	63.5	65.4	75.1	68.5
	SWE Verified (Resolved)	80.6	79.0	80.2	-	80.8	-	80.6
	SWE Pro (Resolved)	55.4	52.6	58.6	58.4	57.3	57.7	54.2
	SWE Multilingual (Resolved)	76.2	73.3	76.7	73.3	77.5	-	-
	BrowseComp (Pass@1)	83.4	73.2	83.2	79.3	83.7	82.7	85.9
	HLE w/tools (Pass@1)	48.2	45.1	54.0	50.4	53.1	52.0	51.6
	GDPval-AA(E10)	1554	1395	1482	1535	1619	1674	1314
	MCPAtlas Public(Pass@1)	73.6	69.0	66.6	71.8	73.8	67.2	69.2
	Toolathlon (Pass@1)	51.8	47.8	50.0	40.7	47.2	54.6	48.8

在推理性能方面, V4-Pro在数学、STEM及竞赛型代码评测中宣称超越当前所有已公开评测的开源模型, 并取得比肩世界顶级闭源模型的成绩。



世界知识评测方面，V4-Pro大幅领先其他开源模型，仅稍逊于Google的Gemini-Pro-3.1。

Agent 能力大幅提高。相比前代模型，DeepSeek-V4-Pro 的Agent能力显著增强。在Agentic Coding评测中，V4-Pro已达到当前开源模型最佳水平，并在其他Agent相关评测中同样表现优异。

目前DeepSeek-V4已成为公司内部员工使用的Agentic Coding模型，据评测反馈使用体验优于Sonnet 4.5，交付质量接近Opus 4.6非思考模式，但仍与Opus 4.6思考模式存在一定差距。

DeepSeek-V4 发布同时，也公布了其详细的技术报告。



DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence

DeepSeek-AI
research@deepseek.com

DeepSeek-V4-Flash：更快捷高效的经济之选

V4-Flash定位为更快捷、经济的轻量化选项。

相比 DeepSeek-V4-Pro，DeepSeek-V4-Flash 在世界知识储备方面稍逊一筹，但展现出了接近的推理能力。

由于模型参数与激活规模更小，其API服务在速度与成本上具备明显优势。

在Agent评测中，V4-Flash在简单任务上与V4-Pro表现相当，但高难度任务上仍有差距。

这一定位使V4-Flash更适合对延迟和成本敏感、任务复杂度适中的企业级应用场景。


结构创新和超高上下文效率



DeepSeek-V4在底层架构上引入了一种全新注意力机制。

在token维度进行压缩，并结合自研DSA稀疏注意力技术（DeepSeek Sparse Attention），官方称其实现了全球领先的长上下文能力，同时相比传统方法大幅降低了对计算资源和显存的需求。

这一架构创新的直接产物是：**1M上下文窗口将成为DeepSeek所有官方服务的标配。**



对于需要处理长文档、长对话或复杂多步骤任务的企业用户而言，这一能力的普及具有实质性意义。

在降低算力消耗的同时扩展上下文窗口，亦有助于进一步压低推理成本，强化DeepSeek在性价比维度的竞争优势。

Agent生态适配同步推进

DeepSeek表示，V4系列针对Claude Code、OpenClaw、OpenCode、CodeBuddy等主流Agent产品进行了专项适配与优化，在代码任务及文档生成任务上均有性能提升。

UGC传播与社交裂变设计

SOCIAL AMPLIFICATION & UGC STRATEGY

构建「触点-参与-分享-激励-再参与」的完整社交传播闭环,让每个地铁站成为内容生产引擎

社交传播飞轮

① 触点触发

地铁站内的品牌视觉+互动装置+灯箱构成第一触点，以高颜值、强差异的东方美学设计激发拍照冲动。

② 轻量参与

集章、扭蛋、拍照打卡等<3分钟即可完成的轻互动降低参与门槛，确保通勤场景下的高转化率

③ 即时激励

完成互动即获基券/周边/限定杯套等即时奖励，正向反馈强化参与满足感与品牌好感

④ 社交分享

内嵌话题标签+拍照辅助(补光灯/支架/样片引导)→用户自发发布小红书/抖音/朋友圈

⑤ 二次裂变

UGC内容触达好友圈→「FOMO效应」驱动新用户前往站点打卡→循环往复，声量指数级放大

传播效果预估（保守测算）

单日日均活跃参与 基于数据国内流行行业(游戏/泛娱乐)1~2%互动转化率	80-150人次
单日月均UGC产出 小红书+抖音+微信+微博, 自然内容+营销引流内容	200-500条
单场次全网曝光量 含UGC自然内容+品牌官方内容+达人内容+品牌直播	300-800万次
全年累计UGC触达 自然内容+品牌官方、G3-G4品牌官方内容+品牌直播	1,500-3,000万次
核心话题阅读量 #霸王茶姬北京探店 #CHAGEE正点茶楼 话题总阅读量	500-1,000万
互动-转化率 从互动参与的小红书探店类内容到消费转化链路数据	8-15%

Page 18 / 25

全年营销排期总览

ANNUAL MARKETING CALENDAR OVERVIEW

四季四波段 · 12个月全覆盖 · 30站轮转激活 · 全年品牌声量无空窗

1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月
波段1：春茶初会 (1-3月)			波段2：夏茶有约 (4-6月)			波段3：秋茶叙友 (7-9月)			波段4：冬茶暖聊 (10-12月)		
春分：元宵、春分微酒 清明微酒、桃花微酒			立夏：立夏、立夏微酒 夏至微酒、夏至微酒			暑气：七夕、七夕微酒 立秋微酒、立秋微酒			感恩节：感恩、感恩微酒 冬至微酒、冬至微酒		

月度活动强度

1月 新春開幕、品牌營運 3區	2月 元宵慶祝、喜氣迎新 3區	3月 新春聯歡、施力量 3區	4月 清明節、城市運動 3區
5月 畢業季、青春聚會 3區	6月 端午節、盛夏嘉年華 3區	7月 暑期熱、文化增進 3區	8月 七夕節、中秋聯歡 3區
9月 中秋聯歡、中秋嘉年華 3區	10月 國慶慶祝、感恩回饋 3區	11月 週年聯歡、社區聖誕 3區	12月 聖誕晚宴、跨年嘉年華 3區

Page 21 / 25

全年营销排期总览（二）：站点使用频次与全域覆盖分析

ANNUAL MARKETING CALENDAR OVERVIEW

30站全年轮转逻辑 | 旗舰站复用策略 | 空白区域补充机制

南沙站	  	2次	钱江大学站	  	1次	车公庄站	  	1次
奥林匹克公园站	  	2次	工人体育场站	  	1次	西直门站	  	1次
星火/朝阳站	  	1次	国城路站	  	1次	丰台站	  	1次
四惠站	  	1次	鼓浪屿站	  	1次	金台路站	  	1次
王府井站	  	2次	巴沟站	  	1次	湾子站(南)	  	1次
瀛海路站	  	2次	宋家庄站(10号线)	  	1次	湾子站(北)	  	0次
前门站	  	1次	雍和宫站	  	1次	宋家庄站(亦庄线)	  	0次
鼓楼大街站	  	1次	呼家楼站	  	1次	七里庄站	  	0次
三元桥站	  	1次	旗市口站	  	1次	安华桥站	  	0次
西惠东站	  	1次	东西站	  	1次	花庄站	  	0次

站点使用策略说明:

- 康乐复发活动 (2次/年): 南锣鼓巷、奥林匹克公园、王府井、潘家园——均为高流量重大面积站点,在2个波谱中出现在空间主题、视觉体系、互动内容完全错位替换,确保“一个站点、完全不同的体验”
- 年度精准主题启动周: 星火(太阳站 208m)——全年最大流量仅在星期体现其价值的秋文化波谱启动一次,保持稀缺性与期待感
- 单次精准使用站 (15个): 根据波谱主题与营销节点精准投放,避免资源浪费与消费者审美疲劳
- 未启动站使用站: 七宝镇、安福寺、花庄、宋家庄(亦庄线)、湾子(站)等5站因本年度波谱主题已匹配完成流量季节性因素暂未纳入主力组合,可作为机动补充完成年度优先考虑站点

Page 22 / 26

分波段投资拆解与资源配置

QUARTERLY INVESTMENT BREAKDOWN & RESOURCE ALLOCATION

基于「标准配置档」500万基准方案的四季度资金与资源分配模型

季度预算拆解（基准方案·年度500万）

项目	G1 参展商大会	G2 展商预日会	G3 展商预日友	G4 展商预日展	全年 合计	占比
站点租赁	30	35	38	42	145	29%
展陈搭建	48	52	55	60	215	43%
互动装置	12	15	15	13	55	11%
人员派遣	8	10	10	12	40	8%
主题车服	28	0	30	28	86	—
灯箱广告	10	12	12	15	49	—
创意设计	15	10	10	10	45	9%
合计(万元)	151	134	170	180	635	—

- 以上为《标准配置表》基本方案(含项目管理费及10%应急储备后)的总报价500万,不含增值税。
- Q4预算略高于其他季度, 因含跨年年度服务(意大利/朝鲜站+奥林匹克公园站主站, 增量约25-35%)。
- 互动装置采用模块化设计+季度内容推送, 实际硬件采购成本在Q1要投入较低, Q2-Q4收取硬件交付与部分新增内容。
- 新增硬件Q2交付(提前完成)相应(租/买/广告), 因成本分摊在总报价的15-20%, 集中已体现在优化报价。
- 主舱车舱Q3交付(提前完成)相应(租/买/广告), 因Q2重点为多站点互动硬件升级。

Page 24 / 25

API层面，两款模型最大上下文长度均为1M，同时支持非思考模式与思考模式。

思考模式支持通过reasoning_effort参数设定推理强度，可选high或max档位。DeepSeek建议，针对复杂Agent场景应启用思考模式并将强度设为max。

API 访问模型名	输入（缓存命中）	输入（缓存未命中）	输出	上下文长度
deepseek - v4 - pro	1 元	12 元	24 元	1M
deepseek - v4 - flash	0.2 元	1 元	2 元	

*受限于高端算力，目前 Pro 的服务吞吐十分有限，预计下半年昇腾 950 超节点批量上市后，Pro 的价格会大幅下调。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

1797 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

6 条评论

- 见闻用户

29分钟前 中国吉林省

祝愿和华为的结合渐入佳境，互相成就，那可真就是另起炉灶啦！

0

回复
- 零一

2小时前 中国重庆

开源的优点部分，自然对手也会吸纳迭代，所以头部闭源总是比开源强，感谢DS4开源

0

回复
- 武仙石

2小时前 中国香港

「不诱于誉，不恐于诽，率道而行，端然正己。」我想DeepSeek原文里的这句话同样适用于价值投资者

1

回复
- 杨sir, 力哥

2小时前 中国江西省

强强联手，打破科技叹息之墙

1

回复



MobileUser5706
2小时前 中国广东省

继续尬吹，老套路的，但似乎已经乏力的。

2 回复



wscn1632626958 2小时前 中国广东省

回复 **MobileUser5706**:

这个世界就两个国家吹ai，其他都影也没有，你却吹自己多高级

0 回复

