


摘要：

DeepSeek把这次发布叫“预览版”，技术报告标题里写的是“Towards”——朝向，还在路上。CSA和HCA的设计逻辑今天已经公开，稀疏训练机制在不同任务分布下怎么表现，是接下来开源社区会告诉我们的事。

DeepSeek发布V4预览版，同步开源。公告里有一句话：

“从现在开始，1M（一百万）上下文将是DeepSeek所有官方服务的标配。”



OpenAI和Google早就支持超长上下文了。问题是成本。Transformer注意力机制的计算量随序列长度平方增长——序列翻倍，算力变四倍——处理100万token在传统架构下几乎无法商业化。

技术报告给出了这次架构改动的幅度：在1M token场景下，V4-Pro的单token推理FLOPs只有V3.2的27%，KV缓存用量只有10%。

Benchmark (metric)		DS-V4-Pro	DS-V4-Flash	K2.6	GLM-5.1	Opus-4.6	GPT-5.4	Gemini-3.1-Pro
Reasoning Effort		Max	Max	Thinking	Thinking	Max	xHigh	High
Knowledge & Reasoning	MMLU-Pro (EM)	87.5	86.2	87.1	86.0	89.1	87.5	91.0
	SimpleQA-Verified (Pass@1)	57.9	34.1	36.9	38.1	46.2	45.3	75.6
	Chinese-SimpleQA (Pass@1)	84.4	78.9	75.9	75.0	76.2	76.8	85.9
	GPQA Diamond (Pass@1)	90.1	88.1	90.5	86.2	91.3	93.0	94.3
	HLE (Pass@1)	37.7	34.8	36.4	34.7	40.0	39.8	44.4
	LiveCodeBench (Pass@1)	93.5	91.6	89.6	-	88.8	-	91.7
	Codeforces (Rating)	3206	3052	-	-	-	3168	3052
	HMMT 2026 Feb (Pass@1)	95.2	94.8	92.7	89.4	96.2	97.7	94.7
	IMOAnswerBench (Pass@1)	89.8	88.4	86.0	83.8	75.3	91.4	81.0
	Apex (Pass@1)	38.3	33.0	24.0	11.5	34.5	54.1	60.9
Long Context	Apex Shortlist (Pass@1)	90.2	85.7	75.5	72.4	85.9	78.1	89.1
	MRCR 1M (MMR)	83.5	78.7	-	-	92.9	-	76.3
	CorpusQA 1M (ACC)	62.0	60.5	-	-	71.7	-	53.8
Agentic	Terminal Bench 2.0 (Acc)	67.9	56.9	66.7	63.5	65.4	75.1	68.5
	SWE Verified (Resolved)	80.6	79.0	80.2	-	80.8	-	80.6
	SWE Pro (Resolved)	55.4	52.6	58.6	58.4	57.3	57.7	54.2
	SWE Multilingual (Resolved)	76.2	73.3	76.7	73.3	77.5	-	-
	BrowseComp (Pass@1)	83.4	73.2	83.2	79.3	83.7	82.7	85.9
	HLE w/tools (Pass@1)	48.2	45.1	54.0	50.4	53.1	52.0	51.6
	GDPval-AA (Elo)	1554	1395	1482	1535	1619	1674	1314
	MCPAtlas Public (Pass@1)	73.6	69.0	66.6	71.8	73.8	67.2	69.2
	Toolathlon (Pass@1)	51.8	47.8	50.0	40.7	47.2	54.6	48.8

两把刀

标准Transformer的自注意力，要让每个token跟序列里所有其他token算相关性权重。这是平方复杂度，结构性的，不是工程调优能解决的。

过去的应对方式大体分两类：要么切掉计算范围（滑动窗口只看局部邻居，全局感知随之消失），要么绕开长文本本身（RAG先检索再喂给模型，检索质量成为新的上限）。还有固定稀疏注意力，人工设计稀疏模式来跳过部分计算，但模式是死的，不同任务的信息分布差异大，泛化能力有限。

V4的方案是CSA + HCA混合注意力架构。

CSA（Compressed Sparse Attention）解决的是“算什么”。用轻量级索引器先对所有token对做粗筛，快速估算相关性排序，再精选出需要完整计算的token集合。关键在于这套稀疏结构是可训练的——模型在训练过程中自己学出哪里需要高密度注意力，哪里可以稀疏。V3.2时代的DSA是雏形，V4在此基础上做了进一步演化。


HCA（Heavily Compressed Attention）解决的是“存什么”。在V3时代MLA（Multi-head Latent Attention）的基础上继续推进，把KV向量映射到低维潜空间，推理时解压。叠上FP4+FP8混合精度——MoE专家参数用FP4，其余用FP8——KV缓存的显存占用再砍一半。

两者叠加的效果，直接体现在那两个数字：27%的FLOPs，10%的KV缓存。换算过来，同等算力下能服务的长上下文并发量大约是原来的3到4倍。

技术报告里还有两个细节值得记一下。mHC（Manifold-Constrained Hyper-Connections）对残差连接做了流形约束强化，针对的是1.6T参数超深度模型训练时跨层信号衰减的问题。Muon优化器替代了Adam系列，基于矩阵正交化更新，在超大规模训练里收敛更快，更稳定——Adam在大模型训练里几乎是默认配置，DeepSeek这次换掉了它。

数字

官方给出了与Claude Opus 4.6、GPT-5.4 xHigh、Gemini 3.1 Pro High的全维度横评。



数学和竞赛推理是V4-Pro表现最突出的维度。Codeforces评分3206，四家最高（GPT-5.4是3168，Gemini和V4-Flash都是3052）。Apex Shortlist 90.2，超过Opus 4.6（85.9）、GPT-5.4（78.1）、Gemini（89.1）。IMOAnswerBench 89.8，仅次于GPT-5.4（91.4）。

Agent能力上，SWE Verified 80.6，Opus 4.6是80.8。Toolathlon 51.8，Opus 4.6是47.2，GPT-5.4是54.6。公告里有一句内部评价：V4已成为员工Agentic Coding的主力模型，“使用体验优于Sonnet 4.5，交付质量接近Opus 4.6非思考模式”。

长上下文测评有两个数字要对比着看：MRCR 1M（长文本关键信息检索）83.5，Gemini是76.3，Opus 4.6是92.9。CorpusQA 1M（长文档精准问答）62.0，Opus 4.6是71.7。MRCR侧重检测关键信息是否存在，CorpusQA要在百万token里精准定位并综合分析——两个测评的分化放在一起，说明的东西自然清楚。

综合知识和科学前沿推理：SimpleQA-Verified 57.9，Gemini是75.6。HLE（前沿科学推理超难题集）37.7，四家里最低。

V4-Flash：284B总参数，13B激活，约为Pro版18%的体量，同样支持1M上下文和Think/Think Max推理模式。官方说简单Agent任务上与Pro“旗鼓相当”。

DeepSeek把这次发布叫“预览版”，技术报告标题里写的是“Towards”——朝向，还在路上。CSA和HCA的设计逻辑今天已经公开，稀疏训练机制在不同任务分布下怎么表现，是接下来开源社区会告诉我们的事。

数据来源：DeepSeek官方公告《DeepSeek-V4 预览版：迈入百万上下文普惠时代》（2026年4月24日）；技术报告 DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取

限免

358 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论

草根

2小时前 中国广西

又开始吹了

0

回复

