

摘要：

DeepSeek V4 Flash 日耗 8 万亿 Token，单价仅 2 元/百万 Token，比 Claude Opus 4.8 便宜约 85 倍。它斩掉的不是最强模型，而是调用旗舰模型前“不计成本”的习惯——当便宜几十倍的模型能完成大多数任务，昂贵模型必须证明那几分优势值不值几十倍的价差。

一天，8 万亿 Token。

这是 DeepSeek V4 Flash 一款模型，在一个 AI 编程工具里的单日用量。



开源 AI Agent 工具 OpenCode 发文称，DeepSeek V4 Flash 正式版通过其平台消耗了 8 万亿 Token。其中，5 万亿来自免费额度，另外 3 万亿来自付费套餐 OpenCode Go。

作为对比，大模型路由平台 OpenRouter 接入了 400 多款模型，每月处理约 200 万亿 Token，平均每天约 6.6 万亿。

也就是说，DeepSeek 一款模型，仅仅在 OpenCode 一个入口里，一天消耗的 Token，就超过了 OpenRouter 全平台的日均规模。



OpenRouter 上 DeepSeek V4 Flash 是本周最热门模型

这和 DeepSeek V4 Flash 的低价有关，能力提升，价格不变，原本被压抑的使用需求会迅速释放。但 8 万亿 Token 背后，还有一个更重要的变化：人们使用 AI 的方式已经变了。

过去，我们向模型问一个问题，得到一段回答，任务就结束了。现在的 Agent 会自己读文件、修改代码、运行程序、检查结果，失败后再重新尝试。一次任务可能持续几个小时，调用几十次工具，也可能让多个 Agent 同时工作。

模型写出的代码未必比过去多很多，消耗的 Token 却可能翻上几十倍、几百倍。

有人用 Claude Opus 5 制作一个单页 3D 游戏。模型需要不断生成页面、截图检查、继续修改。最后只是一个 HTML 文件，一句提示词却消耗了 6.9 亿 Token，费用接近 3000 元。

Agent 任务的大量爆发，让模型要证明自己的价值，除了智能的程度，还有性价比的计算；衡量一款模型的单位，从「单次回答有多聪明」变成了「完成一项长任务要花多少钱、多久、失败几次」。

依据这套标准，DeepSeek V4 Flash 开始成了所有模型的斩杀线。

一百万个输出 Token，DeepSeek 收 2 元人民币。Anthropic 的 Claude Opus 4.8，标准价格是 25 美元，约 170 元，只看输出单价，二者相差约 85 倍。

7 月底，DeepSeek 推出 V4 Flash 正式版，保留了模型架构与规模，只是重新做了后训练，重点加强编码和 Agent 任务。



隔天，大模型竞技场 Arena 公布前端编码评测榜单，将 V4 Flash 列入「价格—性能」的前沿模型。截至 Arena 8 月 2 日的页面快照，V4 Flash 的初步排名暂列 Opus 4.8 Thinking 之前。

而在 Artificial Analysis 的 Intelligence Index v4.1 中，V4 Flash Max 得到 50 分，Claude Opus 4.8 Max 得到 56 分。前者跑完整套评测产生的模型调用费约为 72.02 美元，后者则达到 3752.55 美元。

换句话说，Opus 多拿了 6 分，但跑完同一套评测的调用费高出了约 52 倍。

V4 Flash 当然还不能证明自己全面超过 Opus，但只要两者已经能被放进同一轮候选名单，85 倍的价差就足以改变默认选择。

当一款模型的价格高出几十倍，性能领先却只有几个百分点时，这笔账会越来越难算平。

最先受到冲击的，可能并不是最弱的小模型。便宜、快速的小模型仍然适合分类、提取和路由等简单工作。最强的旗舰模型也会仍然用来处理疑难任务，或者成为高失败成本场景里的保险。

真正尴尬的是中间一批模型：它们比 V4 Flash 强一些，却贵几十倍；又没有强到可以稳定解决 V4 Flash 做不了的问题。

这就是 DeepSeek 的斩杀线，它不需要成为最强模型，只要达到「大多数时候可以做完」，就能利用近两个数量级的价格差，把更贵的模型挤出默认调用位。

V4 Flash 为什么能把茅台当矿泉水卖

一直以来，我们都觉得模型的价格大概就是和它的「聪明程度」相关，模型越聪明，自然它就要卖的越贵。

目前主流的几款大模型，Anthropic 家的 Opus 4.8 和 Opus 5 输出都是 25 美元/百万 Token，Fable 5 输出为 50 美元/百万 Token；OpenAI 的 GPT-5.6 在前几天降价后，Luna 输出由 6 美元降至 1.2 美元，Terra 由 15 美元降至 12 美元，Sol 则保持不变，30 美元。

而几款国产大模型，依旧是讨论每百万输出的价格，DeepSeek V4 Flash 是 2 元，刚刚发布的 Qwen 3.8 Max 是 36 元，Kimi K3 是 100 元，GLM 5.2 是 28 元。

DeepSeek 几乎是以免费的价格提供大模型

国产模型之间的对比，还是与国外旗舰模型的对比，DeepSeek 的价格似乎都是一股「清流」，所以是什么造就了模型价格的不同。

最明显的是每生成一个 Token 的直接推理成本。

它受到激活参数量、数字精度、注意力机制、KV Cache 大小、输出长度、硬件利用率和并发量影响。同一款模型，如果能用更少的计算完成一次推理，或者能让更多请求共享缓存，成本就会下降。

V4 Flash 总参数量为 2840 亿，但每个 Token 只激活约 130 亿参数。它同时使用混合注意力结构、低精度权重和针对长上下文的缓存优化。



V4 系列模型架构图

根据 DeepSeek 在四月公开的 Preview 技术报告估算，在一百万 Token 上下文下，V4 Flash 的单 Token 推理计算量约为 DeepSeek V3.2 的 10%，KV Cache 约为后者的 7%。

这是与 V3.2 的内部架构对比，不代表它只需要其他所有模型十分之一的综合成本，但足以解释 DeepSeek 为什么能把长任务价格压低。

DeepSeek V4 系列结构，改造了一个 Transformer 模块里的三个关键部分，将注意力层改为先压缩再找重点的 CSA 机制和更极致的压缩但全部浏览的 HCA 机制，两种交错排列以平衡成本。

V4 的前馈层沿用 DeepSeekMoE：模型包含大量细分专家和少量共享专家，每个 Token 只被路由到其中一小部分专家。

因此 V4 Flash 虽然共有 2840 亿参数，每个 Token 实际激活的只有约 130 亿；V4 Pro 总参数达到 1.6 万亿，实际激活约 490 亿。它获得了大模型的知识 and 容量，但不需要每生成一个 Token 都运行全部参数。



其次是完成的服务成本，从模型训练、后训练到评测、安全，以及推理基础设施、空闲算力等服务，这些成本虽然不会出现在 Token 账单里，但是必须由模型厂商承担。

最后是商业定价，API 价格并不是简单的成本加成，厂商还需要考虑市场份额、用户迁移成本、品牌溢价、服务能力，以及客户愿意为可靠性支付多少钱。

所以，模型价格从来不是一张纯粹的成本表。它同时反映了模型需要多少算力，也反映了厂商认为自己的能力、品牌和可靠性值多少钱。

OpenAI 和 Anthropic 的高价格，可能同时包含更高的推理成本、产品生态、安全和服务溢价，以及它们在高难度任务上的定价权。

架构没变，Agent 能力为什么能大涨

目前，V4 Flash 正式版还没有发布新的技术报告，DeepSeek 在 7 月 31 日的更新日志中写：正式版 V4 Flash 与 Preview 的结构和尺寸相同，只重新进行了后训练。






此前预览版报告披露的后训练流程，已经把重点放在代码和 Agent 上：DeepSeek 分别训练数学、代码、Agent 和指令遵循专家，使用 SFT 和 GRPO 强化各自能力，再通过十多个教师模型的 On-Policy Distillation 合并回同一个模型。

工具调用也被当成单独的问题处理。

DeepSeek 设计了专门的调用格式，减少参数转义和格式错误；Interleaved Thinking 让模型在工具返回结果后继续保留前面的推理；DSec 则提供数十万个并发沙箱，让模型反复练习运行代码、读取报错和继续修改。



这些后训练并没有给模型增加新的参数，却可以减少 Agent 最常见的失败：选错工具、填错参数、忘记前面的状态，或者在任务还没完成时停下来。

正式版在 Terminal Bench 2.1 上的 82.7 分，**还使用了尚未发布的 DeepSeek Harness 极简模式和 max 推理档**。此外，DeepSeek 为 V4 Flash 加入原生 Responses API，并针对 Codex 做了适配。

预训练决定模型的能力底座，后训练主要改变模型如何调用这些能力。

当 V4 Flash 可以部署在「消费级」电脑上

V4 Flash 的另一个变化，是让前沿 Agent 模型离本地设备更近了一步。

虽然每次推理只激活 130 亿参数，但是完整的 2840 亿参数仍然需要存储和调度，官方仓库中的权重文件合计约 167 GB。



DeepSeek 给出的 vLLM 服务示例使用一台配备 4 张 GB300 的服务器。

社区项目 DwarfStar 则通过低比特量化，把 V4 Flash 的 q2 版本放进了 96GB 或 128GB 统一内存设备，q4 版本建议使用至少 256GB 内存。在部分 128GB Mac 测试中，短上下文速度可以达到每秒二十多 Token。

q2 版本能运行，也不代表它能复现官方 API 的 Agent 成绩。**极低比特量化可能损伤代码、长上下文和工具调用能力，社区运行时本身也仍处于早期阶段。**

不过，DeepSeek 的 API 已经便宜到，本地部署对多数人未必更省钱。按照每百万输出 Token 0.28 美元计算，一台售价约 4699 美元的 DGX Spark，相当于约 168 亿输出 Token，还没算本地部署的电费、维护和调试成本。

而且，换个角度看 V4 Flash 的出现，似乎又是 DeepSeek 斩杀线里的关键一刀。**在本地部署上，DeepSeek 又斩掉了「高水平模型只能待在机房」的一部分门槛，它把门槛降到了高内存工作站。**



一台高配 Mac 或 DGX Spark，已经可以用可交互的速度运行经过激进压缩的完整 V4 Flash。

最强模型也开始谈性价比

更低的价格不一定等于少赚钱。

过去舍不得让 AI 常驻后台的公司，先前开启 Tokenmaxxing 然后又因为实在付不起账单的团队，现在可以开始批量整理文档、检查代码、跟进客服。原本只问一次的问题，也可能变成持续数小时、调用几十次工具的 Agent 任务。

单价下降，Token 总量却可能涨得更快。



Sam Altman 在 7 月底的播客节目曾提到，OpenAI 预计模型会产生极大的使用量，**因此不需要依靠「极高毛利」来承担训练成本**。他们和 DeepSeek 的梁文锋一样，相信 AI 的需求几乎是没有限度的，AI 智能使用量会持续爆发。

即使每次调用赚得不多，只要调用量足够大，累计利润依然可以覆盖下一代模型的训练成本。

这也是 V4 Flash 更值得注意的地方。

它没有用一个绝对领先的榜单成绩，证明自己是最聪明的模型；它做的，是把过去只有旗舰模型才能承担的任务，压进了一个可以被反复调用、持续试错，**甚至可以让我们的 Token 价格区间。**

在聊天机器人的时代，用户会为了更好的回答，多付几倍的价格。但进入 Agent 时代，模型不再只回答一次。它要浏览文件、搜索资料、执行代码、截图检查，再根据结果重新开始。

一次任务中，在智力上几分的能力差距，可能只影响模型要不要多试两轮；但几十倍的价格差距，却会决定这个任务有没有资格真正跑起来。

Intelligence Index vs. Cost to Run Artificial Analysis Intelligence Index

运行 AA 所有测试花费的钱和智能得分对比，DeepSeek 拿下 50 分仅花了 72 美元，而 Fable 5 得到 60 分，花费 5600 美元。



未来模型之间的竞争，很难再只用一张能力榜单解释。

用户需要计算的，是完成率、调用次数、响应速度和最终账单；模型厂商出售的，也不再只是每一个 Token 的智能，而是每一美元最终能够完成多少工作。

从这个角度看，V4 Flash 真正斩掉的，是调用旗舰模型之前那种不需要计算成本的习惯。

当一个便宜 50 倍甚至 80 倍的模型，已经能够完成大多数编码和 Agent 任务，昂贵模型就必须反过来证明：剩下那几分能力，究竟值不值得多付几十倍的钱。

本文来源：[APPSO](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

15 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论