


摘要：

DeepSeek-V4-Flash正式版API开启公测，Agent能力大幅升级，模型架构未变，仅靠后训练实现性能跨越式提升。原生支持Responses API，并可接入OpenAI开源的Codex，提升代码开发效率。200B轻量级模型性价比突出，引发开发者热议。V4-Pro正式版也即将发布。

今天，DeepSeek官宣了重磅消息：DeepSeek-V4-Flash 正式版 API 开启公测！



消息一出，开发者圈直接沸腾了，因为这次有三大爆点——

首先，Agent能力大幅升级，比V4 pro预览版还要强！

	DeepSeek-V4-Flash-0731	DeepSeek-V4-Flash-Preview	DeepSeek-V4-Pro-Preview	GLM-5.2	Opus-4.8
Terminal Bench 2.1	82.7	61.8	72.1	81.0	85.0
NL2Repo	54.2	39.4	38.5	48.9	69.7
Cybergym	76.7	38.7	52.7	-	83.1
DeepSWE	54.4	7.3	12.8	46.2	58.0
Toolathlon-Verified	70.3	49.7	55.9	59.9	76.2
Agents' Last Exam	25.2	15.8	16.5	23.8	25.7
AutomationBench (Public)	25.1	10.8	12.8	12.9	27.2
DSBench-FullStack	68.7	37.0	41.8	61.8	71.6
DSBench-Hard	59.6	25.8	31.1	54.5	71.7

*For public Code Agent tasks, V4-Flash was tested using our upcoming DeepSeek Harness (minimal mode) framework. Settings: max tier, topp=0.95, temperature=1.0.

**DSBench-FullStack (full-stack dev) & DSBench-Hard (Coding Agent challenges) are our internal benchmark sets.

而且，模型架构完全没变，全靠后训练硬生生把性能拔高了一大截。

现在，OpenAI开源的Codex现在能接入deepseek-v4-flash，而deepseek-v4-pro预计2026年8月初支持接入 Codex。

此外，还有好消息——DeepSeek Harness即将公布。

注1: 对于公开基准测试集中的 Code Agent 任务, 正式版 DeepSeek-V4-Flash 使用 DeepSeek Harness 极简模式 (即将发布) 作为框架进行测试, 并使用 max 档位, topp=0.95, temperature=1.0

注2: DSBench-FullStack 是内部使用的全栈开发测试集, DSBench-Hard 是内部使用的 Coding Agent 难题测试集

消息一出, 全球开发者圈都炸锅了。

有人惊呼: 这是魔法? 有人在调侃「友商脸疼不疼」, 甚至, 已经有人在考虑要不要退订 ChatGPT和Claude了。

就在GPT-5.6大降价的今天, DeepSeek-V4-Flash来了一次暴击。

价格 ⁽²⁾	百万tokens输入 (缓存命中)	0.02元	0.025元
	百万tokens输入 (缓存未命中)	1元	3元
	百万tokens输出	2元	6元
并发限制 ⁽³⁾		2500	500

(1) Responses API 目前仅支持 `deepseek-v4-flash` 模型, 暂不支持 `deepseek-v4-pro` 模型。我们将于 2026 年 8 月初增加对 `deepseek-v4-pro` 模型的支持。

AI模型价格大战 (\$/百万 tokens)			
模型	输入价格	输出价格	1M输入+1M输出成本
DeepSeek V4 Flash	\$0.14	\$0.28	\$0.42
Gemini 3.5 Flash	\$1.50	\$9.00	\$10.50
OpenAI GPT-5.6 Luna (低价版)	\$0.20	\$1.20	\$1.40
OpenAI GPT-5.6 Terra	\$2.00	\$12.00	\$14.00

从此, 人人都能用Agent了!

极速版, 把专业版按在地上摩擦

本来, 「Flash」代表着轻量、便宜、快, 「Pro」代表着贵、全能、算力猛兽。

DeepSeek-V4-Flash正式版, 直接把这个潜规则给掀了。

结果现在, 200B轻量级模型就把前代模型干翻了。

甚至在某些测试上, 赶上了Opus 4.8了!

35 Reply Award Share ...



squngy · 28m ago

Top 1% Commenter

Even touches Opus 4.8 on a few benchmarks.

甚至在几项基准测试中触及了 Opus 4.8 的水平。

7 Reply Award Share ...



ILoveSquirtle69 · 22m ago

you think those deepseek engineers been getting laid? maybe some extra head?

你觉得那些 DeepSeek 工程师有在谈恋爱吗？也许还多享受了点额外服务？

8 Reply Award Share ...



squngy · 18m ago

Top 1% Commenter

Don't know, but it sure looks like Anthropic is getting fucked!

不知道，但看起来 Anthropic 确实要完蛋了！

11 Reply Award Share 公众号 · 新智元

另外两项内部测试成绩也相当硬核：DSBench-FullStack和DSBench-Hard。

在这俩专门针对真实开发环境和复杂代码设计的测试里，V4-Flash正式版的分数不仅比预览版「好很多」，甚至让同行侧目。

有人看到跑分后，激动得连发了一串问号：啥？？



Zephyr · 2h

V4 极速版更新发布

200B 模型在 Cybergem 上跑出 76.7 分

啥？？？

公众号 · 新智元



DeepSeek-V4-Flash Update

DeepSeek-V4-Flash official API launch public beta

Agent capabilities have been greatly enhanced, with benchmarks far exceeding those of V4-Pro-Preview:

- Terminal Bench 2.1: 82.7
- NL2Repo: 54.2
- Cybergym: 76.7
- DeepSWE: 54.4
- Toolathlon verified: 70.3
- Agent Last Exam: 25.2
- Automation Bench (Public): 25.1
- DS Bench-FullStack: 68.7
- DS Bench-Hard: 59.6

👤 公众号 · 新智元

开发者们满意点评道：现在，V4-Flash对我的使用场景来说，简直是性能溢出了。

还有人说，这就是我想要的模型——够便宜，也够聪明。

平民化的Agent时代，真的来了。


DeepSeek的「魔法」：谁说后训练没用？

V4-Flash的跑分已经够让人震惊了，但官方透露的另一个细节更让人觉得「不可思议」。


DeepSeek特别注明：

DeepSeek-V4-Flash-0731 的模型结构、尺寸和 DeepSeek-V4-Flash-Preview 保持一致，仅重新进行了后训练。






有人说：这是魔法吧？



这跨越式性能提升关键，就在当前大模型领域最核心的技术——后训练。

有人一针见血点评：谁说后训练没用的？



还有人说：「光靠后训练就能有这样的提升，太厉害了，说明这方面还有巨大的挖掘空间。」

显然，DeepSeek在后训练上找到了某种「不二法门」，硬生生把一个200B的模型调教出了远超它体型的高智商。

原生支持Responses API，全面适配Codex

而且，DeepSeek太懂开发者的痛点了。

这次更新里，官方宣布V4-Flash原生支持Responses API格式，并且全面适配Codex。

正式版 V4-Flash 原生支持 Responses API 格式并针对性适配 Codex，具体配置方法请参考[文档](#)

DeepSeek-V4-Flash-0731 的模型结构、尺寸和 DeepSeek-V4-Flash-Preview 保持一致，仅重新进行了后训练。

注意：本次仅升级了 DeepSeek-V4-Flash 的 API 接口，DeepSeek-V4-Pro API 及 APP/WEB 端模型未做更改。

DeepSeek-V4-Pro 正式版将会尽快发布。

公众号 · 新智元

对开发者，这简直是久旱逢甘霖。

Responses API 彻底解决了大模型开发里最让人头疼的问题：JSON 格式解析失败。

以前输出严格格式的数据，就跟抽盲盒似的。

现在原生支持 Responses API，V4-Flash 可以 100% 稳定、精准地输出开发者定义好的数据结构。

再加上它本身「性能溢出」的 Agent 规划能力，开发者完全可以放心地让 V4-Flash 去调用外部工具、读写数据库、控制 RPA 机器人。

全面适配 Codex，则意味着 V4-Flash 在代码生成、代码审查、自动补全等方面已经达到了专业编程助手的水平。

这意味着，你可以直接将它无缝接入 VS Code、Codex CLI 或 ChatGPT 桌面端。

所以，GPT 和 Claude 可以退订了吗？

很多人说要退订 GPT 和 Claude，真不是玩笑。

性价比这块，200B 的 V4-Flash 靠后训练魔法，在 Agent 和代码能力上「性能溢出」，足够横扫所有长文本、高并发、多 Agent 协同的日常任务。

而在极致性能那边，真正的「大魔王」DeepSeek-V4-Pro 还在路上。

官方说了：「今天升级只针对 V4-Flash API。V4-Pro API 和 App/Web 模型暂时不变。DeepSeek-V4-Pro 正式发布很快会来，敬请期待！」

如果 200B 参数的 Flash，只靠后训练就能达到这个高度；那传说中 1.6T 的 V4-Pro 正式版，有多惊人？



大家都在等，V4-Pro 是不是能跟地表最强 Claude 3.5 Opus 正面碰一碰。

如果那天真来了，就是国产大模型重塑全球 AI 格局的时刻。



风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
VIP会员·7天畅读卡 | 大师课·入门串讲

* 体验资格每人限申领一次

扫码
免费领取



限免

308 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

4 条评论

MobileUser8587
9小时前 中国重庆

梁文锋，呵呵

1 回复

MobileUser6798
11小时前 中国

哪一个厉害。有没有排名榜

0 回复

见闻用户
13小时前 美国

写这个文章的人不懂AI，靠RL提升性能不是很正常么？感觉大惊小怪的。

0 回复

周天 12小时前 中国福建省

回复 **见闻用户**：

不看模型参数量？你真当 RL 万能？

0 回复