

摘要：

分析师认为此次智谱和MiniMax下跌属于过度反应。V4已验证华为昇腾芯片能够支撑1.6万亿参数的前沿模型推理；随着昇腾芯片加速普及与算力供给持续扩张，LLM企业的服务成本将显著下降，从而有效打通“token需求→实际收入”的变现路径。

4月24日，DeepSeek发布V4预览版，国内AI大模型板块应声下挫——这是市场对一个“潜在威胁”的集中释放，还是真正的竞争格局重塑？

据追风交易台消息，摩根大通证券（中国）4月26日发布研究报告，对上述市场反应给出了截然不同的判断：**V4的发布，是行业利好，而非零和冲击。**

股价暴跌9%背后，市场误读了什么？

DeepSeek V4预览版上线当天，智谱和MiniMax股价均下跌9%，而恒生指数同日上午0.2%。

市场的逻辑直接：DeepSeek又出新模型，竞争加剧，纯大型语言模型（LLM）公司的生存空间被压缩。

但上述分析师认为，这是“**过度反应**”。

他们的核心判断是：V4的发布，实际上强化了支撑中国LLM行业的三个关键支柱——**算力供应释放、定价纪律、结构性成本曲线压缩**。唯一竞争加剧的维度是相对竞争定位，但这是“竞争激烈”而非“格局再平衡”。


更重要的是，V4此前一直是分析师所追踪的4-5月事件日历中“最大的单一负面竞争催化剂”。随着V4落地并被市场消化，这一不确定性正式出清。

MiniMax

\$777.50 ↓12.39% -110.00 5天

4月27日, UTC+8 07:33:55 · HKD · HKG · 免责声明

1天 5天 1个月 6个月 YTD 1年 5年 最大范围



MiniMax	\$765.50	-\$122.00	↓13.75%
智谱	\$933.00	+\$37.50	↑4.19%

算力瓶颈松动：这才是V4最大的行业意义

分析师指出，市场与其研究框架之间“价格与解读差异最大”的地方，恰恰在于算力。


DeepSeek V4适配华为昇腾芯片，成功支撑了1.6万亿参数规模的前沿模型推理。这是一次关键验证：国产芯片不仅在技术上可行，与国际芯片相比可能还具备成本竞争力。

过去，算力约束一直是中国LLM公司的隐形天花板——有token需求，却难以转化为可确认收入（ARR）。DeepSeek已明确表示，随着昇腾950超节点在2026年下半年批量上市，V4 Pro的推理成本将进一步下降。

分析师认为，这对智谱和MiniMax是直接利好：**算力供给扩张，意味着这些公司将能以更低成本提供服务，从而打通从token需求到确认收入的转化路径。**

我们认为，这对于包括智谱和 MiniMax 在内的中国 LLM 行业整体而言是一项关键利好，因为缓解了算力供给约束——这是妨碍这些公司全面扩大运营的主要障碍之一。DeepSeek 表示，随着昇腾芯片的更广泛应用和优化，推理成本曲线将会改善，为智谱和 MiniMax 开辟新的将 token 需求转化为确认收入的路径。

图 1: 智谱和 MiniMax 的主要事件时间线



12倍价差：DeepSeek自己否定了“大宗商品化”叙事

市场另一个担忧是：DeepSeek的低价策略会把整个行业拉向大宗商品化，压垮所有人的定价能力。

数据不支持这一判断。

根据报告引用的定价数据（截至2026年4月24日）：

- DeepSeek V4 Pro版：输入/输出价格为每百万token **1.74美元/3.48美元**
- DeepSeek V4 Flash版：输入/输出价格为每百万token **0.14美元/0.28美元**

两者输出价格相差约12倍。DeepSeek自己的产品线，就已经建立了基于任务复杂度的分级定价体系：高端编码和智能体工作流定价高，简单高吞吐任务定价低。

这与智谱和MiniMax一直在推行的变现逻辑完全一致。分析师指出，对比来看，GLM-5.1的输出定价为每百万token 3.50美元，与V4 Pro的3.48美元几乎持平——所谓“DeepSeek定价碾压一切”的悲观论调，与实际数据不符。

表 1：部分国产 AI 模型的 token 输入/输出价格比较


模型提供商	模型	输入价格（美元/百万 token）	输出价格（美元/百万 token）	上下文长度
智谱	glm-5.1	\$1.05	\$3.50	202.8K
月之暗面	kimi-k2.6	\$0.74	\$4.66	256K
DeepSeek	deepseek-v4-pro-thinking	\$1.74	\$3.48	1M
阿里巴巴	qwen3.6-plus	\$0.33	\$1.95	1M
小米集团	mimo-v2-pro	\$1	\$3	1M
MiniMax	minimax-m2.7	\$0.3	\$1.2	196.6K
DeepSeek	deepseek-v4-flash	\$0.14	\$0.28	1M

资料来源：LMArena、DeepSeek 官方网站（按 Code Arena 排名排序，数据截至 2026 年 4 月 24 日）。

V4技术领先，但在B2B核心场景并未压制对手


V4在技术层面确有进步。报告引用DeepSeek官方数据显示，与V3.2相比，V4在推理FLOPS上下降了3.7至9.8倍，KV缓存大小缩小了9.5至13.7倍，长上下文处理效率大幅提升。

图 2：DeepSeek V4 与 V3.2 的推理 FLOPS 对比



资料来源：DeepSeek 官方网站（数据截至 2026 年 4 月 24 日）。

图 3：DeepSeek V4 与 V3.2 的累计 KV 缓存大小对比



资料来源：DeepSeek 官方网站（数据截至 2026 年 4 月 24 日）。

但在投资者最关心的B2B核心场景——编码和智能体工作流——V4并未形成压制。

根据LMArena Code Arena排名（截至2026年4月24日）：

- GLM-5.1：第5名，得分1534
- Kimi K2.6：第6名，得分1529
- DeepSeek V4 Pro：第14名，得分1456

分析师指出，这一排名反映的是行业正常规律：每一个新版本发布，都会带来排名轮动。智谱和MiniMax预计将在6月前后发布GLM-5.5和MiniMax M3，届时排名可能再度刷新。

表 2：根据 Code Arena，DeepSeek V4 排名第 14，落后于同样来自中国的 GLM5.1、Kimi K2.6 和 Qwen3.6

排名	排名区间	模型提供商	模型	得分	票数	输入价格（美元/百万 token）	输出价格（美元/百万 token）	上下文
1	1<->3	Anthropic	claude-opus-4-7-thinking	1572+18/-18	1,393	\$5	\$25	1M
2	1<->4	Anthropic	claude-opus-4-7	1566+16/-16	1,782	\$5	\$25	1M
3	1<->6	Anthropic	claude-opus-4-6-thinking	1552+10/-10	4,922	\$5	\$25	1M
4	2<->6	Anthropic	claude-opus-4-6	1545+9/-9	5,821	\$5	\$25	1M
5	3<->8	智谱	glm-5.1	1534+13/-13	2,478	\$1.05	\$3.50	202.8K
6	3<->8	月之暗面	kimi-k2.6	1529+17/-17	1,408	\$0.74	\$4.66	256K
7	5<->8	Anthropic	claude-sonnet-4-6	1527+9/-9	7,751	\$3	\$15	1M
8	5<->9	Meta	muse-spark	1512+16/-16	1,611	N/A	N/A	N/A
9	8<->9	Anthropic	claude-opus-4-5-20251101-thinking-32k	1491+7/-7	13,065	\$5	\$25	200K
10	10<->14	阿里巴巴	qwen3.6-plus	1471+12/-12	2,854	\$0.33	\$1.95	1M
11	10<->14	Anthropic	claude-opus-4-5-20251101	1468+6/-6	15,283	\$5	\$25	200K
12	10<->16	谷歌	gemini-3.1-pro-preview	1457+8/-8	6,813	\$2	\$12	1M
13	10<->19	OpenAI	gpt-5.4-high (codex-harness)	1457+17/-17	1,482	\$2.50	\$15	1.1M
14	10<->20	DeepSeek	deepseek-v4-pro-thinking	1456+19/-19	1,066	\$1.74	\$3.48	1M
15	12<->21	智谱	glm-4.7	1440+10/-10	4,880	\$0.38	\$1.74	202.8K
16	13<->21	谷歌	gemini-3-pro	1438+7/-7	17,169	\$2	\$12	1M
17	12<->23	OpenAI	gpt-5.4-medium (codex-harness)	1437+16/-16	1,448	\$2.50	\$15	1.1M
18	13<->21	谷歌	gemini-3-flash	1437+7/-7	13,276	\$0.50	\$3	1M
19	13<->22	智谱	glm-5	1435+9/-9	5,640	\$1	\$3.20	202.8K
20	14<->22	月之暗面	kimi-k2.5-thinking	1430+8/-8	7,913	\$0.60	\$3	N/A

资料来源：LMArena Code Arena（数据截至 2026 年 4 月 24 日），国产模型标记为绿色。注：Code Arena 是一个交互式测评平台，基于真实的编码任务测试大型语言模型（LLM），通过使用实时、开发者投票评估和可执行环境来衡量 AI 智能体如何规划、调试和构建软件，从而超越静态基准评估。

此外，V4的token压缩和DeepSeek稀疏注意力（DSA）架构属于开源发布，并非护城河。历史上，V3时期的MoE路由机制在约4-6个月内就被千问、GLM和Kimi吸收。**这些技术创新最终会成为行业通用配置，整体降低成本曲线，对所有玩家均有利。**

接下来两个月：负面催化剂出清，正面催化剂集中

分析师将当前时间窗口定性为“不对称正面格局”。

V4已落地，最大的短期竞争不确定性消除。在7月限售股解禁之前，接下来两个月的催化剂路径如下：

- 5月：指数纳入审核（6月生效），带来被动资金流入
- 6月初：智谱纳入港股通，打开内地投资者渠道
- 6月前后：GLM-5.5和MiniMax M3发布，潜在ARR阶跃式提升

需要注意的风险节点：**7月**，智谱6个月锁定期届满，解禁5.8%股份；MiniMax解禁比例更高，达39.0%。2027年1月，智谱12个月锁定期届满，届时将解禁90.3%股份。

分析师对两家公司均维持“增持”评级：

- 智谱（2513.HK）：目标价950港元（截至2026年12月），基于30倍2030年预期市盈率，WACC 15%。2030年预期收入988.32亿元人民币，预期调整后净利润203.60亿元人民币
- MiniMax（0100.HK）：目标价1100港元（截至2026年12月），同样基于30倍2030年预期市盈率，WACC 15%。2030年预期收入91.36亿美元，预期调整后净利润23.22亿美元

两家公司2026-2030年预期收入年复合增长率均超过100%，这是给予估值溢价的核心依据。

表 3：智谱和 MiniMax 的主要事件时间线、影响和预期股价走向

时间	事件	影响	股价走向	摩根大通解读
2026 年 4-5 月	智谱/MiniMax 持续模型迭代	聚焦于相对模型进展、定价能力和企业落地节奏	正面	算力供给释放、定价纪律、结构性成本曲线压缩、相对竞争定位竞争激烈而不是再平衡对独立 LLM 无明显影响
	发布 DeepSeek-V4	对中国模型竞争和国内基于 GPU 的训练/推理验证的关键解锁	取决于结果	
	腾讯混元 3.0 上线	规模化平台能多快地填补能力差距的关键测试	取决于结果	
2026 年 6 月	GLM 5.5/MiniMax M3	潜在的 ARR 阶跃函数催化剂；市场同时关注绝对能力和相对地位	正面，除非相对表现未及预期	
	可能纳入指数	被动资金流催化剂和机构持有者的更广泛扩展	正面	
	智谱可能纳入港股通	拓宽内地投资者渠道并能改善流动性/估值支撑	正面	
2026 年 7 月	6 个月锁定期结束	Pre-IPO 股东获利 5-7 倍；智谱解禁 5.8% 的股份，MiniMax 为 39.0%	负面	
2026 年 8 月	2026 年上半年业绩	检验 ARR 轨迹，定价持久性和利润率轨迹	取决于结果，若执行得力则为正面	
	MiniMax 可能纳入港股通	扩大投资者群体并可能部分抵消锁定期结束后的资金流压力	正面	
2026 年 10 月	9 个月锁定期结束	MiniMax 在 9 个月后将解禁 18.2% 的股份	负面	
	潜在股票融资	很有可能进一步融资；研发费用为收入的 4-5 倍	负面	
2026 年下半年	Anthropic/OpenAI 可能 IPO	确立全球 AI 估值倍数锚	正面	
	Kimi/阶跃星辰可能上市	验证行业可投资性，但也削弱稀缺性	有涨有跌至略偏负面	
2027 年 1 月	12 个月锁定期结束	智谱 12 个月后将解禁 90.3% 的股份，MiniMax 为 37.4%	负面	

资料来源：公司招股说明书（数据截至 2025 年 12 月 31 日）、恒生指数网站、路透社、新浪财经、阿斯达克财经网和摩根大通估算（数据截至 2026 年 4 月 24 日）



~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入【[追风交易台·年度会员](#)】



# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

限免

304

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

1 条评论



穷在深山  
1小时前 中国北京

不是摩根大通，就是什么高盛，话语权全被别人掌控

0 回复