

摘要：

大摩认为，DeepSeek因阿里、智谱的竞品入场及新品V4.1 Flash上线前夕宣布对V4 Flash降价，降幅达11%-60%，但其降后价格仍高于初始售价且在主流轻量模型中最高。大模型双轨制竞争加剧，但毛利率约束将抑制无序价格战。


竞争压力与新品上线前夕，迫使DeepSeek对旗舰轻量模型实施降价，但此举并未改变其在细分市场的定价劣势。

9月9日，DeepSeek宣布对V4 Flash模型实施降价，自次日起生效。此次调整覆盖非峰值时段的缓存输入、非缓存输入及输出三项定价，降幅分别为60%、33%和11%。调整后，非缓存输入价格降至每百万token人民币1.5元，缓存输入降至0.03元，输出降至6元。

据追风交易台消息，摩根士丹利分析师Gary Yu、Lydia Lin及Yang Liu认为，此次降价有两重驱动力：一是来自阿里巴巴旗下Qwen3.8-flash及智谱AI GLM5.3-flash的竞争压力，两款模型均于今年8月上线；二是DeepSeek自身V4.1 Flash新品即将推出，为旧版本让路的战略性调价。

不过，降价之后，DeepSeek V4 Flash的售价仍高于4月首发时的水平，且在主要竞品中维持最高定价区间，市场格局并未因此逆转。

Exhibit 1: DS V4 Flash price trend



Source: Company, Morgan Stanley Research. Input price averaged with peak and off-peak hour

降价背后：老对手新压力夹击

今年8月，两款轻量级竞品相继入场，直接冲击了DeepSeek V4 Flash的市场地位。

据摩根士丹利数据，阿里巴巴Qwen3.8-flash的非缓存输入价格为每百万token人民币1元，输出价格3元；智谱AI GLM5.3-flash定价更为激进，非缓存输入仅0.4元，输出1.4元——后者在输出端的价格不足DeepSeek降价后报价的四分之一。

在模型规模上，DeepSeek V4 Flash参数数量为2840亿，远超Qwen3.8-flash的1250亿及GLM5.3-flash的3200亿，但三者在大模型评测基准上的评分接近，DeepSeek为52分，GLM5.3-flash以57分小幅领先，Qwen3.8-flash得分56分。这意味着，DeepSeek在性能上并未形成显著溢价优势，定价压力由此累积。

Exhibit 2: Major China flash LLM comparison

AI lab	Alibaba	Z.ai	DeepSeek		
Model	Qwen3.8-flash	GLM-5.3 Flash	V4-flash (initial)	V4-flash (pre-cut)	V4-flash (post-cut)
Release date	Aug-26	Aug-26	Apr-26	Aug-26	Sep-26
License	Qwen Community License 1.0	MIT	MIT	MIT	MIT
Total parameter (B)	125	320	284	284	284
Context window (K)	1000	1000	1000	1000	1000
API price (Rmb/mn tokens)					
Input (uncached)	1.00	0.40	1.00	2.25	1.50
Input (cached read)	n.a	0.12	0.02	0.08	0.03
Output	3.00	1.40	2.00	6.75	6.00
AA Intelligence Index	56	57	52	52	52

Source: Company, Morgan Stanley Research. Input price averaged with peak and off-peak hour

降价后仍是最贵：定价劣势并未消除

尽管大幅削价，DeepSeek V4 Flash在三款主流轻量模型中依然是最贵的选项。

对比来看，降价后DeepSeek V4 Flash的输出价格为每百万token人民币6元，是Qwen3.8-flash（3元）的两倍，是GLM5.3-flash（1.4元）的逾四倍。在非缓存输入端，DeepSeek调整后报价1.5元，高于Qwen3.8-flash的1元，更远高于GLM5.3-flash的0.4元。

更值得注意的是，此次降价后的价格仍高于DeepSeek V4 Flash今年4月上线时的初始售价——彼时非缓存输入为1元，输出为2元。这意味着，V4 Flash自发布以来经历了先涨后降的定价曲线，此番回调仅属部分修正，并未回归原点。

行业逻辑：Pro+Flash双轨制成主流

摩根士丹利指出，“高价旗舰+低价快速”的双轨产品策略正在成为大模型厂商的标准打法，DeepSeek此次调整也符合这一趋势。

这一模式将高性能、高成本的专业版（Pro）模型与低延迟、低价格的轻量版（Flash）模型并行推出，前者服务于对精度要求高的企业级场景，后者主打高频、低成本的消费及开发者需求。随着各厂商在Flash层竞争加剧，定价博弈料将持续。

然而，摩根士丹利强调，毛利率约束将是抑制无序价格战的关键因素。分析师认为，在盈利压力下，市场不太可能出现不计成本的价格竞争，厂商更倾向于以差异化性能和生态优势而非单纯价格来争夺市场份额。

~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)



# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

限免

226

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论