摘要：

DeepSeek全面开源推理框架DeepInfer及Token编解码组件deepseek-recipe，兼容英伟达与华为昇腾平台。基于该框架，DeepSeek V4.1 Flash单集群日吞吐达155万亿Token，按谷电价计算每卡每小时收入38美元。通过Prefill与Decode分离、KVCache复用及投机解码等技术，DeepSeek旨在提升推理效率、降低算力成本与能源消耗。

DeepSeek进一步开放大模型推理基础设施。

继开源大模型、TileLang编译工具及一系列推理算子库后，DeepSeek宣布全面开源内部推理框架DeepInfer，并同步开源Token编解码组件deepseek-recipe，旨在帮助开发者和企业优化大规模模型部署，降低AI服务的算力成本与能源消耗。



DeepSeek 开源推理框架：走向真正普惠的未来

原创 深度求索 DeepSeek 2026年10月20日 16:54 北京

大模型的能力边界由模型本身划定，但如何以合理成本提供超大规模的模型服务，还取决于一个长期未被公众了解的中间层：**推理框架**。

训练使模型学有所成，推理则让模型为人所用。面对如今海量的用户调用，推理框架负责统筹调度庞大的算力集群，其效率直接决定了 AI 服务的算力成本与电力消耗。

DeepSeek 长期致力于将推理性能推向极致。在此前开源一系列大模型、TileLang 编译工具及推理算子库的基础上，我们决定进一步**将内部推理框架 DeepInfer 全面开源**。

「为善与众行之，为巧与众能之。」我们希望通过分享内部的部署经验，帮助开发者与企业组织优化大规模推理的吞吐与延迟，从而高效构建私有化及公有云部署，降低算力成本、减少能源消耗，让智能以更低的价格触达更广泛的人群，实现真正的大模型普惠。我们也将继续支持社区进行大规模部署优化，欢迎加入我们的开源行列。

DeepInfer

基于 DeepInfer，我们已实现 DeepSeek V4.1 Flash 高吞吐、低延迟的大规模推理服务。未来，DeepSeek 新模型的推理代码及后续优化也将在此持续更新。

- **DeepInfer 推理框架**：集成高性能算子与深度优化的推理引擎，支持分布式推理、推测解码、SWA Bounded Replay、结构化输出等能力，兼容英伟达与华为昇腾平台。
- **deepseek-recipe 编解码组件**：同步开源的生产级 Token 编解码组件，与 DeepSeek 官方 API 处理逻辑完整对齐，确保社区获得与官方部署一致的 API 体验。

DeepSeek介绍，**基于DeepInfer，团队已实现DeepSeek V4.1 Flash的高吞吐、低延迟大规模推理服务**。目前，**单一集群的服务吞吐量达到每天155万亿Token，按谷电价计算，每卡每小时收入为38美元。**

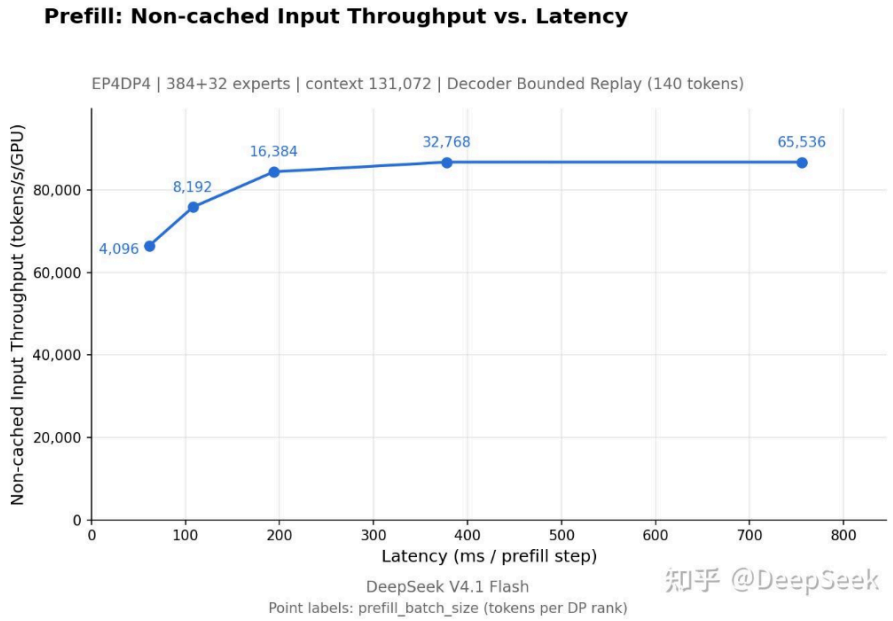
实际线上运行数据

机器已经预留了一定冗余度，以应对流量的波动

阶段	指标	线上实测
prefill	每卡吞吐（不含缓存命中）	**60K** tps
	每卡吞吐（含缓存命中）	**1.5M** tps
	平均输入缓存命中率	**96** %
	首字时延（TTFT）平均	**400** ms
	首字时延（TTFT）P99	**1000** ms
	平均输入长度	**77K** tokens
decode	每卡吞吐	**14K** tps
	吐字速度	**230** tps （代码场景 300 tps）
kvcache 缓存	不活跃后保存时间	**72** 小时

实际部署 P:D 接近 1:1，不考虑波峰波谷，整体收入是平均每卡每小时 38 美金（按谷价）。

知乎 @DeepSeek



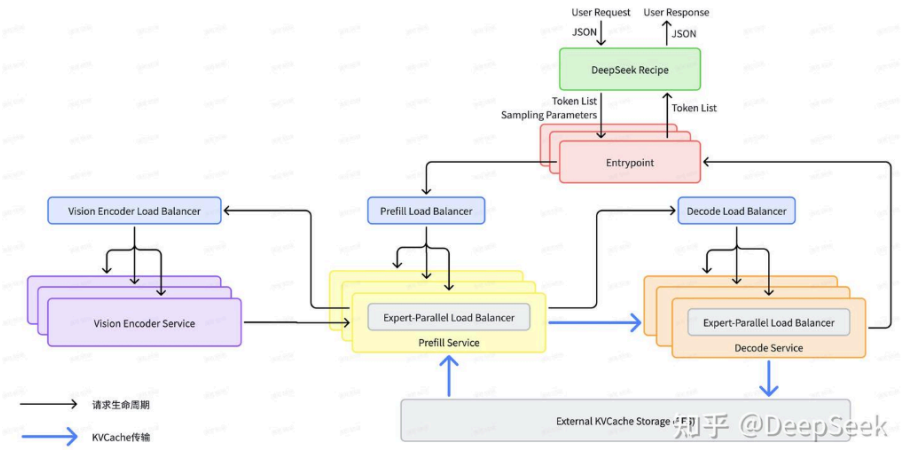
推理框架是连接大模型能力与终端用户的关键基础设施。随着AI应用调用量增长，推理服务的成本不仅取决于模型本身，还受到计算、通信、任务调度及缓存管理等环节的影响。如何在满足延迟要求的同时提高有效吞吐，已成为大规模AI服务降本增效的重要环节。

兼容英伟达与华为昇腾，针对不同推理阶段优化算力配置

DeepInfer集成高性能算子与深度优化的推理引擎，支持分布式推理、推测解码、SWA Bounded Replay及结构化输出等能力，可在英伟达与华为昇腾平台运行。未来，DeepSeek新模型的推理代码及后续性能优化也将在该框架中持续开源。

面对大规模AI调用需求，DeepSeek将推理系统的优化重点放在吞吐量与延迟上。系统采用Prefill与Decode分离部署：前者负责处理输入提示词，后者负责逐步生成Token。由于两个阶段的计算负载不同，分开部署可以独立配置资源，分别优化首个Token生成时间和后续Token生成间隔。

在硬件组织上，DeepSeek使用常见的8卡机器承担Prefill任务，并采用64至128卡超节点承担Decode任务。同时，系统通过自动扩缩容动态调整两个阶段的实例比例，减少流量变化导致的资源错配；在MoE模型推理中，则通过专家并行与动态负载均衡，降低不同计算卡之间的负载差异。



KVCache最长保留7天，减少重复计算开销

缓存复用是DeepSeek降低推理成本的另一项关键设计。随着长上下文对话和AI Agent应用增多，相同前缀可能在不同请求中反复出现。如果每次都重新处理这些内容，就会产生额外的计算开销。

DeepSeek V4.1 Flash将KVCache分为Block KVCache和SWA KVCache两部分，采用不同的存储策略。其中，Block KVCache存储在独立的3FS分布式文件系统中，相关存储容量约为100 PiB。根据DeepSeek披露的数据，Agent流量的KVCache保留时间达到3天，聊天机器人流量则达到7天。

当后续请求命中已有缓存时，系统可以复用此前的计算结果，减少重复的Prefill计算。DeepSeek披露，3FS存储集群的峰值聚合读取带宽达到10 TiB/s，峰值聚合写入带宽约为850 GiB/s，以满足大规模缓存读写需求。

对于主要在活跃会话内短期复用的SWA KVCache，DeepSeek则选择保留在机器内存中，不进行持久化存储。线上数据显示，这部分缓存的保留时间约为180秒，命中率超过98%。

针对SWA KVCache未命中的情况，DeepSeek采用SWA Bounded Replay机制，仅重算最近128个Token，并将注意力窗口限制在重算区间内，以降低缓存缺失带来的额外计算成本。

内容	介质	副本	管理
运行中的Block KVCache + State KVCache	推理卡显存	—	prefill/decode实例
SWA KVCache	产出的prefill/decode机器的内存	单副本，3FS 上没有	prefill/decode实例；跨机命中使用400G VLAN 拉取
分页 Block KVCache	独立 3FS 存储集群	应用层无副本，靠3FS 自身冗余	kvcache-store

投机解码提升吞吐，编解码组件同步开源

除缓存复用外，DeepSeek还通过投机解码和异步调度提高推理效率。

DeepSeek采用DSpark投机解码框架，根据候选Token的预期接受概率动态决定验证范围，避免将验证算力浪费在低接受概率的候选结果上。DeepSeek披露，在线部署中，与固定验证5个Token的方式相比，变长验证使吞吐提升6%。

在调度环节，系统通过CPU与GPU之间的异步协作，让请求调度、前向计算和采样等操作尽可能重叠，减少设备等待时间。此外，DeepInfer支持结构化输出，可依据JSON Schema、正则表达式等约束控制模型生成结果，满足特定应用对输出格式的要求。

DeepSeek还同步开源生产级Token编解码组件deepseek-recipe。该组件支持Chat Completions API、Responses API和Messages API等主流接口，并通过特殊Token边界识别、普通文本分段并行编码及流式输出解析等机制，提升长文本处理效率，确保第三方部署的API处理逻辑与官方服务保持一致。

不过，DeepSeek并未开放推理系统的全部组件。由于KVCache管理和负载均衡部分与内部基础设施耦合较深，相关代码目前尚未完整开源。

从模型、算子库到大规模推理框架，DeepSeek此次进一步扩展了开源技术栈的覆盖范围。对于开发者和企业而言，这有望降低构建私有化及公有云AI服务的技术门槛；对于大模型行业而言，如何提高推理吞吐、复用计算结果并适配不同硬件平台，也正成为控制AI服务成本的重要方向。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

292 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论